

DAY 3

2026 산업전문인력 AI 역량강화 · 건설기계 · AI 적용을 위한 현장 데이터 수집 및 디지털화

멀티모달 기반 비정형 데이터 정보화

소리 · 사진 · 도면 · 회의 녹음처럼 표가 아닌 데이터를 숫자와 표로 바꾸는 하루.
세 개의 파이프라인 (비전 A · 음향 B · 문서 · 음성 C) 을 직접 돌려 정형 DB 에 적재합니다.

시수

8 시간 · 이론 2H + 실습 6H

오늘의 산출물결함 라벨 JSON · 도면 정보 SQL
테이블 · 정상 · 이상 분류 모델 · 정형
DB 파이프라인**사용 데이터**② 설비 소음 · 진동 ④ 도면 · 결함 사진
⑥ 정비 회의 녹음**도구**ChatGPT Vision · Gemini · Claude ·
Colab + librosa · scikit-learn ·
SQL/JSON

오늘은 이렇게 진행합니다

교시	시간	유형	주제	내용
1 교시	09:00-09:50	학습	숙련공 감각적 판단 정량화 기술	소리 (Acoustic) · 비전 데이터 활용 정량화 기술
2 교시	10:00-10:50	학습	파이프라인 A/B/C 설계 원리	수집→전처리→라벨링→ AI 적용→검증 · Acoustic AI(스펙트로그램 · MFCC) · 멀티모달 LLM 작동 원리
3 교시	11:00-11:50	실습	실습 도입 — 정량 KPI 전환 원리	Acoustic AI · 머신비전 기반 감각적 직관의 정량 KPI 전환 원리 이해 (60 분)
점심	12:00-13:00	점심	점심 식사	
4 교시	13:00-13:50	실습	파이프라인 B(음향) — 특징 추출	설비 소음 스펙트로그램 · MFCC 분석 (120 분 전반)
5 교시	14:00-14:50	실습	파이프라인 B(음향) — 분류 모델	정상 · 이상 분류 모델 구축 · 혼동 행렬 검증 (120 분 후반)
6 교시	15:00-15:50	실습	파이프라인 A(비전) — 결함 라벨링 · 도면 추출	ChatGPT Vision · Gemini 기반 결함 사진 라벨링 · 도면 정보 자동 추출 (60 분)
7 교시	16:00-16:50	실습	파이프라인 C(음성) — 회의록 · 화자 분리	정비 회의 음성 기반 자동 회의록 · 액션 아이템 생성 · 화자 분리 (60 분)
8 교시	17:00-17:50	실습	파이프라인 C(문서) — 정형 DB 적재	Vibe Coding 기반 SQL · JSON 스키마 자동 적재 · 정형 DB 파이프라인 구축 (60 분)

무료 실습 환경 — Google Colab + librosa · scikit-learn(음향 분석) · Gemini 무료 Vision. 결과는 패들렛 「Day03 실습결과」에 게시합니다 .

오늘이 끝나면 이것을 할 수 있습니다

- 1 Acoustic AI 원리 (**스펙트로그램** · **MFCC** · **푸리에 변환**) 와 머신비전 검사 알고리즘을 이해한다
- 2 설비 소음 · 진동 녹음을 **정상** · **이상 패턴으로 분류** 하는 모델을 구축한다
- 3 ChatGPT Vision · Gemini · Claude 로 도면 · 부품 결함 사진에서 핵심 정보를 자동 추출한다
- 4 추출된 비정형 정보를 표준 스키마 (**SQL 테이블** · **JSON**) 로 구조화하여 정형 DB 에 적재한다

1 일차 라벨링 가이드라인 (결함 유형 3 계층 · 심각도 S1~S4) 이 오늘 모든 라벨의 **허용 값 목록**입니다 . 옆에 펼쳐 두세요 .

" 소리가 다르다 " 를
숫자 13 개로 바꾸면
기계도 들을 수 있습니다 .

이 파트에서 다룰 것

세 파이프라인 개요 → 공통 5 단계 → 소리를 숫자로 (파형 · 푸리에 · 스펙트로그램 · MFCC) → 비전 : 머신비전 vs 멀티모달 LLM → 검증 지표

오늘 만드는 세 개의 파이프라인

1 일차 암묵지 3 유형 (육안 검사 · 소리 진단 · 체득 정비) 이 각각 하나의 파이프라인이 됩니다 .

PIPELINE A · VISION

비전 — 결함 사진 · 도면

- 입력 : ④ 부품 결함 사진 300 장 + 도면 100 건
- 도구 : ChatGPT Vision · Gemini · Claude
- 처리 : 리사이즈 · 노이즈 제거 → 라벨링 → LLM 자동 분류 → 일치도
- 산출 : 결함 라벨 JSON · 도면 정보 SQL 테이블

PIPELINE B · ACOUSTIC

음향 — 설비 소음 · 진동

- 입력 : ② 소음 · 진동 녹음 수백 건 (라벨 포함)
- 도구 : Colab + librosa · scikit-learn
- 처리 : 노이즈 필터 → 스펙트로그램 · MFCC → 분류 모델 → 혼동 행렬
- 산출 : 정상 · 이상 분류 모델


PIPELINE C · DOC & VOICE

문서 · 음성 — 도면 PDF · 회의 녹음

- 입력 : ④ 도면 PDF · ⑥ 회의 녹음 약 30 건
- 도구 : 멀티모달 LLM · Vibe Coding(SQL/JSON)
- 처리 : 치수 · 재질 추출 · 화자 분리 · 액션 아이템 → 표준 스키마 → DB 적재
- 산출 : 정형 DB 파이프라인

어느 파이프라인이든 다섯 단계는 같습니다

유형 (비전 · 음향 · 문서 / 음성) 이 달라도 설계 원리는 하나입니다 . 각 단계에서 " 무엇을 검증하는가 " 를 정해 두는 것이 설계입니다 .



소리를 숫자로 — 파형에서 스펙트로그램까지

WAVEFORM → SPECTRUM

푸리에 변환이 하는 일

- 녹음은 시간에 따른 압력 변화 (파형) 일 뿐
- 푸리에 변환 (FFT) 은 파형을 **주파수 성분**으로 분해
- " 어느 높이의 소리가 얼마나 세게 " — 베어링 손상은 특정 고주파가 커짐
- 사람 귀가 하는 일을 수식으로 한 것

SPECTROGRAM

스펙트로그램 = 시간 × 주파수 × 세기

- 짧은 구간 (프레임) 마다 FFT 를 반복해 이어 붙인 그림
- 가로 시간 , 세로 주파수 , 색 = 세기 (dB)
- 정상 소음은 규칙적 띠 , 이상은 불규칙한 줄무늬 · 튀는 점
- 이 그림을 **이미지처럼** 학습시킬 수도 , 숫자로 요약 (MFCC) 할 수도

4 교시에 librosa 로 같은 장비의 정상 · 이상 녹음 스펙트로그램을 나란히 그립니다 . 눈으로 차이가 보이면 모델도 배울 수 있습니다 .

MFCC — 소리 한 토막을 숫자 13 개로 요약하는 4 단계

Mel-Frequency Cepstral Coefficients. 사람 귀의 민감도 (멜 척도) 를 반영해 소리의 " 음색 " 을 압축한 특징값입니다 . 음성 인식과 설비 진단에 가장 널리 쓰입니다 .

01

프레임 분할

- 20~40ms 단위로 자름
- 겹치게 (hop) 이동
- 수백 개 프레임

>

02

FFT → 파워 스펙트럼

- 프레임별 주파수 성분
- 세기를 제공 (파워)
- 고주파 강조 (pre-emphasis)

>

03

멜 필터뱅크

- 사람 귀 기준 20~40 개 구간으로 묶음
- 저주파는 촘촘 , 고주파는 성글게
- 로그를 취해 dB 감각으로

>

04

DCT → 계수 13 개

- 이산 코사인 변환으로 압축
- 앞 13 개 계수만 사용
- 프레임 평균 · 표준편차 → 특징 벡터

녹음 1 건 → 프레임 수백 개 → 프레임마다 MFCC 13 개 → 평균 · 표준편차로 요약하면 **숫자 26 개** . 이 26 개가 분류 모델의 입력입니다 .

오늘 뽑는 음향 특징값과 현장 의미

MFCC 외에도 몇 개의 단순 특징을 함께 쓰면 모델이 안정됩니다 . 각 값이 현장의 어떤 현상과 연결되는지 알면 결과 해석이 됩니다 .

특징	librosa 함수	무엇을 재나	현장에서의 의미
RMS 에너지	feature.rms	소리의 평균 세기	전체 소음 수준 · 부하 상태
영교차율 (ZCR)	feature.zero_crossing_rate	파형이 0 을 지나는 빈도	마찰 · 금속성 잡음이 많으면 상승
스펙트럴 센트로이드	feature.spectral_centroid	주파수 분포의 무게중심	" 날카로운 소리 " 일수록 높음 · 베어링 손상
스펙트럴 롤오프	feature.spectral_rolloff	에너지 85% 가 모이는 주파수	고주파 이상을 발생 시 상승
MFCC 1~13	feature.mfcc	음색의 요약	정상 · 이상 패턴 구분의 핵심 입력
스펙트럴 대비	feature.spectral_contrast	피크와 골의 차이	규칙적 회전음 vs 불규칙 충격음

특징값을 **장비별 정상 기준 대비 비율**로 바꾸면 그 자체가 KPI 가 됩니다 (예 : 센트로이드 정상 대비 +35%). 3 교시 실습 도입의 핵심입니다 .

머신비전 검사와 멀티모달 LLM, 언제 무엇을 쓰나

MACHINE VISION

전통적 머신비전 검사

- 고정 카메라 · 조명 · 정해진 부품 · 정해진 결함
- 엣지 검출 · 템플릿 매칭 · CNN 분류기
- 빠르고 일관되지만 **조건이 바뀌면 재학습**
- 라인 검사 · 치수 측정에 적합

MULTIMODAL LLM

멀티모달 LLM (Vision)

- 스마트폰 사진 · 다양한 부품 · 자연어 설명 가능
- " 이 사진에서 결함 유형 · 위치 · 심각도를 JSON 으로 "
- 유연하지만 **일관성은 검증 필요** · 건당 비용 · 속도
- 현장 1 차 분류 · 도면 판독 · 라벨링 보조에 적합

오늘은 멀티모달 LLM 으로 **라벨링을 보조**하고 , 사람 라벨과의 일치도로 신뢰할 수 있는지 판단합니다 . 양산 검사는 그다음 단계입니다 .

멀티모달 LLM 은 사진을 어떻게 " 읽는가 "

작동 원리를 알면 프롬프트를 어떻게 써야 하는지 , 어디서 틀리는지가 보입니다 .

1

이미지 → 토큰

- 사진을 격자 (패치) 로 나눠 벡터로 변환
- 해상도가 낮으면 작은 크랙은 사라짐
- → 결합 부위를 크롭해 넣기

2

텍스트와 결합

- 사진 토큰 + 지시문 토큰을 함께 처리
- " 어디를 봐야 하는지 " 를 글로 안내 가능
- → 부품명 · 촬영 각도를 함께 주기

3

구조화 출력

- JSON 스키마를 주면 그 형식으로 답변
- 허용 값 목록을 주면 그 안에서 선택
- → 1 일차 분류 체계를 그대로

4

한계

- 치수 측정은 못 함 (상대 비교만)
- 없는 결합을 만들기도 (환각)
- → " 없으면 null" + 신뢰도 요구

오늘 결과를 판단하는 네 가지 숫자

모델도 , LLM 라벨도 같은 방식으로 검증합니다 . " 정확도 95%" 만으로는 부족합니다 . 이상을 놓치는 것과 정상을 이상이라 하는 것은 비용이 다릅니다 .

지표	계산	뜻	현장 기준 예시
혼동 행렬	실제 $\times$ 예측 2×2 표	TP(이상→이상) · FN(이상→정상 , 놓침) · FP(정상→이상 , 오경보) · TN	먼저 FN 건수를 본다
재현율 (Recall)	$TP \div (TP + FN)$	실제 이상 중 잡아낸 비율	안전 관련이면 ≥ 0.9
정밀도 (Precision)	$TP \div (TP + FP)$	이상이라 한 것 중 진짜 비율	오경보 피로 방지 ≥ 0.7
F1	$2 \times P \times R \div (P + R)$	정밀도 · 재현율의 조화 평균	모델 비교용 단일 숫자
라벨 일치도 κ	Cohen's kappa	사람 라벨 vs LLM 라벨 일치 (우연 보정)	≥ 0.6 사용 가능 · ≥ 0.8 우수

세 파이프라인을 오늘 안에 세 번 돌립니다. 음향 → 비전 → 문서 · 음성 → 정형 DB.

이 파트에서 다룰 것

실습① 멀티모달 이미지 · 도면 정보 추출 (A + C 문서, 2H) · 실습② Acoustic AI 정량화 · 정형 DB 연동 (B + C 음성, 4H)

DAY 3 실습 구성

시간표는 음향 (B) 을 먼저 , 비전 (A) 과 문서 · 음성 (C) 을 이어서 진행합니다 . 실습 카드 ①②는 산출물 기준 묶음입니다 .

실습	시간	데이터	도구	산출물
① 멀티모달 이미지 · 도면 정보 추출 (A + C 문서)	2H	④ 도면 · 결함 사진	ChatGPT Vision · Gemini · Claude	결함 라벨 JSON · 도면 정보 SQL 테이블
② Acoustic AI 정량화 · 정형 DB 연동 (B + C 음성)	4H	② 설비 소음 , ⑥ 회의 녹음	Acoustic AI(스펙트로그램) · SQL/JSON	정상 · 이상 분류 모델 · 정형 DB 파이프라인

음향 파이프라인은 기본 트랙 (제공 노트북 실행 · 결과 해석) 과 심화 트랙 (특징 · 모델 파라미터 변경) 두 수위로 준비돼 있습니다 . 진도에 맞게 선택합니다 .

감각적 직관을 정량 KPI 로 바꾸는 원리

본격 실습 전에 " 왜 이 숫자가 KPI 가 되는지 " 를 한 건의 녹음과 한 장의 사진으로 확인합니다 .

01

감각

- 숙련공 : " 평소보다 날카롭다 "
- 사진 : " 이 크랙은 위험하다 "
- → 말로는 전수 불가

>

02

특징값

- 센트로이드 2,800Hz (정상 2,050Hz)
- 크랙 길이 비율 · 위치 (응력 집중부)
- → 숫자로 표현

>

03

임계값

- 정상 대비 +30% 이상이면 이상
- 가이드라인 S3 조건 충족
- → 규칙으로 표현

>

04

KPI

- 이상음 감지율 · 오경보율
- 결함 등급별 건수 추이
- → 5 일차 대시보드 지표

실습 : 제공된 정상 · 이상 녹음 각 1 건의 특징값 6 개를 표로 비교하고 , 어느 특징이 가장 크게 차이 나는지 팀별로 발표 (10 분).

파이프라인 B(음향) — 녹음에서 분류 모델까지

Colab 노트북 acoustic_pipeline.ipynb. 단계마다 셀이 나뉘어 있고 , 각 셀의 코드는 아래 프롬프트로 생성한 것입니다 .

01

수집 · 정리

- ② 녹음 파일 + labels.csv
- 파일명 ↔ 라벨 매칭 확인
- 샘플링 22,050Hz 통일



02

전처리

- 무음 구간 제거
- 대역 필터로 배경 소음 제거
- 길이 3 초 단위 분할



03

특징 추출

- MFCC 13 평균 · 표준편차
- RMS·ZCR· 센트로이드 · 롤오프
- features.csv 저장



04

모델 학습

- RandomForest(기본)
- 학습 80% / 검증 20%
- 교차검증 5 회



05

검증

- 혼동 행렬 · 재현율 · 정밀도 · F1
- 오분류 파일 듣기
- model.pkl 저장

4 교시 — librosa 로 특징값 뽑기

Colab 에서 앨리스 모델 또는 ChatGPT 에 이 지시를 넣어 코드를 받고 , 셀에 붙여 넣어 실행합니다 .

확인할 것

- 파일 수와 features.csv 행 수가 같은가
- 라벨 분포 (정상 / 이상 건수) 가 출력됐는가
- 정상 · 이상 스펙트로그램 그림이 눈으로 구분되는가
- 특징값에 NaN 이 없는가
- 기본 트랙은 실행 · 확인까지 , 심화 트랙은 n_mfcc·hop_length 를 바꿔 비교

PROMPT · 특징 추출

[데이터] /content/sound/ 폴더에 .wav 수백 건 ,
labels.csv (filename, equipment, label: normal|abnormal)

[목표] 각 파일에서 음향 특징을 뽑아 features.csv 생성

[제약]

- librosa, numpy, pandas 사용
- sr=22050 으로 로드 , 앞뒤 무음 (top_db=30) 제거
- 특징 : MFCC 13 개의 평균 · 표준편차 (26), RMS 평균 , ZCR 평균 , spectral_centroid 평균 , spectral_rolloff 평균 → 총 30 열
- 파일 하나라도 실패하면 이유를 출력하고 계속 진행

[출력]

- features.csv (filename, equipment, label + 특징 30 열)
- 라벨별 건수 출력
- 정상 1건 · 이상 1건의 멜 스펙트로그램을 나란히 그린 그림 1장
- 라벨별 spectral_centroid 평균 비교 표

5 교시 — 정상 · 이상 분류 모델과 혼동 행렬

해석 요령

- 혼동 행렬에서 **FN(이상을 정상으로)** 부터 본다
- 재현율이 낮으면 : 이상 샘플 추가 · 임계값 조정
- 정밀도가 낮으면 : 배경 소음 필터 강화
- 오분류 파일을 직접 들어 보고 라벨 오류인지 확인
- 특징 중요도 상위 5 개가 이론과 맞는지 (센트로이드 · MFCC)

PROMPT · 분류 모델

[데이터] features.csv (4 교시 산출물)

[목표] label(normal/abnormal) 을 예측하는 분류 모델 학습 · 검증

[제약]

- scikit-learn RandomForestClassifier(n_estimators=200, random_state=42), 특징은 StandardScaler 로 정규화
- 학습 / 검증 80:20 층화 분할 + 5 겹 교차검증
- 장비 (equipment) 별 성능도 따로 출력

[출력]

1. 혼동 행렬 (그림 + 표), 정밀도 · 재현율 · F1
2. 교차검증 F1 평균 · 표준편차
3. 특징 중요도 상위 10 개 막대 그래프
4. 오분류 파일 목록 (filename, 실제 , 예측 , 확률)
5. 모델을 model.pkl, 스케일러를 scaler.pkl 로 저장
6. 새 .wav 하나를 받아 normal/abnormal 과 확률을 돌려주는 predict(path) 함수

혼동 행렬을 현장 언어로 읽습니다

EXAMPLE

예시 결과 (검증 80 건)

실제 이상 40 건 → 예측 이상 36 · 예측 정상 4 (FN)
실제 정상 40 건 → 예측 정상 37 · 예측 이상 3 (FP)

재현율 0.90 · 정밀도 0.92 · F1 0.91
특징 중요도 1 위 spectral_centroid, 2 위 MFCC-2 표준편차

오분류 4 건 중 2 건 : 라벨이 잘못된 파일 (들어 보니 정상)

MEANING

현장에서의 의미

- 이상음 10 건 중 9 건을 자동으로 잡는다 · 1 건은 놓친다 → 사람 점검 병행
- 경보 39 건 중 36 건이 진짜 · 오경보 3 건 → 현장 수용 가능
- 라벨 오류 2 건 발견 → 1 일차 가이드라인에 규칙 추가
- 가장 중요한 특징이 이론 (센트로이드) 과 일치 → 설명 가능
- 5 일차 : predict() 를 n8n 에서 호출해 Slack 알림

파이프라인 A(비전) — 결함 사진 라벨링과 도면 정보 추출

멀티모달 LLM 으로 사진 20 장을 라벨링하고 , 1 일차 가이드라인으로 붙인 사람 라벨과 일치도를 잹니다 . 이어서 도면 PDF 에서 부품 정보를 표로 뽑습니다 .

01

전처리

- 긴 변 1,024px 로 리사이즈
- 결함 부위 크롭본 추가
- 파일명 = 부품 _ 번호

>

02

사람 라벨

- 팀원 2 명이 20 장 독립 라벨링
- 유형 · 위치 · 심각도
- 불일치는 토론 후 확정

>

03

LLM 라벨

- Gemini(무료) 기본 , ChatGPT·Claude 비교
- 같은 프롬프트 , JSON 출력
- 20 장 × 1 회

>

04

일치도

- 유형 일치율 · 심각도 κ
- 불일치 사례 분석
- defect_labels.json 확정

>

05

도면 추출

- PDF 도면 3 장
- 부품 위치 · 치수 · 재질 표
- drawing_parts.csv

결함 사진 → 라벨 JSON

1 일차 8 교시 프롬프트의 사진판입니다. 허용 값은 1 일차 분류 체계와 심각도 정의를 그대로 씁니다.

요령

- 부품명과 촬영 맥락을 알려 주면 정확도가 오릅니다
- 위치는 시계 방향 · 상하좌우 같은 **상대 표현**으로
- "결함 없음" 도 정답이 될 수 있게 허용
- 신뢰도 0.6 미만은 사람 재검토 큐로
- 같은 사진 2 회 요청해 재현성 확인

PROMPT · Vision

첨부 사진은 굴착기 { 부품명 }을 (를) 정비 중 촬영한 것입니다.
1 일차 라벨링 가이드라인에 따라 결함을 판정하고 JSON 으로만 답하세요.

```
{
  "image_id": "{ 파일명 }",
  "part": "{ 부품명 }",
  "defects": [
    { "system": " 유압 | 엔진 | 주행 · 회전 | 구조 · 용접 | 전장 ",
      "type": " 이상 소음 | 누유 | 압력 저하 | 호스 팽윤 | 백연 | 과열 |
        트랙 장력 이상 | 롤러 마모 | 크랙 | 변형 | 용접부 기공 |
        핀 마모 | 단선 | 간헐 접촉 불량 ",
      "location": " 사진 기준 상대 위치 ( 예 : 좌상단 , 용접부 중앙 )",
      "severity": "S1|S2|S3|S4",
      "evidence": " 판정 근거 한 문장 ",
      "confidence": 0.0~1.0 }
  ],
  "no_defect": true|false,
  "needs_human_review": true|false
}
```

type 값은 위 목록에서만 고르고, 사진에서 확인되지 않는 결함은
넣지 마세요. 판단이 어려우면 needs_human_review 를 true 로.

도면 PDF → 부품 위치 · 치수 · 재질 표

도면 이미지 (또는 PDF 페이지) 를 넣고 표로 받습니다 . LLM 은 치수를 " 측정 " 하지 못하므로 , 도면에 **적혀 있는** 값만 옮기게 합니다 .

검증

- 추출된 치수 5 개를 도면과 대조 → 정확도
- 단위 (mm/inch) 혼동 여부
- 부품 번호 (품번) 오독 (0/O, 1/I)
- 표에 없는 부품을 만들어 냈는지
- 결과는 drawing_parts.csv 로 저장 → 8 교시 SQL 테이블

PROMPT · Drawing

첨부한 건설기계 부품 도면에서 정보를 추출해 CSV 형식 표로만 답하세요 .
도면에 명시적으로 적힌 값만 옮기고 , 적혀 있지 않으면 빈칸으로 두세요 .
추정하거나 계산하지 마세요 .

열 :

drawing_no, part_no, part_name, position(도면 내 위치 번호 또는 영역), dimension(치수 문자열 그대로 , 예 : Ø45 H7 / 120±0.5),
unit(mm|inch| 미표기), material(재질 표기 그대로), qty, note

추가로 마지막 줄에 다음을 적어 주세요 .

- 판독이 불확실한 셀의 수와 그 이유
- 도면의 축척 · 단위 표기가 있었는지

사람 라벨 vs LLM 라벨 — 일치도 검증표


사진 20 장 기준 . 팀별로 채우고 κ 는 Colab 에서 sklearn.metrics.cohen_kappa_score 로 계산합니다 .

항목	기준	Gemini	ChatGPT	Claude
결함 유무 일치율	no_defect 판정이 사람과 같은 비율	__ %	__ %	__ %
결함 유형 일치율	type 이 사람 라벨과 같은 비율	__ %	__ %	__ %
심각도 κ	severity S1~S4 의 Cohen's κ	0.__	0.__	0.__
위치 일치	location 이 같은 영역을 가리키는가	__ / 20	__ / 20	__ / 20
환각	사진에 없는 결함을 만든 건수	__ 건	__ 건	__ 건
형식 준수	JSON 만 , 허용 값만	○ / ×	○ / ×	○ / ×
재검토 요청률	needs_human_review=true 비율	__ %	__ %	__ %

$\kappa \geq 0.6$ 이면 **LLM 1 차 라벨 + 사람 검수** 체계로 운영 가능 . 미만이면 가이드라인 예시 사진을 프롬프트에 추가 (few-shot) 해 재시도 .

정비 회의 녹음 → 회의록 · 액션 아이템 · 화자 분리

⑥ 회의 녹음 (5~30 분) 을 텍스트로 바꾸고 , 누가 무엇을 언제까지 하기로 했는지를 표로 뽑습니다 . 1 일차 인터뷰 음성 (①) 도 같은 방법으로 구조화합니다 .



인터뷰 음성 (①) 은 " 노하우 문장 " 단위로 구조화합니다 : 상황 · 판단 근거 · 조치 · 주의점 . 이 구조가 4 일차 **숙련공 노하우 에이전트**의 청크 단위가 됩니다 .

전사 텍스트 → 회의록 JSON

요령

- 전사문에 화자 태그가 있으면 붙여 넣고, 없으면 " 화자 구분 포함 " 을 지시
- 장비 모델 · 부품 코드 목록을 사전으로 제공
- 액션 아이템은 **담당** · **기한**이 없으면 null 로
- 녹음이 길면 10 분 단위로 나누어 넣고 병합

PROMPT · Meeting

아래는 정비 회의 녹음의 전사문입니다 (화자 태그 포함).

용어 사전 : EX210·EX350·WL300·FL120(장비), HYD-P-xx(유압 펌프 품번)

JSON 으로만 답하세요 .

```
{
  "meeting": { "date": "", "participants": [], "topic": "" },
  "decisions": [ { "item": "", "reason": "", "speaker": "" } ],
  "action_items": [
    { "task": "", "owner": "", "due": "YYYY-MM-DD 또는 null",
      "equipment": "", "part_code": "", "priority": "S1|S2|S3|S4|null" }
  ],
  "knowhow": [
    { "situation": "", "judgement": "", "action": "", "caution": "",
      "speaker": "" }
  ],
  "unclear": [ " 확인 필요한 발언 원문 " ]
}
```

knowhow 에는 베테랑의 판단 근거가 드러난 발언만 넣으세요 .

[전사문]

...

정형 DB 스키마 — 오늘 산출물이 들어갈 테이블 4 개

비정형에서 뽑은 정보를 표로 저장해야 2 일차 KPI 스크립트 , 4 일차 RAG, 5 일차 n8n 이 읽을 수 있습니다 . SQLite 로 시작해 Postgres 로 옮겨도 같은 구조입니다 .

테이블	주요 열	원천	연결 키
defect_labels	image_id, equipment_id, part, system, type, location, severity, confidence, labeled_by(human llm), labeled_at	파이프라인 A JSON	equipment_id
drawing_parts	drawing_no, part_no, part_name, position, dimension, unit, material, qty	파이프라인 C 도면 CSV	part_no
acoustic_results	filename, equipment_id, recorded_at, centroid, rms, mfcc_1..13, label, predicted, prob	파이프라인 B features + 예측	equipment_id
meeting_actions	meeting_id, date, task, owner, due, equipment_id, part_code, priority, status	파이프라인 C 회의 JSON	equipment_id, part_code

네 테이블 모두 **equipment_id** 로 2 일차 parts_history 와 연결됩니다 . 이것이 " 정형 DB 파이프라인 " 의 뜻입니다 — 따로 있던 것이 하나의 장비 이력으로 합쳐집니다 .

Vibe Coding 으로 DDL 과 적재 스크립트 만들기

검증

- 테이블 4 개가 생성되고 행 수가 원천 파일과 같은가
- severity·type 값이 허용 목록 밖이면 거부되는가 (CHECK 제약)
- equipment_id 로 parts_history 와 JOIN 이 되는가
- 같은 파일을 두 번 넣어도 중복이 생기지 않는가 (UPSERT)
- 조회 예시 3 개가 실행되는가

PROMPT · load_db.py

[데이터] defect_labels.json, drawing_parts.csv, features.csv(+ 예측),
meeting_actions.csv, 2 일차 clean_parts_history.csv

[목표] SQLite DB(fielddata.db) 에 표준 스키마로 적재하는 load_db.py

[제약]

- sqlite3, pandas 만 사용
- DDL: 앞 슬라이드의 테이블 4 개 + parts_history
 - severity CHECK IN ('S1','S2','S3','S4')
 - type 은 1 일차 분류 체계 값만 허용 (CHECK)
 - 기본키 : defect_labels(image_id), drawing_parts(drawing_no, part_no), acoustic_results(filename), meeting_actions(meeting_id, task)
- 적재는 INSERT OR REPLACE(UPSERT), 거부된 행은 rejected.csv 로
- 적재 후 검증 : 테이블별 행 수 , 제약 위반 건수 출력

[출력]

- load_db.py, fielddata.db, rejected.csv
- 조회 예시 3 개 (SQL + 결과 상위 5 행):
 - 1) 장비별 S3 이상 결함 건수와 최근 정비일
 - 2) 이상음 예측 확률 0.8 이상 장비와 미완료 액션 아이템
 - 3) 도면 부품 중 결함 라벨이 3 건 이상인 부품

정형 DB 파이프라인 정확도 검증 체크리스트

적재가 됐다고 정확한 것이 아닙니다. 원천 표본을 뽑아 DB 값과 대조합니다. 1 일차 품질 기준 (완전성 · 정확성 · 일관성 · 적시성) 이 그대로 항목입니다.

- | | |
|---|--|
| ☐ 완전성 — 테이블별 행 수가 원천 파일 건수와 같다 (차이는 rejected.csv 로 설명) | ☐ 일관성 — equipment_id 표기가 parts_history 와 100% JOIN 된다 |
| ☐ 완전성 — 필수 열 (equipment_id·severity·type) 결측 0 건 | ☐ 일관성 — severity·type 값이 허용 목록 밖인 행 0 건 |
| ☐ 정확성 — defect_labels 표본 10 건을 사진과 대조해 9 건 이상 일치 | ☐ 적시성 — labeled_at·recorded_at 이 실제 발생일 기준 24 시간 내 |
| ☐ 정확성 — drawing_parts 치수 5 개를 도면과 대조해 전부 일치 | ☐ 재현성 — load_db.py 를 두 번 실행해도 행 수가 늘지 않는다 |
| ☐ 정확성 — acoustic_results 예측이 model.pkl 재실행 결과와 같다 | ☐ 조회 예시 3 개가 실행되고 결과가 상식과 맞는다 |

산출물 : fielddata.db + load_db.py + 검증 결과 . 8 교시 종료 시 패들렛 게시 .

오늘의 산출물 — 파이프라인 세 개와 DB 하나

패들렛 build_data1 → 「Day03 실습결과」 섹션 · 노트북 링크 + JSON/CSV + 혼동 행렬 · 일치도 표 스크린샷 ·

B

정상 · 이상 분류 모델

acoustic_pipeline.ipynb ·
features.csv · model.pkl · 혼동
행렬 · 재현율 · 정밀도 · F1

A

결함 라벨 JSON

defect_labels.json 20 장 · 사람
vs LLM 일치도 검증표 · κ

C

도면 정보 SQL 테이블 ·
회의록

drawing_parts.csv ·
meeting_actions.csv · 노하우 문장
(knowhow) 목록

DB

정형 DB 파이프라인

fielddata.db · load_db.py · 검증
체크 10 개 · 조회 예시 3 개

표가 아니던 것이 하나의 장비 이력으로 합쳐졌습니다

TODAY

오늘 정리

- 소리 → FFT · 스펙트로그램 · MFCC → 숫자 30 개 → 분류 모델
- 사진 · 도면 → 멀티모달 LLM → JSON/CSV, 사람 라벨과 κ 로 검증
- 회의 · 인터뷰 음성 → 액션 아이템 · 노하우 문장
- 전부 equipment_id 로 연결된 정형 DB

NEXT · DAY 4

RAG 기반 숙련공 노하우 에이전트 구축

- RAG 파이프라인 — 임베딩 · 인덱싱 · 검색 · 생성
- 벡터 DB 비교 (Pinecone · Chroma · Weaviate · FAISS)
- 오늘의 노하우 문장 + 매뉴얼 PDF 로 트러블슈팅 에이전트 (노코드)

PREPARE

내일 준비물

- NotebookLM 접속 확인 (구글 계정)
- ChatGPT Custom GPT 또는 Claude Project 사용 가능 여부 확인
- 실습 데이터 ⑦ 매뉴얼 PDF 샘플 내려받기
- 오늘 meeting_actions.csv · knowhow 목록 지참

학습 사이트 build-data.jobability.co.kr — 실습 노트북 링크와 도구 가이드 · 질문은 패들렛 「기타」 섹션에 .