

DAY 4

2026 산업전문인력 AI 역량강화 · 건설기계 · AI 적용을 위한 현장 데이터 수집 및 디지털화

RAG 기반 숙련공 노하우 에이전트 구축

1~3 일차에 모은 정비 이력 · 결함 라벨 · 음향 분류 결과 · 매뉴얼을 하나의 지식베이스로 묶고, 신입이 물으면 베테랑의 노하우와 매뉴얼 출처를 인용해 답하는 에이전트를 노코드로 만듭니다.

시수

8 시간 · 이론 3H + 실습 5H

오늘의 산출물최적화된 RAG 파이프라인 설정 · 정비
트러블슈팅 에이전트 프로토타입**사용 데이터**① 인터뷰 음성 (3 일차 구조화 텍스트)
⑦ 정비 가이드 · SOP · 매뉴얼 PDF**도구**Pinecone · Chroma · Weaviate ·
Custom GPT · Claude Project ·
NotebookLM(무료)

오늘은 이렇게 진행합니다

교시	시간	유형	주제	내용
1 교시	09:00-09:50	학습	RAG 파이프라인 구조	임베딩 · 인덱싱 · 검색 · 생성 단계별 동작 원리
2 교시	10:00-10:50	학습	벡터 DB · 임베딩 모델 비교	Pinecone · Chroma · Weaviate · FAISS 및 임베딩 모델 특성 비교
3 교시	11:00-11:50	학습	RAG 최적화 · 환각 최소화 전략	청킹 · 메타데이터 · Reranking 기반 최적화
점심	12:00-13:00	점심	점심 식사	
4 교시	13:00-13:50	실습	실습① RAG 파이프라인 · 벡터 DB 이해	RAG 파이프라인 및 벡터 DB 구조 이해 (60 분)
5 교시	14:00-14:50	실습	실습① 청킹 · 임베딩 · Reranking 최적화	베테랑 인터뷰 · 정비 가이드 · 정비 이력 기반 최적화 (120 분 전반)
6 교시	15:00-15:50	실습	실습① 최적화 (계속)	1~3 일차 산출물 기반 데이터 유형별 청킹 (120 분 후반)
7 교시	16:00-16:50	실습	실습② 답변 품질 개선 · 환각 최소화	메타데이터 필터링 · 하이브리드 검색 기반 답변 품질 개선 (60 분)
8 교시	17:00-17:50	실습	실습② 노하우 에이전트 구축 · 품질 평가	노코드 RAG 정비 트러블슈팅 에이전트 구축 · 출처 인용 정확도 · 환각 발생률 평가 (60 분)

무료 실습 환경 — NotebookLM(출처 인용 RAG) · Chroma 로컬 (Colab) · Gemini Gems. 결과는 패들렛 「Day04 실습결과」에 게시합니다.

오늘이 끝나면 이것을 할 수 있습니다

수업목표 — 현장에서 수집 · 가공한 데이터 특성에 맞는 RAG 파이프라인을 설계하고, 1~3 일차 산출물을 통합 활용하여 숙련공 노하우 에이전트를 구축할 수 있다.

- 1 RAG 파이프라인 단계 (**임베딩** · **인덱싱** · **검색** · **생성**) 를 설명할 수 있다
- 2 벡터 DB(Pinecone · Chroma · Weaviate) 의 차이를 이해하고 적합한 DB 를 선택할 수 있다
- 3 청킹 전략 · 임베딩 모델 · **재순위 (reranking)** 등 RAG 최적화 기법을 적용할 수 있다
- 4 1~3 일차 산출물을 활용한 숙련공 노하우 에이전트를 **노코드 (Custom GPT · Claude Project)** 로 구축할 수 있다

교수방법 — RAG 단계별 시연 → 벡터 DB 비교 · 선택 워크숍 → 노하우 데이터 기반 에이전트 구축 핸즈온 → 답변 품질 평가 · 1:1 멘토링

LLM 에게 **우리 회사 문서**를 읽히는 가장 현실적인 방법 , 검색 증강 생성 (RAG).

이 파트에서 다룰 것

RAG 가 필요한 이유 → 4 단계 파이프라인 (임베딩 · 인덱싱 · 검색 · 생성) → 임베딩이란 → 시연 시나리오 (신입 질문 → 출처 인용 답변)

파인튜닝이 아니라 RAG 인 이유

FINE-TUNING

모델을 다시 학습시키기

- 수천 건의 정제된 Q&A 필요 · GPU 비용
- 매뉴얼이 바뀌면 다시 학습
- 답의 **근거를 보여 주지 못함**
- 잘못 배운 내용을 고치기 어려움

RAG · RETRIEVAL-AUGMENTED GENERATION

검색해서 읽히기

- 문서를 잘게 잘라 저장 → 질문과 관련된 조각을 찾아 LLM 에 함께 제공
- 문서가 바뀌면 **다시 저장만** 하면 됨
- 답마다 출처 (문서 · 페이지) 인용 가능
- 노코드 도구로 오늘 안에 프로토타입

현장 지식은 자주 바뀌고 , 근거가 중요하고 , 양이 수천 건 수준입니다 . 세 조건 모두 RAG 에 맞습니다 .

RAG 파이프라인 4 단계

왼쪽 두 단계는 문서를 넣을 때 한 번, 오른쪽 두 단계는 질문할 때마다 실행됩니다.

01

임베딩

- 문서를 청크로 자름
- 청크마다 의미 벡터 (숫자 수백 ~ 수천 개) 로 변환
- 비슷한 뜻 = 가까운 벡터

>

02

인덱싱

- 벡터 + 원문 + 메타데이터를 벡터 DB 에 저장
- 장비 · 문서 유형 · 날짜 태그
- 빠른 유사도 검색 구조

>

03

검색

- 질문도 벡터로 변환
- 가장 가까운 청크 상위 k 개 추출
- 메타데이터로 필터 · 재순위

>

04

생성

- 질문 + 찾은 청크를 LLM 에 전달
- " 이 자료만 근거로 답하라 "
- 출처 인용 포함 답변

오늘 최적화하는 것은 **청크 크기 (임베딩) · 메타데이터 (인덱싱) · 재순위 (검색) · 프롬프트 (생성)** 네 지점입니다.

임베딩 — 문장을 좌표로 바꾸면 "비슷함"을 계산할 수 있습니다

"유압펌프에서 금속성 소음" 과 "펌프 쪽에서 쇠소리" 는 단어가 다르지만 벡터는 가깝습니다. 키워드 검색이 놓치는 것을 잡는 원리입니다.

1

무엇을 만드나

- 텍스트 → 길이 768~3,072 의 숫자 배열
- 의미가 비슷하면 코사인 유사도가 1 에 가까움
- 같은 모델로 문서와 질문을 모두 변환해야 함

2

모델 선택 기준

- 한국어 성능 (다국어 모델 여부)
- 차원 수 ↑ = 정확도 ↑ , 저장 · 속도 비용 ↑
- 비용 : OpenAI text-embedding-3 · Gemini embedding · 오픈소스 bge-m3 (무료 · 로컬)

3

현장 데이터 주의점

- 품번 · 오류 코드는 의미 벡터로 잘 안 잡힘 → 키워드 검색 병행 (하이브리드)
- 표는 문장으로 풀어서 넣기
- 전문 용어 사전을 청크에 덧붙이기

시연 — 신입이 묻고, 베테랑과 매뉴얼이 답합니다

QUESTION

신입 정비사의 질문

"EX210 시운전 중에 유압펌프 쪽에서 쇠소리 같은 게 나는데, 계속 작업해도 되나요? 뭘 먼저 확인해야 하죠?"

ANSWER

에이전트의 답변 (출처 인용)

" 금속성 소음이 지속되면 **S3(즉시 정비)**에 해당하므로 당일 작업을 중지해야 합니다. [출처 : 라벨링 가이드라인 v1 § 심각도]

먼저 확인할 것 : ① 작동유 레벨과 오염도 ② 흡입 라인 에어 유입 ③ 펌프 커플링 마모 . 베테랑 김 OO 정비사는 " 쇠소리는 커플링보다 흡입 쪽 에어 유입일 때가 더 많다 . 필터 먼저 본다 " 고 조언했습니다 . [출처 : 인터뷰 2026-09-10 knowhow #7]

매뉴얼 절차 : 유압펌프 점검 항목 7.3.2 [출처 : EX210 정비 매뉴얼 p.214]"

답변에 **심각도 판단** + **베테랑 노하우** + **매뉴얼 절차**가 각각 출처와 함께 들어 있어야 합격입니다 . 8 교시 평가 기준입니다 .

벡터 DB 는 네 가지 중
규모 · 운영 · 비용에 맞는 것을
고르면 됩니다 .

이 파트에서 다룰 것

Pinecone · Chroma · Weaviate · FAISS 비교 → 선택 기준 → 임베딩 모델 특성 비교 → 메타데이터 설계

벡터 DB 4 종 비교

	Pinecone	Chroma	Weaviate	FAISS
형태	완전 관리형 클라우드	오픈소스 · 로컬 / 서버	오픈소스 · 클라우드 / 자체 호스팅	라이브러리 (Meta) · 인메모리
설치	없음 (API 키)	pip install chromadb	Docker 또는 클라우드	pip install faiss
메타데이터 필터	강함	기본 제공	강함 · 하이브리드 검색 내장	없음 (직접 구현)
규모	수억 벡터	수백만 벡터 (단일 노드)	수억 벡터	메모리 한도 내
비용	무료 티어 소규모 · 이후 유료	무료	무료 (자체) / 유료 (클라우드)	무료
보안 · 거버넌스	데이터가 외부 클라우드	사내 서버 가능	사내 서버 가능	사내 서버 가능
오늘의 용도	시연 (관리형 경험)	실습 기본 (Colab 로컬)	5 일차 확장 후보	원리 이해용

우리 현장이라면 — 선택 워크숍 4 가지 질문

4 교시에 팀별로 이 질문에 답하고 벡터 DB 하나를 고릅니다. 정답은 없고, 이유가 산출물입니다.

1

문서가 외부로 나가도 되나

- 정비 매뉴얼 (제조사 공개) → 가능
- 고객 정보 · 설계 도면 → 불가
- 불가면 Chroma · Weaviate 자체 호스팅

2

규모는 얼마인가

- 매뉴얼 500 건 × 200 페이지 ≈ 10 만 청크
- 이력 · 라벨 수천 건 추가
- 단일 노드 Chroma 로 충분

3

누가 운영하나

- IT 인력 없음 → 관리형 (Pinecone) 또는 노코드
- 사내 서버 담당 있음 → 오픈소스
- 5 일차 n8n 과 연결 가능한가

4

필터가 필요한가

- 장비 모델별 · 문서 유형별 검색은 필수
- 메타데이터 필터 지원 확인
- FAISS 는 여기서 탈락

임베딩 모델 특성 비교 — 한국어 현장 문서 기준

벡터 DB 보다 임베딩 모델이 검색 품질에 더 큰 영향을 줍니다 . 바꾸면 전체 재인덱싱이 필요하니 처음에 정합니다 .

모델	차원	한국어	비용 · 위치	메모
OpenAI text-embedding-3-small	1,536	양호	유료 (저렴한) · 외부 API	Custom GPT 내부 기본 · 범용
OpenAI text-embedding-3-large	3,072	우수	유료 · 외부 API	정확도 우선 시
Gemini embedding	768~3,072	우수	무료 티어 · 외부 API	NotebookLM · Gems 내부 사용
bge-m3 (오픈소스)	1,024	우수 (다국어)	무료 · 로컬 실행	사내 호스팅 · 하이브리드 지원
ko-sroberta 계열 (오픈소스)	768	한국어 특화	무료 · 로컬	소규모 · 경량

실습 기본은 **Chroma + 기본 임베딩 (무료)** , 비교용으로 Gemini embedding. 품번 · 오류 코드는 어떤 모델이든 약하므로 키워드 검색을 병행합니다 .

RAG 가 틀리는 이유는 대개 LLM 이 아니라 검색이 엉뚱한 조각을 줬기 때문입니다 .

이 파트에서 다룰 것

청킹 전략 → 메타데이터 설계 → 재순위 (Reranking) · 하이브리드 검색 → 환각 최소화 프롬프트 → 평가 지표

청킹 전략 — 데이터 유형마다 자르는 단위가 다릅니다

너무 크면 관련 없는 내용이 섞이고 , 너무 작으면 맥락이 끊깁니다 . 1~3 일차 산출물 유형별 권장 단위입니다 .

데이터	청크 단위	크기	겹침	메타데이터
⑦ 매뉴얼 PDF	절 (section) 단위 , 표는 문장화	300~500 토큰	50 토큰	장비 모델 · 장 · 페이지 · 문서 버전
① 인터뷰 노하우 (knowhow)	노하우 1 건 = 1 청크 (상황 · 판단 · 조치 · 주의)	100~250 토큰	없음	화자 · 장비 · 계통 · 일자
정비 이력 (2 일차)	정비 1 건 = 1 청크 (문장으로 변환)	50~150 토큰	없음	장비 ID · 모델 · 부품 · 심각도 · 일자
결합 라벨 JSON (3 일차)	사진 1 장 = 1 청크 (evidence 문장 포함)	50~100 토큰	없음	장비 · 계통 · 유형 · 심각도
회의 액션 아이템 (3 일차)	결정 · 액션 1 건 = 1 청크	50~100 토큰	없음	일자 · 담당 · 장비 · 상태

구조화된 데이터 (이력 · 라벨 · 액션) 는 "EX210 유압펌프에서 2026-09-10 S3 이상 소음 발생 , 커플링 교체 " 처럼 한 문장으로 바꿔 넣습니다 . JSON 을 그대로 넣으면 검색이 잘 안 됩니다 .

메타데이터 설계 — 청크마다 붙이는 태그가 필터가 됩니다

벡터 DB 에 넣을 때 정한 태그만 나중에 필터로 쓸 수 있습니다 . 1 일차 인벤토리의 열 (장비 · 계통 · 일자 · 담당) 이 그대로 태그 후보입니다 .

태그	값 예시	어디서 오나	어떤 질문에 쓰이나
model	EX210 · WL300 · FL120	파일명 · 문서 표지 · 이력 열	"EX210 유압… " → 다른 모델 배제
system	유압 · 엔진 · 주행 · 회전 · 구조 · 용접 · 전장	1 일차 분류 체계	" 트랙 장력 " → 주행 · 회전만 검색
doc_type	manual · knowhow · history · label · meeting	원천 파일	" 매뉴얼 절차만 " · " 베테랑 조언만 "
severity	S1~S4	라벨 · 이력	"S3 이상 사례 "
date · version	2026-09-10 · v2	파일 메타 · 문서 버전	최신 문서 우선 · 구버전 배제
source · page	EX210_manual.pdf · p.214	청킹 시 자동	출처 인용 문자열 생성

태그 값은 허용 값 목록으로 통제합니다 . " 유압 ", " 유압계 ", "hydraulic" 이 섞이면 필터가 깨집니다 . 1 일차 일관성 기준이 여기서도 적용됩니다 .

검색 품질을 올리는 세 가지 장치

METADATA FILTER

메타데이터 필터링

- 질문에서 장비 모델 · 계통을 뽑아 필터로 먼저 좁힘
- "EX210 유압 " 질문에 WL300 문서가 섞이지 않음
- 문서 버전 필터로 구버전 매뉴얼 배제
- 벡터 DB 선택 기준 4 번이 이것

HYBRID

하이브리드 검색

- 벡터 유사도 + 키워드 (BM25) 점수 결합
- 품번 "HYD-P-210", 오류 코드 "E-047" 은 키워드가 정확
- 두 점수를 가중 합산 (예 0.6 : 0.4)
- Weaviate 내장 · Chroma 는 직접 결합

RERANKING

재순위 (Reranking)

- 1 차 검색 상위 20 개 → 재순위 모델이 질문과 정밀 비교 → 상위 5 개
- Cohere Rerank · bge-reranker(무료)
- 검색은 빠르게 넓게 , 재순위는 느리게 정확하게
- 환각 감소에 가장 효과 큰 단일 장치

생성 단계 — 근거 밖에서는 답하지 않게 하는 시스템 프롬프트

검색이 좋아도 LLM 이 " 아는 척 " 하면 환각이 생깁니다 . 노코드 도구의 지시문 (Instructions) 에 이 원칙을 넣습니다 .

원칙

- 제공 자료만 근거로 , 없으면 " 자료에 없음 "
- 문장마다 출처 태그
- 안전 관련 (S3·S4) 은 보수적으로
- 수치 · 품번은 자료 원문 그대로 인용
- 판단이 갈리면 두 출처를 모두 제시

SYSTEM PROMPT · 정비 트러블슈팅 에이전트

당신은 건설기계 정비팀의 트러블슈팅 도우미입니다 .
사용자는 경력 1년 미만의 신입 정비사입니다 .

규칙

1. 제공된 자료 (매뉴얼 · 베테랑 노하우 · 정비 이력 · 라벨링 가이드라인) 에서 확인되는 내용만 답합니다 . 자료에 없으면 " 자료에서 확인되지 않습니다 . 정비반장에게 확인하세요 . " 라고 답합니다 .
2. 모든 문장 끝에 출처를 [문서명 p. 페이지] 또는 [노하우 # 번호] 형식으로 붙입니다 .
3. 답변 구조 : ① 심각도 판단 (S1~S4, 라벨링 가이드라인 기준)
② 먼저 확인할 것 3 가지 ③ 베테랑 노하우 ④ 매뉴얼 절차 번호
4. 안전 관련 판단 (S3·S4) 은 보수적으로 하고 , 작업 중지를 권고합니다 .
5. 수치 · 품번 · 오류 코드는 자료 원문 그대로 인용하고 추정하지 않습니다 .
6. 자료 간 내용이 다르면 두 출처를 모두 제시하고 최신 문서를 우선합니다 .
7. 답변 마지막에 " 확인 질문 " 1 개를 덧붙여 상황을 더 파악합니다 .

RAG 답변 품질 평가 지표 — 8 교시에 이 표로 채점합니다

질문 10 개를 미리 정하고 정답 (근거 문서 · 페이지) 을 사람이 적어 둡니다 . 그 다음 에이전트 답변을 채점합니다 .

지표	측정	목표	낮을 때 손볼 곳
검색 적중률 (Recall@5)	정답 문서가 상위 5 개 청크에 포함된 비율	$\geq 80\%$	청크 크기 · 임베딩 모델 · 하이브리드
출처 인용 정확도	인용한 출처가 실제로 그 내용을 담고 있는 비율	$\geq 90\%$	시스템 프롬프트 · 재순위
환각 발생률	자료에 없는 내용을 사실처럼 답한 비율	$\leq 5\%$	" 자료에 없음 " 규칙 · 온도 낮추기
답변 완전성	심각도 · 확인 항목 · 노하우 · 절차 4 요소 포함 비율	$\geq 80\%$	답변 구조 지시 · 청크에 4 요소 태그
거부 정확도	자료 밖 질문에 " 확인되지 않음 " 으로 답한 비율	$\geq 90\%$	규칙 1 강화 · 유사도 임계값

3 일 동안 만든 데이터를 한 곳에 넣고 질문해 봅니다 .

이 파트에서 다룰 것

실습① RAG 파이프라인 최적화 (2H) · 실습② 숙련공 노하우 에이전트 구축 (3H)

DAY 4 실습 구성

실습	시간	데이터	도구	산출물
① RAG 파이프라인 최적화	2H	⑦ 매뉴얼 PDF(샘플)	Pinecone / Chroma / Weaviate · 임베딩 모델	최적화된 RAG 파이프라인 설정
② 숙련공 노하우 에이전트 구축	3H	① 인터뷰 음성 (3 일차 구조화 텍스트), ⑦ 매뉴얼 · SOP	ChatGPT Custom GPT · Claude Project	정비 트러블슈팅 에이전트 프로토타입

두 트랙 — **코드 트랙** : Colab + Chroma 로 청킹 · 재순위를 직접 조정 · **노코드 트랙** : NotebookLM → Custom GPT/Claude Project. 팀 안에서 역할을 나눠도 됩니다 .

실습① RAG 파이프라인 · 벡터 DB 이해 — 손으로 한 바퀴

매뉴얼 PDF 1 권으로 4 단계를 직접 돌려 봅니다 . NotebookLM 으로 5 분 만에 결과를 보고 , Colab + Chroma 로 같은 것을 코드로 재현합니다 .

01

NotebookLM

- 매뉴얼 PDF 업로드
- 질문 3 개 → 출처 인용
답변 확인
- " 이것이 RAG " · 10 분

>

02

Colab 준비

- chromadb · pypdf 설치
- 매뉴얼 텍스트 추출
- 10 분

>

03

청킹 · 임베딩 · 인덱싱

- 400 토큰 · 겹침 50
- 메타데이터 (모델 ·
페이지)
- Chroma 컬렉션 생성 ·
15 분

>

04

검색 · 생성

- 같은 질문 3 개 검색 →
상위 5 청크 출력
- LLM 에 청크 + 질문 전달
- 15 분

>

05

벡터 DB 선택 워크숍

- 이론 2 의 4 가지 질문에
팀 답변
- 선택과 이유 1 장
- 10 분

Chroma 로 RAG 한 바퀴 — 코드 생성 프롬프트

확인할 것

- 청크 수와 평균 토큰 길이가 출력됐는가
- 검색 결과 상위 5 개에 정답 페이지가 있는가
- 메타데이터 필터 (모델 =EX210) 를 걸면 결과가 바뀌는가
- 답변에 페이지 출처가 붙는가
- 이 노트북이 5~6 교시 최적화의 기준선 (baseline)

PROMPT · rag_baseline.ipynb

[데이터] /content/manuals/EX210_manual.pdf (약 300 쪽)

[목표] Chroma 로컬 벡터 DB 로 RAG 기준선 노트북 작성

[제약]

- chromadb, pypdf, tiktoken 사용 . 임베딩은 Chroma 기본 (all-MiniLM) 사용 , 이후 교체 가능하게 함수로 분리
- 청킹 : 400 토큰 , 겹침 50 , 페이지 경계 보존
- 메타데이터 : {model:"EX210", page:n, section: 페이지 첫 줄 제목 }
- 검색 함수 search(q, k=5, where=None) → 청크 · 점수 · 메타 출력
- 생성은 LLM API 없이도 되도록 , " 질문 + 청크 " 를 합친 프롬프트 문자열을 만들어 출력 (ChatGPT/Gemini 에 붙여 넣기용)

[출력]

1. 청크 수 , 평균 · 최대 토큰 길이
2. 질문 3 개에 대한 상위 5 청크 (페이지 · 점수 · 앞 100 자)
3. where={"model":"EX210"} 필터 적용 전후 비교
4. 평가용 : questions.csv(질문 , 정답 페이지) 를 읽어 Recall@5 계산 함수

청킹 · 임베딩 · 재순위 최적화 — 기준선을 숫자로 개선합니다

질문 10 개와 정답 페이지 (questions.csv) 를 먼저 만들고 , 설정을 하나씩 바꾸며 Recall@5 를 기록합니다 . 개선된 설정이 오늘의 첫 산출물입니다 .

01

평가 세트

- 팀별 질문 10 개 + 정답 페이지
- 베테랑 노하우 질문 3 개 포함
- 20 분

02

청킹 실험

- 200 / 400 / 800 토큰
- 절 단위 vs 고정 길이
- Recall@5 기록 · 30 분

03

데이터 유형별 청킹

- knowhow 1 건 =1 청크
- 정비 이력 · 라벨 문장화 후 추가
- 메타데이터 태그 · 30 분

04

임베딩 · 재순위

- Gemini embedding 비교
- bge-reranker 상위 20→5
- Recall@5 재측정 · 30 분

05

설정 확정

- 최고 설정 표 1 장
- rag_config.json 저장
- 10 분

최적화 실험 기록표 — 이렇게 채웁니다

한 번에 하나만 바꿉니다 . 기준선 대비 Recall@5 가 오르면 채택 , 아니면 되돌립니다 .

#	바꾼 것	설정	Recall@5	출처 정확도	채택
0	기준선	400 토큰 · 겹침 50 · 기본 임베딩 · 재순위 없음	0.____	____ %	—
1	청크 크기	200 토큰	0.____	____ %	○ / ×
2	청크 크기	800 토큰	0.____	____ %	○ / ×
3	청크 단위	절 (section) 단위 · 표 문장화	0.____	____ %	○ / ×
4	데이터 추가	knowhow · 정비 이력 · 라벨 문장화 추가	0.____	____ %	○ / ×
5	메타데이터 필터	질문에서 모델 추출 → where 필터	0.____	____ %	○ / ×
6	임베딩 모델	Gemini embedding	0.____	____ %	○ / ×
7	재순위	bge-reranker 20 → 5	0.____	____ %	○ / ×

산출물 : 실험 기록표 + rag_config.json (채택 설정) + 노트북 . 6 교시 종료 시 패들렛 게시 .

실습② 답변 품질 개선 — 필터 · 하이브리드 · 프롬프트

검색이 좋아졌으면 이제 답변을 다듬습니다. 같은 질문 10 개로 환각 발생률과 답변 완전성을 측정합니다.

01

메타데이터 필터 자동화

- 질문에서 장비 모델 · 계통 추출 (LLM)
- where 필터로 검색
- 오검색 사례 비교

>

02

하이브리드

- 품번 · 오류 코드 질문 3 개
- 키워드 검색 결과와 결합
- 적중 여부 기록

>

03

시스템 프롬프트

- 이론 3 의 7 개 규칙 적용
- "자료에 없음" 거부 질문 2 개 테스트
- 답변 구조 4 요소 확인

>

04

측정

- 환각률 · 완전성 · 거부 정확도
- 실패 사례 원인 분류 (검색 / 생성)
- 개선 목록

실패 사례는 **검색 실패 (정답 청크가 안 나옴)** 와 **생성 실패 (청크는 맞는데 답이 틀림)** 로 나눠 적습니다. 손볼 곳이 다릅니다.

노코드로 에이전트 만들기 — Custom GPT · Claude Project · NotebookLM

최적화된 설정과 시스템 프롬프트를 노코드 도구에 옮깁니다. 세 도구 중 하나를 골라 20 분 안에 프로토타입을 만듭니다.

BUILD

만드는 순서 (공통)

- 1. 지식 파일 준비 — 매뉴얼 PDF · knowhow.md(노하우 문장) · repair_history.md(이력 문장화) · labeling_guide.md
- 2. 새 GPT / Project / 노트북 생성 → 파일 업로드
- 3. Instructions 에 **시스템 프롬프트 7 규칙** 붙여 넣기
- 4. 대화 시작 예시 3 개 등록 (신입 질문 시나리오)
- 5. 질문 10 개로 채점 → 평가표

TOOLS

도구별 차이

- **Custom GPT** — 파일 20 개 · 업로드 즉시 검색 · 공유 링크 · 액션 (API) 연결 가능 (5 일차)
- **Claude Project** — 긴 문서에 강함 · 프로젝트 지식 200K 토큰 · 답변 근거 인용 우수
- **NotebookLM** — 무료 · 출처 문장 단위 인용 · 소스 50 개 · 공유 가능 · 외부 연결 없음
- **Gemini Gems** — 무료 · 지시문 + 파일 · Google 생태계 연동

노하우 문장 파일 (knowhow.md) — 3 일차 JSON 을 이렇게 바꿉니다

노코드 도구는 JSON 보다 문장을 잘 찾습니다 . 3 일차 meeting/interview JSON 의 knowhow 배열을 아래 형식으로 변환합니다 (Vibe Coding 1 회).

변환 규칙

- 노하우 1 건 = 제목 1 줄 + 본문 4 줄 (상황 · 판단 · 조치 · 주의) + 출처
- 제목에 장비 · 계통 · 현상을 넣어 검색이 잘 되게
- 번호 (#) 는 출처 인용에 쓰임
- 화자는 실명 대신 직급 · 경력으로 (개인정보)
- 정비 이력 · 라벨도 같은 방식으로 문장화

knowhow.md

숙련공 노하우 모음 (인터뷰 2026-09-10, 정비반장 25 년차)

노하우 #7 — EX210 유압펌프 금속성 소음

- 상황 : 시운전 중 유압펌프 부근에서 쇳소리 , RPM 올릴수록 커짐
- 판단 : 커플링 마모보다 흡입 라인 에어 유입일 때가 더 많다 .
소음이 불규칙하면 에어 , 규칙적이면 베어링 · 커플링 .
- 조치 : 작동유 레벨 · 흡입 필터 먼저 확인 → 이상 없으면 커플링 점검
- 주의 : 소음 지속 상태로 작업 계속하면 펌프 손상 (S3, 작업 중지)
- 출처 : 인터뷰 #7 · 관련 매뉴얼 EX210 7.3.2

노하우 #8 — WL300 트랙 장력 이상

- 상황 : ...

에이전트 답변 품질 평가표 — 질문 10 개

팀별 질문 10 개 중 7 개는 자료 안 , 3 개는 자료 밖 (거부해야 정답). 채점 후 총평 3 줄과 함께 패들렛에 게시합니다 .

#	질문 유형	정답 출처	출처 정확	환각	4 요소	판정
1	증상 → 심각도 · 조치 (유압)	가이드라인 § 심각도 · 노하우 #7	○/×	○/×	_/4	합 / 불
2	증상 → 절차 (엔진 백연)	매뉴얼 p.____	○/×	○/×	_/4	합 / 불
3	품번 질문 (HYD-P-210 호환)	부품 목록 p.____	○/×	○/×	_/4	합 / 불
4	오류 코드 (E-047)	매뉴얼 p.____	○/×	○/×	_/4	합 / 불
5	이력 질문 (EX210 최근 S3)	정비 이력 2026-09	○/×	○/×	_/4	합 / 불
6	노하우 질문 (트랙 장력 요령)	노하우 #8	○/×	○/×	_/4	합 / 불
7	두 출처가 다른 경우	매뉴얼 v1 vs v2	○/×	○/×	_/4	합 / 불
8~10	자료 밖 질문 3 개	(없음 → 거부가 정답)	거부 ○ /×	○/×	—	합 / 불

오늘의 산출물 — 설정 하나와 에이전트 하나

패들렛 build_data1 → 「Day04 실습결과」 섹션 . 에이전트 공유 링크 (또는 스크린샷) + 평가표 + 총평 .

1

벡터 DB 선택과 이유

4 가지 질문 답변 · 선택 DB · 1 장

2

최적화된 RAG 파이프라인 설정

실험 기록표 8 행 · rag_config.json
· Recall@5 기준선 대비 개선

3

지식 파일 세트

매뉴얼 PDF · knowhow.md ·
repair_history.md ·
labeling_guide.md

4

정비 트러블슈팅 에이전트 프로토타입

Custom GPT / Claude Project /
NotebookLM · 시스템 프롬프트 ·
평가표 10 문항

신입이 물으면 베테랑이 출처와 함께 답하는 시스템이 생겼습니다

TODAY

오늘 정리

- RAG 4 단계 — 임베딩 · 인덱싱 · 검색 · 생성
- 벡터 DB · 임베딩 모델은 규모 · 운영 · 보안으로 선택
- 청킹 · 메타데이터 · 재순위로 Recall@5 를 숫자로 개선
- 노코드 에이전트 + 시스템 프롬프트 7 규칙 + 평가표

NEXT · DAY 5

엔터프라이즈 전사 자동화 통합 실무

- n8n · Zapier — 트리거 · 액션 · 조건 분기 · 반복
- Sheets · Slack 연동 실시간 KPI 보드 (2 일차 스크립트 자동 실행)
- 이상음 감지 (3 일차 모델) → RAG 검색 (오늘 에이전트) → Slack 승인 라우팅

PREPARE

내일 준비물

- Slack 워크스페이스 (무료) 가입 · 테스트 채널 생성
- Google Sheets 빈 시트 1 개
- n8n 클라우드 무료 체험 또는 Make 무료 계정
- 오늘 에이전트 링크 · 3 일차 predict() 노트북

학습 사이트 build-data.jobability.co.kr — RAG 실습 노트북과 지식 파일 템플릿 · 질문은 패들렛 「기타」 섹션에 .