

Day 3 · 8 hours

고도화된 텍스트 마이닝 & 정보 추출.

Ph.D 이애본 / 한신대학교 AI.SW대학 (aebon@hs.ac.kr)

BIG WIN · Contract clause & tech-requirement auto-extraction system

비정형 문서 → 정형 스키마 · 근거 인용 · 반복 가능한 재현 체계.

DAY 3 · 파랑 · Blue

오늘, 지도의 3분의 1지점.

DAY	THEME	BIG WIN	ACCENT	STATUS
DAY 1	전략적 프롬프트 · 거버넌스	제안서 초안 + 예산안	■ 마젠타	✓ 완료
DAY 2	Vibe Coding · 빅데이터 분석	재사용 분석 스크립트 패키지	■ 녹색	✓ 완료
DAY 3 ★	텍스트 마이닝 · 정보 추출	계약서 자동 추출 시스템	■ 파랑 · TODAY	진행 중
DAY 4	RAG 사내 지식 챗봇	기술 지원 챗봇 + 운영 규칙	■ 보라	예정
DAY 5	자동화 워크플로우 (n8n)	무인 주간 보고 워크플로우	■ 주황	예정
DAY 6	통합 AI 에이전트 · 수료	통합 AI 업무 에이전트	■ 빨강	예정

문서의 80%는 표가 아니라 계약서다.

PDF · 도면 · 매뉴얼 · 계약서 — 비정형 문서에서 구조화된 정보를 반복 가능하게 뽑아내는 시스템을 만듭니다.

01 · 문서 유형 진단

텍스트 레이어 · 레이아웃 복잡도로
OCR · Vision 경로를 선택.

02 · 멀티모달 6패턴

영역 · 표 재구성 · 근거 인용 ·
불확실 · 반복 스캔 · 교차 검증.

03 · JSON 스키마 설계

다음 시스템이 그대로 받는
기계 우선 출력 형식.

04 · BIG WIN ★

계약서 독소 조항 15항 자동 추출 시스템
= 스키마 + 프롬프트 + 검수 절차.

"시스템"의 정의

소프트웨어가 아니라 "표준 프롬프트 + 출력 스키마 + 검수 절차"의 3요소가 문서화되어, 누가 어떤 문서를 넣어도 같은 형식의 결과가 나오는 재현 가능한 체계.

이론 2H · 실습 6H.

시간	구분	주제	주요 산출물	슬라이드
09:00 · 30m	오리엔테이션	지도 · 목표 · 흐름	—	01 ~ 04
09:30 · 1H	이론 1	비정형 문서 · 멀티모달 프롬프팅	문서 유형별 추출 경로 결정표	05 ~ 09
10:30 · 1H	이론 2	구조화 출력 · 대량 처리 전략	JSON 스키마 설계 원칙	10 ~ 13
11:30 · 3H	실습 1	기술 문서 핵심 정보 추출 (실습 3-1 · 3-2)	추출 데이터 · 요건 비교표	14 ~ 20
14:30 · 3H	실습 2 ★	계약서 독소 조항 자동 추출 시스템 구축	추출 시스템 1식 (BIG WIN)	21 ~ 28
17:30 · 1H	심화 · 정리	사례 · 워크스루 · 트리블슈팅 · 마무리	자가진단 · 퀴즈 · 실습 기록	29 ~ 54

"같은 문서라도 다르게 읽힌다."

디지털 PDF · 스캔본 · 도면 · 손글씨는 서로 다른 추출 경로를 요구합니다. 문서 유형을 진단하는 것이 첫 결정.

이론 1 · 60분 · 3단계

① 문서 유형 진단표 · ② OCR vs Vision 도구 비교 · ③ 멀티모달 프롬프팅 6패턴.

2축으로 진단 · 5유형으로 분기.

① 텍스트 레이어 유무 · ② 레이아웃 복잡도 — 두 축의 조합으로 **1차 추출** 경로를 결정.

#	문서 유형	텍스트 레이어	레이아웃	1차 경로	실습 대응
D1	디지털 PDF (텍스트)	■ 있음	단순 서술	직접 업로드 · 원문	실습 3-2 (매뉴얼)
D2	스캔 인쇄물 (점검표 · 표)	■ 없음	중간 (표 포함)	전용 OCR → AI 정제	실습 3-1 (점검표)
D3	도면 · 표제란 혼재	■ 없음	복잡 (도형+텍스트)	Vision + 영역 지정	실습 3-1 (도면)
D4	손글씨 · 필드 노트	■ 없음	비정형 서식	Vision · 문맥 판독	선택 실습
D5 ★	계약서 (장문 · 조항)	■ 있음	긴 텍스트 · 조항 번호	장문 도구 직접 분석 + 근거 인용	실습 3-3 · 3-4

잘못 진단하면 **정확도가 오르지 않는 게 아니라**, 정확도가 "평균 90%"로 안정되면서 **10%의 결정적 오류**가 조용히 흘러갑니다.

대량·정형 → OCR · 소량·비정형 → Vision.

전용 OCR과 범용 Vision은 경쟁이 아니라 분업. 실무에서는 **두 경로를 섞어** 씁니다.

A · 전용 OCR

Google Cloud Vision
Naver Clova · Upstage

강점.

- 인쇄 한글 정확도 **96~97%**
- 대량·정속 처리 (분당 수백 페이지)
- 좌표 · 신뢰도 함께 반환

약점.

- 표 구조 인식 제한적
- 문맥 판단 불가 (오타자 자동 교정 X)
- 손글씨 정확도 급락

B · 범용 Vision (LLM)

GPT-4o · Claude 3.5 Sonnet
Gemini 2.5 Pro

강점.

- 인쇄 **94%** · 손글씨 **85%** (문맥 보정)
- 표 재구성 · 도면 이해
- 프롬프트로 즉시 스키마 지정

약점.

- 페이지당 비용 · 처리 속도 상대적 저조
- 결정성 낮음 (같은 입력, 다른 출력 가능)
- 표본 감사 필수

하이브리드 표준 = OCR로 텍스트 확보 → Vision(LLM)으로 문맥 정제 · 스키마 매핑. 실습 3-1이 이 방식.

Vision 프롬프트는 주문서다.

모델이 이해할 수 있는 **6**가지 지시 방식. ①~④는 상시 · ⑤는 중요 문서 · ⑥은 **고위험 문서에만**.

#	패턴	지시 방식 (예)	효과	비용
①	영역 지정	"우측 하단 표제란만 읽어라"	혼재 레이아웃 오독 감소	낮음
②	표 재구성	"열 이름 그대로 재구성 · 병합 셀은 반복 기재"	표 구조 붕괴 방지	낮음
③	근거 인용	"각 값 옆에 (쪽.구역) 병기"	검수 시간 단축	낮음
④	불확실 표기	"확신이 낮으면 값 뒤에 (?)를 붙여라"	오류 후보 자동 표면화	낮음
⑤	반복 스캔	"누락 점검을 위해 한 번 더 훑고 추가분만 보고"	누락률 감소	중간 (2회 호출)
⑥ ★	교차 검증	두 도구(또는 두 실행)로 추출 → 불일치만 사람 판정	고위험 문서 정확도	높음

"99% 정확도"의 진짜 비용.

문서 유형·리스크에 따라 "수용 가능한 오차"를 먼저 정하고, 그 다음에 도구·패턴을 선택.

문서 · 리스크	목표 정확도	권장 조합	페이지당 비용	검수 강도
사내 매뉴얼 · 내부 참고	90%	Vision 단독 (①~④)	낮음 (~\$0.02)	표본 5%
기술 문서 · 점검표	95%	OCR + Vision 정제 (①~⑤)	중간 (~\$0.05)	표본 15%
★ 계약서 · 규정	98% + 근거 인용	Vision 교차검증 (①~⑥)	높음 (~\$0.15)	전수 or 표본 30%

비용 감축 3원칙

① 사전 필터. 표지·목차 등 불필요한 페이지 제거. 첫 실행 전 사람 5분 검토가 API 비용 30% 감축.

② 계층 처리. 1차 저비용 스캔 → 고위험 페이지만 2차 고비용 재추출.

③ 캐시. 같은 문서를 반복 추출하지 말 것 — 결과 **JSON**을 저장하고 diff만.

"읽기 좋은 요약"이 아니라, 기계가 먹는 데이터.

추출의 목적은 다음 시스템(DB·챗봇·워크플로우)이 그대로 받아먹는 데이터. 사람이 아니라 기계 우선 형식.

이론 2 · 60분 · 4단계

① JSON 스키마 설계 5원칙 · ② 대량 처리 배치 전략 · ③ 정확도 표본 측정 · ④ 골든셋 운영.

스키마 = 계약서다.

"AI가 알아서" 대신 "이 필드로만". 필드 이름·타입·필수 여부·기본값·검증 규칙을 명시.

#	원칙	내용	실패 시 결과
①	타입 명시	string · number · boolean · date · enum. "적당히"는 금지.	"1,234,000" 문자열 · 계산 불가
②	필수 · 선택 구분	required 필드는 결측 시 추출 실패. 선택 필드는 null 허용.	누락을 조용히 넘김
③	enum 제한	"장비유형" 같은 필드는 사전에 허용 값 목록. 그 외 값은 "기타" 라벨.	유사 표현 난립
④	근거 필드 강제	모든 값에 source_page · source_span 필드 병행.	환각 검증 불가
⑤ ★	불확실 필드 강제	confidence: high medium low · low면 검수 자동 큐잉.	"조용한 오독" 예방

이 5원칙을 만족하면 "AI 오독"의 대부분은 확신도 low 필드로 자동 표면화. 사람은 그것만 봅니다.

1건 시연 → 10건 검증 → 100건 자동.

3단계 스케일링. 각 단계에서 중단 조건을 정하지 않으면 100건에 **50건 재작업**이 나옵니다.

STEP 1 · 시연

1건 · 사람이 스키마 완성.

- 대표 문서 1건 선택
- 사람이 정답 JSON 직접 작성
- 이것이 "골든 원본"

중단 조건.

추출 항목 · 스키마가 이 시점에 확정되지 않으면 STEP 2 금지.

STEP 2 · 검증

10건 · 표본 감사 · 오류율 측정.

- 10건 자동 추출 → 사람 전수 감사
- 필드별 오류율 표 (회사명 0% · 금액 3%)
- 오류 유형별로 프롬프트 개정

중단 조건.

필드 오류율 > 5% 있으면 STEP 3 금지 → STEP 1 재진입.

STEP 3 · 자동 ★

100건+ · 병렬 · 표본만 감사.

- 대량 병렬 (n8n · 스크립트)
- **confidence: low** 자동 큐잉
- 표본 15%만 사람 감사

중단 조건.

표본 오류율 > 5% → 즉시 중단 · STEP 2 재진입.

가장 흔한 실패 = STEP 1 · 2 없이 "바로 100건 자동". 사람이 그것을 전수 검토하다가 자동화가 무의미해집니다.

"평균 정확도"는 함정이다.

필드별 · 문서 유형별로 쪼개서 측정. 회사명 100% + 금액 82% = "평균 91%"는 실패.

필드	표본 수	일치	필드별 정확도	주요 오류 유형	다음 조치
계약 상대방	50	50	100%	—	양호
계약 금액	50	41	82%	천단위 콤마 · VAT 포함/별도 혼재	단위 필드 추가
계약 기간	50	47	94%	자동갱신 조항 오독	enum 추가
하자보수 기간	50	33	66%	별첨 조항 미스캔 · 부위별 기간 혼재	스키마 재설계
지체상금	50	45	90%	일할계산 vs 정액 혼동	enum + 근거 인용
★ 지연 이자율	50	32	64%	"연 · 월" 단위 혼동 · % vs 금액	치명 · STEP 1 재진입

골든셋 규칙

- 표본은 최소 **50**건, 계약서처럼 다양성이 큰 경우 **100**건 권장.
- 표본은 주기적으로 재구성 (분기별) — 문서 형식 변경에 대응.

실습 3-1

도면 · 점검표 추출.

Vision + 영역 지정 + 표 재구성 + 근거 인용 **4패턴** 동시 적용. 두 소재로 감을 잡습니다.

시간 · **90분** · 실습 개요

교재 실습 **3-1**의 도면 표제란 + 정비 점검표. 스키마 정의 → 프롬프트 → 추출 → 감사. 각 STEP **20~25분**.

도면 표제란 · 6필드 추출.

치수·기호 오독을 줄이는 영역 지정 + 근거 인용. 원문은 교재 실습 3-1a.

A · 스키마 (6필드)

```
{
drawing_no: string,
title: string,
scale: string,
material: string,
revision: string,
approved_by: string,
source_page: number,
confidence: enum
}
```

B · 프롬프트 요약

역할. 도면 표제란 추출 담당.

지시.

- 우측 하단 표제란만 판독 (①영역 지정)
- 6필드를 JSON으로 (②표 재구성)
- 각 값에 (도면번호 · 셀 위치) 병기 (③근거 인용)
- 확신 낮으면 confidence: low (④불확실 표기)

제약. 도면 본체의 치수·기호는 무시.

원문 프롬프트 → 교재 실습 3-1a 참조.

스캔 점검표 · 표 재구성 원칙.

병합 셀 · 체크박스 · 손글씨 코멘트 혼재. **OCR 1차 + Vision** 정제 흐름.

STEP	작업	지시 (핵심)	중단 조건
S1	1차 OCR 텍스트 확보	전용 OCR (Clova · Vision API) — 좌표 포함 raw text.	해상도 < 300 DPI 시 재스캔
S2	Vision 스키마 매핑	"열 이름 그대로 유지 · 병합 셀은 반복 기재 · 체크박스는 checked/unchecked".	필수 필드 결측 3+ 시 재실행
S3	손글씨 코멘트 정제	"손글씨는 문맥 판독. 확신 낮으면 (?) · 원본 텍스트 병기".	고유명사 오독 발견 시 재검
S4	스키마 검증	JSON Schema로 자동 validate → enum · required 위반 즉시 raise.	위반 > 5% 시 S1 재진입
S5 ★	표본 감사 (10건)	confidence:low + 필드별 오류율 표 → 프롬프트 개정 후보 목록.	평균 오류 > 5% 시 스키마 재설계

산출물

JSON 40건 + 필드별 오류율 표 + 개정 프롬프트 **v1.1**. 원문 프롬프트 · 원본 이미지 → 교재 참조.

실습 3-2

매뉴얼 · 요건 비교표.

디지털 PDF 매뉴얼에서 기술 요건 **12**항을 뽑아 경쟁 **3**사와 비교표로 만드는 실습.

시간 · 90분 · 실습 개요

교재 실습 **3-2** · 스키마 → 3사 병렬 추출 → 요건 비교표 → 겹 분석 → 차별화 카드 **3**장.

디지털 매뉴얼 · 4 STEP.

텍스트 레이어가 있는 PDF는 직접 업로드 + 스키마 지시. 표 구조 붕괴만 조심.

STEP	작업	지시 · 산출물	주의점
S1	사전 필터	표지 · 목차 · 안전 경고 페이지 제외. 실제 기술 사양 페이지 목록만.	별첨 사양 누락 주의
S2	기술 요건 12항 스키마	엔진 · 유압 · 하중 · 소음 · 배출 · 안전 · ... 12개 필드 · 단위 · 조건.	단위 명시 (kg · t · MPa)
S3	근거 인용 강제	각 값 옆에 source_page · source_line · confidence.	별첨 표 오독 다수
S4 ★	스키마 검증 + 표본 감사	JSON Schema 자동 validate · 5건 사람 감사 · 오류율 > 5% 시 S2 재진입.	단위 오독이 가장 흔함

산출물

3사 × 12항 = 36 JSON. 다음 슬라이드 요건 비교표의 입력.

건설기계 기술 요건 12항.

각 요건마다 타입 · 단위 · **enum** · 근거 필드를 사전 확정.

#	요건	타입	단위	ENUM / 범위	주의
01	엔진 출력	number	kW	50 ~ 500	HP 혼용 주의
02	엔진 배기량	number	L	3.0 ~ 15.0	cc·L 통일
03	최대 굴착 깊이	number	m	3 ~ 12	암반 조건 별도
04	유압 시스템 압력	number	MPa	20 ~ 40	bar·kgf/cm² 통일
05	작동 중량	number	t	5 ~ 100	건조중량과 구분
06	버킷 용량	number	m³	0.5 ~ 5.0	SAE 규격
07	주행 속도	number	km/h	3 ~ 40	저속·고속 병기
08	배출가스 등급	enum	—	Tier4 · Stage V · Tier3	지역별 상이
09	캐빈 소음	number	dB(A)	70 ~ 85	EN 규격
10	연비	number	L/h	15 ~ 40	부하 조건 명시
11	보증 기간	number	개월	12 ~ 60	파워트레인 별도
12 ★	텔레매틱스 · IoT	enum	—	기본 · 옵션 · 미지원	"기본" vs "옵션" 오독 다수

3사 병렬 비교 · 겹 3장.

36 JSON을 단위 정규화 + 비교표로. 우위 · 열위 · 동등을 색상 코드로 표시.

#	요건	단위	자사	경쟁 A	경쟁 B	겹 판정
01	엔진 출력	kW	225	220	210	우위
02	엔진 배기량	L	6.7	6.7	6.9	동등
03	굴착 깊이	m	6.5	7.0	7.2	열위
04	유압 압력	MPa	35	32	34	우위
05	작동 중량	t	22.5	22.8	21.9	동등
06	캐빈 소음	dB	78	74	73	열위
07	연비 (부하)	L/h	22	25	24	우위
08 ★	텔레매틱스	—	기본	옵션	옵션	우위 · 차별화

차별화 카드 3장

우위 4항 (엔진 · 유압 · 연비 · 텔레매틱스) → 제안서 첫 페이지에 배치. 열위 2항은 "용도별 최적화" 프레임으로 재해석.

계약서 3시간 → 20분.

독소 조항 **15**항 체크리스트 + 기술 요건 **12**항 스키마 + 근거 인용 강제 + 교차 검증 = 자동 추출 시스템 **1**식.

3시간 · 4 STEP · 실습 3-3 & 3-4

STEP 1 스키마 확정 · **STEP 2** 15항 체크리스트 · **STEP 3** 근거 인용 + 교차 검증 · **STEP 4** 감사 리포트.

계약서 12필드 · 근거 인용 강제.

계약서는 오류의 대가가 큰 문서. 모든 필드에 조항 번호 · 페이지 · 원문 인용을 강제.

#	필드	타입	ENUM / 형식	필수 근거
01	contract_no	string	계약번호 (표지)	표지 인용
02	parties	object[]	발주자 · 수주자 (법인명·대표자)	전문 조항
03	contract_amount	number	KRW · VAT 별도 여부	단위 필드 병기
04	contract_period	date range	시작일 · 종료일 · 자동갱신 enum	조항 번호 병기
05	payment_terms	object	선급 · 중도 · 잔금 (비율 · 시점)	계산식 병기
06	delivery_terms	object	납기일 · 장소 · 검수 기한	조항 인용
07	warranty_period	object[]	부위별 기간 · 하자보수 범위	별첨 포함
08	liquidated_damages	object	지체상금율 · 상한 · 일할·정액 enum	단위 필드 필수
09	termination_clauses	object[]	해지 사유 · 통지 기간 · 정산	복수 조항
10	confidentiality	object	범위 · 존속 기간 · 손해배상	별첨 포함
11	governing_law	string	준거법 · 관할 법원	일반 조항
12 ★	toxic_flags	array<object>	15항 체크리스트 결과 (다음 슬라이드)	조항+확신도 필수

"위험 조항"을 어휘 아니라 조건으로.

"불공정한 조항" 같은 모호 지시는 금물. 각 항은 검색 가능한 조건문으로.

#	항목	조건 (탐지 규칙)	위험도
T01	일방적 계약 해지	발주자만 "언제든", "즉시" 해지 가능 표현	■ 상
T02	지체상금 상한 부재	지체상금을 있고 "상한" 명시 없음	■ 상
T03	무제한 손해배상	"모든 손해", "간접·특별 손해 포함" 표현	■ 상
T04	과업 변경 무통보	"발주자 재량", "일방적 변경 가능"	■ 상
T05	지식재산권 전부 이전	"모든 지식재산권 · 저작권"의 "이전" · "귀속"	■ 상
T06	지연 이자 · 이자율 과다	연 15% 초과 · "월" 단위 표기 혼동	■ 중
T07	무상 유지보수 강요	보증기간 초과 후에도 "무상" 의무 조항	■ 중
T08	하자보수 상주 인력	"상주", "전담", "24시간 대기" 표현	■ 중
T09	비밀유지 존속 무제한	"영구" · "무기한" · 5년 초과	■ 중
T10	불가항력 배제	"불가항력에도 면책되지 않는다" 표현	■ 중
T11	단독 관할 · 원거리 법원	"발주자 소재지 법원 전속" · 관할 조작	■ 중
T12	지불 조건 후불 과다	"검수 완료 후 90일 초과" 지불	■ 하
T13	검수 지연 자동 승인 부재	검수 기한 지나도 "자동 승인" 조항 없음	■ 하
T14	계약 양도 금지	사전 서면 동의 없이 "일체 양도 불가"	■ 하
T15 ★	자동갱신 · 해지 통지 곤란	해지 통지 기한 > 90일 or 갱신 자동 · 알림 없음	■ 상

근거 없는 값은 환각이다.

모든 필드에 "조항 · 페이지 · 원문 인용"을 강제. 근거 없으면 필드 자체를 채우지 말 것.

A · 나쁜 예 (환각 위험)

```
{
  "contract_amount": 1234000000,
  "warranty_period": "24개월",
  "liquidated_damages": {
    "rate": 0.0015,
    "cap": null
  }
}
```

- 값만 있고 출처 없음.
- 어떤 조항에서 뽑았는지 감사 불가능.
- null 값의 근거도 없음 → 진짜로 없는지, 못 찾은 건지 판별 불가.

B · 좋은 예 (감사 가능) ★

```
{
  "contract_amount": {
    "value": 1234000000, "unit": "KRW",
    "vat": "excluded",
    "source": {"clause": "3조 1항", "page": 4},
    "quote": "본 계약의 총액은 ...",
    "confidence": "high"
  },
  "liquidated_damages": {
    "rate": 0.0015, "cap": null,
    "cap_reason": "not_found",
    "source": {"clause": "9조", "page": 11},
    "confidence": "medium"
  }
}
```

- 필드마다 **source · quote · confidence**.
- null 발생 시 이유 필드 (**not_found · unclear**).

감사자는 **quote**를 원문과 대조. 이 한 필드만 검증하면 값의 신뢰가 확립됩니다.

두 번 추출 → 불일치만 사람이.

전수 검토 대신 "AI vs AI 불일치"를 대상으로 좁힙니다. 계약서 15항에만 적용 (비용 관리).

STEP	작업	구성	산출물
X1	1차 추출 (기본 모델)	Claude 3.5 · 스키마 v1 · temperature 0	extract_a.json
X2	2차 추출 (다른 모델)	GPT-4o · 동일 스키마 · temperature 0	extract_b.json
X3	diff · 자동 비교	필드별 값 · source · confidence 비교. 3열 리포트 생성.	diff_report.md
X4	불일치 3분류	① 값 불일치 · ② 근거 조항 불일치 · ③ 한쪽만 null. ③이 가장 위험.	reviewer_queue.csv
X5 ★	사람 판정 (전수)	diff 항목만 원본 조항 대조 · 정답 결정 · gold.json 확정.	gold.json + reason

경험 규칙

불일치율 10~15%가 정상. 5% 이하면 스키마가 "쉬운 항목"만이거나 두 모델이 같은 실수. 25% 초과면 스키마 재설계.

시스템 5개 산출물.

계약서 1건 처리가 아니라 "다음 계약서에도 그대로 쓰이는 시스템"이 산출물.

01

계약서

추출 스키마 v1.0

12필드 · JSON Schema

모든 후속 처리의 계약서

02

독소 조항

15항 체크리스트

15 조건 · 위험도 3등급

법무 팀과 공동 관리 문서

03

표준 프롬프트

3층 구조

시스템 · 업무 · 데이터

6구획 템플릿 준수

04

교차 검증 절차서 + diff 리포트

2 모델 · 3분류 · 사람 결정

전수 검토 대체 · 비용 관리

05 ★

감사 리포트 (계약서별)

JSON + 리스크 순위 + 협상 카드

DAY 4 챗봇의 지식 소스로 재사용

DAY 5 워크플로우에서 "추출 노드"로 · DAY 6 에이전트의 "계약 리뷰 모듈"로 편입.

감사 리포트 · 5블록.

JSON을 사람이 읽는 리포트로. 협상 담당자가 5분 안에 위험을 파악.

블록	제목	내용	독자
B1	1줄 결론	"위험 조항 3건 · 협상 필요 5건 · 즉시 서명 가능"	임원
B2	위험 조항 요약표	15항 중 발견된 항목 · 조항 번호 · 위험도 · 협상 우선순위	협상 담당자
B3	필드별 상세 (12필드)	각 필드 · 값 · 조항 인용 · confidence · 협상 여지	법무 · 협상
B4	협상 카드 3장	"양보 가능 · 조건 교환 · 절대 불가"의 현재 포지션 정리	협상 담당자
B5 ★	감사 부록	confidence:low 항목 목록 · diff 결과 · 사람 결정 근거 · 검수자 서명	감사 · 사후 검증

B5(감사 부록)가 있어야 리포트는 "의견"이 아닌 "근거 있는 결정"이 됩니다. 훗날 감사에 대비.

3시간 → 20분.

계약서 1건 · 근거 인용 100% · 위험 조항 15항 표면화 · 협상 카드 3장. 문서 유형이 바뀌어도 스키마. 프롬프트.검수 절차는 그대로 재사용.

01 추출 스키마 v1.0 + 15항 체크리스트 12 필드 · 15 조건 법무 · 협상 공동 관리	02 표준 프롬프트 + 근거 인용 강제 6구획 · 3층 · 조항 인용 환각 없는 값 · 감사 가능	03 교차 검증 절차서 2 모델 · diff · 3분류 전수 검토를 표적 검수로	04 ★ 감사 리포트 5블록 + 협상 카드 결론 · 요약 · 상세 · 협상 · 부록 DAY 4 챗봇 · DAY 5 노드
---	---	---	---

이 산출물 세트가 DAY 5 워크플로우의 "추출 노드"로, DAY 6 통합 에이전트의 계약 리뷰 모듈로 편입.

"치수 1.85 → 185로 뽑았다."

S사(부품 제조) · 도면 표제란 재료 사양의 **소수점 인식 실패**. 재료 두께 100배 오독으로 견적 실패.

단계	배경 · 문제	조치	결과 · 교훈
배경	도면 200장/일 자동 추출.	Vision 단독 · 영역 지정 없음. "표제란만 추출"로 지시.	평균 정확도 92% — 착각.
문제	"1.85mm" 소수점 인식 실패.	185mm로 자동 저장 → 견적 100배 왜곡.	한 건에 3천만원 손실.
조치	단위·범위 필드 추가.	스키마에 <code>unit:enum · value:{min,max} · confidence</code> . 범위 초과 시 자동 raise.	
결과	오독 4.2% → 0.3%.	범위 벗어난 값은 <code>confidence:low</code> 로 자동 큐잉.	사람은 low 만 검수.
교훈 ★	"평균 정확도"에 속지 말 것. 필드별 · 값의 크기별로 범위 검증 을 스키마에 내장. 소수점·단위 오독은 한 건이 전체 이익을 지운다 .		

"자동갱신 90일 통지" 놓쳤다.

T사(장비 OEM) · 계약 5건 중 1건이 **별첨의 갱신 조건**. 본문만 스캔해서 15항 T15 미탐지.

Before · 본문만 스캔

"본문 30페이지"만 추출 대상.

- 별첨 A~C (총 45p) 추출 제외 (비용 절감 목적).
- 계약 5건 중 1건 · 갱신 조건이 별첨 B에 은닉.
- 자동갱신 알림 놓쳐 3년 재계약 강제 · 협상 기회 상실.

After · 별첨 강제 스캔

전체 페이지 · 필터 후 병렬.

- 별첨 = 본문과 동등 처리 원칙.
- 별첨 목차에 "갱신 · 해지 · 통지" 키워드 있으면 필수 스캔 페이지로 승격.
- T15 항목은 본문 + 별첨 전체 검색. 조항 여러 곳에 흩어져 있어도 모두 수집.

교훈

비용 절감 명분으로 **"별첨 제외"** 하지 말 것. 대신 목차 키워드 기반 스캔 페이지 선별을 자동화.

"영·한 병기 계약, 뭐가 원본?"

U사(해외 수주) · 영문·한글 병기 계약. 두 버전이 **미묘하게 다른 값**. 어느 언어를 추출해야 하나?

필드	한글판 (조항)	영문판 (CLAUSE)	불일치 여부	해결
계약 금액	USD 1,200,000 (VAT 별도)	USD 1,200,000 (VAT included)	■ 불일치 · 치명	영문 우선 조항 확인
계약 기간	36개월	36 months	■ 일치	문제 없음
지체상금	일 0.15%	0.15% per day	■ 일치	—
준거법	대한민국법	Laws of Singapore	■ 불일치 · 치명	원본 언어 확인
★ 우선 조항	"본 계약은 한국어를 우선"	"English version shall prevail"	■ 모순 · 최상 위험	별도 협상 이슈

교훈

- 다국어 계약은 각 언어를 별도 추출 · 필드별 diff 리포트를 감사 리포트에 포함.
- **"우선 조항"**이 존재하는지 최상위 확인 항목. 없으면 협상 필수.

"API 비용 월 \$18,000 청구서."

V사 · 매뉴얼 5,000장 · 교차 검증 무차별 적용. 3단계 필터로 \$18K → \$2.4K 감축.

단계	조치	BEFORE	AFTER	감축
①	사전 페이지 필터	전 페이지 스캔 (5,000장)	사양 페이지만 (1,800장)	-64%
②	계층 처리	전건 Vision 고비용 모델	1차 저비용 → 저확신만 재추출	-70%
③	교차 검증 표적화	전건 2회 추출	계약서 · 위험 문서만 2회	-50%
④	결과 캐시	동일 문서 반복 재추출	파일 해시 기반 캐시	-15%
계 ★	누적 효과	\$18,000 / 월	\$2,400 / 월	-86.7%

교훈. "정확도"만 최적화하지 말 것. 대량 처리는 비용 3원칙(필터 · 계층 · 캐시)을 스키마와 함께 설계.

추출 파이프라인용 10종.

6구획 구조 · 파이프라인 5단계에 매핑 · 원문 → 교재 **PART 03 §10.**

#	템플릿 ID	단계	주요 산출물	검수 포인트
①	공통_시스템계층_v2.0	전 단계	역할 · 검수 · 근거 원칙	미제공 정보 처리
②	추출_문서분류_v1.0	진단	유형·경로 결정표	텍스트 레이어 확인
③	추출_영역지정_v1.0	Vision	표제란 · 영역 필드	좌표 · 셀 위치
④	추출_표재구성_v1.0	Vision	병합 셀 · 헤더 유지	체크박스 enum
⑤	추출_스키마매핑_v1.1	구조화	JSON · 5원칙 준수	required · enum · 근거
⑥	추출_근거인용_v1.0	구조화	source · quote · confidence	quote 원문 대조
⑦	추출_계약서스키마_v1.0	계약서	12필드 · 15항 체크리스트	별첨 포함 스캔
⑧	추출_교차검증_v1.0	검증	2 모델 · diff 리포트	불일치 3분류
⑨	추출_감사리포트_v1.0	보고	5블록 · 협상 카드 3장	감사 부록 필수
⑩ ★	추출_골든셋운영_v1.0	검증	50~100건 · 필드별 오류율	분기별 재구성

가상 계약서 · 45페이지 · 별첨 3.

STEP 1: 스캔 전에 문서 진단표를 만듭니다. 무엇을 어떤 경로로 뽑을지 확정.

부	부문	페이지	텍스트 레이어	경로	비고
01	표지	1	있음	직접 · contract_no만	필드 01
02	전문 · 당사자	2 ~ 3	있음	직접 · 스키마 v1	필드 02
03	본문 (조항 1~35)	4 ~ 30	있음	직접 · 12필드 + 15항	교차 검증 대상
04	별첨 A (품목 사양)	31 ~ 36	있음 (표)	표 재구성 패턴	기술 요건 필드
05	별첨 B (지불 · 갱신)	37 ~ 41	있음	직접 · T12 · T15 검색	위험 조항 은닉
06 ★	별첨 C (기술 표준 스캔)	42 ~ 45	없음 · 스캔본	OCR + Vision 정제	해상도 확인

이 표가 없으면 별첨 B의 자동갱신 · C의 기술 표준이 조용히 빠집니다. 사례 B와 동일한 실패.

1건 · 사람이 골든 JSON.

담당자가 대표 계약서 1건을 직접 채워봅니다. 이 시점에 스키마 · 필드 · enum 확정.

골든 원본 · 발췌

```
{
  "contract_amount": {
    "value": 1234000000,
    "unit": "KRW",
    "vat": "excluded",
    "source": {"clause": "3조 1항", "page": 4},
    "quote": "본 계약의 총액은 ...",
    "confidence": "high"
  },
  "warranty_period": [{
    "scope": "주요 부품",
    "months": 24,
    "source": {"clause": "11조 별첨A", "page": 33}
  }, {
    "scope": "소모품",
    "months": 6,
    "source": {"clause": "11조 별첨A", "page": 33}
  }]
}
```

확정 스키마 규칙 (엄격)

- R1. 모든 금액 필드는 {value, unit, vat} 객체.
- R2. 기간 · 범위 필드는 배열. 부위별 별개 값이 자주 나옴.
- R3. 모든 값에 source(조항+페이지) + quote(원문 25자 이상).
- R4. null 필드는 reason: "not_found" | "unclear".
- R5.confidence: high | medium | low.low 필드는 자동으로 검수 큐잉.

이 골든 JSON = 이후 자동 추출의 채점 기준. STEP 2 이후로 스키마 변경은 v2로 승격.

3회 반복 · 골든 대비 오차 표.

스키마 · 프롬프트 · 감사 절차의 3회 개정을 통해 골든 대비 오차를 허용 범위 내로.

회차	스키마	전체 정확도	주요 오류 유형	개정 결정
R1	v1.0	76.4%	VAT 포함/별도 혼동 · 별첨 A 필드 결측	R2: VAT enum · 별첨 강제 스캔
R2	v1.1	89.1%	지연 이자율 "월/연" 단위 혼동 · 하자보수 부위별 미분리	R3: 이자율 단위 필드 · 배열 강제
R3 ★	v1.2	96.7%	남은 3.3% = confidence:low로 자동 큐잉. 사람은 이 6건만 검수.	배포 승인

회차 개정의 규칙

- ① 오류 유형별 그룹핑. 한 회차에 1~2 유형만 개정 — 여러 개 동시 개정 시 어느 개정이 효과 있었는지 판별 불가.
- ② 골든 JSON은 회차마다 재검토. 프롬프트가 정교해지면 골든의 부실도 드러남 → 골든도 v2로 승격.
- ③ 종료 기준. 정확도 95%+ · 남은 오류가 전부 confidence:low에 잡히면 배포.

이 계약서 · 위험 3건 발견.

15항 체크리스트 결과. 상 3건 → **협상 필수**, 중 2건 → 협상 여지, 하 없음.

#	항목	조항 · 페이지	위험도	원문 인용 (요약)	협상 방향
T02	지체상금 상한 부재	17조 · p.19	■ 상	"지연 시 일 0.15% ... 상한 언급 없음"	상한 도입 (계약금 10%)
T05	지식재산권 전부 이전	22조 · p.24	■ 상	"납품 결과물의 모든 저작권은 발주자에게 귀속"	사용권 라이선스로 조정
T15	자동갱신 (별첨 B)	별첨 B · p.38	■ 상	"만료 90일 전 서면 통지 없으면 3년 자동갱신"	통지 기간 30일로 · 캘린더 알림
T06	지연 이자율 12%	17조 · p.19	■ 중	"연 12%" (한도 상한 초과 아님)	현행 유지 (범위 내)
T11 ★	관할 · 발주자 소재지 전속	29조 · p.28	■ 중	"본 계약의 관할 법원은 발주자 본점 소재지 지방법원의 전속 관할"	중재 조항 추가 · 국제 계약

임원용 1페이지 · 협상용 5페이지.

B1 결론 + B2 위험표는 임원용 1페이지 요약. 나머지는 협상 담당자 전용 부록.

B1 · 결론 1줄

"위험 3 · 협상 필수 · 조건 조정 후 서명"

B2 · 위험표 3항

- T02 지체상금 상한 부재 (17조)
- T05 지식재산권 전부 이전 (22조)
- T15 자동갱신 (별첨 B)

권고. 협상 담당자 배정 · 3일 내 개정 요청 문서 발송.

B3~B5 · 부록 5페이지

B3 상세 필드 12항
· 각 필드 값 · 조항 인용 · confidence · 협상 여지 (양보/조건/불가)

B4 협상 카드 3장
· T02: 상한 도입 → 발주자에게도 유리 (예측 가능성)
· T05: 사용권 라이선스 조정 → 저작권 유지 · 사용 무제한
· T15: 통지 기간 30일 · 상호 알림

B5 감사 부록
· confidence:low 6건 (사람 검수 완료)
· 교차 검증 diff (Claude vs GPT-4o)
· 검수자 서명 · 검수 일시 · 추출 스키마 버전

임원은 B1+B2 1페이지만 봅니다. 협상 담당자는 전체. 두 청중을 하나의 리포트로 · 종이 낭비 없이.

"글자가 있는데 못 읽는다."

Vision 층 · 6유형 · 증상 · 1차 대책. 이미지 품질부터 확인.

#	유형	증상	1차 대책
①	해상도 부족	300 DPI 미만 스캔 · 소수점 · 첨자 오독	재스캔 · 확대 후 조각별 스캔
②	스큐 · 회전	기울어진 스캔 · 표 열이 어긋남	사전 이미지 정렬 (deskew)
③	병합 셀 분해 실패	병합된 헤더 셀이 첫 행에만 채워짐	"병합 셀 반복 기재" 지시
④	체크박스 오독	체크된 것과 안 된 것이 뒤바뀜	enum: checked/unchecked/unclear
⑤	긴 문서 후반 누락	30페이지 후반 조항 · 별첨이 응답에서 사라짐	페이지 청킹 · 반복 스캔 (⑤)
⑥ ★	환각 (없는 값 생성)	문서에 없는 값을 그럴듯하게 채움	근거 인용 강제 (③) · quote 대조

"JSON은 예쁜데 쓸 수가 없다."

문법은 맞지만 스키마 계약 위반. 6유형 · 자동 검증(JSON Schema)으로 잡습니다.

#	유형	증상	대책
①	필수 필드 결측	required 필드가 null · 사유 없이	JSON Schema validate · raise
②	enum 위반	"장비유형: 기타굴착기" (사전에 없음)	enum 강제 · "기타" 옵션 별도
③	타입 불일치	number 필드에 "1,234,000" (кома 문자열)	타입 강제 · 자동 파싱
④	단위 필드 누락	"amount: 1200" — USD? KRW? m³?	amount + unit 객체 강제
⑤	근거 필드 위조	quote 필드에 조항 원문이 아닌 요약	quote 최소 25자 · 원문 대조 자동
⑥ ★	confidence 위조	모두 "high"로 응답 (사용자 신뢰 이용)	교차 검증에서 low로 교정

스키마 층 오류는 자동 검증으로 대부분 잡힘. JSON Schema · Pydantic 등 도구 사용을 파이프라인 필수 단계로.

"감사자가 감사를 못 한다."

추출은 잘 됐지만 확인 · 재현 · 추적이 안 되는 경우. 5유형.

#	유형	증상	대책
①	골든셋 부재	"평균 정확도 92%" 주장 · 근거 데이터 없음	골든 50~100건 · 분기별 갱신
②	필드별 오류율 미측정	회사명·금액이 같은 92%로 취급됨	필드별 표 · 위험 필드 별도
③	버전 관리 부재	스키마 v1인지 v2인지 · 언제 개정됐는지 모름	MAJOR.MINOR 버전 필드 · 로그
④	검수자 서명 부재	confidence:low 항목의 사람 판정 근거 없음	reviewer + reason + 시각 필수
⑤ ★	재현 실패	동일 문서를 다시 넣었을 때 다른 결과 (temperature > 0)	temperature=0 · seed 고정 · 로그

"규칙"과 "AI"를 함께 쓴다.

정규식 · 룰이 잘 맞는 필드는 규칙으로, 문맥 판단이 필요한 필드는 AI로. 하이브리드 6원칙.

#	필드 유형	1차 도구	2차 (검증)	비고
①	계약 번호 · 날짜	정규식	AI (문맥 확인)	규칙 강함
②	금액 · 단위	정규식 + AI 정제	AI (VAT 포함 여부)	단위 오독 다수
③	당사자 · 대표자	AI (문맥 필요)	DB 대조 (사업자번호)	외부 시스템 연동
④	기술 사양 (표)	AI (표 재구성)	범위 검증 (규칙)	단위 정규화 필수
⑤	독소 조항 15항	키워드 검색 (규칙)	AI (문맥 판정)	둘 다 필요
⑥ ★	협상 카드 3장	AI (판단)	사람 (최종 결정)	AI 단독 금지

규칙이 잘 되는 필드에 AI 쓰지 말 것 (비용·재현성) · 반대로 문맥 판단에 규칙만 쓰지 말 것 (재현성 대신 정확도 손실).

"원본 언어"를 필드로.

해외 계약 · OEM 매뉴얼 · 병기 문서. 각 필드에 원본 언어 · 번역본 여부를 기록.

A · 원본 언어 필드

```
{
  "contract_amount": {
    "value": 1200000, "unit": "USD",
    "source_language": "en",
    "has_translation": true,
    "translation_diff": false,
    "quote_en": "The total value shall be...",
    "quote_ko": "본 계약의 총액은..."
  }
}
```

- 언어별 원문을 모두 저장.
- translation_diff: true면 사람 검수.

B · 다국어 4원칙

- R1. 원본 언어 확인 우선. "우선 조항"(prevail clause) 존재 여부를 최상위로.
- R2. 언어별 별도 추출. 한 언어를 다른 언어로 번역해 뽑지 말 것 — 원문 각각을.
- R3. 필드별 diff. 언어별 값이 다르면 감사 리포트 위험 항목.
- R4. 문자 인코딩 통일. UTF-8 · NFC 정규화. "미쓰비시" vs "미츠비시" 표기 통일.

번역이 필요할 때는 "원본을 뽑고 나서 번역" — 번역 후 추출하면 원문의 뉘앙스가 소실됩니다.

계약서는 3등급 이상이다.

DAY 1 §18 등급표 준수. 계약서 · 견적 · 하자 데이터는 마스킹 후 투입 or 자체 호스팅.

등급	데이터 예시	클라우드 API	자체 호스팅 (n8n)	마스킹 정책
1 · 공개	RFP · 공고문 · 카탈로그	■ 허용	■ 허용	불필요
2 · 내부	회의록 · 내부 매뉴얼	■ 허용	■ 허용	담당자명 마스킹
3 · 대외비 ★	계약서 · 견적 · 원가 · 전략	▲ 마스킹 후만	■ 권장	치환 · 범위 · 구조 분리
4 · 개인정보	주민번호 · 계좌 · 개인 사진	■ 불가 (원본)	▲ 마스킹 후만	필수 마스킹
5 · 핵심기술 ★	특허 미출원 도면 · 코어 알고리즘	■ 절대 불가	■ 자체 호스팅만	투입 자체 검토

가장 흔한 실수

계약서 PDF를 "공개 SaaS 챗봇"에 업로드. 상대 회사명 · 금액 · 조항이 모두 학습 데이터 후보로 유입. **DAY 5**의 자체 호스팅 워크플로우가 정답.

"밤에 돌리고 아침에 본다."

대량 처리는 시간 · 병렬 · 재시도의 3축으로. 각 축의 상한을 사전 확정.

#	파라미터	기본값	주의점	영향
①	병렬 워커 수	3~5 (rate limit 여유)	벤더 rate limit (RPM · TPM)	시간 vs 안정성
②	재시도 정책	지수 백오프 · 최대 3회	429 · 500 · 스키마 위반 구분	누락 방지
③	temperature	0.0 (강제)	추출은 창의성 요구 없음	재현성 필수
④	max_tokens · context	문서 페이지 수에 맞춰	긴 문서 → 청킹 필수	context 초과 시 침묵 오류
⑤	비용 한도 (일일)	사전 알림 임계	\$100/일 초과 시 자동 중단	청구서 폭발 예방
⑥ ★	배치 스케줄	야간 (00:00~06:00)	일부 벤더 야간 할인 (~50%)	비용 감축 · 처리 안정

DAY 5 워크플로우에서 스케줄 트리거 · 재시도 노드 · 비용 감시 노드로 구현. 오늘의 스키마 + 프롬프트가 그때 노드로 그대로 편입.

신규자 · 60분 · 자율 실행.

신규 담당자가 **60분 안에** 스키마 · 프롬프트 · 검수 절차를 이해하고 **1건을 자율 실행**할 수 있는가.

#	체크 항목	통과 기준	담당
□ 01	스키마 v1.2 문서화	JSON Schema + 필드별 설명 + enum 근거	전임자
□ 02	골든셋 50건	필드별 오류율 표 · 최근 3개월 데이터	전임자
□ 03	프롬프트 라이브러리 v1.0	10 템플릿 · 개정 이력 · 담당자 · 사유	전임자
□ 04	15항 체크리스트	위험도 · 검색 조건 · 법무팀 서명	공동
□ 05	감사 리포트 3건 시연	전임자가 신규자 앞에서 3건 완주 시연	전임자 시연
□ 06	신규자 1건 자율	가상 계약서 1건 · 감사 리포트 5블록 · 60분 내	신규자
□ 07	이상 케이스 노트	전임자가 만난 예외 처리 · 6개월치	전임자
□ 08 ★	에스컬레이션 규칙	신규자가 판단 못 할 때 누구에게 · 어느 조건인지 성명 목록.	필수

오늘의 산출물 → 워크플로우 4 노드.

DAY 5(주황)에서 자동 트리거로 연결. 스키마 · 프롬프트 · 검수 · 리포트가 각각 노드로.

노드	이름	입력	DAY 3 산출물	다음 노드로
N1	Trigger · 파일 감시	공유 폴더 · S3 · 메일 첨부	문서 유형 진단표	경로별 N2 분기
N2	Extract · Vision	문서 · 스키마 · 프롬프트	스키마 v1.2 · 프롬프트 3층	JSON → N3
N3	Validate · 자동 검증	JSON · Schema	JSON Schema · 규칙	위반 시 재시도 / N4
N4	Toxic Scan · 15항	JSON	15항 체크리스트	위험 발견 → 사람 큐잉
N5 ★	Report · 감사 리포트	JSON + 15항 결과	감사 리포트 5블록 템플릿	메일 · 슬랙 · DB 저장

계약서 폴더 투입 → 30분 후 감사 리포트 메일. DAY 5에서 이 5노드가 한 시나리오로 완성.

"정확도"보다 4개 지표.

Precision · Recall · F1 · **Calibration**. 한 숫자로 요약하지 말 것.

01 · Precision

뽑은 것 중 맞은 비율

$TP / (TP + FP)$

낮으면 **환각 · 과추출**.
계약서에는 **Precision** 우선.

02 · Recall

있는 것 중 뽑은 비율

$TP / (TP + FN)$

낮으면 **누락 · 별첨 미스캔**.
독소 조항 15항은 **Recall** 우선.

03 · F1

Precision × Recall 조화

$2 \cdot P \cdot R / (P + R)$

균형 지표 · 하지만 **단일 요약에 속지 말 것**. Precision/Recall을 함께 봅니다.

04 · Calibration ★

confidence == 실제 정확도?

confidence:high 필드의 실제 정확도가 > 95%인가?
low가 실제로 낮고 **high**가 실제로 높아야 "검수 큐잉"이 신뢰 가능.

네 지표를 필드별 · 문서 유형별로 나눠 대시보드로, 분기마다 갱신 · 개정 트리거로 사용.

"오늘 배운 걸 복제할 수 있나?"

각 항목 5점 척도. **3점** 이하는 교재 해당 대단원으로 즉시 복귀.

#	항목	통과 기준 (4점 이상)	교재 복귀	자가 점수
A1	문서 5유형 · 각각의 추출 경로를 말할 수 있다	D1~D5 · OCR·Vision·직접	§06 문서 진단	☐ ☐ ☐ ☐ ☐
A2	멀티모달 6패턴을 예로 설명할 수 있다	영역·표·근거·불확실·반복·교차	§08 6패턴	☐ ☐ ☐ ☐ ☐
A3	JSON 스키마 5원칙을 이유와 함께 말할 수 있다	타입·필수·enum·근거·불확실	§11 5원칙	☐ ☐ ☐ ☐ ☐
A4	1 → 10 → 100 배치 전략의 중단 조건을 설계할 수 있다	필드별 5% 임계	§12 배치	☐ ☐ ☐ ☐ ☐
A5	15항 체크리스트를 조건문 3개 이상 만들 수 있다	T02 · T05 · T15	§23 15항	☐ ☐ ☐ ☐ ☐
A6	감사 리포트 5블록을 이름 없이 재현할 수 있다	결론·요약·상세·협상·부록	§27 감사	☐ ☐ ☐ ☐ ☐
A7 ★	BIG WIN 5 산출물을 자기 부서 문서로 재구성할 수 있다	스키마· 15항 ·프롬프트·검증·리포트	§28 DAY 3 BIG WIN	☐ ☐ ☐ ☐ ☐

현장에서 가장 많이 나오는 질문 5.

답의 근거는 교재 참조. 여기는 판단 방향만.

Q1

Vision과 OCR 중 뭘 먼저 배워야 하나?

둘 다. 대량·정형(점검표·인쇄)은 OCR, 소량·비정형(도면·손글씨·계약서)은 Vision.
실무는 하이브리드.

Q2

계약서를 챗봇에 그냥 붙여넣으면 안 되나?

3등급 이상 · **공개 SaaS 금지**. 마스킹 후 · 또는 **DAY 5** 자체 호스팅 워크플로우.

Q3

"평균 정확도 90%"면 충분한가?

아니오. **필드별 · 문서 유형별**로 쪼갬. 필드 하나의 66%가 전체 90%에 숨어 사고를 냅니다.

Q4

추출 정확도가 오르지 않을 때는?

1) 이미지 품질 · 2) 스키마 5원칙 위반 · 3) 프롬프트 6패턴 미적용. 이 순서로 점검.

Q5 ★

"AI 추출 결과"의 법적 효력은?

AI 추출 결과는 "검토 보조 자료". 법적 효력은 원본 계약서에서 나옴 — 그러나 근거 인용 강제 + 감사 리포트 부록이 있으면 검수 담당자의 검토를 문서화한 내부 감사 자료가 됨.
결정은 항상 사람 담당자 서명으로 · AI는 감사를 돕는 도구.

10문항 · 4점 이상이면 DAY 4로.

정답 · 해설은 교재 부록 A. 여기는 문항만.

A · 개념 (Q1~Q5)

Q1. 문서 진단 2축과 5유형을 설명하시오.

Q2. 멀티모달 6패턴 중 "비용 낮음" 4가지와 "비용 높음" 2가지를 구분.

Q3. JSON 스키마 5원칙 각각의 실패 시 결과를 매칭.

Q4. 1 → 10 → 100 배치의 중단 조건 3개.

Q5. Precision · Recall · F1 · Calibration의 정의.

B · 적용 (Q6~Q10) ★

Q6. "치수 1.85mm → 185"의 원인·대책 3단계.

Q7. "본문 30p · 별첨 45p" — 자동갱신 놓치지 않으려면?

Q8. 다국어 계약 · "우선 조항" 없을 때의 대응.

Q9. API 비용 폭발 시 3원칙(필터 · 계층 · 캐시) 적용 순서.

Q10. 감사 리포트 B5(감사 부록)에 반드시 포함해야 할 4가지는?

4점 미만 · 교재의 해당 대단원을 다시 → 실습 로그 재작성 → DAY 4 진입.

4개 실습 · 산출물 · 검수.

교재 실습 기록지 양식에 그대로 옮겨 · 팀 리뷰 · 리포지토리 커밋.

ID	실습명	스키마 · 프롬프트	산출물	검수 포인트
3-1	도면 · 점검표 추출	6필드 스키마 + 4패턴 프롬프트 (영역·표·근거·불확실)	JSON 40건 + 필드별 오류율 표	confidence:low 우선 검수
3-2	매뉴얼 · 요건 비교표	12필드 · 3사 병렬 · 단위 정규화	36 JSON + 비교표 + 차별화 카드 3장	단위 오독 우선 검수
3-3 ★	계약서 스키마 확정	12필드 + 15항 체크리스트 + 근거 인용 강제 스키마 v1.2 + 골든 원본 1건		R1~R5 규칙 준수
3-4 ★★	자동 추출 시스템 완성	3-1 · 3-2 · 3-3 산출물 + 교차 검증 절차	감사 리포트 5블록 + 협상 카드 3장 (계약서 3건)	신규자 60분 재현 · 결과 일치

DAY 4 · Preview

RAG 기반 사내 지식 자산화.

다루는 문제

문서 → "조직이 질문할 수 있는 지식".

- 청킹 · 임베딩 · 검색 · 리랭킹 · 생성
- NotebookLM · Claude Projects · Custom GPT
- 근거 인용 필수 · 환각 최소화

DAY 4 BIG WIN ★

사내 기술 지원 챗봇
+ 운영 규칙.

- SOP 답변 에이전트 → 기술 지원 챗봇 확장
- 골든 질문 세트 검증
- 에스컬레이션 규칙 · 운영 수칙

DAY 3의 구조화된 **JSON**이 DAY 4의 청킹 친화적 지식베이스가 됩니다.

비정형 문서가 데이터가 되는 조건.

스키마 없이 뽑은 값은 데이터가 아닙니다.
근거 인용 없는 값은 신뢰가 아닙니다.

DAY 3 · 완료 · Next: DAY 4 · RAG & 지식 챗봇