

Vibe Coding 기반 빅데이터 분석 자동화

코드를 직접 작성하지 않고 자연어 명세로 분석 스크립트를 생성·실행·개선.
오늘의 결과물은 자기 부서 데이터에 재사용 가능한 자동 분석 스크립트 패키지.

Ph.D 이해본 / 한신대학교 AI.SW대학 (aebon@hs.ac.kr)

PART

02 / 08 · DAY 2

Duration

8시간 · 이론 2H + 실습 6H

★ BIG WIN

재사용 자동 분석 스크립트 패키지

어제의 표준 프롬프트 위에서 코드로 확장.

DAY 1이 세운 조직의 언어 표준을 데이터 분석 스크립트 자동화로 확장합니다. 오늘의 BIG WIN은 DAY 6 에이전트의 분석 모듈이 됩니다.

일차	BIG WIN	함께 남는 자산	DAY 6에서의 자리
DAY 1	제안서 초안 + 예산안 산출표	표준 프롬프트 · 거버넌스 체크리스트	표준 프롬프트 계층
DAY 2	재사용 분석 스크립트 패키지 ★	데이터 사전 · 차트 세트 · 해석 규율	분석 모듈
DAY 3	계약서 자동 추출 시스템	판단 규칙 15항 · JSON 스키마 · 검수 절차	입력 처리 모듈
DAY 4	기술 지원 챗봇 + 운영 규칙	지식베이스 · 골든 질문 세트	지식 모듈
DAY 5	무인 주간 보고 워크플로우	4계층 캔버스 · AI 노드 표준	실행 · 연결 계층
DAY 6	통합 AI 업무 에이전트	ROI 보고 · 90일 로드맵	최종 결합

Read · 오늘의 스크립트 패키지가 없으면 DAY 5 워크플로우의 "분석 노드"에 채울 것이 없습니다. 그래서 DAY 2가 이 자리에 있는 것입니다.

오늘 끝나면 이 여섯 가지를 할 수 있어야 합니다.

- ① 분석 파이프라인 5단계에서 **AI가 대체하는 구간**과 **사람이 검증해야 하는 구간**을 구분합니다.
- ② 바이브 코딩의 **반복 루프**(명세→생성→실행→검증→개선)와 명세 프롬프트 패턴을 적용합니다.
- ③ 결측치·이상치·형 변환 포함 **전처리 스크립트**를 자동 생성하고 타당성을 검증합니다.
- ④ 전사 **KPI·운영** 지표를 **목적에 맞는 차트**로 시각화하고 경영 보고 수준으로 다듬습니다.
- ⑤ 상관·회귀 분석을 수행하고 "**상관은 인과가 아니다**" 원칙 아래 결과를 해석·보고합니다.
- ⑥ 파라미터화·문서화를 거쳐 **재사용 가능한 분석 스크립트 패키지**를 구성합니다.

8시간, 네 블록으로 갑니다.

오전은 파이프라인·바이브 코딩 루프·명세 패턴을 확립하고, 오후는 정비이력 데이터로 전처리→시각화→상관분석→패키지화까지 순차적으로 밀어붙입니다.

#	블록	시간	내용	산출물
01	이론 1 데이터 사이언스 워크플로우	1H	분석 파이프라인 5단계 · 실행 환경 비교 · AI 대체 구간	환경 선택 기준
02	이론 2 Vibe Coding 기법	1H	반복 루프 · 명세 프롬프트 3요소 · 오류 개선 요령	명세 프롬프트 패턴
03	실습 1 전처리 · 시각화	3H	실습 2-1 데이터 사전·품질진단·처리방침 · 실습 2-2 차트 10종	전처리 스크립트 · 차트
04 ★	실습 2 · BIG WIN 상관분석 + 패키지화	3H	실습 2-3 상관·회귀 · 실습 2-4 파라미터화·README·재현 테스트	스크립트 패키지 ★

"AI가 만든 그럴듯한 차트"를 검증 없이 보고서에 실는 사고, 막을 방법이 있습니다.

이 파트에서 다룰 것

분석 파이프라인 5단계에서 AI가 대체할 수 있는 구간과 사람이 책임져야 하는 구간을 구분합니다.
구분이 없으면 자동화가 사고를 키웁니다.

분석 파이프라인 5단계 · 대체 vs 책임.

AI가 대체하는 것은 코드와 초안. 사람이 책임지는 것은 분석 질문 설계와 도메인 검증.

단계	내용	AI가 대체	사람이 책임
01	수집	원천 확보·통합, 형식 변환 코드	출처·권한·등급 판단
02 ★	전처리	결측·이상치·형 변환·파생변수 처리 코드 생성	처리 방침 결정 (삭제 vs 대체, 오류 vs 실사건)
03	분석	집계·상관·회귀·세분화 · 분석 코드와 수치 산출	분석 질문 설계와 해석
04	시각화	차트 코드 · 스타일링 전체	차트 유형과 강조점 선택
05	보고	요약·시사점 서술 · 초안 작성	결론과 의사결정 책임

데이터 사전이 열쇠
전처리 진입 전 데이터 사전(각 열의 의미·단위·허용 범위·결측 표기)을 먼저 확정 — AI에게 데이터 맥락을 전달하는 가장 압축적 수단. 실습 2-1의 첫 단계입니다.

어디에서 코드를 돌릴 것인가.

탐색은 대화형에서, 보존·운영은 **노트북/로컬**에서. 파일로 저장된 스크립트만이 자산입니다.

Runtime 01

대화형
내장 실행

ChatGPT Code Interpreter · Claude 분석 도구

진입 장벽 최저 · 파일 업로드만으로 즉시 실행

Limit
파일 크기 · 실행 시간 · 세션 유지 제한. **탐색 단계용.**

Runtime 02

노트북 실행

Google Colab · Jupyter

파일 보존 가능 · 재실행 용이 · 라이브러리 확장

Sweet spot
대부분의 자동화가 이 자리. **DAY 2** 실습의 기본 환경.

Runtime 03 ★

로컬 실행

사내 서버 · 개인 노트북

데이터 외부 반출 없음 · **3등급 이상 필수**

Pattern
코드는 밖에서 만들고 실행은 안에서 — 사전+가상표본만 AI에 제공.

표준 경로 — ① 대화형에서 로직 완성 → ② 노트북으로 이식·확장 → ③ 필요 시 로컬로 이전. **환경이 넘어갈 때마다 재현성 점검.**

문법을 배우는 대신 명세와 검증을 배웁니다.

Vibe Coding · 한 문장 정의

자연어 명세로 코드를 생성하고, 실행 결과를 보며 대화로 개선하는 반복 루프 — 코드를 짜는 것이 아니라 코드에게 원하는 것을 지시하고 검증하는 방식.

5박자 리듬 · 개선이 곧 사이클의 심장.

한 번에 완성하려 하지 말고 **3~5회 짧게** 반복. 매 사이클 결과를 검증하고 다음 명세에 반영합니다.

Beat 01

01

명세
Spec

데이터 사전 · 처리 방침 · 출력
정의를 문장으로.

Beat 02

02

생성
Generate

AI가 코드 초안을 산출. 코드는
읽는 것이 아니라 실행할 것.

Beat 03

03

실행
Run

즉시 실행. 중간 결과 출력을
항상 요구하여 검증 여지를
확보.

Beat 04

04

검증
Verify

기준값 대조 · 로그 확인 · 표본
검산. 조용한 오류가 여기서
잡힘.

Beat 05 ★

05

개선
Improve

오류 메시지 전문을 그대로
붙여넣기. 최고의 개선 지시.

함정 — "대화 속 결과는 자산이 아닙니다." 세션 종료로 소멸하며 재현·이관 불가. **완성된 코드는 반드시 파일로 저장하고 이후에는 그 파일만 실행**합니다.

명세 프롬프트 3요소.

이 셋 중 하나가 비면 AI는 임의로 채웁니다 — 그럴듯하지만 검증 불가능한 코드가 나옵니다.

Element 01

데이터 사전

Data dictionary

각 열의 의미 · 단위 · 허용 범위 · 결측 표기

없으면 발생하는 문제

"RT"를 **Repair Time**으로 잘못 확정 → 이후 전 분석이 조용히 어긋남

Element 02

처리 방침

Handling policy

결측 · 이상치 · 형 불일치를 어떻게 다룰지 사전 결정

없으면 발생하는 문제

AI가 자동 제거 규칙을 발동 → 드문 실사건이 이상치로 삭제 (사례 B)

Element 03 ★

출력 정의

Output schema

산출물의 형식 · 저장 위치 · 필수 항목 + 가정 명시 요구

필수 포함 (모든 스크립트)

✓ 처리 전후 행 수 로그

✓ 사용한 파라미터 요약

✓ 가정한 것 목록

6구획 대응 — DAY 1의 6구획 템플릿에서 분석 프롬프트는 [역할]-[데이터 사전]-[처리 방침]-[지시]-[출력 정의]-[검증]. 6구획 표준을 분석 도메인으로 이식한 것.

가장 정확한 개선 지시 = 오류 메시지 전문 그대로 붙여넣기.

오류 유형	잘못된 지시 (모호)	올바른 지시 (구체적)
실행 오류	"에러가 났어. 고쳐줘"	" <code>KeyError: 'RPR_MIN'</code> — 실제 열은 Repair_Time . 열 이름을 대조하고 수정하라."
논리 오류	"결과가 이상해. 다시 해줘"	"전처리 후 행 수가 12,417 → 11,974 . 443건이 어느 단계에서 어떤 규칙으로 빠졌는지 로그를 출력하라."
환경 오류	"라이브러리가 없대"	" <code>ImportError: No module named 'seaborn'</code> — 사용 가능한 환경은 Colab 기본. 표준 라이브러리로 대체하라."
한글 깨짐	"차트에서 한글이 안 보여"	"차트 라벨이 □로 표시됨. matplotlib에서 ' Malgun Gothic ' 명시 지정 코드를 추가하라."
조용한 오류 ★	(오류 메시지 없음)	"결과가 이상함 — 단계별 중간 행 수와 요약 통계를 출력하도록 코드를 수정하라. 기준값 4개(총 12,417 · 6월 987건 · 유압 42% · 합계 100%)와 대조하겠다."

오류 개선 3원칙

① 오류 메시지 전문 붙여넣기

② 실제 데이터의 조건 명시

③ 기대 결과 · 검증 기준 제시

데이터 정리에 3일 → 2분.

실습 데이터

정비이력 · 가동률 데이터 (Excel · 12,000행)

자사 데이터 대체 시 2등급 이하로 비식별 처리 후 지참

4 STEP

데이터 사전 · 품질 진단 · 처리 방침 · 파생변수

각 STEP의 산출물이 실습 2-2·2-3·2-4의 직접 입력이 됨

데이터 사전 — 사람이 확정하는 4개 열.

AI가 초안을 만들되 의미와 특이사항은 사람이 채웁니다. 데이터만 보아서는 알 수 없기 때문입니다.

열 이름	의미	형·단위	허용 범위 · 특이사항	결측	담당
EQ_CD	장비 코드	문자(8)	EX-####(굴착기) · WL-####(휠로더)	0	사람 ★
SVC_DT	정비일	날짜	2022-01-03 ~ 2024-12-28	0	AI
FLT_TP	고장 유형	범주(6)	유압/전장/엔진/구동/외관/기타	0	사람 ★
RPR_MIN	수리시간	정수(분)	5~4,320 · "미상" 문자열 41건 혼재	112	사람 ★
PRT_AMT	부품비	정수(원)	0~18,400,000 · 음수 7건 (오류)	0	AI
UTL_RT	가동률	실수(%)	0~100 · 100 초과 3건 (오류)	54	AI
SITE	현장 구분	범주(4)	수도권/영남/호남/기타	0	AI
ENG_ID	담당 엔지니어	문자	31명 · 퇴사자 코드 포함	9	사람 ★

사람이 반드시 채워야 하는 것
"의미" 열과 특이사항. EQ_CD의 두 계열이 굴착기·휠로더를 뜻한다는 것, "미상" 문자열이 결측과 별개로 존재한다는 것은 데이터만 보아서는 알 수 없습니다.

품질 진단 4범주 · 심각도로 정렬.

심각도 정렬이 회의 시간 배분을 결정합니다. 상에 20분, 중·하는 규칙 처리.

Category 01 형식 Type · Encoding 형 불일치 · 문자 혼입 · 인코딩 이상 이번 데이터 RPR_MIN "미상" 문자열 41건 — 숫자 옆에 문자 혼입	Category 02 결측 Missing 열별 결측 수·비율 · 결측 패턴 (특정 기간·값 몰림) 이번 데이터 RPR_MIN 112건(0.9%) · UTL_RT 54건 · MFG_YM 38건	Category 03 범위 Value range 물리적 불가능값 · 사전 정의 범위 이탈 · 범주 미정의 심각도 상 PRT_AMT 음수 7건 · UTL_RT 100 초과 3건 · 이상치 후보 62건	Category 04 ★ 논리 Logic · 열 간 관계 통계 진단으로 안 잡힘 — 열 간 관계 규칙 필수 심각도 상 · 조용한 오류 SVC_DT < MFG_YM (제조 전 정비) 12건
--	---	--	--

중요한 제약 — "문제를 발견하는 데 그치고 자동으로 수정하지 말 것." 판단은 STEP 03 처리 방침에서.

처리 방침 표 = 전처리 명세의 본체.

이 표가 확정되면 코드 생성은 번역 작업. 코드가 바뀌어도 방침은 남습니다 — 6개월 뒤 "왜 이 값을 이렇게 처리했지"에 답합니다.

문제	건수처리 방침	결정 근거
PRT_AMT 음수	7결측 처리 · 원본 행 번호 보존	반품·정정 입력 추정 — 원인 조사 별도
UTL_RT 100 초과	3100으로 절단 · 표시 열 부여	측정 방식 오류로 확인
제조 전 정비 (논리 오류)	12분석 제외 · 별도 시트 보관	데이터 정합성 오류 — 원장팀 이관
RPR_MIN "미상" 문자열	41결측으로 통일	문자열 자체가 정보 없음
RPR_MIN 결측 총계	153중앙값 대체 · 대체 여부 표시 열 추가	1.2% 수준 — 삭제 시 정보 손실 큼
UTL_RT 결측	54대체하지 않고 해당 분석에서만 제외	가동률은 대체 시 왜곡 위험
이상치 후보 ★	62표시만 · 제거하지 않음	사례 B의 교훈 — 도메인 검토 대상
완전 중복 행	23 삭제 · 삭제 로그 보관	완전 일치 중복은 입력 오류

중요 원칙 — 이상치는 표시까지가 자동화의 몫이고 제거 판단은 도메인의 몫. 자동 제거는 드문 실사건까지 지워 분석의 핵심을 잃게 만듭니다.

"장비연령"이 무엇인지 주석에 없으면, 몇 달 뒤 다른 사람이 다른 정의로 다시 만듭니다.

변수명	산식 (주석 문자열)	단위	주의점
EQ_AGE_YR	(SVC_DT - MFG_YM) / 365.25	년(소수)	MFG_YM 결측 시 계산 불가
REPAIR_HR	RPR_MIN / 60	시간	대체 여부 표시 열 참조 필수
SVC_MONTH	YEAR(SVC_DT)*100 + MONTH(SVC_DT)	정수 YYYYMM	월별 집계용 · 정렬 가능
REVISIT_30D ★	동일 EQ_CD의 다음 SVC_DT - 현재 SVC_DT ≤ 30일	부울	"재방문" 정의가 결과를 좌우 — 30일 vs 동일계통 vs ...
MISSING_FLAG	원본이 결측이었는지 True/False	부울	대체 여부 표시 열 — 원본만으로 재계산 가능

파생변수 3원칙

- ① 산식을 코드 주석에 문자열로 반드시 남긴다 (6개월 뒤 자신도 해석 가능)
- ② 정의(재방문·리드타임 등)를 먼저 못 박고 파생변수를 만든다 — 정의가 흔들리면 이후 정밀함 무의미
- ③ 표본 3~5건을 손으로 계산해 대조 (5건 모두 맞으면 산식 신뢰)

차트는 그리기 전에 명세표부터.

명세 없이 요청했을 때

"차트 10개 만들어 줘"

매번 다른 차트가 나옴 · 회사 보고 표준 미적용 · 재현 불가

명세표 있을 때

10종 차트가 일관된 스타일로 즉시 생성

다음 달 재실행 시 동일 결과 · 명세표만 바꾸면 확장

차트 명세표 10종 · 말하려는 것과 유형 매핑.

#	유형	말하려는 것	사용 데이터	강조점
C1	막대(정렬)	"무엇이 많은가"의 순위	MDL, 건수	상위 10 · 1위 색 강조
C2	선(시계열)	"시간에 따라 어떻게 변했는가"	SVC_DT(월), UTL_RT	3개월 이동평균 중첩
C3	콤보	"건수와 강도의 결합 흐름"	월, 건수, 수리시간	이중축 배율 근거 주석
C4	도넛	"구성 비율 (6분류 이하만)"	FLT_TP	5% 미만은 기타 병합
C5	히트맵	"요일 × 시간대 밀도"	SVC_DT 요일·시간대	상위 3셀 수치 표기
C6	박스플롯	"그룹별 분포와 이상치"	FLT_TP × RPR_MIN	이상치 점 표시 (제거 아님)
C7	산점도	"두 변수의 관계"	장비연령, 부품비	회귀선 + R ² 표기
C8	파레토	"소수가 다수를 설명"	부품 항목, 금액	누적 80% 수직선
C9	누적 영역	"구성 변화의 흐름"	월별 유형 구성	구성비 변화 구간 주석
C10	KPI 카드	"한 눈에 목표 대비"	UTL_RT 목표 85%	달성/미달 색 구분

보고 표준의 제약

글꼴 통일 · 색상 팔레트 5색 고정 · 제목은 "무엇을 말하는가"의 문장 · 모든 차트 하단에 데이터 기준일과 행 수 · 축 라벨에 단위 필수.

차트는 주장입니다 — 왜곡 금지 8종.

왜곡을 배우는 목적은 남이 만든 차트에서 왜곡을 알아보기 위해서. 명세의 [제약] 구획에 그대로 옮겨 넣습니다.

#	왜곡	어떻게 속이는가	점검 규칙
01	축 절단 ★	막대 차트 y축을 0이 아닌 값에서 시작	막대는 0에서 시작 · 선 그래프만 예외 (명시 필수)
02	이중축 배율	두 축의 배율을 임의로 맞춰 동조 착시	배율 선택 근거 주석 · 또는 분리 차트로
03	과다 파이 ★	항목 7개 이상 파이/도넛	5개 초과 시 정렬 막대로 대체
04	면적 왜곡	반지름을 값에 비례 → 면적이 제곱으로 커짐	면적이 값에 비례하도록
05	구간 임의 설정	히스토그램 구간 폭을 골라 모양 조작	구간 수 2~3개 버전 확인
06	색 강조 유도	주장에 맞는 항목만 강조색	강조는 1개까지 · 사유 캡션 명시
07	기간 체리피킹	유리한 구간만 표시	전 구간 제시 후 관심 구간 음영
08	3D 효과	입체 표현으로 크기 비교 왜곡	2D만 사용

규칙만으로는 부족 · 검증 지시가 함께

"위 8종 위반 여부를 스스로 점검하고 위반 시 수정안을 제시하라" — 검증 지시가 없으면 규칙은 종이 위에서만 살아 있습니다.

차트 10장 중, 본문에 오를 2~3장.

"이 차트를 빼면 결론이 흔들리는가"가 판단 기준. 흔들리지 않으면 부록입니다.

Tier 01 · 본문

2~3장

결론을 직접 지지

결론 한 문장을 직접 지지하는 차트만

필수 요소

✓ 데이터 기준일 · 행 수

✓ 축 단위 · 강조 근거

✓ "무엇을 말하는가" 제목

Tier 02 · 부록

5~7장

질문 대비용

"질문 나올 때 꺼낼" 차트 — 정보를 버리는 게 아니라 대비

예

세부 분포 · 하위 그룹 비교 · 파레토 · 히트맵 상세

Tier 03 · 폐기

0~2장

"패턴 없음"

결론이 "특별한 패턴 없음"인 차트

판단 기준

결론을 말로 옮겨 보면 그 차트가 필요한지가 즉시 드러남

프롬프트 지시 — "각 차트가 유도하는 결론 1문장을 목록으로 함께 출력하라. 결론이 데이터로 지지되지 않는 차트를 스스로 표시하라."

상관은 인과가 아니다 — 그리고 패키지화.

Principle 01

유의성과 크기의 구분

p값(유의성)과 $r \cdot R^2$ (효과 크기)를 반드시 함께 보고, 표본이 크면 작은 관계도 유의해집니다.

Principle 02

파일로 저장된 것만 자산

대화 속 결과는 세션 종료로 소멸. 패키지화 = **README + 재현** 테스트까지 통과해야 BIG WIN.

탐색은 넓게, 결론은 가설이 있는 곳에서만.

다중 비교 문제에 대한 실무적 방어. 20쌍을 검정하면 우연히 1쌍은 유의해집니다.

STEP 01

01

상관행렬로 탐색

연속 변수 전체의 상관행렬을 색상 히트맵으로 확인. | $r| \geq 0.4$ 쌍만 후보로.

Purpose

"어디를 볼지"의 좌표 확보 · 결론 아님

STEP 02 ★

02

가설 있는 3쌍 심층 분석

업무 가설이 있는 3쌍만 회귀 분석 · 산점도 · R^2 산출. "넓게 훑고, 좁게 결론".

Output

3쌍의 r · R^2 · p · 산점도 3장

STEP 03 ★

03

해석 리포트 작성

각 쌍마다 4항목 필수 — 인과 방향 · 혼재변수 · 편향 · 추가 측정 제안.

필수 마무리

"이 분석이 말할 수 없는 것" 목록

범주형 변수 경고 — 범주형 쌍(SITE ↔ FLT_TP)에는 피어슨 상관 사용 불가. 카이제곱 검정이 맞음. 명세에 유형 검사 지시 필수.

p값과 효과 크기는 반드시 함께.

p값은 "차이가 있는가"에, 효과 크기는 "얼마나 있는가"에 답합니다. 표본이 크면 두 답이 다르게 나옵니다.

변수 쌍	R	P값	표본 N 해석 시 유의점
장비연령 ↔ 부품비	+0.52	<0.001	12,232 중간 관계 · R²≈27% · 사용강도 혼재
정비간격 ↔ 수리시간 ★	-0.31	<0.001	11,980 약한 관계인데도 p 매우 작음 — 표본 크기 효과. 결론 자제
가동률 ↔ 고장건수	-0.44	<0.001	2,208 중간 관계 · 인과 방향 불명
수리시간 ↔ 부품비	+0.68	<0.001	12,232 강한 관계 · "작업 규모" 라는 공통 요인 의심
SITE ↔ FLT_TP ✕	—	0.03	12,417 범주형 — 피어슨 상관 불가 · 카이제곱 검정 사용

보고 표현 규칙 (명세의 [제약])

"통계적으로 유의미한 강한 관계" ✕ → "p<0.001이지만 r=0.31로 관계의 크기는 작다" ✓

표본 100 미만이면 해석 유보 권고.

상관 해석의 4개 필수 점검.

이 넷을 각 상관 쌍마다 서술로 강제 — 명세의 [필수 포함] 구획.

가 인과 방향 검토

A→B, B→A, 양방향 · 시간적 선후 확인. 사례 D의 정비-고장 사례: "정비가 고장을 부른다" ↔ "고장이 잦아 정비를 자주"

나 혼재변수 후보

최소 2개 이상 · 각 근거 1문장. 예: 장비연령↔부품비의 혼재는 누적 가동시간·현장 환경 (분진·경사)

다 빠진 대상 (편향)

선택 편향 · 생존자 편향. "조기 폐기된 장비는 이력에 남지 않는다" — 고연령 구간이 과소 대표될 가능성

라 ★ 추가 측정 제안

"이 결론을 검증하려면 무엇을 추가로 측정해야 하는가" — 다음 분기 데이터 수집 계획의 근거

필수 마무리 — "이 분석이 말할 수 없는 것" 목록. 이 목록이 있는 보고서만 대외 방어 가능.

스크립트에서 패키지로 · 4 STEP.

실습 2-1~2-3의 코드를 하나의 재사용 가능한 패키지로 재구성. 사용 프롬프트 분석_리팩터링_v1.0

STEP 01

01

파라미터 추출

코드 곳곳의 값(경로·기간·임계값·색상)을 상단 설정 구획으로.

완료 기준
사용자가 바꿀 값이 상단 20행 안에

STEP 02

02

함수화 · 모듈 구성

전처리 · 시각화 · 상관분석을 각각 함수로 분리 + 메인 흐름.

주석 강제
각 함수에 입력·출력·주의

STEP 03

03

실행 안내서 (README)

비개발 동료가 따라 할 수 있는 8항목. 독자는 "분석 경험 없는 신입".

→ 슬라이드 27 상세

STEP 04 ★

04

재현 테스트

옆 사람과 패키지 교환 → 안내서만 보고 처음부터 실행. 통과해야 BIG WIN 인정.

실패 지점
그 자리에서 패키지에 반영

패키지 구조 · 코드보다 오래 남는 문서.

#	파일	유형	담긴 것
01★	config.txt	설정	파일 경로 · 분석 기간 · 이상치 기준 · 색상 팔레트 · 목표 가동률
02	step1_check.py	코드	열 검증 · 품질 진단
03	step2_clean.py	코드	처리 방침 표 기반 전처리 · 처리 로그 출력
04	step3_chart.py	코드	차트 명세표 기반 10종 생성
05	step4_stat.py	코드	상관 · 회귀 산출 · 해석 입력표 생성
06	run_all	코드	순차 실행 메인 흐름
07★	README.txt	문서	실행 안내서 8항목 (신입 사원 관점)
08★	처리방침표.xlsx	문서	전처리 방침의 근거 문서 · 변경 이력 포함

코드가 아닌 파일이 자산의 수명을 결정

config.txt · README.txt · 처리방침표.xlsx — 이 셋이 없으면 코드는 개인의 도구. 이 셋이 있어야 조직의 자산.

실행 안내서는 스크립트의 절반입니다.

안내서 없는 코드 = 개인 도구 · 안내서 붙은 코드 = 조직 자산. **R사 사례** 참조.

8 필수 항목

- ① 이 스크립트가 답하는 질문 **1문장**
- ② 필요한 입력 파일과 받는 곳
- ③ 폴더 구조와 파일명 규칙
- ④ 실행 순서 (명령 또는 클릭 단위)
- ⑤ ★ 설정값의 의미와 권장 범위
- ⑥ 산출물 목록과 저장 위치
- ⑦ ★ 자주 나는 오류 **3종**과 대처
- ⑧ 작성자 · 최종 수정일 · 문의처

⑦번의 실제 · 자주 나는 오류 3종

Error 01 · 파일 경로 오류
FileNotFoundError
대처 — config.txt의 DATA_PATH를 절대 경로로 확인. Windows/Mac 구분 주의

Error 02 · 열 이름 불일치
KeyError: 'RPR_MIN'
대처 — step1_check.py 첫 함수의 열 대조 결과 확인. 원장 양식 변경 시 매핑 표 갱신

Error 03 · 라이브러리 미설치
ImportError: No module named ...
대처 — pip install requirements.txt 재실행. Colab은 !pip install 셀 먼저 실행

월 3일 → 월 20분.

P사 사례 · 월 22시간 절감. 패키지 완성 후에 진짜 가치가 나옵니다.

01 확정 데이터 사전 10 열 · 특이사항 포함 모든 후속 분석의 계약서	02 처리 방침 표 + 차트 명세표 8 처리 · 10 차트 코드보다 오래 남는 문서	03 상관분석 + 해석 리포트 가설 3쌍 · 4점검 완비 "말할 수 없는 것" 포함	04 ★ 스크립트 패키지 + README + 재현 테스트 8 파일 · 상호검증 통과 DAY 6 에이전트의 분석 모듈
--	---	---	---

4개 산출물 세트가 DAY 5 워크플로우의 "분석 노드"로 호출되고, DAY 6 통합 에이전트의 분석 모듈로 편입됩니다.

"3일짜리 반복 리포트를 20분에 끝냈다."

P사(부품 유통) · 월간 판매·재고·불량 리포트 자동화 · 담당 인원 2명 · 기간 6주

단계	배경 · 문제	조치	결과 · 교훈
배경	월말 3영업일 완전 소진. 담당자 야근 상시.	엑셀 매크로만으로는 매월 컬럼 명칭·시트 순서가 달라져 실패.	수작업 의존 → 재현성 0.
문제	동일 리포트 3명이 각각 다른 컬럼명 사용.	데이터 사전을 계약서로 격상 — 12열 확정.	이후 컬럼 변경 시 사전 개정이 선행.
조치	Vibe 루프 3회. 사양서 → 실행 → 관찰.	단계별 산출물(사전·정책·차트·해석) 분리 → 재사용.	패키지 6파일 완성.
결과	3영업일 → 20분.	월 22시간 절감 · 재작업률 41% → 9%.	담당자 → 검수·해석 시간 확보.
교훈 ★	"컬럼 검증 체크"를 스크립트 최상단에 필수. 사전에 없는 컬럼이 들어오면 즉시 중단하고 사전 개정부터 — 이 규칙 없이는 자동화가 조용히 오작동합니다.		

"IQR × 1.5로 자동 삭제했다."

Q사(장비 원격 모니터링) · 이상치 처리 실패 · **현장 이슈를 통계로 지워버림.**

Before · 통계적 자동 제거

IQR × 1.5 벗어난 값 = 즉시 삭제.

- 온도 급상승 데이터 **40건** 제거 → 유압 계통 결함 발견 지연.
- 야간 가동 시간이 "**이상치**"로 분류 → 실제 3교대 정상 운영.
- 통계는 맞았지만 **현장은 틀렸다.**

After · 라벨링 + 도메인 판단

삭제하지 말고 **is_outlier 플래그만.**

- 이상치 보존 + 별도 컬럼 라벨.
- 후속 분석에서 포함/제외 결정을 도메인 담당자가.
- 리포트에 "**삭제 없음, 라벨링만**" 명시.

교훈

통계적 이상치 ≠ 도메인 이상치. AI는 "**라벨링만**", 삭제는 **사람의 결정**. 처리 방침 표의 "결정" 열에 반드시 담당자 이니셜을 남깁니다.

"코드는 있는데, 아무도 못 돌린다."

R사(중장비 렌탈) · 담당자 이직 후 **3개월간 분석 스크립트 방치**. 원인 = README 부재.

#	README 필수 항목	R사 스크립트 실태 (당시)	결과
①	목적 (한 문장)	주석 3줄만 존재	용도 불명
②	입력 파일 스펙	"data.xlsx" — 어느 시스템 export인지 없음	재현 불가
③	실행 방법 · 순서	3개 파일 실행 순서 미기재	오류 발생
④	환경 · 패키지	pandas 버전 미기재	호환성 문제
⑤	출력 · 저장 위치	경로 하드코딩	결과 유실
⑥	가정 · 제약	없음	해석 오류
⑦	테스트 · 재현 데이터	없음	검증 불가
⑧ ★	변경 이력 (버전 · 담당)	없음 — 누가 언제 뭘 바꿨는지 추적 불가	교훈: 8항목 필수

"정비 횟수가 많을수록 고장이 늘어난다?"

유지보수팀 리포트에서 $r = 0.71$ 발견 → "정비를 줄이자"는 결론. **역인과·혼재변수 무시.**

해석 규칙	금지 표현	허용 표현	근거
인과 단정어 배제	"영향을 미친다", "때문에", "유발한다"	"연관성이 관찰된다", "함께 움직인다"	관측 데이터
역인과 점검	"정비가 고장을 늘렸다"	"고장이 많은 장비 → 정비 횟수가 늘어남 (역인과 가능)"	시점 확인
혼재변수 명시	단일 변수로 결론	"장비 연식·가동시간을 통제하지 않은 상관"	공변량 목록
p 값 오해 금지	" $p < 0.05$ 이므로 인과"	"통계적 유의성 $\neq$ 실무 유의성"	효과크기 병기
★ 표본 편향	전체로 일반화	"12개월 · 국내 3개 현장 데이터에 한함"	경계 명시

교훈

상관계수를 보고할 때는 "말할 수 있는 것"과 "말할 수 없는 것"을 한 문단씩 병기. 인과 단정어를 프롬프트 검수 단계에서 **치환 규칙**으로 강제합니다.

분석 파이프라인용 프롬프트 10종.

6구획 구조 그대로 · 파이프라인 5단계에 매핑 · 원문은 교재 **PART 02 §10** 프롬프트 라이브러리 참조.

#	템플릿 ID	파이프라인 단계	주요 산출물	검수 포인트
①	공통_시스템계층_v2.0	전 단계	역할·검수 원칙	보안·미제공 정보 처리
②	분석_데이터사전초안_v1.0	수집	10열 데이터 사전	단위·타입·범위 확인
③	분석_품질진단_v1.1	전처리	품질 리포트 · 심각도별	결측 · 이상치 · 중복
④	분석_결측처리설계_v1.0	전처리	결측 후보 3안 + 영향	한 안으로 좁히지 말 것
⑤	분석_처리방침표_v1.0	전처리	8행 결정 표(사유·담당)	담당자 이니셜 필수
⑥	분석_차트일괄생성_v1.0	시각화	10 차트 명세표	축·단위·기준선 명시
⑦	분석_상관해석_v2.0	분석	r · p · 신뢰구간 · 해석	인과 단정어 금지
⑧	분석_시계열해석_v1.0	분석	추세 · 계절성 · 이상	$\pm 2\sigma$ · 이동평균 병기
⑨	분석_리포트초안_v1.0	보고	결론1 · 근거3 · 액션N	서술 순서 고정
⑩ ★	분석_README작성_v1.0	패키지	README 8항목	재현 데이터 · 버전

가상 · 부품 판매 12,417행.

STEP 1: 원본을 열기 전에 데이터 사전부터 만듭니다. 이후 모든 분석의 계약서.

#	열 이름	타입	단위	범위 · 코드	특이사항
01	order_id	string	—	ORD-YYYYMMDD-###	PK · 중복 시 최신 우선
02	order_date	date	YYYY-MM-DD	2024-01 ~ 2025-12	시차 UTC+9
03	part_code	string	—	4자리 코드 (A~Z + 0~9)	사전 5차 개정 반영
04	qty	int	개	1 ~ 5,000	음수 = 반품 (별도)
05	unit_price	float	KRW	100 ~ 12,000,000	VAT 별도
06	region	enum	—	서울·중부·영남·호남·해외	"—"= 미분류 12건
07	channel	enum	—	직판·대리점·온라인	—
08	lead_time_days	int	일	0 ~ 90	결측 4.2%
09	defect_flag	bool	—	0/1	1 = 하자 신고 있음
10 ★	amount	float · 파생	KRW	qty × unit_price	계산식 사전 명시

품질 리포트 · 심각도 3구간.

"결측률 4.2%"보다 "어디에 어떻게 몰렸는지"가 훨씬 중요. 심각도 색상 코드로 후속 처리 우선순위를 강제합니다.

#	항목	지표	패턴	심각도	다음 조치
Q1	결측	lead_time 4.2% (521건)	해외 지역에 63% 몰림	■ 상	해외만 별도 정책
Q2	결측	region "—" 12건	2024-03 이전 데이터	■ 중	"기타" 라벨 부여
Q3	이상치	qty > 3,000 · 87건	대량 발주 (연 계약) 정상	■ 하	라벨링만 (삭제 X)
Q4	중복	order_id 32건 중복	수정 재접수 케이스	■ 중	최신 order_date 우선
Q5	타입 오류	unit_price "1,234,000" 문자열 엑셀 export 기본 서식		■ 하	coma 제거 · float 변환
Q6	범위 위반	lead_time = 145 (2건)	사전 범위 초과	■ 상	원본 확인 · 사전 개정
Q7★	사전 미등록 열	"promo_code" 신규 열	2025-Q2부터 자동 생성	■ 상	진행 중단 · 사전 개정

"무엇을 어떻게 처리했는가"의 기록.

스크립트보다 오래 남는 문서. 담당자 이니셜 + 근거 문서 페이지가 감사에서 요구되는 형태.

#	대상	이슈	결정	근거 · 담당	영향
01	lead_time 결측 (해외)	특정 지역에 63% 몰림	해외 지역만 별도 계산	사전 §3.2 · 김OO	국내 평균 왜곡 방지
02	region "—"	12건 · 2024-03 이전	"기타" 라벨 부여	사전 §3.3 · 김OO	지역 집계 유지
03	qty > 3,000	87건 · 연 계약 정상	is_bulk = TRUE 라벨링	현장 확인 · 이OO	삭제 없음
04	order_id 중복	32건 · 수정 재접수	최신 order_date 유지	사전 §2.1 · 김OO	32행 제거
05	unit_price 문자열	엑셀 서식 잔재	콤마 제거 · float 변환	스크립트 자동 · 김OO	숫자 연산 가능
06	lead_time = 145	범위 초과 2건	원본 재확인 · 사전 개정	발주팀 확인 · 박OO	사전 최대값 180 조정
07	promo_code 열	신규 자동 생성	사전에 열 추가 후 재실행	사전 5차 개정 · 박OO	1회차 폐기
08 ★	amount 파생	계산식 표기 필요	qty × unit_price · VAT 별도 명시	사전 §5.1 · 김OO	재현성 확보

차트 10 · "왜 만들었는가"까지 표에 담기.

C1~C10 · 각 차트에 답할 질문 · 축 · 단위 · 기준선을 사전 정의해야 왜곡을 예방.

ID	유형	답할 질문	X · Y · 단위	기준선 · 주석
C1	라인	월별 매출 추이가 어떻게 되나?	월 · 억원	전년 동월 점선
C2	라인 · 3M 이동평균	계절성 제외한 추세는?	월 · 억원	3개월 롤링
C3	막대 (누적)	지역별 매출 구성비는?	지역 · 억원	"기타" 라벨 별도
C4	막대 (그룹)	채널별 · 분기별 매출은?	분기 · 억원 · 채널	Y축 0부터
C5	파레토	상위 20% 부품이 몇%를 차지?	부품 · 매출 %	80% 라인
C6	박스플롯	채널별 단가 분포는?	채널 · KRW	이상치 개별 표시
C7	산점도	단가와 수량은 관계 있나?	단가 · 수량	회귀선 + r 표기
C8	히트맵	지역 × 부품 매출 매트릭스는?	지역 · 부품 · 억원	색상 범례 필수
C9	라인 · YoY	전년 대비 성장률은?	월 · %	0선 굵게
C10 ★	스택 라인	불량률과 매출의 동시 추이는?	월 · 억원 + %	이중축 명시

3쌍의 가설 · 결론 · 경계.

"r 값 = 정답"이 아니다. r · p · 95% CI + "말할 수 없는 것"까지 리포트에 함께.

#	가설 (H)	R · P · CI	말할 수 있는 것	말할 수 없는 것
H1	단가 ↑ ⇔ 수량 ↓ 가격 탄력성	r = -0.42 p < 0.001 CI [-0.46, -0.38]	전 채널 평균, 단가와 수량이 약한 역상관. 대량 발주(is_bulk) 제외 시 r = -0.51로 강해짐.	인과 방향 · 시장 상황 변수 미통제.
H2	lead_time ↑ ⇔ 불량률 ↑ 공급망 지연 = 품질 저하?	r = +0.07 p = 0.31 CI [-0.05, +0.19]	통계적으로 유의하지 않음. lead_time으로 불량률을 설명할 근거 없음.	"관계 없다"고 단정도 금지 — 표본 크기 문제.
H3 ★	지역 · 채널 → 매출 다변량 · ANOVA	F(8, 12408) = 34.2 p < 0.001 η² = 0.13	지역·채널 조합이 매출 분산의 13%를 설명. 실무 유의성 확보.	잔여 87%는 미측정 요인 (마케팅 · 경기).

해석 원칙

각 가설마다 "경계"를 함께 기록. 이 세 열이 없으면 리포트는 과대 해석으로 오해받습니다.

"데이터가 나쁘면 뭘 해도 나쁘다."

3층 오류 중 첫째 층 — 여기서 못 잡으면 뒤에서 못 잡습니다. 6유형 · 증상 · 대책.

#	유형	증상	1차 대책
①	인코딩 불일치	한글 깨짐(cp949 · utf-8-sig 혼재)	최상단 인코딩 감지 함수 · encoding 파라미터 명시
②	타입 자동 추론 오류	"01234"가 int로 → 앞자리 0 소실	dtype=str 강제 · 사전에 타입 명시
③	단위 혼재	"kg"과 "t"가 같은 열에 혼재 (1000배 왜곡)	사전에 단위 확정 · 사전 위반 시 중단
④	사전 미등록 열	신규 열 추가 → 스크립트 무시	사전 대비 열 목록 diff → 오류 raise
⑤	시간대 불일치	UTC · KST 혼재 → 일자 경계 오류	timezone 명시 · 모두 KST로 변환
⑥ ★	결측 · NaN · None · "" 혼재	각 라이브러리마다 다르게 취급 → 카운트 불일치	단일 표기(np.nan)로 통일 · 최초 로드 시

"돌아가는 코드"가 "옳은 코드"는 아니다.

Vibe Coding에서 가장 흔한 함정 — 오류 없이 실행되지만 결과가 **조용히 틀린** 경우.

#	유형	증상 (조용한 오작동)	1차 대책
①	경로 하드코딩	C:\\Users\\... — 다른 PC에서 실행 불가	상대경로 · config 파일 분리
②	groupby 정렬 의존	기본 정렬이 바뀌면 결과 순서 뒤바뀜	sort_values 명시 · sort=False 사용
③	merge · join 다중 매칭	중복 키 → 행 수 폭발 · 합계 왜곡	validate="1:1" · 사전 중복 검사
④	부동소수점 비교	amount == 0.1 → False (조용히)	np.isclose · 반올림 자릿수 통일
⑤	인덱스 리셋 누락	filter 후 loc[0] → 원본 첫 행이 아님	reset_index(drop=True) 습관화
⑥ ★	난수 시드 미고정	샘플링 · 학습 결과가 매번 달라짐	random_state=42 · 시드 기록

디버깅 원칙

에러 메시지가 없어도 "기대값 vs 실제값"을 항상 확인 — 스크립트 실행 후 최소 3지점(행수 · 합계 · 표본값)을 비교.

숫자를 문장으로 옮길 때 사고가 난다.

데이터 · 코드가 다 맞아도 서술 규칙이 없으면 리포트는 여전히 위험. 6유형 오독.

#	유형	위험 서술 (예)	교정 서술
①	인과 단정어	"X가 Y를 유발한다"	"X와 Y는 함께 움직인다 (r=..., p=...)"
②	과대 일반화	"우리 회사 모든 부품이 그렇다"	"부품군 A 3종에 한한 관찰"
③	기준선 없는 비교	"매출이 12% 늘었다"	"전년 동월 대비 +12% (계절 조정 후)"
④	평균 편중	"평균이 상승 → 전체 개선"	"평균 · 중앙값 · 분포 함께 제시"
⑤	단일 관측 결론	"이번 달 5% 감소 → 시장 침체"	"3개월 이동평균 확인 필요"
⑥ ★	"말할 수 없는 것" 누락	경계 없이 결론만	각 결론에 "데이터 한계 1문장" 병기

외우지 말고 언제 쓸지 기억.

비전공자용 최소 통계 지표 6종 · 각 지표는 한 질문에 대응.

01 · 중심 경향

평균 · 중앙값 · 최빈값

데이터가 어느 값 근처에 몰려 있나?
이상치 있을 때는 중앙값 우선.

02 · 산포

표준편차 · IQR · 변동계수

얼마나 흩어져 있나?
평균 비교 시 CV로 스케일 보정.

03 · 관계

상관계수 r · Spearman ρ

두 변수가 함께 움직이나?
비선형 · 이상치 있으면 Spearman.

04 · 불확실성

95% 신뢰구간 · p 값

이 추정이 얼마나 흔들리나?
단일 수치보다 구간을 보고.

05 · 효과크기 (Cohen's d · η^2) · 06 · 분포 정규성 (Shapiro-Wilk)
지표 6종 · 한 지표에 한 질문. 헛갈리면 리포트에 지표명 · 값 · 해석 세 줄로 병기.

"품질이 좋다"를 6차원으로 쪼갭니다.

DAMA-DMBOK 6대 차원 · 각 차원마다 체크 함수를 스크립트 최상단에 배치.

#	차원	정의	체크 함수 (예)	실패 시
D1	완전성 (Completeness)	필요한 값이 다 있는가?	<code>df.isna().sum() < 임계</code>	중단 · 사전 확인
D2	유일성 (Uniqueness)	PK가 실제로 유일한가?	<code>df.duplicated().sum() == 0</code>	중복 정책 적용
D3	유효성 (Validity)	사전이 정한 범위 · 형식인가?	<code>df[col].between(lo, hi).all()</code>	사전 개정
D4	일관성 (Consistency)	다른 열/파일과 모순 없나?	<code>amount == qty*price</code>	계산식 재검증
D5	적시성 (Timeliness)	최신 데이터인가?	<code>max(date) > today - 7d</code>	데이터 재추출
D6 ★	정확성 (Accuracy)	현실을 얼마나 정확히 반영?	표본 감사 · 원본 대조	가장 어려운 차원

건설기계 5개 부서에 어떻게 붙나?

영업 · 생산 · 품질 · 구매 · 서비스 — 각 부서의 "주간 반복 리포트"가 우선 자동화 대상.

부서	타깃 리포트	핵심 지표	주의점	ROI 우선순위
영업 (판매)	지역·채널별 판매 · 파이프라인 · 실적	매출 · YoY · 전환율	CRM 데이터 표준화 선행	■■■■■□
생산 (제조)	라인별 가동률 · 불량률 · 사이클타임	OEE · FTT · Takt	MES 연동 필수	■■■■□□
품질 (QM)	부적합 정규화 · 부위·원인 분류 · 파레토 불량률 · PPM · 재발률		코드 사전 5차 개정 상시	■■■■■
구매 (SCM)	견적 6축 비교 · 납기 · 리스크 리포트	단가 · 리드타임 · 결제	숨은 조건 명시 검색 필수	■■■■■□
★ 서비스 (AS)	7항목 구조화 · 재발률 · 모델·계절 메타	MTBF · MTTR · 재발률	사진·음성 데이터 별도 처리	■■■■■

패키지는 만든 이후가 본론.

6개월 뒤에도 굴러가려면 버전 · 회귀 테스트 · 개정 절차가 필요.

A · 버전 규칙

MAJOR . MINOR . PATCH

MAJOR · 데이터 사전 · 출력 스키마 변경 → 하위호환 X

MINOR · 함수 추가 · 새 지표 · 하위호환 O

PATCH · 버그 수정 · 문서 개선

예: v2.3.1 — 2차 사전 개정, 3번째 지표 추가, 1개 패치.

B · 회귀 테스트 (재현 데이터)

"작은 표본 + 기대값"

· **tests/sample_input.csv** — 30~100행 · 실 데이터와 동일 구조

· **tests/expected_output.json** — 지표 5~10개 기대값 · 소수점 자리 명시

· **tests/run_check.py** — 실행 → 실제 vs 기대 diff → **임계 초과 시 실패**

· 매 개정 시 **먼저 회귀 통과** → 그 후 실 데이터.

회귀 테스트가 없으면 개정은 "조용한 오작동"을 도입할 위험. 100줄 코드에 30줄 테스트가 **최소치**.

담당자 이직에도 살아남게.

30분 · 신규 담당자가 혼자 실행할 수 있다가 통과 기준으로.

#	체크 항목	통과 기준	담당
☐ 01	README 8항목 완비	신규자가 15분 안에 실행 방법 파악	전임자
☐ 02	환경 파일	requirements.txt · Python 버전 명시 · 설치 5분 이내	전임자
☐ 03	회귀 테스트 통과	신규자 환경에서 run_check.py 성공	공동
☐ 04	실 데이터 1회 실행	최근 월 데이터로 리포트 산출 → 전임자와 결과 일치	신규자
☐ 05	처리 방침 표 리뷰	8행 결정의 사유 · 근거 문서 페이지 확인	신규자
☐ 06	데이터 사전 개정 이력	최근 3차 개정의 사유 · 영향 열 확인	신규자
☐ 07	에러 케이스 시연	이상 데이터 넣고 스크립트가 적절히 중단하는지	전임자 시연
☐ 08 ★	"질문 노트" 전달	전임자가 6개월간 만난 이상 케이스 · 예외 처리 기록	필수

"매출이 늘었다"를 3층으로 쪼갭니다.

추세(Trend) · 계절성(Seasonality) · 이상(Anomaly) — 세 성분을 따로 보고해야 오독을 막습니다.

01 · TREND

추세

방법. 3~6개월 이동평균 · LOESS · Prophet trend

서술.
"12개월 추세는 완만한 상승 (월평균 +0.8%)"

함정. 창(window)을 짧게 잡으면 계절성이 추세로 오인.

02 · SEASONALITY

계절성

방법. 전년 동월(YoY) 대조 · 요일 · 분기 프로파일

서술.
"7·8월 성수기 (평균 +18%) · 2월 저점 (-12%)"

함정. 계절 조정 없이 MoM만 보고 → 과잉 반응.

03 · ANOMALY ★

이상

방법. 잔차(actual - trend - season)가 $\pm 2\sigma$ 초과

서술.
"2025-04 판매 급락 · 잔차 -2.8σ · 이벤트 원인 조사 필요"

필수. 이상 발견 시 도메인 확인 없이 리포트 배포 금지.

셋을 나눠 보고 → "이번 달 급락"이 추세인지 · 계절인지 · 진짜 이상인지 즉시 판별.

한 문장 · 세 근거 · N 액션.

임원 대상 리포트 표준 구조. 서술 순서 고정이 반복성과 신뢰를 만듭니다.

블록	분량	담을 것	담지 말 것
결론 (1)	1문장 · 최대 40자	숫자 1개 + 방향(↑/↓) + 대상. "부품 A군 매출이 전년 대비 +18% 상승"	"...한 것으로 보인다" 애매어
근거 (3)	차트 2~3개 + 표 1개	① C1 라인차트 (추세) ② C9 YoY 성장률 ③ H1 상관계수 표 (변수 관계) · 각 차트 아래 한 문장 해설.	차트 5개 이상 나열 · 해설 없이 이미지만
액션 (N) ★	3~5개 · 담당자 지정	① "부품 A군 재고 확대 검토 — 영업본부" ② "해외 채널 lead_time 원인 조사 — SCM" ③ "품질 코드 사전 6차 개정 — 품질보증"	"검토가 필요하다" (담당 없음)

"오늘 배운 걸 돌릴 수 있나?"

각 항목 5점 척도 · 3점 이하는 교재 해당 페이지로 즉시 복귀.

#	항목	통과 기준 (4점 이상)	교재 복귀	자가 점수
A1	파이프라인 5단계를 순서대로 말할 수 있다	수집·전처리·분석·시각화·보고	§05 파이프라인 개요	
A2	Vibe 루프 4단계를 예로 설명할 수 있다	사양서·실행·관찰·수정	§08 Vibe 루프	
A3	데이터 사전 10열 구조를 만들 수 있다	이름·타입·단위·범위·특이사항 포함	§13 데이터 사전	
A4	차트 왜곡 5유형을 지적할 수 있다	Y축·이중축·색상·범위·집계 왜곡	§19 차트 왜곡	
A5	상관과 인과를 구분해 서술할 수 있다	인과 단정어 금지 · 경계 병기	§24 인과 규칙	
A6	README 8항목을 열거할 수 있다	목적·입력·실행·환경·출력·가정·테스트·이력	§27 README	
A7 ★	BIG WIN 4개 산출물을 이름 없이 재현할 수 있다	사전·방침·차트명세·상관해석 리포트	§28 DAY 2 BIG WIN	

현장에서 가장 많이 나오는 질문 5.

답의 근거는 **교재 참조**. 여기는 판단의 방향만.

Q1

개발자가 아닌데 **Vibe Coding**이 가능한가?

가능. 사양서 · 관찰 · 판단은 사람 몫. 다만 **"돌아가는 코드"**와 **"옳은 코드"**의 차이는 검수 기준으로 배워야 합니다.

Q2

이상치는 자동 제거해도 되는가?

아니오. **삭제는 도메인 판단**. AI는 **라벨링만** · 처리 방침 표에 담당자 결정 기록.

Q3

에러가 났는데 원인을 모르겠다.

에러 메시지를 **그대로 복사**해 AI에 붙여넣기 → 상황·환경 정보 함께 → 기대값 **vs** 실제값을 함께 첨부.

Q4

데이터에 개인정보가 있으면?

DAY 1 §18 민감도 **5등급** 참조. 3등급 이상은 **치환/범위/구조 분리** 마스킹 후 투입.

Q5 ★

"AI가 만든 코드"는 회사 자산인가?

네 — 단, 패키지 **4대 요소**(사양서 · 코드 · README · 회귀 테스트)를 모두 갖췄을 때. 그 전까지는 개인 메모. 사내 리포지토리 · 버전 규칙 · 검수 절차가 있어야 자산으로 편입됩니다. DAY 5 워크플로우 · DAY 6 에이전트의 **"분석 노트"**로 재사용되기 위한 최소 조건.

10문항 · 4점 이상이면 다음 파트로.

정답 · 해설은 교재 부록 A. 여기는 문항만.

A · 개념 (Q1~Q5)

Q1. 파이프라인 5단계를 순서대로.

Q2. Vibe 루프 4단계 중 사람 몫 vs AI 몫 구분.

Q3. "데이터 사전"이 계약서인 이유 2가지.

Q4. 상관계수가 -0.42 일 때 서술 규칙 3가지.

Q5. BIG WIN 4대 산출물은?

B · 적용 (Q6~Q10) ★

Q6. 결측률 4.2% 발견 → 다음 3단계 조치.

Q7. "정비 횟수 ↑ 고장 ↑" 서술 → 오독 유형 지적.

Q8. merge 후 행수가 원본의 3배 → 원인 · 대책.

Q9. 이중축 그래프 발표 시 오해 방지 3장치.

Q10. README 8항목 중 "질문 노트"가 왜 중요한가?

4점 이하 시 · 교재의 해당 대단원을 다시 → 실습 로그 재작성 → 다음 DAY 진입.

4개 실습 · 산출물 · 검수.

교재 실습 기록지 양식에 이 표를 그대로 옮겨 · 팀 리뷰 · 리포지토리 커밋.

ID	실습명	사양서 (입력)	산출물 (출력)	검수 포인트
2-1	전처리 스크립트	데이터 사전(10열) + 품질 리포트 + 처리 방침 표(8행)	preprocess.py · 결측·이상·중복 처리 완료 · 사전에 없는 열 raise · 원본 vs 정제 행수 log 남김	
2-2	KPI 차트 10종	차트 명세표(C1~C10) + 정제 데이터	charts/*.png · 각 차트에 답할 질문 1문장 축 · 단위 · 기준선 · 이중축 명시	
2-3 ★	상관 · 회귀 리포트	가설 3쌍 (H1·H2·H3) · 유의수준 · 통제 변수	correlation_report.md · r · p · CI + "말할 수 인과 단정어 0건 · 경계 명시 없는 것"	
2-4 ★★	스크립트 패키지	2-1 ~ 2-3 산출물 + README 요구사항	package/ (6~8 파일) + README(8항목) + 신규자 30분 재실행 · 결과 일치 tests/ + 회귀 통과	

DAY 3 · Preview

고도화된 텍스트 마이닝 및 정보 추출.

다루는 문제

계약서 · 하자 리포트에서
정확히 뽑아 표로 만듭니다.

- 비정형 텍스트 → 정형 스키마
- JSON · CSV · 표 · 근거 인용 강제
- 프롬프트 = 추출 스펙

DAY 3 BIG WIN ★

계약서 자동 추출
시스템.

- 계약서 5부 구조 · 추출 스키마 12필드
- 근거 페이지 인용 · 오추출 유형 8종
- **DAY 5** 워크플로우의 추출 노드로 편입

DAY 2의 데이터 사전이 DAY 3의 추출 스키마가 됩니다 — 사양서 문화는 이어집니다.

데이터가 자산이 되는 세 번째 조건.

코드가 있어도 **README**가 없으면 자산이 아닙니다.
재현 테스트가 있어야 **개정**이 시스템이 됩니다.

DAY 2 · 완료 · Next: DAY 3 · 텍스트 마이닝 & 정보 추출