

Spark — 클러스터 확인 · 작업 제출

5주차의 분산 처리 엔진입니다. 5-2 의 compose(apache/spark:3.5.3, 마스터 spark-master + 워커 2개)로 띄운 상태를 기준으로 합니다. 마스터 웹 화면은 <http://localhost:8080> 입니다.

워커가 붙었나

```
curl -s http://localhost:8080/json/ | python3 -c "import sys,json;d=json.load(sys.stdin);p=bash
rint(d['status'], d['aliveworkers'], d['cores'])"
```

ALIVE 2 4

text

마스터 상태 ALIVE, 살아 있는 워커 2개, 코어 합계 4개(워커당 --cores 2)입니다. 웹 화면 「Workers」 칸과 같은 값입니다.

예제 작업 제출 — SparkPi

```
docker exec spark-master /opt/spark/bin/spark-submit \
  --master spark://spark-master:7077 \
  --class org.apache.spark.examples.SparkPi \
  /opt/spark/examples/jars/spark-examples_2.12-3.5.3.jar 10 2>/dev/null | tail -1
```

bash

Pi is roughly 3.141279141279141

text

내 파이썬 작업 제출

```
# job.py - 클러스터에서 도는 가장 작은 PySpark 작업
from pyspark.sql import SparkSession
spark = SparkSession.builder.appName("hello-job").getOrCreate()
df = spark.range(1, 1_000_001) # 1 ~ 1,000,000
print("합계:", df.selectExpr("sum(id)").first()[0])
print("파티션 수:", df.rdd.getNumPartitions())
spark.stop()
```

python

```
docker cp job.py spark-master:/tmp/job.py
docker exec spark-master /opt/spark/bin/spark-submit --master spark://spark-master:7077 /tmp/j
ob.py 2>/dev/null
```

bash

합계: 500000500000
파티션 수: 2

text

자주 쓰는 명령

명령	하는 일	확인한 결과
docker exec spark-master /opt/spark/bin/spark-sql --master spark://spark-master:7077 -e "SELECT 1 + 1 AS two"	SQL 한 줄 바로 실행	2

명령	하는 일	확인한 결과
<code>docker compose up -d --scale spark-worker=3</code>	워커 늘리기	aliveworkers 3
<code>docker compose logs --tail 2 spark-worker</code>	워커가 마스터에 붙었는지	Successfully registered with master
<code>docker logs spark-master grep "Registering worker"</code>	마스터 쪽에서 본 워커	with 2 cores, 2.0 GiB RAM

짚을 점

- `spark-submit` 의 `2>/dev/null` 은 진행 로그(INFO)를 숨겨 결과만 보려는 것입니다. 작업이 실패할 때는 이걸 빼고 다시 실행해 오류를 봅니다.
- 파이썬 파일은 컨테이너 안에 있어야 합니다. `docker cp` 로 넣거나, `compose` 에 볼륨을 붙여(volumes) 둡니다.
- `--master` 를 빼면 클러스터가 아니라 그 컨테이너 혼자(local) 돌고, 웹 화면 「Running Applications」에 나타나지 않습니다.

데이터 엔지니어링 & RAG 파이프라인 · 부록 — 서버 주소(SERVER_IP)·계정(devuser)·비밀번호(CHANGE_ME...)는 자리표시입니다. 본인 환경의 값으로 바꿔 쓰세요.