

2-5 · Python 기반의 크롤러 · 이론 1H

웹 크롤링 원리와 크롤링 예절

요청과 응답, 그리고 남의 가게에 들어가는 예절

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1시간 뒤에는

- ① HTTP 요청-응답과 상태코드 200·403·429 의 대응을 말할 수 있다
- ② robots.txt 를 읽고 수집 가능 여부를 판단한다
- ③ CSS 선택자로 HTML 에서 원하는 요소를 고른다
- ④ fetch·parse·load 로 나누는 이유와 DB 중복 방지 원칙을 안다

다음 1H 실습에서 robots.txt 확인부터 한 페이지 파싱까지 직접 해 봅니다

1. 크롤러는 손님

크롤러는 남의 가게에 들어가는 손님



요청을 몰아치면 상대 서버에 장애를 일으킬 수 있다 — 회사에서는 이용약관까지 확인하는 것이 보통

예절을 어기면 가게(서버)에 부담을 주고 출입이 막힌다(차단) — 매너가 아니라 실무 요건

상태코드 — 크롤러가 할 일이 달라진다

상태코드	뜻	크롤러가 할 일
200	정상	본문을 파싱한다
301 / 302	주소가 옮겨졌다	requests 가 자동으로 따라간다
403	접근 거부	차단됐을 수 있다 — 멈추고 확인
404	없는 페이지	건너뛰고 로그에 남긴다
429	너무 많이 요청함	반드시 간격을 늘린다
5xx	서버 쪽 문제	잠시 쉬었다 재시도

크롤러가 URL 로 요청(request)을 보내면 서버가 HTML 문서를 응답(response)으로 돌려준다

요청에 꼭 넣는 세 가지

- 1 User-Agent — 나는 누구인가**
요청 헤더에 담는 표시 — 정체를 숨기지 말고 목적을 밝힌다
- 2 timeout — 무한정 기다리지 않게**
빠뜨리면 서버가 응답하지 않을 때 프로그램이 멈춰 버린다
- 3 raise_for_status() — 오류를 예외로**
200 이 아닌 응답을 예외로 바꿔 조용히 넘기지 않게 한다

429 가 보이면

**반드시 간격을
늘린다**

robots.txt — 문 앞의 안내문 네 줄

줄	뜻
User-agent: *	모든 크롤러에게
Disallow: /admin/	이 경로는 들어가지 않는다
Crawl-delay: 1	요청 사이 1초 쉬라는 권고
User-agent: BadBot / Disallow: /	특정 크롤러는 전부 금지

사이트 루트(example.com/robots.txt)에 있는 수집 규칙 안내문 — Disallow 경로는 수집하지 않는 것이 원칙

법이 아니라 약속이지만, 어기면 차단·분쟁의 근거가 된다

HTML 을 트리로 읽는다 — CSS 선택자 다섯 개

선택자	고르는 것
div.quote	class 가 quote 인 div 전부
span.text	class 가 text 인 span
div.tags a.tag	div.tags 안에 있는 a.tag 전부
a[href^="/tag/"]	href 가 /tag/ 로 시작하는 a
li.next a	next 인 li 안의 a — 다음 페이지

파싱 = HTML 문자열을 태그 트리로 해석 · BeautifulSoup 의 select() 에 선택자를 넣는다

선택자는 외우지 않는다 — F12 → 요소 우클릭 → 검사 → Copy selector 로 시작해 손으로 줄인다

한 함수에 다 넣기 vs 세 함수로 나누기

한 함수에 다 넣으면

짧지만 하나가 바뀔 때 전체를 다시 봐야 한다

- 요청·파싱·저장이 한 덩어리
- 사이트 구조가 바뀌면 전부 손댄다
- 따로 시험할 수 없다

VS

fetch · parse · load

각각 따로 고치고 따로 시험한다



6. 중복 방지

중복은 코드가 아니라 DB 가 막게 한다

- 1 크롤러는 같은 페이지를 다시 만난다**
재실행·여러 대 실행이 보통 — 파이썬에서 「이미 있는지」 검사하면 뚫린다
- 2 UNIQUE 제약 + INSERT IGNORE**
DB 가 거부하게 한다 — ON DUPLICATE KEY UPDATE 도 같은 역할
- 3 무엇이 「같은 것」인지가 설계**
여기서는 (저자, 본문)을 같은 명언으로 본다

과정 내내 반복

Iceberg 도
Kafka 도 같다

이 1시간에서 꼭 가져갈 것

- 1 수집 전에 robots.txt 를 확인하고, User-Agent 를 밝히고, 간격을 둔다
- 2 상태코드 429·403 이 보이면 멈추고 간격부터 늘린다
- 3 선택자는 개발자 도구에서 찾는다
- 4 fetch·parse·load 를 나누면 한 단계만 갈아 끼울 수 있다
- 5 중복 방지는 코드가 아니라 DB 제약으로 한다

2-5 · 이론 1H 마무리

다음은 requests·BeautifulSoup 실습 (1H)

robots.txt 확인을 코드의 첫 단계로 넣고, 한 페이지에서 명언 10건을 뽑아냅니다

✓ `pip install requests beautifulsoup4 pymysql`

✓ `check_robots.py` 로 수집 가능 여부 확인

✓ `fetch_raw.py` → `fetch_one.py` 로 받기와 해석 나누기

✓ 선택자를 일부러 틀려 `NoneType` 오류 겪기

준비할 것

de-mysql 기동 · 2-3 의 가상환경