

2-5 · Python 기반의 크롤러 · 실습 1.5H

수집 파이프라인 구축 — 크롤링 데이터 DB 적재

세 함수로 나누고, 재실행해도 saved 0

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1.5시간 뒤에는

- ① quotes 표에 UNIQUE(author, quote_text) 제약을 건다
- ② fetch·parse·load 세 함수로 3페이지 30건을 적재한다
- ③ 한 번 더 실행해 saved 0 — DB 제약이 중복을 막는 것을 본다
- ④ 재시도·백오프를 붙이고 없는 주소로 일부러 실패시킨다

파이썬 코드에 중복 검사 로직이 한 줄도 없다는 점이 오늘의 핵심

여섯 단계 — 표 만들기부터 안전장치까지

mysql> 접속은 실습점검 3단계 명령 그대로 — SQL 은 거기서, 파이썬은 (.venv) 터미널에서

1. 표 만들기	2. 파이프라인	3. 재실행	4. SQL 검증	5.6. 안전장치·과제
CREATE TABLE UNIQUE KEY	fetch·parse·load run(max_pages=3)	saved 0 중복 방지 확인	COUNT(*) = 30 저자별 집계	재시도·백오프 일부러 실패


quotes 표 — 중복 방지를 DB 제약으로

필드	뜻
id INT AUTO_INCREMENT	기본키
author VARCHAR(100)	저자
quote_text TEXT	본문 — VARCHAR(500) 이면 긴 명언이 잘린다
tags VARCHAR(300)	태그 — 쉼표로 이어짐
crawled_at DATETIME	수집 시각
UNIQUE KEY uq_author_text	(author, quote_text(200)) — 같은 명언 거부

무엇이 「같은 명언」인지 정하는 것이 설계 결정 — 여기서는 (저자, 본문) · DESC quotes 로 확인

확인 포인트: DESC quotes 에서 author 의 Key 가 MUL — 복합 UNIQUE 의 첫 칸. quote_text(200) 은 앞 200자만 인덱스에

crawler_pipeline.py — 함수 세 개와 run()



확인 포인트: page 1~3 각각 parsed 10, saved 10 — 요청 셋 + 간격 1초 둘로 8초 안팎(실측 7.6초)

with ... as ... — 다 쓰고 나면 알아서 닫아라

1 with conn.cursor() as cur:
안쪽 블록을 벗어나는 순간 커서를 자동으로 닫는다

2 오류로 튕겨 나가도 닫힌다
직접 close() 를 부르면 오류 때 그 줄까지 못 가 연결이 남아 쌓인다

3 conn 은 try/finally 로 닫는다
드라이버마다 연결을 with 로 감쌌을 때 동작이 달라 명시적으로 닫는 편이 안전

파일 열 때도

with open
as f:

같은 명령을 한 번 더 실행하면

첫 실행

page 1~3 각각 parsed 10, saved 10

- python3 crawler_pipeline.py
- 30건이 quotes 표에 들어간다
- 8초 안팎 — 요청 간격 1초

VS

곧바로 한 번 더

parsed 10, saved 0 — DB 가 UNIQUE 로 거부

- 파싱은 똑같이 10건
- INSERT IGNORE 가 건너뛴 → 영향 행 0
- 파이썬 코드에 중복 검사 로직 0줄

적재 결과를 SQL 로 검증

쿼리	기대 결과
SELECT COUNT(*) FROM quotes	total 30 (3페이지 × 10건)
GROUP BY author ORDER BY cnt DESC LIMIT 5	저자별 집계 내림차순
SELECT author, tags ... LIMIT 3	tags 가 한 칸에 여러 값

cur.execute() 는 영향받은 행 수를 돌려준다 — INSERT IGNORE 로 건너뛰면 0, 더한 것이 saved

tags 「change,deep-thoughts,thinking」= 2-4 에서 배운 1NF 위반 — 심화 과제에서 quote_tags 교차 표로 고친다

재시도·백오프 — 없는 주소로 일부러 실패시킨다

새 파일이 아니다 — `crawler_pipeline.py` 의 `def fetch` 네 줄을 바꿔 넣는다. 없는 주소 시험은 15초 안팎

retries=3	429 면	RequestException	3번 다 실패	시험
for attempt in 1..3	5초 대기 후 continue	2·4·6초 갈수록 더 씬	RuntimeError 수집 실패	/no-such-page-xyz 예상대로 실패

이 1.5시간이 끝날 때 확인할 것

- 1 DESC quotes 에서 author 의 Key 가 MUL (복합 UNIQUE 의 첫 칸)
- 2 첫 실행: page 1~3 parsed 10 / saved 10, 8초 안팎
- 3 재실행: parsed 10 / saved 0 — 코드에 중복 검사 0줄
- 4 COUNT(*) 가 30, tags 는 쉼표로 이어진 1NF 위반
- 5 없는 주소는 2→4→6초 재시도 뒤 「예상대로 실패」가 찍힌다
- 6 미니 과제: max_pages=10 → 100건 · 접속 정보 상수로 · failed.log

2-5 · 실습 1.5H 마무리

다음은 주차 산출물 정리 (0.5H)

2-4 의 ERD 설계서와 오늘의 크롤러 소스를 README 와 함께 묶어 제출합니다

✓ Is 로 제출 파일 네 개 확인

✓ .gitignore 에 .venv/ · __pycache__/

✓ README 다섯 절 채우기

✓ 2주차 되짚기와 3주차 정돈

가져갈 것

crawler_pipeline.py 완성본