

2-5 · Python 기반의 크롤러 · 정리·회고 0.5H

주차 산출물 정리 — ERD 설계서 + 크롤러 소스

두 가지를 묶어 제출하고, 한 주를 되짚는다

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

30분 뒤에는

- ① 제출 파일 네 개를 ls 로 확인하고 .gitignore 를 만든다
- ② README 만 보고 남이 재현할 수 있게 다섯 절을 채운다
- ③ 2주차 다섯 차시에서 남은 결과물을 한 표로 되짚는다
- ④ 3주차 폴더를 만들고 de-mongo 를 정지한다

제출은 사이트 「산출물 제출」에서 — 마감 10-08(목) 23:59, 그 뒤 주차별 산출물 갤러리에도 공유

제출할 것

두 가지 — ~/data-eng/week2 에서 Is

① ERD 설계서

01

ERD_설계서.md 또는 이미지 + 설명 문서
엔터티 · 관계 · 정규화 근거 · 반정규화

② 크롤러 소스

02

check_robots.py · README.md
crawler_pipeline.py

가상환경 폴더는 제출에서 뺀다 — echo '.venv/' > .gitignore 그리고 __pycache__/ 도 한 줄 더

README 다섯 절 — 남이 재현할 수 있게

절	적을 것
1. ERD 설계서	표 4개 · N:M 을 order_items 로 해소
2. 크롤러	fetch→parse→load · 예절 3가지 · UNIQUE + INSERT IGNORE
3. 실행 방법	docker start → venv → pip install → 스크립트 2개
4. 검증한 것	첫 실행 30건 · 재실행 saved 0 · COUNT(*) 30
5. 남은 개선점	tags 1NF 위반 → quote_tags 분리 + 본인이 찾은 것

README 만 보고 다른 사람이 처음부터 재현할 수 있으면 완성 — 5번에 스스로 찾은 것을 한 줄이라도

다섯 차시 — 배운 것과 남은 결과물

차시	배운 것	남은 결과물
2-1	RDBMS 기본과 SQL 네 가지	de-mysql 컨테이너 · products 표
2-2	CTE 와 Window Function	monthly_sales 표 · 분석 쿼리
2-3	문서 DB 와 aggregate	de-mongo 컨테이너 · 로그 1,000건
2-4	정규화와 ERD 설계	customers · orders · order_items 표
2-5	수집 파이프라인	quotes 표 · 크롤러 소스

한 주를 관통한 생각: 데이터를 어디에, 어떤 모양으로 담을 것인가 — 3주차부터는 담은 데이터를 다룬다

여덟 개를 스스로 확인해 보세요

- 1 상태코드 200·403·429 의 뜻과 대응을 말할 수 있다
- 2 robots.txt 확인·User-Agent·요청 간격을 코드에 넣었다
- 3 선택자가 틀렸을 때의 NoneType 오류를 겪고 방어 코드를 썼다
- 4 다음 페이지 링크가 None 이면 순회를 끝내게 했다
- 5 수집·정제·적재를 함수 3개로 분리했다
- 6 재실행 시 saved 0 으로 DB 제약의 중복 방지를 확인했다
- 7 재시도·백오프를 붙이고 일부러 실패시켜 확인했다
- 8 ERD 설계서 + 크롤러 소스를 산출물 형식으로 정리해 제출했다

증상으로 찾는 원인과 해결

증상	원인	해결
'NoneType' object has no attribute	선택자에 걸리는 요소 없음 (오타 · 구조 다름)	F12 로 HTML 재확인 · None 검사 후 건너뛰기
OperationalError (2003) Can not connect	de-mysql 꺼짐 또는 호스트·포트 다름(3307)	docker ps 로 PORTS 확인 · host·port 맞추기
글자 깨짐 · Incorrect string value	연결·테이블 문자셋이 utf8mb4 가 아님	charset=utf8mb4 · SHOW CREATE TABLE
실행할 때마다 건수가 늘어난다	UNIQUE 없음 또는 INSERT IGNORE 아님	SHOW CREATE TABLE quotes 로 UNIQUE 키 확인

중복 방지를 파이썬 쪽 검사로 옮기는 것은 해결책이 아니다 — 이론에서 본 원칙 그대로

자주 나오는 질문 네 가지

1 자바스크립트로 그려지는 페이지는?

requests 는 HTML 만 받는다 — Selenium·Playwright 가 필요하지만 무거우니 먼저 그 사이트의 API 를 찾는다

2 로그인이 필요한 페이지는?

requests.Session 으로 로그인 후 쿠키 유지 — 다만 그 데이터는 이용약관 제약이 훨씬 강하다

3 차단당하면?

우회하지 말고 멈춘다 — 간격을 늘리고, 그래도 막히면 그 사이트는 수집을 원하지 않는 것

4 매일 자동으로 돌리려면?

1-2 의 cron 이 가장 단순 — 8주차 Airflow 로 제대로 스케줄링

다음 회차 예고

3-1 · Pandas 를 활용한 데이터 처리

01

이론 1H

Pandas 기초와
데이터 구조

02

실습 1H

데이터 불러오기와
저장

03

실습 1.5H

선택 · 필터 · 변환

04

정리 0.5H

핵심 요약 ·
체크리스트 점검

준비: Python 3.11 이상 · venv 를 만들 수 있는 상태 · 2주차 수집 데이터가 없어도 시드 고정 생성 스크립트로 진행

2-5 · 정리·회고 0.5H 마무리

다음 회차는 3-1 Pandas

답은 데이터를 다루는 쪽으로 — Series·DataFrame, CSV·Parquet, loc·iloc 와 파생 컬럼까지

✓ Series·DataFrame 구조와 dtype

✓ CSV·Parquet 읽고 쓰기 · 두 형식 비교

✓ loc·iloc·불리언 인덱싱으로 행·열 고르기

✓ 시드 고정 실습 데이터 orders.csv 생성

준비할 것

de-mongo 정지 · week3 폴더 생성