

3-1 · Pandas를 활용한 데이터 처리 · 이론 1H

Pandas 기초와 데이터 구조

표를 한 번에 다루는 도구 — 구조·타입·형식

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기


1시간 뒤에는

- ① Series·DataFrame·인덱스의 관계와 dtype 의 뜻을 설명한다
- ② 조건은 & | 와 괄호로 잇고, and·or 가 안 되는 이유를 안다
- ③ loc(이름표)와 iloc(위치)를 구별하고 범위의 끝 포함 여부를 안다
- ④ CSV 와 Parquet 를 타입 보존·크기·열 읽기로 비교한다

다음 1H 실습에서 orders.csv 를 만들어 날짜가 문자열로 읽히는 것을 직접 봅니다

1. Pandas 의 자리

ETL 의 가운데 Transform 을 말한다



Pandas = 파이썬에서 표 형태의 데이터를 다루는 표준 도구

2-5 크롤러의 parse 는 값을 하나씩 리스트에 담았다 — 수천·수만 건이면 표 전체를 한 번에 다루는 도구가 필요하다

같은 일 — 순수 파이썬과 Pandas

하려는 일	순수 파이썬	Pandas
조건에 맞는 행 고르기	for 반복 + if	df[df['price'] > 10000]
열 하나의 평균	합계 변수 + 카운트	df['price'].mean()
그룹별 집계	dict 로 직접 누적	df.groupby('category').sum()
두 표 붙이기	중첩 반복문	pd.merge(a, b, on=...)

반복문으로 한 건씩 돌리던 일이 표 전체에 대한 한 줄이 된다

2. 구조

DataFrame · Series · 인덱스 — 학급 명렬표로

1 DataFrame — 엑셀 시트 같은 2차원 표
한 줄(행)이 학생 한 명, 각 칸(열)이 이름·키·반 같은 항목

2 Series — 세로 한 줄(열 하나)
명렬표에서 키 열만 뜯어낸 것

3 인덱스 — 각 행에 붙은 이름표
기본은 0, 1, 2... 이지만 날짜나 ID 로 바꿀 수도 있다

기억할 것

열 하나 →
Series

DataFrame 은 결국 「같은 인덱스를 공유하는 Series 여러 개」 — 열 하나만 뽑았을 때 Series 가 나오는 이유

3. dtype

dtype — 얼마나 붙는 자료형 딱지

dtype	무엇	틀렸을 때 생기는 일
int64	정수	—
float64	실수 (결측 NaN 을 담을 수 있다)	결측이 생긴 정수 열은 여기로 바뀐다
object	문자열 (또는 섞인 것)	'10' > '9' 가 False 가 된다
datetime64[ns]	날짜·시각	문자열이면 날짜 비교·월별 집계 불가
category	정해진 몇 가지 값	메모리를 크게 아낄 수 있다
bool	참·거짓	—

정수 열에 NaN 이 하나라도 생기면 int64 → float64 — 1000 이 1000.0 으로 보이는 것은 버그가 아니라 정상 동작

4. 불리언 인덱싱

조건으로 행 고르기 — True 인 행만 남긴다

1 조건식이 True/False 목록을 만든다
`mask = df['price'] > 100000` → 0 False, 1 True, ...

2 대괄호에 넣으면 True 인 행만 남는다
`df[mask]` — 출석부에서 지각한 학생만 형광펜으로 뿔뿔

3 조건을 여러 개 잇기
`(df['price'] > 100000) & (df['quantity'] >= 3)`

쓰면 안 되는 것

and · or

→ & · |

우선순위 때문에 각 조건을 반드시 괄호로 감싼다 — 빼면 엉뚱한 곳에서 오류가 나 원인을 찾기 어렵다

5. loc 와 iloc

loc 는 이름표, iloc 는 위치 번호

loc — 이름표

인덱스 값.열 이름으로 고른다 — 범위는 끝을 포함

- `df.loc[0, 'price']`
- `df.loc[0:2]` — 끝을 포함
- `df.loc[조건, ['a','b']]` — 조건과 함께

VS

iloc — 위치 번호

0 부터 세는 위치로 고른다 — 범위는 끝을 제외

- `df.iloc[0, 3]`
- `df.iloc[0:2]` — 끝을 제외
- 조건은 못 쓴다

6. 파일 형식

CSV 와 Parquet — 무엇이 다른가

항목	CSV	Parquet
저장 방식	텍스트, 행 단위	이진, 열 단위
타입 보존	안 됨 — 전부 문자열로 저장	됨 — dtype 이 파일에 함께
크기	큼	보통 1/5 ~ 1/10 (열별 압축)
일부 열만 읽기	불가 — 전체를 읽어야 함	가능 — 필요한 열만
사람이 열어 보기	메모장으로도 됨	전용 도구 필요
쓰는 곳	주고받기·처음 받는 원본	중간 산출물·분석용 저장

밖에서 받는 것은 CSV 일 수 있지만, 내가 저장하는 중간 산출물은 Parquet — 4주차 레이크하우스도 5주차 Spark 도 Parquet

이 1시간에서 꼭 가져갈 것

- 1 DataFrame 은 같은 인덱스를 공유하는 Series 들의 모음이다
- 2 dtype 은 열마다 붙고, 틀리면 그 열의 계산이 전부 어긋난다
- 3 조건은 & | 로 잇고 각 조건을 괄호로 감싼다 — and·or 는 안 된다
- 4 loc 는 이름표, iloc 는 위치 번호 — loc 의 범위는 끝을 포함한다
- 5 CSV 는 타입을 저장하지 않고, Parquet 는 저장한다

3-1 · 이론 1H 마무리

다음은 데이터 불러오기와 저장 실습 (1H)

3주차 내내 쓸 orders.csv 를 시드 고정으로 만들고, 읽어서 첫인상을 파악하는 순서를 몸에 익힙니다

✓ **venv 만들고 pandas·pyarrow 설치**

✓ **make_orders.py 로 1015행 생성**

✓ **shape·dtypes·head·info·describe 5종 세트**

✓ **Parquet 로 저장해 크기·열 읽기 비교**

준비할 것

Python 3.11 이상 · 터미널에서 venv 가능