

3-1 · Pandas를 활용한 데이터 처리 · 정리·회고 0.5H

정리·회고

오늘 쓴 문법을 한 장으로, 3-2 파일을 확인

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

30분 뒤에는

- ① 오늘 쓴 Pandas 문법을 「하려는 일 → 코드 → 주의」로 정리한다
- ② 3-2 가 쓸 orders_step1.parquet 의 shape·열·날짜 타입을 확인한다
- ③ 자주 겪는 오류 네 가지의 원인과 해결을 안다
- ④ 3-2 Pandas 데이터 분석의 준비물을 안다

orders_step1.parquet 가 (1015, 10) 이고 order_date 가 datetime64[us] 면 오늘 목표 달성

Pandas 요약 — 읽기 · 보기 · 고르기

하려는 일	코드	주의
읽기	read_csv · read_parquet	CSV 는 타입이 안 살아난다
첫인상	shape · dtypes · head · info	받자마자 하는 습관
열 하나 / 여럿	df['a'] · df[['a', 'b']]	대괄호 겹수에 주의
조건 필터	df[(조건1) & (조건2)]	and·or 대신 & , 괄호 필수
이름표로 선택	df.loc[조건, ['a', 'b']]	범위가 끝을 포함
위치로 선택	df.iloc[0:3]	범위가 끝을 제외
값 목록·분포	unique() · value_counts()	오염을 찾는 데 유용

loc 의 범위는 끝을 포함, iloc 은 제외 — 조건과 열 목록을 함께 쓰는 쪽은 loc

Pandas 요약 — 정리 · 변환 · 저장

하려는 일	코드	주의
공백 제거	<code>df['a'].str.strip()</code>	문자열 열은 받자마자
타입 변환	<code>pd.to_datetime(df['d'])</code>	날짜는 반드시 변환 후 사용
파생 열	<code>df.assign(amount=df.a * df.b)</code>	체이닝에 유리
날짜 부품	<code>df['d'].dt.year · dt.month</code>	datetime 일 때만 가능
결측 보기·처리	<code>isna().sum() · dropna() · fillna()</code>	0 으로 채우지 말 것
정렬	<code>df.sort_values('a')</code>	<code>ascending=False</code> 는 내림차순
저장	<code>to_parquet('f.parquet', index=False)</code>	중간 산출물은 Parquet

정렬은 `sort_values('a', ascending=False)` 로 내림차순 — 미니 과제의 상위 10건이 이 형태

다음 차시(3-2)를 위한 확인

~/data-eng/week3 에 네 파일이 있는가

1 `cd ~/data-eng/week3 · ls -lh`
make_orders.py · orders.csv · orders_raw.parquet · orders_step1.parquet

2 `d = pd.read_parquet('orders_step1.parquet')`
d.shape → (1015, 10) 안팎

3 `d.columns.tolist()`
amount · year · month · weekday 가 들어 있다

4 `d['order_date'].dtype`
datetime64[us] — 3-2 에서 이어 쓸 준비 완료

기대 shape

1015 행

10 열 안팎

여덟 개를 스스로 확인해 보세요

- 1 DataFrame·Series·인덱스·dtype 의 관계를 설명할 수 있다
- 2 orders.csv(1015행)와 orders_step1.parquet 를 생성했다
- 3 shape·dtypes·head·info 로 첫인상을 파악하는 순서를 익혔다
- 4 결측 때문에 int64 가 float64 로 바뀌는 것을 확인했다
- 5 불리언 인덱싱과 loc 로 원하는 행·열을 골라냈다
- 6 str.strip() 을 빼면 20건이 새는 것을 수치로 확인했다
- 7 to_datetime·assign·dt 로 변환하고 결측 세 방법을 실행했다
- 8 CSV 와 Parquet 의 타입 보존·크기 차이를 실행 결과로 확인했다

증상으로 찾는 원인과 해결

증상	원인	해결
read_csv 에서 UnicodeDecodeError	인코딩이 UTF-8 이 아님 (공공데이터는 CP949 가 많다)	encoding="cp949" 로 읽고 저장은 utf-8 로 통일
ChainedAssignmentError (pandas 2: SettingWithCopy)	df[조건][열] = 값 처럼 두 번에 나눠 접근	df.loc[조건, 열] = 값 한 번으로
to_parquet 에서 ImportError	Parquet 엔진 pyarrow 미설치	venv 활성화 상태에서 pip install pyarrow
truth value of a Series is ambiguous	and·or 로이었거나 괄호를 빼먹음	(조건1) & (조건2) 각 조건을 괄호로

pip list 로 설치 여부를 먼저 확인 · 부분집합을 계속 쓸 거면 .copy() 로 명시적 복사본을 만든다

자주 나오는 질문 네 가지

1 Pandas 로 몇 건까지 다룰 수 있나요?

메모리에 다 올려야 하므로 대략 수백만 행이 한계 — 그 이상은 3-3 의 DuckDB 나 5주차 Spark 로

2 df["a"] 와 df.a 는 같나요?

대개 같지만 열 이름에 공백이 있거나 메서드 이름과 겹치면(count) 점 표기가 안 된다 — 대괄호가 안전

3 원본을 안 바꾸고 작업하려면?

대부분의 메서드는 새 객체를 돌려주고 원본을 둔다 — inplace=True 는 쓰지 않는 편을 권한다

4 Parquet 를 사람이 열어 볼 방법은?

pandas 로 읽어 head() 하거나, 3-3 에서 배울 DuckDB 로 바로 SQL 질의

다음 회차 예고

3-2 · Pandas를 활용한 데이터 분석

01

이론 1H

그룹 집계·결합의
원리 · 조인 방식

02

실습 1.5H

그룹 집계와 피벗
결합과 재구조화

03

실습 1H

시계열과
기초 통계

04

정리 0.5H

핵심 요약
체크리스트 점검

준비: venv 활성화 + pandas·pyarrow · orders_step1.parquet 가 ~/data-eng/week3 에 있어야 — 없으면 3-1 실습 1H 2단계 + 1.5H 1·4·5·7 단계를 다시 실행

3-1 · 정리·회고 0.5H 마무리

다음 회차는 3-2 Pandas 데이터 분석

나흘 뒤 10-12(월) 3-2 — orders_step1.parquet 에 고객 마스터를 붙입니다. 그때까지 week3 파일 넷을 지우지 마세요

✓ groupby 분할-적용-결합과 명명 집계 agg

✓ pivot_table 로 두 축의 교차 요약표

✓ merge 결합 후 행 수를 검증하는 습관

✓ resample·rolling 으로 시간 단위 추세

준비할 것

orders_step1.parquet · venv 활성화