

3-2 · Pandas를 활용한 데이터 분석 · 이론 1H

그룹 집계·결합의 원리

묶고, 붙이고, 시간축으로 접는 세 동작의 원리

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① groupby 의 분할-적용-결합 세 단계를 말로 설명한다
- ② 명명 집계(agg)로 결과 열 이름을 내가 정한다
- ③ merge 의 how 네 가지를 SQL JOIN 에 대응시킨다
- ④ 조인에서 행이 불어나는 사고와 validate 를 안다

다음 1.5H 실습에서 키를 일부러 중복시켜 행이 불어나는 것을 직접 봅니다

1. groupby

groupby — 나누고, 계산하고, 모은다



2-1 에서 배운 SQL GROUP BY 와 같은 동작 — 도구만 바뀌었으니 그때 잡은 감각 그대로

1. groupby

명명 집계 — 결과 열 이름을 내가 정한다

방법 A — 리스트로 넘기기

열 이름이 두 겹(MultiIndex)으로 나온다

- `agg({'amount': ['sum', 'mean']})`
- 결과 열 ('amount', 'sum') · ('amount', 'mean')
- 다음 단계에서 계속 걸림돌

VS

방법 B — 명명 집계(권장)

한 겹, 이름도 내가 정한 대로

- `agg(orders=('order_id', 'count'), ...)`
- `total=('amount', 'sum')`
- 결과 열 `orders · total · avg_price`

2. merge

merge — how 네 가지와 SQL JOIN

how	남는 것	SQL 로 치면
inner (기본)	양쪽 다 있는 키만	INNER JOIN
left	왼쪽 전부 + 짝이 있으면 오른쪽	LEFT JOIN
right	오른쪽 전부	RIGHT JOIN
outer	양쪽 전부	FULL OUTER JOIN

파이프라인에서는 left 를 가장 많이 쓴다 — 원본 행은 잃지 않고, 붙일 수 있는 정보만 붙인다

2. merge

조인에서 행이 불어나는 사고 — 오류도 나지 않는다

1

키가 한쪽에서 중복되면

한 행이 여러 행과 짝지어져 행이 불어난다 — 오류는 하나도 없다

2

부풀려진 SUM · COUNT

2-4 의 COUNT(DISTINCT) 문제와 같다 — 잘못된 숫자를 보고하게 된다

3

최소한의 방어

결합 전후 행 수 비교 · validate='many_to_one' 이면 즉시 오류

규칙 한 줄

조인했으면

행 수 확인

validate 값: 'one_to_one' · 'one_to_many' · 'many_to_one' · 'many_to_many' — 오류로 멈추는 것이 틀린 숫자보다 낫다

pivot_table — 두 축의 교차표

인자	뜻
index	행 축이 될 열
columns	열 축이 될 열
values	칸을 채울 값
aggfunc	어떻게 접을지 (sum · mean · count)
fill_value	조합이 없는 칸을 무엇으로 채울지

피벗은 재배열할 뿐 총합을 바꾸지 않는다 — 「교차표 총합 == 원본 총합」으로 실수를 잡는다

4. resample

resample — 시간 단위로 다시 담기

빈도 문자	단위
D	일
W	주 (일요일 기준)
ME	월말
h	시간
min	분

매일 쓴 용돈 기록을 주 단위로 합산해 보는 것과 같다

인덱스가 날짜 타입일 때만 된다 — set_index 로 먼저 올린다

4. resample

resample 은 접고, rolling 은 유지한다

resample — 시간 상자에 다시 담기

행이 접힌다 — 일·주·월 단위로 행 수가 줄어든다

- 빈도 문자 D · W · ME · h · min
- 날짜 인덱스일 때만 동작
- 결과 행 수 = 시간 상자 수

VS

rolling — 최근 N개의 평균

행 수를 유지한 채 창 평균을 옆에 붙인다

- 행 수는 그대로
- 「최근 N개의 평균」을 붙인다
- 2-2 의 Window Function 과 같은 발상

이 1시간에서 꼭 가져갈 것

- 1 `groupby` 는 나누고·계산하고·모은다 — 결과 행 수는 그룹 수와 같다
- 2 집계는 명명 집계 `agg(새이름=(열, 함수))` 로 쓴다
- 3 `merge` 는 대개 `how='left'` — 결합 전후 행 수를 반드시 비교한다
- 4 `validate='many_to_one'` 이 행 불어남을 오류로 잡아 준다
- 5 `pivot_table` 의 총합은 원본 총합과 같아야 한다
- 6 `resample` 은 접고, `rolling` 은 유지한다

3-2 · 이론 1H 마무리

다음은 집계·결합·피벗 실습 (1.5H)

3-1 산출물에 고객 마스터를 붙이고, 일부러 키를 중복시켜 행이 붙어나는 것을 직접 봅니다

✓ `make_customers.py` 로 고객 마스터 200명 생성

✓ 명명 집계로 카테고리별 요약

✓ `validate` 로 결합하고 전후 행 수 비교

✓ 지역×카테고리 교차표와 `melt·pivot`

준비할 것

`orders_step1.parquet` 와 `venv`