

3-2 · Pandas를 활용한 데이터 분석 · 실습 1.5H

그룹 집계와 피벗 · 결합과 재구조화

집계·결합·피벗을 쌓고, 단계마다 결과를 검증

수도권ICT 이노베이션스퀘어

데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1.5시간 뒤에는

- ① 고객 마스터를 만들고 명명 집계로 카테고리별 요약을 만든다
- ② `validate='many_to_one'` 로 결합하고 전후 행 수를 비교한다
- ③ 키를 일부러 중복시켜 행·합계가 부풀려지는 것을 본다
- ④ 지역×카테고리 교차표를 만들고 `melt·pivot` 으로 오간다

모든 단계에 「확인 포인트」가 있습니다 — 숫자가 맞는지 보고 다음으로

일곱 단계 — ~/data-eng/week3 한 폴더에서

3-1 에서 만든 orders_step1.parquet 가 있는 폴더에서 시작합니다

1. 마스터	2.3. 집계	4. 결합	5. 실패	6.7. 피벗
make_customers.py customers.csv	명명 집계 두 열로 묶기	merge + validate	중복 키로 행 분리기	교차표 melt · pivot

고객 마스터 생성 — 시드 고정

시드	<code>rng = np.random.default_rng(7)</code>
고객	<code>customer_id = np.arange(1, 201)</code>
region	서울 · 경기 · 부산 · 광주 중 무작위
joined	2025-01-01 + 0~364일
확인	orders (1015, ...) / customers (200, 3)

customers.csv 가 폴더에 생긴다 — orders 의 열 수는 3-1 에서 만든 파생 열 개수에 따라 다르다

명명 집계와 두 열 묶기 — 열 이름이 한 겹인가

1

명명 집계

orders.total.avg_price 세 열이 한 겹 — 카테고리 4종이 행으로

2

리스트 집계와 비교

agg({'amount': ['sum', 'mean']}) → 열 이름이 튜플 두 겹

3

두 열로 묶기

groupby(['category', 'month']) → reset_index() 로 평탄화

확인 포인트

열 이름이
한 겹인가

groupby 뒤 reset_index() 를 습관으로 — 인덱스에 값이 있으면 merge_to_parquet 에서 걸린다 (as_index=False 도 같은 효과)

4단계

주문과 고객을 결합 — 핵심 명령

읽기	<code>pd.read_csv('customers.csv', parse_dates=['joined'])</code>
결합	<code>df.merge(customers, on='customer_id', how='left', ...)</code>
선언	<code>validate='many_to_one'</code>
전후 행 수	<code>len(df) / len(m) → 1015 / 1015</code>
결측	<code>m['region'].isna().sum() → 0</code>

다대일 왼쪽 조인은 행이 늘지 않는다 — region 결측 0 이면 모든 주문이 고객 마스터와 연결된 것

고객 마스터에 중복을 심고 결합해 본다

이론에서 본 사고를 직접 일으킵니다 — validate 가 없을 때와 있을 때 무엇이 다른지

중복 심기	validate 없이	validate 주면	미리 확인
concat 으로 head(5) 붙임	행 수·합계 부풀려짐	MergeError 즉시 차단	duplicated() .sum()

같은 merge — 조용히 부풀거나, 그 자리에서 멈추거나

validate 없이

행 수 1015 초과, 매출 합계도 커진다 — 오류 0

- `bad = concat([customers, customers.head(5)])`
- `m_bad = df.merge(bad, on='customer_id', how='left')`
- `len(m_bad) > 1015` · amount 합계 부풀려짐

VS

validate='many_to_one'

MergeError — 잘못된 숫자 대신 멈춘다

- Merge keys are not unique in right dataset
- `bad['customer_id'].duplicated().sum()` → 5
- customers 쪽은 0 — 정상 마스터

교차표와 긴↔넓은 형태 — 핵심 명령

교차표	<code>pivot_table(index='region', columns='category', ...)</code>
검증	<code>pv.to_numpy().sum() == m['amount'].sum() → True</code>
건수 · 평균	<code>aggfunc='count' · 'mean'</code> — 건수 총합 1015
넓게 → 길게	<code>pv.reset_index().melt(id_vars='region', ...)</code> → 16행
길게 → 넓게	<code>long.pivot(index, columns, values).equals(pv) → True</code>

피벗은 재배열일 뿐 총합을 바꾸지 않는다 — 사람은 넓게, 프로그램은 길게

이 1.5시간이 끝날 때 확인할 것

- 1 orders (1015, ...) · customers (200, 3) · customers.csv 생성
- 2 summary 의 열 이름이 orders·total·avg_price 한 겹이다
- 3 결합 전후 행 수 1015 = 1015 · region 결측 0건
- 4 중복 마스터로는 행·매출이 불고, validate 는 MergeError
- 5 교차표 총합 == 원본 총합 True · long 16행 · equals True

3-2 · 실습 1.5H 마무리

다음은 시계열과 기초 통계 실습 (1H)

결합한 표 `m` 을 날짜 인덱스로 올려 일·주·월로 접고, `orders_enriched.parquet` 로 저장합니다

✓ `set_index('order_date').sort_index()`

✓ `resample('D')` 와 `rolling(7)` 행 수 비교

✓ `describe()` · `quantile()` 기초 통계

✓ `orders_enriched.parquet` 저장

가져갈 것

결합된 `m` (1015행) 이 살아 있는 세션