

3-2 · Pandas를 활용한 데이터 분석 · 실습 1H

시계열과 기초 통계

날짜 인덱스로 추세를 보고, 다음 차시용 파일로 저장

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① `order_date` 를 인덱스로 올려 `datetime64` 임을 확인한다
- ② `resample('D')` 와 `rolling(7)` 의 행 수 차이를 확인한다
- ③ `describe()` · `quantile()` 로 분포를 읽는다
- ④ `orders_enriched.parquet` 를 저장한다 — 3-4-3-5 의 입력

미니 과제 세 개까지 마치면 3-2 분석 문법을 한 바퀴 돈 것입니다

여섯 단계 — 결합한 m 에서 이어서

앞 실습에서 결합한 m(1015행) 이 세션에 남아 있어야 합니다

1. 인덱스	2. 일별	3. 주·월	4. 통계	5.6. 저장·과제
set_index sort_index	resample('D') rolling(7)	'W' · 'ME' count 합 1015	describe quantile	to_parquet 미니 과제 3개

날짜 인덱스와 일별 집계 — 핵심 명령

인덱스	<code>ts = m.set_index('order_date').sort_index()</code>
타임 확인	<code>ts.index.dtype → datetime64[ns]</code>
일별	<code>daily = ts['amount'].resample('D').sum()</code>
이동 평균	<code>weekly_trend = daily.rolling(7).mean()</code>
행 수	<code>len(daily) == len(weekly_trend) ← 같다</code>

기간 2026-06-01 ~ 07-30 안팎 — `sort_index()` 를 빼면 시계열 집계 결과가 어긋날 수 있다

resample 은 접고, rolling 은 유지한다 — 행 수로 확인

resample('D').sum()

하루 한 행으로 접힌다

- daily 행 수 = 날짜 수
- 'W' 주별 9~10행
- 'ME' 월별 2행 (6월 · 7월)

VS

rolling(7).mean()

행 수는 그대로, 앞쪽 6일은 NaN

- 창이 아직 안 찬 구간이 NaN
- 7번째부터 값이 나온다
- min_periods=1 이면 「7일 평균」이 아닌 값이 섞임

set_index 를 빼고 resample 해 본다

정리 시간의 「자주 겪는 오류」를 미리 겪어 둡니다 — 인덱스가 날짜 타입이 아닐 때

인덱스 없이	오류	원인	해결
<code>m['amount'] .resample('D')</code>	Only valid with DatetimeIndex	인덱스가 날짜 타입 아님	<code>to_datetime</code> → <code>set_index</code>

주·월 요약과 기초 통계 — 핵심 명령

주별	<code>ts['amount'].resample('W').sum()</code> → 9~10행
월별	<code>resample('ME').agg(['sum', 'mean', 'count'])</code> → 2행
기초 통계	<code>m[['price', 'quantity', 'amount']].describe()</code>
분위수	<code>m['amount'].quantile([0.25, 0.5, 0.75, 0.9, 0.99])</code>
지역별	<code>groupby('region')['amount'].agg(['mean', 'std', 'count'])</code>

월별 count 의 합이 1015 면 빠진 데이터가 없다 · price 의 count 가 작으면 3-1 결측 30건이 남은 것

평균만 보지 말고 — describe() 여덟 줄 읽는 법

1 describe() 여덟 줄

count · mean · std · min · 25% · 50% · 75% · max

2 평균과 중앙값(50%)을 함께

둘이 크게 다르면 한쪽으로 치우친 분포라는 뜻

3 매출 데이터의 습성

소수의 큰 주문이 평균을 끌어올린다

4 price 의 count 가 작다면

3-1 에서 심은 결측 30건이 아직 남아 있는 것

저장하고, 미니 과제 세 개

1 저장

`to_parquet('orders_enriched.parquet', index=False)` → 1015행

2 확인

열 목록에 `region·joined` 가 있으면 성공 — 3-4·3-5 의 입력

3 미니 과제 ①

고객별 주문 수·총 구매액·마지막 주문일 — 상위 10명

4 미니 과제 ②③

요일별 평균 매출(`weekday` 열) · 지역별 최다 카테고리

과제 ③ 힌트

groupby
.head(1)

이 1시간이 끝날 때 확인할 것

- 1 `ts.index.dtype` 이 `datetime64[ns]` · 기간 6-01 ~ 7-30 안팎
- 2 `daily` 와 `rolling` 의 행 수가 같고, 앞쪽 6개가 NaN
- 3 주별 9~10행 · 월별 2행 · 월별 count 합 1015
- 4 `describe()` 여덟 줄 — 평균과 중앙값을 함께 봤다
- 5 `orders_enriched.parquet` 1015행 · `region-joined` 포함

3-2 · 실습 1H 마무리

다음은 정리·회고 (0.5H)

분석 문법을 표 한 장으로 모으고, 산출물 파일을 확인한 뒤 3-3 DuckDB 를 예고합니다

✓ 분석 문법 요약표 10줄

✓ ls -lh 와 shape 로 산출물 확인

✓ 체크리스트 자가 점검

✓ 자주 겪는 오류 네 가지

가져갈 것

orders_enriched.parquet 저장 완료