

3-3 · DuckDB 로컬 대용량 데이터 처리 · 수업 전 10분

실습점검 · 환경재설정

3-2 의 파일과 duckdb, 디스크 여유 확인

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

3-3 은 3-2 의 파일과 duckdb 를 그대로 받는다

- ① orders_enriched.parquet 가 있는가 — (1015, 12) 0
- ② duckdb 가 들어 있는가 — 1.5.6, 3-2 정리 시간에 설치
- ③ 디스크 여유 1G 이상 — 오늘 만드는 파일은 합쳐 약 100MB
- ④ 오늘 만드는 파일과 실행 방법(이어 붙이기)을 미리 안다

duckdb 가 있으면 새로 설치할 것은 없다 — 도커도 없다

네 단계 — 지우는 것 없이 확인만

재설정(4단계)은 오늘 실습을 처음부터 다시 하고 싶을 때만

1 3-2 의 파일

ls · (1015, 12) 0

2 duckdb·디스크

1.5.6 · Avail 1G

3 오늘 만들 것

py 셋 · 이어 붙이기

4 재설정

오늘 것만 rm

파일·판·디스크 — 명령 넷으로 끝

폴더	<code>cd ~/data-eng/week3 · ls -lh</code>
켜기	<code>source .venv/bin/activate</code> — OS 셋 같다
파일	<code>python3 -c "... read_parquet('orders_enriched.parquet') ... shape, isna"</code>
판	<code>python3 -c "import sys, pandas as pd, duckdb; print(...)"</code>
디스크	<code>df -h ~</code> — Avail 이 1G 이상

확인 포인트: (1015, 12) 0 · 3.0.6 1.5.6 .../week3/.venv 한 줄 · Avail 1G 이상이면 시작

오늘 코드는 파일 셋 — 둘은 이어 붙인다

1 **make_events.py** — 1H 2단계, 단독으로 한 번
100만 행 events.csv 를 만든다

2 **query.py** — 1H 3~6단계를 이어 붙인다
블록을 파일 끝에 붙이고 매번 `python3 query.py`

3 **speed.py** — 1.5H 1~6단계를 이어 붙인다
`bench()` 는 3단계에서 정의 — 매번 `python3 speed.py`

4 **parted_again.py** — 일부러 실패, 단독
실측기록_3-3.md 는 편집기로 만든다

다시 돌리면

앞 단계 출력도
함께 나와 정상

오늘 만드는 파일 — 누가 만들고 누가 쓰나

파일	누가 만드나	누가 쓰나
events.csv	1H 2단계 make_events	오늘 전체(원본)
query.py	1H 3~6단계	오늘만
events.parquet	1.5H 1단계 speed.py	3-4 · 3-5 심화
speed.py	1.5H 1~6단계	오늘만
events_zstd 외 둘	1.5H 5단계	오늘만
events_parted/	1.5H 6단계	오늘만 · 3-4 심화
parted_again.py	6단계 뒤 일부러 실패	오늘만
실측기록_3-3.md	1.5H 7단계(편집기)	3-5 · 3주차 산출물

events.parquet 는 3-4 가 받는다 — 수업이 끝나도 지우지 않는다

막혔을 때

증상 → 원인 → 해결

증상	원인	해결
orders_enriched.parquet No such file	3-2 파일을 지웠다	make_customers.py · timeseries.py 다시 실행
No module named 'duckdb'	3-2 정리 때 설치를 못 했다	없을 때만 pip install duckdb
sys.prefix 가 .../week3/.venv 아님	다른 가상환경이 켜져 있다	deactivate 뒤 1단계부터 다시
WSL2 에서 속도가 몇 배 느리다	실습 폴더가 /mnt/c 아래	~/data-eng 처럼 우분투 홈에

WSL2 의 df -h ~ 는 우분투 가상 디스크 기준 — C: 가 거의 차 있으면 탐색기에서도 확인

오늘 것만 처음부터 — 3-1·3-2 파일은 남긴다

1 **rm -rf events_parted · rm -f 오늘 파일 아홉**
노트 4단계 명령 그대로 — events* 같은 와일드카드는 쓰지 않는다

2 **ls**
3-1·3-2 의 파일만 남으면 끝 — 1H 2단계부터 다시

3 **실측기록_3-3.md · .venv 는 지우지 않는다**
직접 쓴 기록과 가상환경은 그대로 둔다

내일 3-4

**이 폴더의
파일 넷을 받는다**

파이썬, 이만큼이면 됩니다

오늘 새로 나오는 문법 6가지 — W3Schools 로 연결

문자열

"""...""" 긴 SQL · 줄바꿈 \n · 칸 폭 f'{size:6.1f}'

숫자

1_000_000 — 밑줄은 읽기 쉽게, 값은 1000000

반복

for _ in range(rounds) · append 로 모아 sum / len

2-5 의 13가지 · 3-1 의 9가지 · 3-2 의 7가지에 이어진다 — SELECT·COPY 는 오늘 노트가 가르친다

3-3 · 수업 전 10분 마무리

다음은 이론 1H — DuckDB 개요와 열 지향 저장

(.venv) 가 켜진 터미널은 그대로 두세요. 1H 실습에서 바로 씁니다

✓ 서버가 없는 DB

✓ 행 지향과 열 지향

✓ Pandas 와의 분업

✓ 압축 방식 — zstd

켜 둘 것

(.venv) 터미널 · week3 폴더