

3-3 · DuckDB를 이용한 로컬 대용량 데이터 처리 · 실습 1H

파일 직접 질의 (CSV·Parquet)

100만 행 CSV 를 적재 절차 없이 SQL 로 바로

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① 3-2 정리 때 설치한 duckdb 판(1.5.6)을 확인한다
- ② 시드 고정 100만 행 events.csv 를 만들고 크기(41M)를 적는다
- ③ query.py 에 이어 붙이며 CSV 를 FROM 에 적어 바로 질의한다
- ④ .df() 로 결과를 받고, DataFrame 을 SQL 에서 참조한다

events.csv 크기(41M)는 다음 1.5H 에서 Parquet 와 비교하니 꼭 적어 두세요

여섯 단계 — ~/data-eng/week3 한 폴더에서 끝까지

make_events.py 는 단독으로 한 번, 3~6단계는 query.py 에 이어 붙여 매번 python3 query.py

1. duckdb 확인	2. 100만 행 생성	3. CSV 바로 질의	4.5. 구조·집계	6. Pandas 왕복
1.5.6 3-2 때 설치	make_events.py 단독 · 41M	query.py 시작 GROUP BY	DESCRIBE CTE·Window	.df() FROM 변수이름

판 확인과 데이터 생성 — 핵심 명령

폴더·venv	cd ~/data-eng/week3 && source .venv/bin/activate
판 확인	python3 -c "import duckdb; print(duckdb.__version__)"
없으면	No module named 'duckdb' 일 때만 pip install duckdb
생성	python3 make_events.py
크기 확인	ls -lh events.csv

시드 42 고정 — 누가 실행해도 같은 데이터 · 이 맥에서 4초 · 메모리가 빠듯하면 n 을 30만으로(노트 수치와 달라진다)

확인 포인트 — 서버를 띄운 적이 없는데 곧바로 쓸 수 있다

- 1 1.5.6 이 찍히면 준비 완료**
서버를 띄운 적이 없다 — 2주차 MySQL 은 컨테이너부터 띄웠다
- 2 「생성 완료: 1000000 행」**
event_id·user_id·event_type·value·ts 다섯 열, 60일치 이벤트
- 3 events.csv 41M (42,525,663 bytes)**
이 크기를 기록 — 1.5H 에서 Parquet 와 비교한다

적어 둘 것

events.csv
크기(MB)

적재 없이 CSV 를 바로 질의 — query.py

MySQL 과 다른 점

적재 두 단계

통째로 없음

1 FROM 'events.csv' ... GROUP BY event_type
CREATE TABLE 도 INSERT 도 없다 — 파일 이름을 duckdb.py 로 짓지 않는다

2 view 799932 · cart 150025 · buy 50043
생성 확률 0.8·0.15·0.05 그대로

3 DESCRIBE — ts 가 TIMESTAMP
3-1 의 pd.read_csv 는 문자열 — DuckDB 는 날짜를 알아서 잡는다

4 LIMIT 5 · count(*)
첫 줄 0 · 4463 · view · 5700 ... · 행 수 1000000

3단계 뒤 — 다른 폴더에서 돌려 IO Error 를 본다

경로는 「실행하는 폴더」 기준 — 오늘 가장 많이 만날 오류를 직접 냅니다

cd ~	다른 폴더에서 실행	IO Error	왜?	week3 로 복귀
week3 밖으로 나간다	python3 ~/data- eng/ week3/query.py	No files found that match the pattern	'events.csv' 를 ~ 에서 찾았다	cd 로 돌아오면 다시 이 오류엔 pwd 부터

조건과 집계 — 2-2 에서 배운 SQL 이 그대로 통한다

질의	확인 포인트
WHERE event_type = 'buy'	50043 건
WITH daily AS (... date_trunc('day', ts) ...)	CTE 가 그대로 동작
sum(total) OVER (PARTITION BY ... ORDER BY d)	buy 6행 — 4064300 → 8372100 ...
GROUP BY 1, 2	식이 길 때 반복을 줄인다

GROUP BY 1, 2 는 「SELECT 의 첫째·둘째 식으로 묶어라」 — DuckDB·PostgreSQL·MySQL 모두 되는 문법

Pandas 왕복 — .df() 와 FROM 변수이름

.df() — 결과를 DataFrame 으로

ORDER BY 를 넣는다 — 빼면 행 순서가 흔들린다

- duckdb.sql("... ORDER BY cnt DESC").df()
- <class 'pandas.DataFrame'> · 3행
- avg_value 5001.49 · 4996.51 · 4993.89

VS

FROM orders — 변수를 SQL 에서

파이썬 변수 이름을 FROM 에 그대로 적는다

- orders = pd.read_parquet('orders_enriched.parquet')
- FROM orders GROUP BY region
- 부산 276 · 경기 254 · 서울 235 · 광주 250

이 1시간이 끝날 때 확인할 것

- 1 duckdb 1.5.6 이 찍히고, 서버는 띄운 적이 없다
- 2 「생성 완료: 1000000 행」 · events.csv 41M 을 적어 두었다
- 3 view 799932 · cart 150025 · buy 50043 — 세 행
- 4 DESCRIBE 의 ts 가 TIMESTAMP · count(*) 1000000
- 5 다른 폴더에서 No files found 를 봤고 pwd 로 원인을 찾았다
- 6 .df() 가 DataFrame · FROM orders 로 지역 4행

3-3 · 실습 1H 마무리

다음은 대용량 변환 실습 (1.5H)

speed.py 한 파일에 이어 붙이며 CSV 를 zstd Parquet 로 바꾸고, 크기와 질의 속도를 직접 잽니다

✓ COPY ... TO 'events.parquet' (zstd)

✓ 크기 배율 · 질의 속도 배율

✓ 한 열 vs 다섯 열 — 일부러 틀린 비교부터

✓ 압축 3종 비교 · PARTITION_BY

가져갈 것

events.csv 41M 기록 · query.py