

3-3 · DuckDB 로컬 대용량 데이터 처리 · 정리·회고 0.5H

정리·회고

실측 수치를 나누고, DuckDB 문법을 한 장으로

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

30분 뒤에는

- ① 파일 크기 배율과 질의 속도 배율을 옆 사람과 비교한다
- ② DuckDB 문법 여덟 가지를 「하려는 일 → 코드」로 정리한다
- ③ 자주 겪는 오류 네 가지의 원인과 해결을 안다
- ④ 3-4 에 쓸 events.parquet 와 3-1.3-2 파일이 있는지 확인한다

노트북 사양에 따라 배율이 달라도 괜찮습니다 — 그 차이 자체가 이야깃거리

오늘 쟈 배율 두 가지 — 옆 사람과 비교

① 파일 크기 배율

01

events.csv 와 events.parquet(zstd)
getsize 로 쟈 MB 와 배율

② 질의 속도 배율

02

같은 집계 질의를 CSV·Parquet 에
bench 3회 평균으로 쟈 초와 배율

메모리·디스크 종류에 따라 차이가 크다 — 특히 SSD 인지 HDD 인지. 실측 표를 주차별 산출물 갤러리에 올려 두면 서로 참고하기 좋다

DuckDB 요약 — 하려는 일과 코드 여덟 줄

하려는 일	코드
파일 질의	duckdb.sql("SELECT ... FROM 'f.csv'")
구조 보기	DESCRIBE SELECT * FROM 'f.csv'
여러 파일	FROM 'data/*.parquet'
옵션 주기	FROM read_csv('f.csv', sample_size = -1)
DataFrame 으로 받기	duckdb.sql(...).df()
DataFrame 을 질의	FROM 파이썬변수이름
Parquet 로 내보내기	COPY (...) TO 'out.parquet' (COMPRESSION zstd)
파티션 저장	COPY (...) TO 폴더 (... , PARTITION_BY (열))

메모리 한도는 SET memory_limit = '4GB' — 정렬·조인 중간 결과가 넘칠 때

여덟 개를 스스로 확인해 보세요

- 1 DuckDB 가 서버 없이 도는 임베디드 분석 DB 임을 설명할 수 있다
- 2 행 지향과 열 지향의 차이를 서랍 정리 비유로 설명할 수 있다
- 3 100만 행 events.csv 를 생성하고 적재 없이 SQL 로 질의했다
- 4 2-2 의 CTE·Window 문법이 그대로 통하는 것을 확인했다
- 5 .df() 로 DataFrame 을 받고, 반대로 DataFrame 을 SQL 에서 참조했다
- 6 COPY 로 zstd Parquet 를 만들고 크기·속도를 실측해 기록했다
- 7 한 열만 vs 전부 읽기로 열 지향의 이유를 확인했다
- 8 PARTITION_BY 로 값별 폴더를 만들어 봤다

증상으로 찾는 원인과 해결

증상	원인	해결
IO Error No files found	파일 경로가 현재 작업 디렉터리 기준으로 없다	pwd·ls 로 위치 확인 확실치 않으면 절대 경로
CSV 열 타입이 이상하게 추론	앞부분 표본으로 추론 — 뒤쪽에 다른 형태가 섞임	read_csv(..., sample_size = -1) 또는 열 타입 직접 지정
대용량 질의 중 메모리 부족	정렬·조인 중간 결과가 메모리 한도를 넘음	SET memory_limit 명시 필요한 열만 SELECT
COPY ... TO 폴더 Directory is not empty	같은 경로에 이전 결과가 남아 있다	OVERWRITE_OR_IGNORE 또는 폴더 지우고 재실행

SELECT * 습관이 대용량에서는 그대로 비용 — 필요한 열만 SELECT 하도록 질의를 줄인다

자주 나오는 질문 네 가지

1 DuckDB 로 MySQL 을 대체할 수 있나요?

아니다 — 여러 사람이 동시에 쓰고 고치는 업무 처리는 MySQL, 혼자 크게 읽어 분석하는 쪽이 DuckDB

2 데이터를 파일로만 두나요?

`duckdb.connect("my.duckdb")` 로 `.duckdb` 파일에 테이블로 저장할 수도 있다 — 이번 과정은 파일 직접 질의

3 Spark 와는 뭐가 다른가요?

DuckDB 는 한 대, Spark 는 여러 대 — 한 대로 감당되는 수십 GB 면 DuckDB 가 훨씬 간단. 5주차에 그 경계

4 Parquet 를 사람이 열어 보려면?

DuckDB 로 SELECT 하면 된다 — 오늘 배운 방법이 곧 뷰어

다음 회차 예고

3-4 · DuckDB를 이용한 데이터 분석

01

이론 1H

SQL 분석 문법
집계·윈도·CTE

02

실습 1.5H

집계·조인 분석
윈도 함수와 CTE

03

실습 1H

Pandas 연동
분석

04

정리 0.5H

핵심 요약
체크리스트 점검

준비: venv + duckdb·pandas·pyarrow · 3-3 events.parquet · 3-1 orders_step1.parquet · 3-2 customers.csv 를 작업 폴더에

3-3 · 정리·회고 0.5H 마무리

다음 회차는 3-4 DuckDB 데이터 분석

SQL 로 질문하기 — 집계·조인·윈도 함수·CTE 를 익히고, DuckDB 와 Pandas 를 왕복하는 감각을 손에 익힙니다

✓ GROUP BY 집계와 파일 간 JOIN

✓ rank·누적 집계 — 윈도 함수

✓ CTE 로 질의를 읽기 쉬운 단계로

✓ 어떤 일은 SQL, 어떤 일은 Pandas

준비할 것

세 파일이 없으면 각 차시 생성 단계 먼저(시드 고정)