

3-4 · DuckDB 분석 · 수업 전 10분

실습점검 · 환경재설정

앞 세 차시가 남긴 파일 넷과 가상환경 확인

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

왜 점검하나

3-4 는 앞 세 차시의 파일 넷을 받는다

① 3-3 의 events.parquet · 3-1 의 orders_step1.parquet

② customers.csv · orders_enriched.parquet(3-2)

③ week3 가상환경 — pandas · duckdb · pyarrow 판 확인

④ 오늘 만드는 파일 — 이어 붙이기 둘, 단독 둘

오늘 새로 설치할 것은 없다 — 도커도 쓰지 않는다

네 단계 — 지우는 것 없이 확인만

재설정(4단계)은 오늘 실습을 처음부터 다시 하고 싶을 때만

1 파일 넷

ls -lh
events 1000000

2 venv·판

3.0.6 · 1.5.6
25.0.1

3 오늘 만들 것

py 넷
parquet 둘

4 재설정

오늘 것만 rm

파일 넷과 가상환경 — 명령 세 줄

폴더	<code>cd ~/data-eng/week3 · source .venv/bin/activate</code>
파일	<code>ls -lh events.parquet orders_step1.parquet customers.csv orders_enriched.parquet</code>
크기	<code>9.8M · 21K · 4.2K · 24K</code>
행 수	<code>SELECT count(*) FROM 'events.parquet' → 1000000</code>
판	<code>print(pandas.__version__, duckdb.__version__, pyarrow.__version__, sys.prefix)</code>

확인 포인트: ls 네 줄 · 1000000 · 3.0.6 1.5.6 25.0.1 .../week3/.venv — n 을 30만으로 줄였다면 300000

막혔을 때

없는 파일은 이렇게 되살린다

없는 파일	되살리는 곳
events.parquet	events.csv 있으면 3-3 1.5H 1단계 없으면 3-3 1H 2단계부터
customers.csv orders_enriched.parquet	3-2 1.5H 1단계 → 1H 의 timeseries.py
orders_step1.parquet	3-1 1H 2단계 + 1.5H 1·4·5·7단계

시드 고정이라 같은 파일이 나온다 · No module named 'duckdb' 면 pip install duckdb

오늘 만드는 파일 — 누가 만들고 누가 쓰나

파일	누가 만드나	누가 쓰나
sql_analysis.py	1.5H 1~7단계 이어 붙이기	오늘만
roundtrip.py	1H 1~4단계 이어 붙이기	오늘만
user_segments · segment_summary	1H 4단계 (Parquet 둘)	3주차 회고 표
df_cost.py	1H 5단계 단독	오늘만
funnel.py	1H 6단계 정답 예시	오늘만

코드 블록 첫 줄 주석이 파일 이름 — 이어 붙이는 파일은 단계마다 다시 돌린다

오늘 것만 처음부터 — 앞 차시 파일은 남긴다

- 1 rm -f 오늘 만든 파일 여섯 (py 넷 · parquet 둘)**
노트 4단계의 한 줄 명령 그대로
- 2 ls**
3-1-3-2-3-3 의 파일만 남으면 끝 — 1.5H 1단계부터
- 3 events* · orders_* · customers.csv · .venv 는 그대로**
지우면 앞 차시를 다시 돌려야 한다

내일 3-5

**orders.csv 를
다시 꺼낸다**

파이썬, 이만큼이면 됩니다

오늘 새로 나오는 문법 3가지 — W3Schools

float('inf')

어떤 수보다 큰 값 — 1H 1단계 등급 경계의 끝

q[0]

리스트 번호로 꺼내기 — 0 부터, 1H 1단계 분위기 경계

del 변수

다 쓴 큰 데이터를 놓아준다 — 1H 5단계 del big

오늘은 SQL 이 대부분이라 새 파이썬 문법이 적다

3-4 · 수업 전 10분 마무리

다음은 이론 1H — 집계·윈도 함수·CTE

(.venv) 가 켜진 터미널은 그대로 두세요. 실습 1.5H 에서 바로 씁니다

✓ 2-2 문법이 DuckDB 에서 그대로

✓ 윈도 함수 — 행을 줄이지 않는 계산

✓ QUALIFY 와 CTE

✓ .df() 는 줄인 다음에

켜 둘 것

(.venv) 터미널 · 파일 넷