

3-4 · DuckDB를 이용한 데이터 분석 · 실습 1H

Pandas 연동 분석

DuckDB 로 줄이고 Pandas 로 다듬는 왕복

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① 눈대중 경계가 전원 S 를 만드는 것을 보고 분위수로 고친다
- ② FROM top — 파이썬 변수를 SQL 이 곧바로 읽는다
- ③ SQL → Pandas → SQL 을 이어 세그먼트 3종을 만든다
- ④ 줄이기 전 .df() 의 시간·메모리를 실측해 규칙의 근거를 본다

100만 행을 Pandas 로 직접 다루지 않는다 — 오늘 실습의 한 줄 요약

여섯 단계 — 왕복을 한 번, 두 번, 여러 번

1~4단계는 roundtrip.py 에 이어 붙이기 · 5단계 df_cost.py · 6단계 funnel.py 는 단독

1. SQL → df	2. df → SQL	3. 왕복 잇기	4. 파일로	5.6. 비용·과제
top 100 → .df() pd.cut 등급	FROM top 등급별 요약	users → cvr → segment	to_parquet COPY ... TO	.df() 통째로 퍼널 전환율

등급 경계를 눈대중으로 정하면 — 전원 S

실패 — bins 15000 · 25000

상위 100명 spend 28700 ~ 44700

경계	[0, 15000, 25000, inf]
결과	S 100 · B 0 · A 0
이유	전원 28,700 이상

VS

해결 — 분위수 경계 grade2

quantile([0.33, 0.66]) 로 데이터에서

경계	[30200, 32800]
결과	B 34 · A 34 · S 32
이후	2단계부터 grade2 를 쓴다

반대 방향 — DataFrame 을 SQL 로

1 **SELECT grade2 AS grade, count(*), avg(spend) FROM top**
파이썬 변수 top 을 FROM 에 그대로 쓴다

2 **GROUP BY grade2 ORDER BY avg_spend DESC**
등급 3행 요약표가 DataFrame 으로 돌아온다

3 **S 32명 36343.75 · A 34명 31658.82 · B 34명 29476.47**
1단계의 grade 로 묶었다면 S 한 줄만 나왔을 것

완성

DuckDB ↔
Pandas 왕복

3단계

SQL → Pandas → SQL 을 이어 세그먼트 분석



high_intent 13486 · count(*) FILTER (WHERE 조건) 은 SUM(CASE WHEN 조건 THEN 1 ELSE 0 END) 과 같은 일을 짧게

browser 의 avg_spend 0.0 — 구매가 없어 NaN 인 spend 를 coalesce 가 0 으로 바꾼 결과

세그먼트 규칙과 저장 — 핵심 줄

단계	핵심 줄	뜻
② cvr	buys / views, fillna(0)	전환율 · round(3)
② segment	cvr >= 0.1 → high_intent	세밀한 규칙은 Pandas
② segment	buys == 0 → browser	구매 없으면 browser
④ Pandas 저장	users.to_parquet(...)	user_segments 약 480 KB
④ DuckDB 저장	COPY (SELECT * FROM seg) TO	segment_summary 0.6 KB

어느 쪽으로 저장하든 같은 Parquet — 크기는 행 순서에 따라 조금씩 달라진다

.df() 를 통째로 불러 본다 — 시간과 메모리

나쁜 예 — SELECT * 전체

1,000,000행이 통째로 DataFrame 으로

시간	1초 안쪽(0.3~0.9초)
메모리	42 MB
끝나면	del big

VS

좋은 예 — 집계 후

GROUP BY event_type 3행 뒤에 .df()

시간	0.01초
메모리	191 bytes
차이	메모리로 20만 배 넘게

미니 과제 세 가지 — 정답 예시는 퍼널

- 1 첫 구매일 → 주차별 사용자 수**
힌트: min(ts) FILTER, date_trunc
- 2 지역×카테고리 교차표**
orders_enriched.parquet 를 SQL 로 — PIVOT 또는 조건부 집계
- 3 view → cart → buy 퍼널**
각 단계 사용자 수와 다음 단계로 넘어간 비율
- 4 정답 예시 — funnel.py 단독**
viewed 50000 · carted 47525 · bought 31501 → 95.1 · 66.3

데이터가 무작위라 전환율이 현실적이지는 않다 — 계산 구조를 익히는 것이 목적

이 1시간이 끝날 때 확인할 것

- 1 눈대중은 전원 S, 분위수 경계는 B 34 · A 34 · S 32
- 2 FROM top 이 등급 3행 요약표를 낸다
- 3 (50000, 5) → (50000, 7) → 세그먼트 3종
- 4 user_segments·segment_summary 두 Parquet 이 생겼다
- 5 전체 변환 42 MB, 집계 후 변환 191 bytes

3-4 · 실습 1H 마무리

다음은 정리·회고 (0.5H)

분석 문법을 표 하나로 정리하고, 3-5 하이브리드 설계에 쓸 재료를 모읍니다

✓ DuckDB 분석 문법 요약표

✓ SQL 이 나왔던 것·Pandas 가 나왔던 것 적기

✓ 자주 겪는 오류 네 가지

✓ 3-5 준비 — 원본 orders.csv 확인

가져갈 것

5단계에서 쟀 시간·메모리 두 쌍