

3-4 · DuckDB를 이용한 데이터 분석 · 실습 1H

Pandas 연동 분석

DuckDB 로 줄이고 Pandas 로 다듬는 왕복

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① LIMIT 100 결과를 .df() 로 받아 pd.cut 으로 등급을 매긴다
- ② FROM top — 파이썬 변수를 SQL 이 곧바로 읽는다
- ③ SQL → Pandas → SQL 을 이어 세그먼트 3종을 만든다
- ④ 줄이기 전 .df() 의 시간·메모리를 실측해 규칙의 근거를 본다

100만 행을 Pandas 로 직접 다루지 않는다 — 오늘 실습의 한 줄 요약

여섯 단계 — 왕복을 한 번, 두 번, 여러 번

무거운 집계는 DuckDB 가, 등급 매기기 같은 세밀한 가공은 Pandas 가 맡습니다

1. SQL → df	2. df → SQL	3. 왕복 잇기	4. 파일로	5.6. 실패·과제
top 100 → .df() pd.cut 등급	FROM top 등급별 요약	users → cvr → segment	to_parquet COPY ... TO	.df() 통째로 퍼널 전환율

1단계

SQL 로 100명으로 줄이고 pd.cut 으로 등급

1 `duckdb.sql("...").df()`
buy 만 user_id 로 묶어 spend DESC LIMIT 100 — shape (100, 2)

2 `pd.cut(top['spend'], bins=...)`
[0, 15000, 25000, inf] 경계로 B·A·S 라벨

3 **경계는 분위수로도**
quantile([0.33, 0.66]) 로 정하면 세 등급이 대체로 균등

확인

type 이
DataFrame

손으로 정한 경계는 치우치기 쉽다 — 실측 분포에 맞춰 조정해도 된다

반대 방향 — DataFrame 을 SQL 로

SQL → DataFrame

.df() — 결과를 Pandas 로 받는다

호출	duckdb.sql("...").df()
뜻	결과 전부를 메모리에
규칙	줄인 다음에 부른다

VS

DataFrame → SQL

FROM top — 변수 이름을 그대로

호출	SELECT grade, count(*) ... FROM top
묶기	GROUP BY grade
확인	등급 3행의 요약표

3단계

SQL → Pandas → SQL 을 이어 세그먼트 분석



count(*) FILTER (WHERE 조건) — 조건에 맞는 것만 센다 · 2-2 의 CASE WHEN 합계와 같은 일을 더 짧게

① 이 5만 행 안팎으로 줄고 ③ 에 세그먼트 3종이 나오면 성공 — 100만 행을 Pandas 로 직접 다루지 않았다

세그먼트 규칙과 저장 — 핵심 줄

단계	핵심 줄	뜻
② cvr	buys / views, fillna(0)	전환율 · round(3)
② segment	cvr >= 0.1 → high_intent	세밀한 규칙은 Pandas
② segment	buys == 0 → browser	구매 없으면 browser
④ Pandas 저장	users.to_parquet(...)	index=False
④ DuckDB 저장	COPY (SELECT * FROM seg) TO	FORMAT parquet
확인	os.path.getsize 로 KB	두 파일이 생긴다

어느 쪽으로 저장하든 결과는 같은 Parquet — 이후 어느 도구로든 읽을 수 있다

.df() 를 통째로 불러 본다 — 시간과 메모리

나쁜 예 — SELECT * 전체

100만 행이 통째로 DataFrame 으로

시간	time.perf_counter() 로 잴다
메모리	memory_usage(deep=True) 수백 MB
끝나면	del big

VS

좋은 예 — 집계 후

GROUP BY event_type 3행 뒤에 .df()

시간	순식간
메모리	KB 단위
규칙	변환은 항상 「작아진 다음」

미니 과제 세 가지 — 정답 예시는 퍼널

- 1 첫 구매일 → 주차별 사용자 수**
힌트: min(ts) FILTER, date_trunc
- 2 지역×카테고리 교차표**
orders_enriched.parquet 를 SQL 로 — PIVOT 또는 조건부 집계
- 3 view → cart → buy 퍼널**
각 단계 사용자 수와 다음 단계로 넘어간 비율
- 4 정답 예시 — 퍼널**
per_user 에서 max(CASE WHEN ...) 으로 viewed·carted·bought 를 만들고 합산

데이터가 무작위라 전환율이 현실적이지는 않다 — 계산 구조를 익히는 것이 목적

이 1시간이 끝날 때 확인할 것

- 1 top 의 shape 가 (100, 2) 이고 grade 분포가 찍힌다
- 2 FROM top 이 등급 3행 요약표를 낸다
- 3 users 가 5만 행 안팎, seg 에 세그먼트 3종
- 4 user_segments·segment_summary 두 Parquet 이 생겼다
- 5 전체 변환은 수백 MB, 집계 후 변환은 KB 단위

3-4 · 실습 1H 마무리

다음은 정리·회고 (0.5H)

분석 문법을 표 하나로 정리하고, 3-5 하이브리드 설계에 쓸 재료를 모읍니다

✓ DuckDB 분석 문법 요약표

✓ SQL 이 나왔던 것·Pandas 가 나왔던 것 적기

✓ 자주 겪는 오류 네 가지

✓ 3-5 예고 — 정제 파이프라인·품질 리포트

가져갈 것

5단계에서詹 시간·메모리 두 쌍