

3-5 · Pandas·DuckDB 하이브리드 가공 · 수업 전 10분

실습점검 · 환경재설정

3주차 마지막 날 — 원본·가상환경·duckdb

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

왜 점검하나

3-5 는 3-1 의 원본 orders.csv 를 다시 꺼낸다

① orders.csv 가 그대로인가 — 36244 bytes · wc -l 1016

② week3 가상환경 — 3.0.6 25.0.1 1.5.6 .../week3/.venv

③ 오늘 만드는 파일을 미리 안다 — 단계마다 작은 파일 하나씩

④ 내일 4-1 은 도커로 돌아간다 — 순서만 미리 본다

오늘 새로 설치할 것은 없다 — 결측 30 · 공백 20 · 중복 15 를 정리하는 날

다섯 단계 — 지우는 것 없이 확인만

재설정(4단계)은 처음부터 다시 하고 싶을 때만 — 산출물 제출 전에는 하지 않는다

1 원본	2 venv·판	3 오늘 만들 것	4 재설정	5 4-1 미리
ls -l · wc -l 1016 줄	pandas 3.0.6 duckdb 1.5.6	py 일곱 parquet · md	오늘 것만 rm	도커 순서만 치지 않는다

원본과 가상환경 — 명령 셋이면 끝

폴더	<code>cd ~/data-eng/week3</code>
원본	<code>ls -l make_orders.py orders.csv · wc -l orders.csv</code>
켜기	<code>source .venv/bin/activate</code> — Windows(WSL2)·macOS·리눅스 같다
판	<code>python3 -c "import sys, pandas, pyarrow, duckdb; print(...)"</code>
없으면	<code>python3 make_orders.py</code> (시드 고정) · <code>pip install duckdb</code>

확인 포인트: 36244 bytes · 1016 줄(머리글 1 + 1015행) · 3.0.6 25.0.1 1.5.6 .../week3/.venv 가 한 줄

오늘 만드는 파일 — 누가 만들고 누가 쓰나

파일	누가 만드나	누가 쓰나
baseline.py	1.5H 1단계	오늘만
clean_orders.py	1.5H 2단계 → 6단계 최종본	3·4단계 import · 제출
orders_clean.parquet	1.5H 2·6단계 · 1H 5단계	리포트 · 교차 검증 · 제출
check_rerun.py 외 둘	1.5H 3·4·5단계	오늘만
quality_report.py·csv	1H 1단계	2단계 · 제출
improve_crosscheck.py	1H 2·3단계	오늘만
quality_report.md	1H 4단계 (편집기)	제출

clean_orders.py 는 6단계에서 최종본으로 통째로 바꾼다 · 3·4단계는 이 파일을 import 하니 같은 폴더에서 실행

오늘 것만 처음부터 — 3-1~3-4 파일은 남긴다

- 1 rm -f 오늘 만든 파일 (두 줄)**
baseline.py ... crosscheck.py · t1·t2.parquet — 노트 4단계 명령 그대로
- 2 rm -rf __pycache__**
import 할 때 파이썬이 만든 캐시 폴더라 지워도 된다
- 3 ls**
3-1~3-4 의 파일만 남으면 끝 — 직접 쓴 quality_report.md 는 지우지 않는다

제출 전에는

**재설정하지
않는다**

2주 만에 도커로 — 순서만 보고 치지 않는다

1

Docker 켜기

`docker version --format '{{.Server.Version}}'` 로 확인

2

MinIO 이미지 두 개

`docker pull pgsty/minio (216MB)` · `docker pull pgsty/mc (76.5MB)`

3

~/lakehouse

실습 폴더가 바뀐다 — 4-1 실습 1단계에서 만든다

3주차 마감

10-16(금)

23:59

내일 실습점검에서 켜기 · 9000·9001 포트 · 이미지 받기를 차례로 — 오늘 밤 이미지만 미리 받아 두면 좋다

파이썬, 이만큼이면 됩니다

오늘 새로 나오는 문법 6가지 — W3Schools 로 연결

표시

타입 힌트 → `pd.DataFrame · int()` 로 보통 정수로

고르기

~ 로 `True/False` 뒤집기 · `dict.values()` 로 값만

멈추기

`any(v > 0 for v in ...)` · `raise SystemExit(1)` → \$? 가 1

2-5 · 3-1~3-4 표에 나온 것(`def` · `if __name__` · `from ... import` 등)은 뺐다

3-5 · 수업 전 10분 마무리

다음은 이론 1H — 하이브리드 파이프라인 설계

(.venv) 가 켜진 터미널은 그대로 두세요. 실습 1.5H 에서 바로 씁니다

✓ 줄이는 DuckDB · 다듬는 Pandas

✓ 품질 점검 항목 다섯

✓ 결측 처리 — 정답보다 근거

✓ 측정 → 수정 → 측정

켜 둘 것

(.venv) 터미널 · orders.csv