

3-5 · Pandas와 DuckDB를 이용한 하이브리드 가공 · 이론 1H

하이브리드 파이프라인 설계

줄이는 것은 DuckDB, 다듬는 것은 Pandas

수도권ICT 이노베이션스퀘어

데이터 엔지니어링 & RAG 파이프라인 160H · 3기


1시간 뒤에는

- ① 데이터 크기·작업 성격으로 DuckDB 와 Pandas 의 역할을 나눈다
- ② 품질 점검 항목 다섯 가지와 재는 법을 말할 수 있다
- ③ 결측 처리 방법 여섯 가지의 조건과 위험을 비교한다
- ④ 측정 → 수정 → 측정 순서와 재실행 가능성의 뜻을 안다

다음 1.5H 실습에서 이 설계대로 `clean()` 함수를 만들고 두 번 돌려 봅니다

1. 역할 분담

한 도구로 끝나지 않는다 — 창고와 조리대



DuckDB 는 대형 창고에서 지게차로 필요한 상자만 꺼내고, Pandas 는 조리대에서 재료를 하나하나 다듬는다

창고 전체를 조리대에 쏟아붓지 않는 것이 설계의 핵심 — 단계 사이는 Parquet, 단계는 함수로(2-5 의 fetch·parse·load 와 같은 발상)

1. 역할 분담

DuckDB 가 말하는 것 · Pandas 가 말하는 것

DuckDB — 줄이는 쪽

메모리보다 크거나 무거운 필터·집계·조인

- 데이터가 메모리보다 클 때
- 무거운 필터·집계·조인
- 추출 단계 — 필터·열 선택으로 줄인다

VS

Pandas — 다듬는 쪽

행 단위 세밀한 정제·검증·리포트 가공

- 행 단위 세밀한 정제
- 검증과 리포트 가공
- 정제 단계 — 규칙을 함수 하나에

데이터 품질 — 무엇을 점검하는가

점검 항목	무엇을 묻나	재는 법
완전성 (결측)	있어야 할 값이 비었는가	isna().sum() · count 차이
유일성 (중복)	같은 것이 두 번 있는가	duplicated().sum()
정확성 (타입)	딱지가 맞는가	dtypes · DESCRIBE
유효성 (범위)	있을 수 없는 값인가	가격 ≤ 0 · 미래 날짜 건수
일관성 (표기)	같은 뜻이 다르게 적혔나	nunique() · unique()
적시성	데이터가 최신인가	max(날짜)와 오늘의 간격

이번 실습은 앞의 다섯 가지 — 적시성은 실시간 파이프라인(6주차)에서 중요해진다. 점검 항목을 정하고 숫자로 재는 순간 구체적인 작업이 된다

3. 결측 처리

결측을 어떻게 할 것인가 — 정답은 없고 근거가 답

방법	언제 맞나	위험
그대로 둔다	집계에서 자동으로 빠져도 될 때	몇 건 빠졌는지 모르게 된다
행을 버린다	결측이 소수이고 편향이 없을 때	데이터가 줄고 편향 위험
중앙값으로 채운다	분포를 크게 흔들지 않아야 할 때	분산이 실제보다 작아진다
평균으로 채운다	분포가 대칭일 때	이상치에 평균이 끌려간다
0으로 채운다	「없음」이 정말 0 을 뜻할 때만	대개 나쁜 선택 — 평균 왜곡
앞/뒤 값으로 채운다	시계열에서 값이 이어질 때	추세를 왜곡할 수 있다

이번 실습은 중앙값 — 결측 30건(2.96%)으로 적고, 이상치에 흔들리지 않는다. 이 데이터는 거의 대칭(평균 100,346 · 중앙값 101,000)이라 평균이어도 비슷

4. 정제 순서

같은 규칙, 다른 순서 — 숫자가 달라진다

순서 A — 중복 제거 후 중앙값

drop_duplicates → fillna(median)



VS

순서 B — 중복 있는 채로 중앙값

fillna(median) → drop_duplicates



4.5. 순서와 재실행

측정 → 수정 → 측정, 그리고 두 번 돌려도 같게

- 1 측정 (before)**
원본의 결측·중복·카테고리 값을 먼저 쟀다 — 이 숫자가 리포트의 출발점
- 2 수정**
공백 제거 → 타입 복원 → 중복 제거 → 결측 보정 — 순서를 문서에 적는다
- 3 측정 (after)**
같은 잣대로 다시 재야 「얼마나 고쳤는가」를 말할 수 있다
- 4 재실행 가능해야 파이프라인**
규칙은 함수 하나에, 원본은 읽기 전용, 두 번 돌리면 같은 출력(멥등성)

fillna 로 채운 뒤 결측률을 재면 당연히 0 — 아무것도 증명하지 않는다. 손으로 한 번 고친 데이터는 다음 달에 재현할 수 없다(8주차 Airflow 재시도도 이 원칙 위에)

품질 리포트 — 이번 주 산출물의 본질

전·후 표

01

정제 전·후 지표를 나란히
무엇을 얼마나 고쳤는가

근거

02

표만 있으면 반쪽
왜 그렇게 했는지 함께

교차 검증

03

다른 도구로 다시 재면
신뢰가 올라간다

고치지 않기로 한 것도 적는다 — 「이 결측은 그대로 두었다, 왜냐하면...」이 오히려 중요

이 1시간에서 꼭 가져갈 것

- 1 줄이는 것은 DuckDB, 다듬는 것은 Pandas
- 2 품질은 완전성·유일성·정확성·유효성·일관성으로 나눠 쟀다
- 3 결측 처리에 정답은 없고, 근거를 적는 것이 답이다
- 4 측정 → 수정 → 측정 순서를 지킨다
- 5 원본은 읽기 전용, 정제는 함수로, 두 번 돌려도 같은 결과

3-5 · 이론 1H 마무리

다음은 정제 파이프라인 구현 (1.5H)

DuckDB 로 원본의 기준선을 재고, `clean()` 함수를 만들어 두 번 돌려도 같은지 확인합니다

✓ DuckDB 로 원본 기준선(before) 측정

✓ `clean_orders.py` 로 정제

✓ 두 번 돌려 `equals()` True 확인

✓ `validate()` 를 일부러 깨뜨려 보기

준비할 것

3-1 의 `orders.csv` · `venv` 활성화