

3-5 · Pandas와 DuckDB를 이용한 하이브리드 가공 · 실습 1H

데이터 품질 리포트 작성 · 산출물 제출

무엇을 얼마나 고쳤는가를 숫자로 증명

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1시간 뒤에는

- ① before·after 를 같은 잣대로 재서 `quality_report.csv` 를 낸다
- ② 개선을 네 줄을 숫자로 뽑아 리포트 문서에 옮긴다
- ③ DuckDB 로 다시 재서 Pandas 의 after 와 같은지 교차 검증한다
- ④ 파일을 지우고 스크립트만으로 재현한 뒤 산출물 3종을 제출한다

이 챕터의 결과물이 3주차 산출물입니다 — 품질 리포트 + `orders_clean.parquet`

다섯 단계 — 리포트에서 제출까지

before 는 반드시 원본 orders.csv 에서 새로 읽습니다 — 이번 시간에 가장 자주 나는 실수

1 리포트 CSV

profile() ×2
concat

2 개선을

before → after
네 줄

3 교차 검증

DuckDB 로
다시 측정

4 문서 작성

근거·검증
여섯 절

5 점검·제출

지우고 재현
3종 제출

profile() — 다섯 지표를 before·after 로


지표	재는 법	after 기대값
rows	len(df)	1000
dup_order_id	duplicated().sum()	0
null_price	price.isna().sum()	0
null_rate_pct	isna().mean() * 100	0.0
category_values	category.nunique()	4

before 행은 앞 실습 1단계의 기준선과 같은 수치 — raw = pd.read_csv('orders.csv') 로 새로 읽고, 두 프로파일을 concat 해 quality_report.csv 로

before 를 정제본에서 만들면 — 증거가 사라진다

실수 — cleaned 를 재사용


before 와 after 가 똑같이 나온다



VS

정답 — 원본에서 새로

pd.read_csv('orders.csv') 로 before



개선율을 내고, 다른 도구로 다시 쟀다

1

개선율 네 줄

중복 15 → 0 · 결측 30+ → 0 · 카테고리 5 → 4 · 행 수 -1.5% 안팎

2

DuckDB 로 교차 검증

orders_clean.parquet 를 count(*)·count(DISTINCT ...)·min/max(order_date) 로

3

통과 기준

rows 1000 · null_price 0 · dup_orders 0 · category_values 4

신뢰의 근거

Pandas 값과

DuckDB 값 일치

날짜 범위는 2026-06-01 부터 두 달 안쪽이면 통과 — 만든 도구(Pandas)와 다른 도구(DuckDB)로 재면 검증의 신뢰가 올라간다. 개선율 수치는 리포트 문서에 그대로 옮겨 적는다

리포트 문서 — 여섯 절

절	적을 것
1. 대상	원본 · 정제 결과 · 파이프라인 파일
2. 전후 비교	행 수·중복·결측·고유값 표
3. 처리 내용과 근거	문제 · 처리 · 왜 그렇게 했나
4. 고치지 않은 것	그대로 둔 것과 그 이유
5. 검증	재실행·교차·유효성·검사기 자체
6. 남은 과제	본인이 발견한 것

3번(근거)과 5번(검증)이 채워져 있는가 — 표만 있으면 다음 사람이 규칙을 바꿔도 되는지 판단할 수 없다

지우고 다시 만들어지는가, 그리고 제출

1 `rm -f orders_clean.parquet`

지운 뒤 `python3 clean_orders.py` → `python3 quality_report.py` — `ls -lh` 로 다시 생겼는지

2 제출 3종

`orders_clean.parquet` · 품질 리포트(`quality_report.csv` + 문서) · `clean_orders.py`

3 어디에

사이트의 「산출물 제출」 페이지 — 제출 후 주차별 산출물 갤러리에도 올려 동료와 공유

4 함께 올리면 좋은 것

3-3 에서詹 CSV 대비 Parquet 크기·속도 실측표

파일을 지우고 스크립트만으로 다시 만들어지면 재현성 검증 완료

시간이 남으면 — 미니 과제 셋

값 범위 점검

01

가격 0 이하·수량 6 이상을
profile() 열로 추가

행 버리기로 바꾸기

02

중앙값 대신 행 버리기로
리포트를 다시 내 비교

100만 행에 적용

03

3-3 events.parquet 에
측정은 전부 DuckDB SQL

셋째는 Pandas 로 할 때와 시간을 비교해 보세요

산출물 완성 기준

- 1 quality_report.csv 의 after 행: 중복 0 · 결측 0 · 카테고리 4
- 2 before 행이 원본 기준선(1015 · 15 · 30+)과 같다
- 3 DuckDB 로 다시 켜 값이 Pandas 의 after 와 같다
- 4 리포트 문서에 3번 근거와 5번 검증이 채워져 있다
- 5 지우고 스크립트만으로 재현된 뒤 3종을 제출했다

3-5 · 실습 1H 마무리

다음은 주차 회고 · 산출물 점검 (0.5H)

3주차 다섯 차시를 되짚고, 4주차 레이크하우스로 넘어가는 다리를 놓습니다

✓ 3-1 ~ 3-5 지나온 길과 남은 결과물

✓ 오늘의 체크리스트

✓ 자주 겪는 오류 넷

✓ 4-1 MinIO 오브젝트 스토리지 예고

제출 확인

제출 페이지에 3종이 올라갔는지