

3-5 · Pandas·DuckDB 하이브리드 가공 · 정리·회고 0.5H

주차 회고 · 산출물 점검

도구는 목적에 따라 고른다 — 3주차 한 장

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

30분 뒤에는

- ① 3-1 ~ 3-5 에서 배운 것과 남은 결과물을 한 표로 되짚는다
- ② 오늘의 체크리스트로 산출물 3종이 완성됐는지 점검한다
- ③ 자주 겪는 오류 네 가지의 원인과 해결을 안다
- ④ 4주차 레이크하우스로 무엇이 이어지는지 안다

한 주를 관통한 생각 — Pandas 가 좋다 DuckDB 가 좋다가 아니라, 크기와 작업 성격에 따라

다섯 차시 — 배운 것과 남은 결과물

차시	배운 것	남은 결과물
3-1	Pandas 기본기와 타입 정리	orders.csv orders_step1.parquet
3-2	groupby·merge·resample	customers.csv orders_enriched.parquet
3-3	DuckDB와 열 지향 저장	events.csv/parquet 크기·속도 실측표
3-4	SQL 분석과 Pandas 왕복	user_segments.parquet
3-5	하이브리드 파이프라인과 품질	orders_clean.parquet 품질 리포트

4주차부터는 이 데이터를 여러 사람이 함께 쓰는 저장소에 올린다

4주차로 이어지는 것

오늘까지 만든 것이 어디로 가는가

01

Parquet

4주차 레이크하우스의
저장 형식 그대로

02

파티셔닝

3-3 PARTITION_BY 가
Iceberg 에서 정교하게

03

SQL

4주차 Trino ·
5주차 SparkSQL 로

04

품질 검증

8주차 Airflow 에서
단계마다 검증

3주차 파일을 오브젝트 스토리지에 올려 보는 것은 4-1 심화 과제에서

여덟 개를 스스로 확인해 보세요

- 1 품질 점검 항목 다섯 가지를 말할 수 있다
- 2 DuckDB 로 before 를 재고, 오염된 카테고리 값을 눈으로 봤다
- 3 정제 규칙을 clean() 하나로 모으고 두 번 돌려 같은 것을 확인했다
- 4 정제 순서가 결과를 바꿀 수 있음을 실험으로 확인했다
- 5 유효성 검사기를 일부러 깨뜨려 보고, 실패 시 종료 코드 1 로 멈춘다
- 6 after 의 결측·중복 0, 카테고리 4 — DuckDB 로 교차 검증했다
- 7 처리마다 근거를 적은 리포트 문서를 작성했다
- 8 재현 확인 뒤 산출물 3종을 제출했다 (10-16 23:59)

증상으로 찾는 원인과 해결

증상	원인	해결
before 와 after 가 똑같다	before 를 정제본으로 만들 또는 원본을 덮어씀	원본은 읽기 전용 . before 는 orders.csv 에서
중복이 기대만큼 안 지워진다	subset 없이 모든 열이 같은 행만 중복으로 봄	subset='order_id' . keep 도 의도대로
보정 후 통계가 미묘하게 다르다	중복 제거 전 중앙값 . 채운 뒤 결측률 측정	측정 → 중복 제거 → 결측 보정 → 측정
ModuleNotFoundError clean_orders	그 폴더에서 실행하지 않음	cd ~/data-eng/week3 뒤 실행

측정과 수정을 섞지 않는다 — 순서를 고정해야 「얼마나 고쳤는가」를 말할 수 있다

자주 나오는 질문 네 가지

1 결측을 중앙값으로 채우는 게 정말 맞나요?

결측 3% 라 영향이 작아 선택 — 30% 라면 「그 열을 쓰지 않는다」가 나올 수 있다. 비율을 먼저 보고 정한다

2 중복을 지울 때 어느 것을 남기나요?

keep='first' 는 먼저 나온 것, 'last' 는 나중 것 — 갱신 이력이면 last, 최초 기록이 중요하면 first

3 품질 검사를 매번 손으로 하나요?

validate() 처럼 함수로 두고 8주차 Airflow 의 단계로 — 실패하면 다음 단계로 안 넘어가게

4 원본을 고치면 안 되나요?

안 된다 — 정제 전이 어땠는지 영영 알 수 없고, 규칙을 바꿔 다시 돌릴 수도 없다

넷 중 하나 — 시간이 남을 때

01

값 범위 점검

가격 0 이하·수량 6 이상
profile() 열로

02

100만 행 DuckDB

events.parquet 에
측정 전부 SQL 로

03

로깅

무엇을 몇 건 고쳤는지
실행마다 출력

04

quotes 점검

2주차 수집 데이터 ·
심표 태그 문제 리포트

참고: Pandas · DuckDB · Apache Parquet 공식 문서 링크는 사이트 본문 맨 아래에

다음 회차 예고

4-1 · MinIO 오브젝트 스토리지 구축

01

이론 1H

오브젝트 스토리지의
이해

02

실습 1.5H

MinIO 컨테이너
구축

03

실습 1H

mc CLI 와
S3 API 활용

04

정리 0.5H

정리·회고

내일 10-16(금) 19시 — 실습 폴더는 ~/lakehouse, 9000(S3 API)·9001(웹 콘솔) 포트를 쓴다

도커 다시 켜기 — 각자 운영체제대로

운영체제	켜기	확인할 것
Windows (WSL2)	Docker Desktop 실행	고래 아이콘 멈춤 WSL Integration Ubuntu
macOS	Docker Desktop 실행	메뉴 막대 고래 멈춤
리눅스 (Ubuntu)	sudo systemctl enable --now docker	명령은 터미널에서

컨 뒤 pull pgsty/minio(216MB) · pgsty/mc(76.5MB) — Cannot connect 면 Docker 가 꺼진 것

3-5 · 정리·회고 0.5H 마무리

다음 회차는 4-1 MinIO 오브젝트 스토리지

3주차까지는 내 노트북의 파일 — 4주차부터는 여러 사람과 도구가 함께 쓰는 저장소, 그 바닥층을 직접 구축합니다

✓ 블록·파일·오브젝트 스토리지의 차이

✓ S3 API 가 표준이 된 이유와 버킷·키 구조

✓ Docker Compose 로 MinIO 서버·웹 콘솔

✓ mc CLI 로 버킷 생성·업로드·목록 조회

오늘 밤

도커 켜기 · 이미지 두 개 받기