4-2 · Apache Iceberg 레이크하우스 구축 · 실습 1H

Spark + Iceberg 환경 구성

컨테이너 둘을 더해 레이크하우스 기반 완성

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1시간 뒤에는

① compose 를 통째로 교체해 컨테이너 넷을 모두 Up 으로 만든다

② minio · REST 카탈로그 · Spark · 카탈로그 위치를 하나씩 확인한다

③ spark-defaults.conf 에서 demo 카탈로그 설정 줄을 읽는다

④ spark-sql 에서 demo 를 보고, 카탈로그를 멈춰 오류도 본다

이미지를 안 받았으면 up 이 20분 넘게 걸립니다 — 미리 받아 두세요

실습 흐름

다섯 단계 — 4-1 의 ~/lakehouse 에서 이어서

4-1 에서 띄운 minio · mc 와 raw 버킷이 그대로 있는 상태에서 시작합니다

1. compose 교체	2. 살아 있나	3. 설정 읽기	4. spark-sql	5. 일부러 실패
히어독으로 통째로 덮어쓰기	curl · 버전 · uri · 로그	spark-defaults.conf	SHOW CATALOGS	rest 멈추고 다시 조회

1단계

핵심 명령 — 교체하고, 띄우고, 버킷 보기

교체	cat > docker-compose.yml << 'EOF' … EOF
달라진 셋	CATALOG_URI·볼륨 · MINIO_DOMAIN·별칭 · 태그 고정
띄우기	mkdir -p scripts → docker compose up -d
상태	docker compose ps
버킷	exec mc mc mb -p local/warehouse → mc ls local

확인: 네 컨테이너(iceberg-rest · mc · minio · spark-iceberg) Up · 볼륨 lakehouse_rest-catalog Created · 버킷 raw/ · warehouse/

카탈로그를 볼륨의 파일에 남긴다

볼륨 없이 — 이미지 기본값

jdbc:sqlite:file:/tmp/iceberg_rest_mode=memory

- 이름과 달리 컨테이너 안의 파일
- restart 는 버틴다
- down → up 이면 테이블 목록이 사라진다
- MinIO 의 파일은 그대로 남는다

VS

rest-catalog 볼륨 — 4-2 판

jdbc:sqlite:file:/home/iceberg/iceberg_catalog.db

- 카탈로그 파일이 볼륨에 놓인다
- down → up 뒤에도 count 4 유지(실측)
- 정리 시간에 down → up 으로 확인

2단계

컨테이너가 넷 — 하나씩 확인해 문제를 좁힌다

1. **minio — curl .../minio/health/live**
   minio: 200

2. **REST 카탈로그 — curl localhost:8181/v1/config**
   {"defaults":{},"overrides":{}}

3. **Spark — spark-sql --version**
   로고 아래 version 3.5.5

4. **카탈로그 위치 — logs rest | grep uri**
   uri=jdbc:sqlite:file:/home/iceberg/iceberg_catalog.db

로그 끝 줄

Started

@...ms

3단계

demo 카탈로그는 이미 연결돼 있다

설정	뜻
spark.sql.catalog.demo	demo 라는 이름의 카탈로그 등록
...demo.type rest	그 카탈로그는 REST 방식
...demo.uri http://rest:8181	카탈로그 서비스 주소
...demo.s3.endpoint http://minio:9000	S3 API 주소 (MinIO)
...demo.warehouse s3://warehouse/wh/	이미지 기본값 — REST 카탈로그가 정함
spark.sql.defaultCatalog demo	이름을 빼면 demo 로 본다

실제 자리는 REST 카탈로그(warehouse=s3://warehouse/)가 정한다 — 파일은 warehouse/lakehouse/orders/

4단계

spark-sql 에 들어가 카탈로그를 본다

1. **docker compose exec spark-iceberg spark-sql**
   WARN 몇 줄 뒤 spark-sql ()> 프롬프트 — 실측 6초
2. **SHOW CATALOGS;**
   demo · spark_catalog 두 줄이면 연결 성공
3. **SHOW DATABASES IN demo;**
   결과 줄 없이 Time taken 만 — 다음 실습에서 채운다
4. **quit; 또는 Ctrl+D**
   나가기

4041 줄

다른 Spark 가 4040 — 무시

5단계 — 일부러 실패시키기

카탈로그를 멈추면 Spark 는 무엇을 못 하나

Spark 는 테이블 목록을 스스로 갖지 않고 매번 카탈로그에 묻습니다 — spark-sql 은 quit; 으로 나온 뒤

rest 멈추기	다시 조회	오류 읽기	왜 이름 오류	되살리기
docker compose stop rest	spark-sql -e | grep Exception	UnknownHost Exception: rest	멈춘 컨테이너는 이름표에서 빠짐	compose start rest → 다시 조회

확인 포인트

이 1시간이 끝날 때 확인할 것

1. ps 에 네 컨테이너 Up · mc ls local 에 raw/ · warehouse/
2. minio: 200 · defaults·overrides JSON · version 3.5.5
3. uri 가 /home/iceberg/iceberg_catalog.db (볼륨 자리)
4. SHOW CATALOGS 에 demo · spark_catalog 두 줄
5. rest 를 멈추면 UnknownHostException: rest — start 로 복구

4-2 · 실습 1H 마무리

다음은 테이블 생성과 타임 트래블 (1.5H)

demo 카탈로그에 orders 테이블을 만들고, 스냅샷을 쌓아 과거로 갔다 오고, 컬럼을 더해 봅니다

- ✓ **CREATE TABLE … USING iceberg**
- ✓ **MinIO 에 생긴 metadata/ · data/ 파일**
- ✓ **UPDATE → VERSION AS OF → 롤백**
- ✓ **ADD COLUMN 뒤 parquet 개수 비교**

가져갈 것

spark-sql ()> 프롬프트가 떠 있는 터미널