4-3 · 데이터 파이프라인 · 수업 전 10분

실습점검 · 환경재설정

4-2 끝 상태 · s3a 부품 미리 받기

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

왜 점검하나

수업 전에 걸러 둘 것

① 4-2 끝 상태가 아니다 — 테이블이 없거나 행 수가 다르다

② s3a 부품(hadoop-aws)을 실습 중에 처음 받으면 몇 분 멈춘 듯 보인다

③ 이 부품은 Spark 이미지에 없다 — 처음 쓰는 순간 275MB 를 받는다

점검(1~3단계)은 확인과 미리 받기만 · 재설정(4단계)은 적재를 다시 할 때만

흐름

네 단계 — 위에서부터 한 번씩

재설정은 오늘 올린 파일과 orders 테이블만 4-2 끝 모양으로 되돌린다

1 4-2 끝 상태	2 부품 받기	3 오늘 만들 것	4 환경 재설정
up · ps count 4	hadoop-aws 275MB	순서만 확인 아직 치지 않음	적재를 처음부터 다시 할 때만

1단계

4-2 끝 상태를 확인해 보세요

1. **cd ~/lakehouse → docker compose up -d → ps**
   iceberg-rest · mc · minio · spark-iceberg 네 컨테이너가 Up
2. **spark-sql -e "SELECT count(*) FROM demo.lakehouse.orders;"**
   4 가 나오면 4-2 끝 상태
3. **docker compose exec mc mc ls local/raw/orders/**
   orders_2026-08-01.csv 한 줄

NOT_FOUND 면

예전 compose

→ 4단계로

2단계

s3a 부품(hadoop-aws)을 미리 받아 두기

1. **spark-sql --packages ...hadoop-aws:3.3.4 -e "SELECT 1;"**
   hadoop-aws 판은 이미지 하둡과 같은 3.3.4 · grep 으로 두 줄만

2. **처음: 3 artifacts copied, 0 already retrieved 와 1**
   275MB — 실측 macOS 2분 29초 · 4분 24초 · 5분 39초

3. **다시: 0 artifacts copied, 3 already retrieved 와 1**
   받아 둔 것을 다시 쓴다 — 11초

언제 걸까

이론 시작 때

걸어 두기

2단계 · 왜 필요한가

부품이 없으면, 받아 둔 부품은 어디에

01

없으면

ClassNotFound

S3AFileSystem

02

stop 하면

/root/.ivy2 에

그대로 남는다

03

down 하면

함께 사라져

다음에 다시 받는다

질문 — 받는 데 몇 분 걸렸나요 · 회사망 프록시에서 막힌 분은 「질문」으로

3단계 · 순서만

오늘 만드는 것 — 아직 치지 않는다

무엇	어디서 처음 만드나	뒤에서 누가 받나
orders_2026-08-02.csv	원천 데이터 적재 2단계	오늘 ETL 전부
etl_bad.py (일부러 실패)	ETL 1단계 히어독	오늘만
etl_orders.py	ETL 2단계 히어독	오늘 3~6단계 8주차 Airflow
orders_2026-08-03.csv	ETL 5단계	4-4 · 4-5
orders 6행 (1~5 · 7)	ETL 6단계 끝	4-4 Trino · 4-5

지금 spark-submit ... etl_orders.py 를 치면 can't open file — 아직 만들기 전이라는 뜻

4단계 · 환경 재설정

4-3 적재만 처음부터 다시 할 때

1. **mc rm 으로 08-02 · 08-03 · orders_bad.csv 세 파일**
   Removed 줄 — 아직 안 올린 파일은 오류 줄, 무시해도 된다

2. **DROP TABLE … PURGE + CREATE + 4행 INSERT 한 번에**
   spark-sql -e 한 줄 — 4-2 끝 모양의 orders 를 다시 만든다

3. **mc ls local/raw/orders/ → SELECT count(*)**
   orders_2026-08-01.csv 한 줄과 4 — 원천 데이터 적재 2단계부터

스냅샷 이력

4-2 기록은 새로 시작

확인 포인트

수업 준비가 끝났는지

1. 네 컨테이너가 Up 이고 count 가 4 다
2. raw/orders/ 에 orders_2026-08-01.csv 한 줄만 있다
3. 다시 치면 0 artifacts copied, 3 already retrieved 가 나온다
4. etl 스크립트는 아직 없다 — 실습 시간에 히어독으로 만든다

받아 둔 부품은 stop 하면 남고, down 하면 사라져 다시 받는다

4-3 · 수업 전 10분 마무리

다음은 데이터 파이프라인 설계 (1H)

점검을 마쳤으니 몇 번 돌려도 같은 결과가 나오는 적재부터 잡습니다

- ✓ 랜딩 존을 따로 두는 이유
- ✓ 멱등성 — 몇 번 돌려도 같은 결과
- ✓ MERGE INTO — 있으면 갱신, 없으면 삽입
- ✓ s3a와 S3FileIO — 두 갈래 경로

> 막혔다면
> 그 단계 아래 「막혔어요」 · 「질문」