4-3 · MinIO–Iceberg 데이터 파이프라인 구축 · 실습 1H

원천 데이터 적재

새 배치 파일을 올리고, Spark 가 읽는지부터

수도권ICT 이노베이션스퀘어

데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1시간 뒤에는

① 4-2 의 컨테이너 4개와 orders 테이블 4행이 살아 있는지 확인한다

② raw 버킷의 orders/ 랜딩 존에 새 배치 CSV 를 올린다

③ --packages 하나와 --conf 네 개로 spark-shell 에서 랜딩 존을 읽는다

④ 두 파일에 겹치는 order_id 2 를 눈으로 확인한다

ETL 을 짜기 전에 읽기부터 — 여기서 s3a 설정을 잡아 두면 나중에 원인을 좁히기 쉽습니다

실습 흐름

네 단계 — ~/lakehouse 폴더에서 4-2 구성 그대로

새 배치 파일 하나를 랜딩 존에 올리고, ETL 없이 읽기만 해 봅니다

1. 상태 확인	2. 파일 업로드	3. 읽기 확인	4. 겹치는 키
compose ps orders 4행	orders_2026-08-02 mc cp	spark-shell --packages · --conf	groupBy count order_id 2

1단계

4-2 상태를 확인한다 — 핵심 명령

폴더	cd ~/lakehouse
띄우기	docker compose up -d
상태	docker compose ps
테이블	spark-sql -e "SELECT * FROM demo.lakehouse.orders ORDER BY order_id;"
랜딩 존	docker compose exec mc mc ls local/raw/orders/

확인 포인트: 컨테이너 4개 Up · orders 4행(order_id 1~4) · raw/orders/ 에 orders_2026-08-01.csv

2단계

새 배치 파일 orders_2026-08-02.csv — 세 행

order_id	customer	amount	order_date	channel
2	lee	35000	2026-08-02	web
3	park	12000	2026-08-02	app
4	choi	58000	2026-08-02	web

cat > data/orders_2026-08-02.csv 로 만들고 mc cp /data/... local/raw/orders/ 로 올린다 → mc ls 에 파일 두 개

order_id 2 는 8월 1일 파일에도 있는 행의 갱신본, 3·4 는 값이 바뀐 행 — 매일 도착하는 증분 파일을 흉내 낸 것

3단계

spark-shell 에 붙이는 --packages 하나와 --conf 네 개

붙이는 것	값	뜻
--packages	hadoop-aws:3.3.4	s3a 부품 — 이미지 하둡과 같은 판
fs.s3a.endpoint	http://minio:9000	S3 API 주소 — 컨테이너 이름
fs.s3a.access.key	minioadmin	접근 키
fs.s3a.secret.key	minioadmin	비밀 키
fs.s3a.path.style.access	true	MinIO 형식(주소/버킷)으로

s3a 부품(hadoop-aws)은 이미지에 없어 받아 온다 — 첫 실행 275MB, 「실습점검」 2단계를 했다면 바로

3단계

scala> 프롬프트에서 — 읽기가 되는지

1. **val raw = spark.read ... .csv("s3a://raw/orders/")**
   option("header","true") — 접두사를 통째로 읽으면 두 파일이 함께 들어온다

2. **raw.show() · raw.count()**
   5행(8-02 의 2·3·4 + 8-01 의 1·2, 순서는 섞일 수 있음) · res1: Long = 5

3. **나가기 :quit**
   4단계까지 본 뒤 나간다 — 다음 챕터는 spark-submit 으로

멈춘 듯하면

첫 실행은

275MB 받는 중

일부러 실패시키기

--packages 줄을 빼고 붙여 본다

빼면 — 실패

s3a 부품이 없는 이미지 그대로 읽으려다 실패

- ClassNotFoundException 오류
- 끝에 fs.s3a.S3AFileSystem — 부품이 없다는 뜻
- 이 이미지에는 hadoop-aws 가 들어 있지 않다

VS

넣으면 — 성공

hadoop-aws:3.3.4 를 받아 s3a:// 를 읽는다

- 모든 spark-shell·spark-submit 에 같은 줄
- 주의: path.style.access 를 빼면 오류 없이 멈춤
- 몇 분째 조용하면 Ctrl+C 로 끊고 확인

4단계

겹치는 키를 눈으로 — order_id 2 가 두 번

1 **raw.groupBy("order_id").count().orderBy("order_id").show()**
order_id 2 가 2건, 나머지는 1건

2 **raw.filter("order_id = 2").show()**
amount 32000(8-01) 과 35000(8-02) — 두 파일의 값이 다르다

3 **이 상태로 MERGE 하면**
「한 대상 행에 원천 여러 행」 오류 — 다음 챕터에서 규칙을 정해 하나로 줄인다

남길 규칙

가장 최근

order_date

확인 포인트

이 1시간이 끝날 때 확인할 것

1. docker compose ps 에 컨테이너 4개가 Up 이다
2. mc ls 에 orders_2026-08-01 · 08-02 두 파일이 보인다
3. spark-shell 에서 raw.count() 가 res1: Long = 5 다
4. --packages 를 빼면 왜 실패하는지 말할 수 있다
5. order_id 2 가 2건이고 amount 가 35000 · 32000 으로 다르다

4-3 · 실습 1H 마무리

다음은 Spark ETL 과 MERGE 적재 (1.5H)

중복을 안 줄이고 MERGE 해 오류를 먼저 본 뒤, 결정적 중복 제거를 넣은 ETL 로 두 번 돌려 검증합니다

- ✓ **etl_bad.py 로 카디널리티 오류 보기**
- ✓ **Window + row_number 로 최신 한 행만**
- ✓ **MERGE INTO 실행 · 5 → 4 → 4 확인**
- ✓ **같은 명령 두 번 · snapshots 이력**

가져갈 것

spark-shell 을 :quit 로 나온 상태