

4-3 · MinIO-Iceberg 데이터 파이프라인 구축 · 실습 1H

원천 데이터 적재

새 배치 파일을 올리고, Spark 가 읽는지부터

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① 4-2 의 컨테이너 4개와 orders 테이블 4행이 살아 있는지 확인한다
- ② raw 버킷의 orders/ 랜딩 존에 새 배치 CSV 를 올린다
- ③ s3a --conf 네 개로 spark-shell 에서 랜딩 존을 읽는다
- ④ 두 파일에 겹치는 order_id 2 를 눈으로 확인한다

ETL 을 짜기 전에 읽기부터 — 여기서 s3a 설정을 잡아 두면 나중에 원인을 좁히기 쉽습니다

네 단계 — ~/lakehouse 폴더에서 4-2 구성 그대로

새 배치 파일 하나를 랜딩 존에 올리고, ETL 없이 읽기만 해 봅니다

1. 상태 확인

```
compose ps  
orders 4행
```

2. 파일 업로드

```
orders_2026-08-02  
mc cp
```

3. 읽기 확인

```
spark-shell  
--conf 네 개
```

4. 겹치는 키

```
groupBy count  
order_id 2
```

4-2 상태를 확인한다 — 핵심 명령

폴더	<code>cd ~/lakehouse</code>
띄우기	<code>docker compose up -d</code>
상태	<code>docker compose ps</code>
테이블	<code>spark-sql -e "SELECT * FROM demo.lakehouse.orders ORDER BY order_id;"</code>
랜딩 존	<code>docker compose exec mc mc ls local/raw/orders/</code>

확인 포인트: 컨테이너 4개 Up · orders 4행(order_id 1~4) · raw/orders/ 에 orders_2026-08-01.csv

새 배치 파일 orders_2026-08-02.csv — 세 행

order_id	customer	amount	order_date	channel
2	lee	35000	2026-08-02	web
3	park	12000	2026-08-02	app
4	choi	58000	2026-08-02	web

cat > data/orders_2026-08-02.csv 로 만들고 mc cp /data/... local/raw/orders/ 로 올린다 → mc ls 에 파일 두 개

order_id 2 는 8월 1일 파일에도 있는 행의 갱신본, 3·4 는 값이 바뀐 행 — 매일 도착하는 증분 파일을 흉내 낸 것

spark-shell 에 붙이는 --conf 네 개

spark.hadoop.fs.s3a.*	값	뜻
endpoint	http://minio:9000	S3 API 주소 — 컨테이너 이름
access.key	minioadmin	접근 키
secret.key	minioadmin	비밀 키
path.style.access	true	MinIO 형식(주소/버킷)으로

카탈로그 설정은 이미 되어 있어도 s3a 설정은 따로 — 이론에서 본 「두 갈래 경로」

spark-shell 프롬프트에서 — 읽기가 되는지

1 `val raw = spark.read ... .csv("s3a://raw/orders/")`
`option("header","true")` — 접두사를 통째로 읽으면 두 파일이 함께 들어온다

2 `raw.show() · raw.count()`
5행(8-01 의 2행 + 8-02 의 3행)이 나오면 s3a 읽기 성공

3 **나가기 :quit**
4단계까지 본 뒤 나간다 — 다음 챕터는 spark-submit 으로

403 이 나면

--conf 네 개
다시 확인

path.style.access 를 빼고 붙여 본다

빼면 — 실패

AWS 방식(버킷.주소)으로 붙으려다 실패

- 403 또는 UnknownHost 오류
- 가장 흔한 원인 — 오류 문구를 알아 둔다
- 카탈로그 쓰기는 되는데 읽기만 죽는 이유

true — 성공

MinIO 형식(주소/버킷)으로 붙는다

VS

- MinIO 는 기본이 path style
- 반드시 true 로 준다
- endpoint 는 https 가 아닌 http://minio:9000

겹치는 키를 눈으로 — order_id 2 가 두 번

1 `raw.groupBy("order_id").count().orderBy("order_id").show()`
order_id 2 가 2건, 나머지는 1건

2 `raw.filter("order_id = 2").show()`
amount 32000(8-01) 과 35000(8-02) — 두 파일의 값이 다르다

3 **이 상태로 MERGE 하면**
「한 대상 행에 원천 여러 행」 오류 — 다음 챕터에서 규칙을 정해 하나로 줄인다

남길 규칙

가장 최근
order_date

이 1시간이 끝날 때 확인할 것

- 1 **docker compose ps** 에 컨테이너 4개가 Up 이다
- 2 **mc ls** 에 **orders_2026-08-01 · 08-02** 두 파일이 보인다
- 3 **spark-shell** 에서 **raw.count()** 가 5 다
- 4 **path.style.access** 를 빼면 왜 실패하는지 말할 수 있다
- 5 **order_id 2** 가 2건이고 **amount** 가 32000 · 35000 으로 다르다

4-3 · 실습 1H 마무리

다음은 Spark ETL 과 MERGE 적재 (1.5H)

중복을 안 줄이고 MERGE 해 오류를 먼저 본 뒤, 결정적 중복 제거를 넣은 ETL 로 두 번 돌려 검증합니다

✓ etl_bad.py 로 카디널리티 오류 보기

✓ Window + row_number 로 최신 한 행만

✓ MERGE INTO 실행 · 5 → 4 → 4 확인

✓ 같은 명령 두 번 · snapshots 이력

가져갈 것

spark-shell 을 :quit 로 나온 상태