

4-3 · MinIO-Iceberg 데이터 파이프라인 구축 · 실습 1.5H

Spark ETL과 MERGE 적재

결정적 중복 제거와 MERGE — 두 번 돌려 검증

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1.5시간 뒤에는

- ① 중복을 안 줄이고 MERGE 해 카디널리티 오류를 직접 본다
- ② Window + row_number 로 키별 최신 한 행만 남기는 ETL 을 쓴다
- ③ 같은 스크립트를 두 번 돌려 행 수가 늘지 않음을 확인한다
- ④ 새 파일만 추가해 증분 배치를 돌리고 불량 행이 걸러짐을 본다

스크립트는 /home/iceberg/scripts/ 에, spark-submit 의 --conf 네 개는 앞 챕터와 같습니다

여섯 단계 — 실패를 먼저, 검증은 두 번

스크립트 하나(etl_orders.py)를 완성한 뒤에는 파일만 바꿔 가며 같은 명령을 반복합니다

1. 실패 먼저	2. ETL 작성	3. 실행·확인	4. 역등성	5·6. 증분·불량
etl_bad.py 중복 안 줄임	etl_orders.py row_number	5 · 4 · 4 amount 35000	한 번 더 snapshots	08-03 파일 orders_bad

중복을 안 줄이고 MERGE 하면

1 etl_bad.py — 읽기 · 형 변환 · 바로 MERGE
row_number 없이 updates 뷰를 만들어 MERGE INTO demo.lakehouse.orders

2 spark-submit --conf x4 ... etl_bad.py 2>&1 | tail -n 20
마지막 20줄에서 오류 문구를 찾는다

3 multiple source rows matched a single target row
order_id 2 가 두 행이라 어느 값으로 갱신할지 정할 수 없다는 뜻 — 나야 정상

알아 둘 이름

카디널리티

오류

etl_orders.py — 랜딩 존 → 정제 → MERGE 적재



「가장 최근 order_date 의 행을 남긴다」는 규칙을 명시 — 2-2 의 ROW_NUMBER 를 PySpark 로 쓰는 것

핵심 줄 — 정제와 적재

형 변환	<code>cast("bigint") · cast("double") · F.to_date("order_date")</code>
불량 제거	<code>filter("order_id IS NOT NULL AND amount >= 0")</code>
창	<code>Window.partitionBy("order_id").orderBy(F.col("order_date").desc())</code>
최신 한 행	<code>withColumn("rn", F.row_number().over(w)).filter("rn = 1").drop("rn")</code>
적재	<code>MERGE INTO demo.lakehouse.orders AS t USING updates AS s ON t.order_id = s.order_id</code>

filter 의 두 조건 — 키가 비었거나 금액이 음수인 행은 적재 전에 버린다

실행하고 출력 세 줄을 읽는다

1 **spark-submit ... etl_orders.py | grep 세 줄**
--conf 네 개는 앞 챕터와 같다 → 원천 행 5 · 정제 후 행 4 · total rows 4

2 **왜 5 → 4 → 4 인가**
order_id 2 의 중복 하나가 빠져 4행, 대상도 전부 갱신이라 4행 그대로

3 **spark-sql -e "SELECT * ... ORDER BY order_id;"**
order_id 2 의 amount 가 35000(8-02) · 1 은 8-01 에만 있어 15000 그대로

출력 세 줄

5 · 4 · 4

같은 명령을 한 번 더 — 결과는 같고 기록은 남는다

한 번 더 spark-submit

total rows 가 여전히 4 — 중복 삽입이 없다

- grep -E "total rows" 로 한 줄만
- 2-5 의 UNIQUE 제약이 한 일을
- 여기서 MERGE 의 키 조건이 한다

VS

snapshots 메타테이블

MERGE 실행마다 커밋 이력이 한 건씩

- SELECT committed_at, snapshot_id, operation
- FROM demo.lakehouse.orders.snapshots
- count 는 그대로, 실행 기록은 쌓인다

파일만 추가하고 같은 스크립트 — 실무의 하루

올린 파일	원천 행	정제 후	total rows	무슨 일이
orders_2026-08-02	5	4	4	2 갱신 35000 · 신규 없음
orders_2026-08-03	7	5	5	4 갱신 61000 · 5 신규
orders_bad	10	6	6	6(음수)·빈 키 걸러짐 · 7 신규

매번 랜딩 존 전체를 읽는 방식 — 파일이 수천 개면 느려진다. 날짜 경로(dt=...)는 8주차 Airflow 에서

스크립트는 한 글자도 안 고쳤다 · 정리: `mc rm local/raw/orders/orders_bad.csv` 로 불량 파일은 랜딩 존에서 뺀다

이 1.5시간이 끝날 때 확인할 것

- 1 etl_bad.py 에서 multiple source rows matched 오류를 봤다
- 2 etl_orders.py 첫 실행 출력이 원천 5 · 정제 4 · total 4 다
- 3 order_id 2 의 amount 가 35000 으로 갱신했다
- 4 한 번 더 돌려도 total rows 4, snapshots 는 한 건 늘었다
- 5 08-03 · bad 파일 뒤 orders 가 6행(order_id 1~5, 7)이다

4-3 · 실습 1.5H 마무리

다음은 정리·회고 (0.5H)

오늘 만든 파이프라인 다섯 단계를 한 장으로 정리하고, 4-4 Trino 가 읽을 테이블 상태를 확인합니다

✓ 랜딩 → 읽기 → 형 변환 → 정제 → 적재

✓ 체크리스트 · 자주 겪는 오류 4가지

✓ orders 행 수 적어 두기

✓ 4-4 Trino 준비물

가져갈 것

orders 6행(order_id 1~5, 7) · 불량 파일 삭제