

4-4 · Trino 기반 S3 SQL 엔진 구축 · 실습 1H

Trino SQL 실습

배운 SQL 이 도구를 바꿔도 그대로 통하는지

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① 고객별·채널별 집계와 윈도우 함수를 Trino 에서 실행한다
- ② CTAS 로 `daily_sales` 를 만들고 Spark 에서도 읽히는지 확인한다
- ③ "`orders$snapshots`" 와 `FOR VERSION AS OF` 로 타임 트래블한다
- ④ `EXPLAIN`·웹 UI 로 실행 계획을 보고, `INSERT`·`DELETE` 를 해 본다

쓰기는 되지만 대량 변환은 여전히 Spark — 역할을 기억하며 실습합니다

여섯 단계 — 읽고, 만들고, 되돌아가고, 써 본다

Trino CLI(docker compose exec -it trino trino)에 접속한 상태에서 시작합니다

1. 집계	2. CTAS	3. 타임 트래블	4. 실행 계획	5.6. 쓰기·과제
GROUP BY 윈도 함수	daily_sales Spark 로 확인	\$snapshots AS OF 조회	EXPLAIN 웹 UI 8080	INSERT·DELETE 채널별 비중

세 쿼리 — 2-2·3-4 의 SQL 그대로

1

고객별 합계

count(*) AS orders, sum(amount) AS total — GROUP BY customer

2

채널별 · 날짜별

GROUP BY order_date, channel — cnt·revenue

3

누적 합계(윈도 함수)

sum(amount) OVER (ORDER BY order_date, order_id) AS running

확인 포인트

세 쿼리

모두 동작

FROM iceberg.lakehouse.orders — 도구를 또 바꿔도 SQL 은 그대로 통한다. SQL 을 익혀 두는 것의 가치

CTAS 로 만든 표를 Spark 가 읽는가

1 CREATE TABLE ... AS SELECT
iceberg.lakehouse.daily_sales — order_date 별 order_cnt·revenue

2 Trino 에서 조회
SELECT * FROM iceberg.lakehouse.daily_sales ORDER BY order_date

3 Spark 에서 같은 표
spark-sql -e "SELECT * FROM demo.lakehouse.daily_sales ..."

4 MinIO 에 파일이 생겼나
mc ls --recursive local/warehouse | grep daily_sales

성공 조건

**양쪽 같은 집계
+ 파일 생성**

타임 트래블 — Spark 와 Trino 문법 차이

하려는 일	Spark	Trino
스냅샷 이력	FROM t.snapshots	FROM "t\$snapshots"
파일 목록	FROM t.files	FROM "t\$files"
버전 조회	VERSION AS OF id	FOR VERSION AS OF id
시각 조회	TIMESTAMP AS OF '..'	FOR TIMESTAMP AS OF TIMESTAMP '..'
테이블 이름	demo.lakehouse.orders	iceberg.lakehouse.orders

SELECT committed_at, snapshot_id, operation FROM iceberg.lakehouse."orders\$snapshots" — 4-2·4-3 의 snapshot_id 와 같은 값

\$ 는 식별자에 못 들어가므로 메타테이블 이름에 큰따옴표가 필요하다 — 빼면 문법 오류

EXPLAIN 과 웹 UI 로 실행 계획 보기

- 1 EXPLAIN SELECT customer, sum(amount) ...**
ScanProject · Aggregate · Output 같은 단계가 보인다
- 2 <http://localhost:8080>**
방금 실행한 쿼리를 클릭하면 각 단계가 몇 행을 처리했는지 보인다
- 3 느린 쿼리를 만나면**
어느 단계가 오래 걸렸는지 여기서 찾는다
- 4 5주차 Spark UI**
비슷한 화면을 제공한다

큰따옴표 없이 orders\$snapshots 를 불러 보기

Trino 에서 \$ 가 식별자에 못 들어간다는 것을 오류 메시지로 확인합니다

1. 따옴표 없이	2. 오류 읽기	3. 큰따옴표로	4. 이력 확인	5. 과거로
...lakehouse. orders\$snapshots	문법 오류 \$ 위치	"orders\$snapshots" 다시 실행	committed_at snapshot_id	AS OF 조회 snapshot_id 복사

Trino 로 쓰기, 그리고 미니 과제

INSERT	(99, 'trino_user', 45000, DATE '2026-08-04', 'web') → 7행
DELETE	WHERE order_id = 99 → 6행 · Spark 에서도 같은 값
과제 1	채널별 매출 비중(%) — 2-2 의 Window 패턴
과제 2	daily_sales 를 Trino 에서 갱신 → Spark 에서 확인
과제 3	"orders\$files" 로 데이터 파일 수와 각 행 수

`round(sum(amount) * 100.0 / sum(sum(amount)) OVER (), 1) AS pct` — 비중의 합이 100 에 가까우면 성공

이 1시간이 끝날 때 확인할 것

- 1 집계 세 쿼리가 모두 동작한다
- 2 `daily_sales` 가 Spark 에서도 보이고 `warehouse` 에 파일이 생겼다
- 3 "`orders$snapshots`" 의 `snapshot_id` 가 4-2·4-3 과 같다
- 4 INSERT 후 7행, DELETE 후 6행 — Spark 에서도 같다
- 5 채널별 비중의 합이 100 에 가깝다

4-4 · 실습 1H 마무리

다음은 정리·회고 (0.5H)

두 엔진의 문법 차이를 정리하고, 4-5 통합 검증을 위한 상태를 확인합니다

✓ 오늘 확인한 것 — 양방향으로 통한다

✓ 컨테이너 5개 Up · 두 엔진 count 6

✓ 자주 겪는 오류 네 가지

✓ 4-5 카탈로그 연결·레이크하우스 통합 예고

가져갈 것

orders·daily_sales 두 표가 남은 상태