4-5 · 데이터 카탈로그 연결 및 레이크하우스 통합 · 이론 1H

데이터 카탈로그의 역할

도서관의 장서 목록 — 두 사서가 같은 목록을 본다

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1시간 뒤에는

① 카탈로그가 레이크하우스의 단일 진실 원천인 이유를 설명한다

② REST·Hive Metastore·Glue·Nessie 카탈로그 선택지를 비교한다

③ 같은 저장소라도 카탈로그가 다르면 서로 못 본다는 것을 안다

④ 이번 주에 쌓은 다섯 층을 한 그림으로 그린다

다음 1.5H 실습에서 두 엔진이 정말 같은 테이블을 보는지 양방향으로 확인합니다

1. 이번 주에 쌓아 올린 것

다섯 층 — 저장부터 질의 엔진까지

저장	테이블 포맷	카탈로그	적재 엔진	질의 엔진
MinIO 오브젝트 스토리지	Iceberg 파일 묶음을 테이블처럼	REST 카탈로그 어디 있는지	Spark 쓰기·변환	Trino 대화형 조회

포트: MinIO 9000·9001 · REST 카탈로그 8181 · Trino 8080

책(데이터 파일)이 아무리 많아도 「어느 서가에 있고 최신판이 몇 판인지」는 목록(카탈로그)이 알려 준다

1. 이번 주에 쌓아 올린 것

층마다 무엇을 어느 날 만들었나

층	무엇	어느 날	포트
저장	MinIO — 오브젝트 스토리지	4-1	9000 · 9001
테이블 포맷	Iceberg — 파일 묶음을 테이블처럼	4-2	—
카탈로그	REST 카탈로그 — 어디 있는지	4-2	8181
적재 엔진	Spark — 쓰기·변환	4-2 · 4-3	—
질의 엔진	Trino — 대화형 조회	4-4	8080

Spark 와 Trino 라는 두 사서가 같은 목록(REST 카탈로그)을 보기 때문에 한쪽이 꽂은 책을 다른 쪽이 바로 찾는다

카탈로그가 단일 진실 원천인 이유

1. **테이블 이름 → 최신 메타데이터 위치**
   이 결정을 카탈로그 한 곳이 담당한다 — 그래서 단일 진실 원천

2. **커밋도 카탈로그를 거친다**
   4-2 커밋 4단계의 ④ 포인터 교체 — 여러 엔진이 동시에 써도 일관성

3. **같은 카탈로그 = 같은 테이블**
   다른 카탈로그면 같은 저장소를 써도 서로의 데이터를 못 찾는다

4-4 count 대조의 뜻

같은 카탈로그를 보는지 확인

2. 단일 진실 원천

「저장소가 같으니 보이겠지」— 틀린 생각

같은 카탈로그

두 엔진이 같은 테이블을 본다

- Spark 가 쓰면 Trino 가 바로 읽는다
- 커밋 이력이 한 줄로 쌓인다
- 4-4 에서 두 count 가 같았던 이유

VS

다른 카탈로그

같은 버킷인데도 서로의 데이터를 못 찾는다

- 파일은 같은 버킷에 그대로 있다
- 어느 파일이 현재 상태인지 모른다
- 각 엔진이 자기 테이블만 본다

3. 카탈로그 선택지

다섯 가지 — 역할은 같고 고르는 기준이 다르다

카탈로그	특징	언제 고르나
REST	엔진 중립 · 표준으로 자리 잡는 중	여러 엔진이 함께 쓸 때 (이번 주)
Hive Metastore	전통적 표준 · RDB 에 저장	기존 Hive/Hadoop 자산이 있을 때
AWS Glue	AWS 관리형 · 운영 부담 없음	AWS 위에서 돌 때
Nessie	Git 처럼 브랜치·머지 지원	데이터에 실험 브랜치가 필요할 때
JDBC / Hadoop	가장 단순	혼자 쓰거나 학습용

어느 것을 골라도 역할은 같다 — 「테이블 이름 → 최신 메타데이터 위치」. 그래서 나중에 바꿀 수도 있다

상호운용 — 데이터는 한 곳, 도구만 갈아 끼운다

1. **작업 성격에 맞는 엔진**
   적재는 Spark, 대화형 분석은 Trino — 레이크하우스의 핵심 가치
2. **복사하지 않는다**
   저장 비용이 늘지 않고 사본 간 불일치가 생기지 않는다
3. **새 도구가 나와도**
   카탈로그만 연결하면 기존 데이터를 그대로 쓴다
4. **예전 방식은**
   도구마다 자기 형식으로 저장 → 사본을 만들고 동기화해야 했다

> **3주차 「도구는 목적에 따라 고른다」를 저장소 수준에서 가능하게 만드는 구조가 4주차**

5. 없으면

카탈로그가 없으면 무엇이 깨지나

없으면	무슨 일이
최신 상태를 모른다	어느 파일이 유효한지 각자 추측한다
커밋 지점이 없다	쓰는 중인 데이터가 읽는 쪽에 보인다
스키마를 모른다	옛 파일과 새 파일의 컬럼이 달라 깨진다
이력이 없다	과거 시점으로 못 돌아간다
엔진 간 공유가 안 된다	도구마다 사본을 만든다

다섯 가지 전부 「어느 파일이 현재 상태인지」를 아무도 정해 주지 않아서 생기는 일

정리

이 1시간에서 꼭 가져갈 것

1. 카탈로그는 「테이블 이름 → 최신 메타데이터 위치」를 정하는 단일 진실 원천
2. 커밋이 카탈로그를 거치므로 여러 엔진이 동시에 써도 일관성이 지켜진다
3. 같은 저장소를 써도 카탈로그가 다르면 서로의 데이터를 못 본다
4. 카탈로그 종류는 여럿이지만 역할은 같아서 나중에 바꿀 수 있다
5. 이번 주 구조는 저장·테이블 포맷·카탈로그·적재 엔진·질의 엔진 다섯 층

4-5 · 이론 1H 마무리

다음은 Spark–Trino 상호운용 검증 (1.5H)

양방향으로 쓰고 읽으며, 두 엔진이 정말 같은 테이블을 보는지 여러 각도로 확인합니다

- ✓ **Trino INSERT → Spark 조회**
- ✓ **Spark ALTER·UPDATE → Trino DESCRIBE**
- ✓ **커밋 이력과 스냅샷 개수 대조**
- ✓ **임시 카탈로그 · 실패한 쓰기 실험**

준비할 것

컨테이너 5개 Up · 두 엔진 count 6