

4-5 · 데이터 카탈로그 연결 및 레이크하우스 통합 · 이론 1H

데이터 카탈로그의 역할

도서관의 장서 목록 — 두 사서가 같은 목록을 본다

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기


1시간 뒤에는

- ① 카탈로그가 레이크하우스의 단일 진실 원천인 이유를 설명한다
- ② REST·Hive Metastore·Glue·Nessie 카탈로그 선택지를 비교한다
- ③ 같은 저장소라도 카탈로그가 다르면 서로 못 본다는 것을 안다
- ④ 이번 주에 쌓은 다섯 층을 한 그림으로 그린다

다음 1.5H 실습에서 두 엔진이 정말 같은 테이블을 보는지 양방향으로 확인합니다

1. 이번 주에 쌓아 올린 것

다섯 층 — 저장부터 질의 엔진까지



포트: MinIO 9000·9001 · REST 카탈로그 8181 · Trino 8080

책(데이터 파일)이 아무리 많아도 '어느 서가에 있고 최신판이 몇 판인지'는 목록(카탈로그)이 알려 준다

1. 이번 주에 쌓아 올린 것

층마다 무엇을 어느 날 만들었나

층	무엇	어느 날	포트
저장	MinIO — 오브젝트 스토리지	4-1	9000 · 9001
테이블 포맷	Iceberg — 파일 묶음을 테이블처럼	4-2	—
카탈로그	REST 카탈로그 — 어디 있는지	4-2	8181
적재 엔진	Spark — 쓰기·변환	4-2 · 4-3	—
질의 엔진	Trino — 대화형 조회	4-4	8080

Spark 와 Trino 라는 두 사서가 같은 목록(REST 카탈로그)을 보기 때문에 한쪽이 쏜은 책을 다른 쪽이 바로 찾는다

2. 단일 진실 원천

카탈로그가 단일 진실 원천인 이유

1 테이블 이름 → 최신 메타데이터 위치
이 결정을 카탈로그 한 곳이 담당한다 — 그래서 단일 진실 원천

2 커밋도 카탈로그를 거친다
4-2 커밋 4단계의 ④ 포인터 교체 — 여러 엔진이 동시에 써도 일관성

3 같은 카탈로그 = 같은 테이블
다른 카탈로그면 같은 저장소를 써도 서로의 데이터를 못 찾는다

4-4 count 대조의 뜻

**같은 카탈로그를
보는지 확인**

「저장소가 같으니 보이겠지」— 틀린 생각

같은 카탈로그

두 엔진이 같은 테이블을 본다

- Spark 가 쓰면 Trino 가 바로 읽는다
- 커밋 이력이 한 줄로 쌓인다
- 4-4 에서 두 count 가 같았던 이유

VS

다른 카탈로그

같은 버킷인데도 서로의 데이터를 못 찾는다

- 파일은 같은 버킷에 그대로 있다
- 어느 파일이 현재 상태인지 모른다
- 각 엔진이 자기 테이블만 본다

3. 카탈로그 선택지

다섯 가지 — 역할은 같고 고르는 기준이 다르다

카탈로그	특징	언제 고르나
REST	엔진 중립 · 표준으로 자리 잡는 중	여러 엔진이 함께 쓸 때 (이번 주)
Hive Metastore	전통적 표준 · RDB 에 저장	기존 Hive/Hadoop 자산이 있을 때
AWS Glue	AWS 관리형 · 운영 부담 없음	AWS 위에서 돌 때
Nessie	Git 처럼 브랜치·머지 지원	데이터에 실험 브랜치가 필요할 때
JDBC / Hadoop	가장 단순	혼자 쓰거나 학습용

어느 것을 골라도 역할은 같다 — 「테이블 이름 → 최신 메타데이터 위치」. 그래서 나중에 바꿀 수도 있다

4. 상호운용

상호운용 — 데이터는 한 곳, 도구만 갈아 끼운다

- 1** **작업 성격에 맞는 엔진**
적재는 Spark, 대화형 분석은 Trino — 레이크하우스의 핵심 가치
- 2** **복사하지 않는다**
저장 비용이 늘지 않고 사본 간 불일치가 생기지 않는다
- 3** **새 도구가 나와도**
카탈로그만 연결하면 기존 데이터를 그대로 쓴다
- 4** **예전 방식은**
도구마다 자기 형식으로 저장 → 사본을 만들고 동기화해야 했다

3주차 「도구는 목적에 따라 고른다」를 저장소 수준에서 가능하게 만드는 구조가 4주차

5. 없으면

카탈로그가 없으면 무엇이 깨지나

없으면	무슨 일이
최신 상태를 모른다	어느 파일이 유효한지 각자 추측한다
커밋 지점이 없다	쓰는 중인 데이터가 읽는 쪽에 보인다
스키마를 모른다	옛 파일과 새 파일의 컬럼이 달라 깨진다
이력이 없다	과거 시점으로 못 돌아간다
엔진 간 공유가 안 된다	도구마다 사본을 만든다

다섯 가지 전부 「어느 파일이 현재 상태인지」를 아무도 정해 주지 않아서 생기는 일

이 1시간에서 꼭 가져갈 것

- 1 카탈로그는 「테이블 이름 → 최신 메타데이터 위치」를 정하는 단일 진실 원천
- 2 커밋이 카탈로그를 거치므로 여러 엔진이 동시에 써도 일관성이 지켜진다
- 3 같은 저장소를 써도 카탈로그가 다르면 서로의 데이터를 못 본다
- 4 카탈로그 종류는 여러이지만 역할은 같아서 나중에 바꿀 수 있다
- 5 이번 주 구조는 저장·테이블 포맷·카탈로그·적재 엔진·질의 엔진 다섯 층

4-5 · 이론 1H 마무리

다음은 Spark-Trino 상호운용 검증 (1.5H)

양방향으로 쓰고 읽으며, 두 엔진이 정말 같은 테이블을 보는지 여러 각도로 확인합니다

✓ Trino INSERT → Spark 조회

✓ Spark ALTER·UPDATE → Trino DESCRIBE

✓ 커밋 이력과 스냅샷 개수 대조

✓ 임시 카탈로그 · 실패한 쓰기 실험

준비할 것

컨테이너 5개 Up · 두 엔진 count 6