4-5 · 데이터 카탈로그 연결 및 레이크하우스 통합 · 실습 1.5H

Spark–Trino 상호운용 검증

양방향으로 쓰고 읽고, 같은 테이블인지 확인

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1.5시간 뒤에는

① 다섯 컨테이너 Up · Trino "6" · Spark 6 을 확인하고 시작한다

② Trino 에서 넣고 Spark 에서, Spark 에서 바꾸고 Trino 에서 본다

③ 커밋 이력과 스냅샷 개수가 두 엔진에서 같은지 대조한다

④ 이름만 다른 카탈로그와 실패한 쓰기로 「같은 테이블」을 확인한다

여섯 단계의 확인 포인트를 다 지나면 두 엔진이 같은 메타데이터를 본다는 뜻입니다

실습 흐름

여섯 단계 — 셸 · trino> · spark-sql 을 오가며

~/lakehouse 에서 시작합니다 — 상자의 [Trino CLI] 는 trino> 안, [Spark] 는 셸에서

1. 시작 상태	2. Trino → Spark	3. Spark → Trino	4. 커밋 이력	5·6. 실험
다섯 Up	8번 행 INSERT	memo 컬럼	orders$snapshots	iceberg2
"6" · 6	count 7	4 choi vip	개수 대조	실패한 쓰기

오늘 쓰는 창구

trino> · spark-sql · 한 줄 실행

Trino CLI	docker compose exec -it trino trino → trino>
나가기	trino> 에서 quit
spark-sql	docker compose exec spark-iceberg spark-sql
나가기	spark-sql 에서 quit;
한 줄 실행	docker compose exec -T trino trino --execute "..."

trino> 에서는 앞 결과가 다 나온 뒤 다음 줄을 친다 — 재시작 직후 첫 쿼리 3~9초, 그 사이 친 줄은 사라진다

1단계

시작 상태 — 다섯 Up · Trino "6" · Spark 6

기동	cd ~/lakehouse && docker compose up -d
상태	docker compose ps — 다섯 컨테이너 Up
Spark	spark-sql -e "SELECT count(*) FROM demo.lakehouse.orders;"
Trino	exec -T trino trino --execute "SELECT count(*) ..."
실측	Trino "6" · Spark 6 — 같아야 시작

두 값이 다르면 4-4 의 카탈로그 설정 대조부터 — 여기가 안 맞으면 오늘 실습이 의미를 잃는다

2·3단계

양방향으로 쓰고 읽는다

Trino 에서 쓰고 Spark 에서 읽기

trino> 에서 INSERT, quit 뒤 셸에서 Spark 조회

- (8, 'jung', 27000, DATE '2026-08-04', 'app')
- INSERT: 1 row → count 7
- Spark 끝 줄 8 jung 27000.0 2026-08-04 app

VS

Spark 에서 바꾸고 Trino 에서 확인

스키마 진화도 카탈로그를 통해 공유된다

- ALTER TABLE … ADD COLUMN memo STRING
- UPDATE … SET memo = 'vip' WHERE order_id = 4
- DESCRIBE 여섯 줄(memo varchar) · 4 | choi | vip

4단계

커밋 이력이 한 줄로 쌓이는가

1. **trino> 에서 "orders$snapshots" 를 시간순으로**
   append · overwrite · delete 가 섞여 엔진 구분 없이 한 이력

2. **Spark — orders.snapshots 의 count**
   spark-sql -e "SELECT count(*) AS snapshot_count FROM … .snapshots;"

3. **Trino — 바깥을 작은따옴표로 감싼 --execute**
   큰따옴표면 셸이 $snapshots 를 지워 orders 행 수 "7" 이 나온다

실측(쓰기 횟수마다 다름)

Spark 9

Trino "9"

5단계

카탈로그 이름은 별명 — iceberg2 를 하나 더

uri·warehouse 는 그대로, 이름만 iceberg2 — 목록 실측 "iceberg" "iceberg2" "system"

iceberg2 파일	restart trino	카탈로그 목록	trino> count	정리
cat > 히어독 uri·warehouse 같게	until 로 대기 실측 48초	SHOW CATALOGS iceberg2 추가	두 이름 모두 7 · 7	rm · restart until

6단계 — 일부러 실패시키기

커밋 전에는 아무에게도 안 보인다

Spark — 타입이 안 맞는 INSERT

order_id 자리에 문자열 '없는아이디' 를 넣는다

INSERT 시도	커밋 없음
CANNOT_SAFELY_CAST	STRING → BIGINT 불가

VS

Trino — 그대로

실패한 쓰기는 어디에도 흔적이 없다

count(*)	스냅샷
"7" 그대로	새 스냅샷 없음

확인 포인트

이 1.5시간이 끝날 때 확인할 것

1. 다섯 컨테이너 Up · Trino "6" · Spark 6 으로 시작했다
2. INSERT: 1 row · count 7 · Spark 끝 줄에 8 jung
3. DESCRIBE 끝에 memo varchar · 4 | choi | vip 한 줄
4. 스냅샷 개수가 Spark · Trino 에서 같다(실측 9 · "9")
5. iceberg · iceberg2 모두 count 7 — 지우고 restart 했다
6. CANNOT_SAFELY_CAST 한 줄 뒤에도 Trino count "7"

4-5 · 실습 1.5H 마무리

다음은 레이크하우스 통합 산출물 (1H)

검증에 쓴 쿼리를 한 파일로 정리하고, 아키텍처 다이어그램을 그려 제출합니다(마감 10-23 23:59)

- ✓ **scripts/lakehouse_queries.sql 정리**
- ✓ **구성 요소 5개 · 포트 다이어그램**
- ✓ **「없으면」 열이 있는 설명 문서**
- ✓ **down → up 재현 확인**

가져갈 것

count 7 · iceberg2 는 지운 상태