

4-5 · 데이터 카탈로그 연결 및 레이크하우스 통합 · 실습 1.5H

Spark-Trino 상호운용 검증

양방향으로 쓰고 읽고, 일부러 다르게 보게도

수도권ICT 이노베이션스퀘어

데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1.5시간 뒤에는

- ① 컨테이너 5개 Up 과 두 엔진의 count 6 을 확인하고 시작한다
- ② Trino 에서 넣고 Spark 에서, Spark 에서 바꾸고 Trino 에서 본다
- ③ 커밋 이력과 스냅샷 개수가 두 엔진에서 같은지 대조한다
- ④ 임시 카탈로그와 실패한 쓰기로 '같은 카탈로그'의 뜻을 실감한다

6단계의 확인 포인트를 다 지나면 두 엔진이 완전히 같은 메타데이터를 보고 있다는 뜻입니다

여섯 단계 — spark-sql 과 Trino CLI 를 번갈아

~/lakehouse 에서 docker compose exec 로 두 엔진에 번갈아 들어갑니다

1. 시작 상태	2. Trino → Spark	3. Spark → Trino	4. 커밋 이력	5·6. 실험
compose ps count 6 · 6	INSERT 8행 count 7	ADD COLUMN memo = vip	\$snapshots 개수 대조	임시 카탈로그 실패한 쓰기

1단계

시작 상태 확인 — 5개 Up · count 6 과 6

기동	<code>cd ~/lakehouse && docker compose up -d</code>
상태	<code>docker compose ps</code> — 5개 Up
Spark	<code>spark-sql -e "SELECT count(*) FROM demo.lakehouse.orders;"</code>
Trino	<code>trino --execute "SELECT count(*) FROM iceberg.lakehouse.orders;"</code>
기준	두 count 가 6 으로 같아야 시작 — 다르면 4-4 로

count 가 다르면 4-4 의 카탈로그 설정 대조부터 — 여기가 안 맞으면 오늘 실습이 전부 의미를 잃는다

양방향으로 쓰고 읽는다

Trino 에서 쓰고 Spark 에서 읽기

INSERT 한 행이 Spark 조회에 즉시 보인다

- INSERT ... VALUES (8, 'jung', 27000, ...)
- Trino count 가 7
- Spark ORDER BY order_id 에 8(jung) 행

VS

Spark 에서 바꾸고 Trino 에서 확인

스키마 진화도 카탈로그를 통해 공유된다

- ALTER TABLE ... ADD COLUMN memo STRING
- UPDATE ... SET memo = 'vip' WHERE order_id = 4
- Trino DESCRIBE 에 memo · 4 행의 memo 가 vip

커밋 이력이 한 줄로 쌓이는가

1

"orders\$snapshots" 를 committed_at 순으로

4-2 INSERT/UPDATE · 4-3 MERGE · 4-4 INSERT/DELETE · 오늘 것까지 한 이력

2

어느 엔진이 만든 커밋인지 구분이 없다

Trino INSERT 와 Spark UPDATE 가 같은 이력에 시간순으로 이어진다

3

스냅샷 개수를 양쪽에서 센다

Spark orders.snapshots 의 count 와 Trino "orders\$snapshots" 의 count

두 숫자가 같으면

**완전히 같은
메타데이터**

임시 카탈로그 — 이름은 별명일 뿐

uri-warehouse 가 같은 카탈로그를 iceberg2 라는 이름으로 하나 더 만들어 봅니다

iceberg2.properties	restart trino	count 비교	정리
catalog/ 에 uri-warehouse 같게	sleep 45 SHOW CATALOGS	iceberg 와 iceberg2 같음	rm 뒤 restart trino

실패한 쓰기는 어디에도 흔적이 없다

Spark — 타입이 안 맞는 INSERT

order_id 자리에 '없는아이디' 를 넣는다



VS

Trino — count 그대로

커밋 전 데이터는 어디서도 보이지 않는다



이 1.5시간이 끝날 때 확인할 것

- 1 docker compose ps 에 컨테이너 5개가 Up · 두 엔진 count 가 6
- 2 Trino count 7 · Spark 조회에 order_id 8(jung) 행이 보인다
- 3 Trino DESCRIBE 에 memo · order_id 4 의 memo 가 vip
- 4 \$snapshots 이력이 시간순 한 줄 · 스냅샷 개수가 양쪽 같다
- 5 iceberg 와 iceberg2 의 count 가 같다 — 지운 뒤 restart
- 6 실패한 INSERT 뒤에도 Trino count 는 7 그대로

4-5 · 실습 1.5H 마무리

다음은 레이크하우스 통합 산출물 (1H)

검증에 쓴 쿼리를 한 파일로 정리하고, 아키텍처 다이어그램을 그려 제출합니다

✓ `scripts/lakehouse_queries.sql` 정리

✓ 구성 요소 5개·포트 4개 다이어그램

✓ 「없으면」열이 있는 설명 문서

✓ down → up 재현 확인

가져갈 것

count 7 · 임시 카탈로그는 지운 상태