

4-5 · 데이터 카탈로그 연결 및 레이크하우스 통합 · 실습 1H

레이크하우스 통합 산출물

쿼리 스크립트 한 파일과 그림 한 장 — 주차 산출물

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1시간 뒤에는

- ① `scripts/lakehouse_queries.sql` 이 처음부터 끝까지 오류 없이 돈다
- ② 구성 요소 5개와 포트를 넣은 아키텍처 다이어그램을 그린다
- ③ 「없으면」열이 있는 설명 문서를 그림에 붙인다
- ④ `down` → `up` 뒤에도 `count 7` 인지 확인하고 제출한다

제출은 사이트의 「산출물 제출」 페이지에서 · 제출 후 주차별 산출물 갤러리에도 올려 주세요

네 단계 — 스크립트 · 그림 · 문서 · 재현

제출 파일: docker-compose.yml · catalog/iceberg.properties · scripts/ · 다이어그램 · 설명 문서

1. 쿼리 스크립트

lakehouse_
queries.sql

2. 다이어그램

구성 5개
포트 4개

3. 설명 문서

구성.흐름
검증.한계

4. 재현 확인

down → up
count 7


lakehouse_queries.sql — 네 부분

부분	쿼리	확인
1. 연결 확인	SHOW CATALOGS SHOW SCHEMAS · TABLES	iceberg.lakehouse 가 보인다
2. 데이터 조회	SELECT * ORDER BY order_id	order_id 8 까지 7행
3. 집계	customer · channel daily_sales	GROUP BY 와 sum() OVER ()
4. 이력	"orders\$snapshots" "orders\$files"	committed_at 순 · file_path·record_count

실행: `docker compose exec -it trino trino < scripts/lakehouse_queries.sql | head -n 40` — 중간에 멈추면 그 쿼리만 CLI 에서 따로

2단계

다이어그램에 그릴 것 — 구성 5개 · 흐름 5단계



포트: 9000(S3 API) · 9001(콘솔) · 8181(카탈로그) · 8080(Trino) — 도구는 자유(손그림 촬영·draw.io·Mermaid)

연결선: Spark → raw 읽기 · Spark → warehouse 쓰기 · Trino → warehouse 읽기 · 두 엔진 → 카탈로그 — 흐름에 번호를

설명 문서 1. 구성 — 「없으면」열이 핵심

구성 요소	역할	포트	없으면
MinIO	파일을 담는 오브젝트 스토리지	9000·9001	저장할 곳이 없다
Iceberg	파일 묶음을 테이블처럼	—	무엇이 현재 상태인지 모른다
REST 카탈로그	테이블 → 최신 메타데이터 위치	8181	엔진끼리 같은 테이블을 못 본다
Spark	적재·변환 (MERGE)	—	대량 쓰기를 할 수 없다
Trino	대화형 조회·집계	8080	빠른 분석 질의가 어렵다

「없으면」열을 스스로 채울 수 있으면 각 구성 요소를 이해한 것 — 4. 한계에 본인이 느낀 것을 한 줄이라도

설명 문서 네 절 — 그림만 있으면 반쪽

1. 구성

구성 요소 · 역할 · 포트 · 없으면 — 표 한 장

2. 데이터 흐름

raw 도착 → Spark 정제 → MERGE → 커밋 → Trino 조회, 번호를 붙여서

3. 검증한 것

양방향 쓰기·읽기 · count·sum·스냅샷 개수 일치 · 실패한 쓰기는 안 보임

4. 한계와 다음 단계

랜딩 존 전체 재읽기 → 날짜 파티션 · 손 실행 → 8주차 Airflow 스케줄링

각 구성 요소가 왜 필요한지 한 줄씩 적어야 다음 사람이 읽는다

제출 전 재현 확인 — down 직후 조회부터

환경을 내렸다 올려도 같은 상태인지 — 볼륨과 카탈로그가 남아 있어야 제출할 수 있습니다

down	up 직후 조회	sleep 60	count 7
docker compose down (-v 금지)	기동 전이라 응답이 없다	기동 뒤 다시 조회	볼륨이 남아 카탈로그가 가리킴

이 1시간이 끝날 때 확인할 것

- 1 lakehouse_queries.sql 의 쿼리가 위에서 아래로 전부 오류 없이 실행된다
- 2 다이어그램에 MinIO·Iceberg·REST 카탈로그·Spark·Trino 와 포트 4개
- 3 연결선: raw→Spark · Spark→warehouse · warehouse→Trino · 엔진→카탈로그
- 4 설명 문서 1번 표의 「없으면」열을 스스로 채웠다
- 5 down 후 up 했는데도 count 가 7 그대로다
- 6 제출 파일: compose.yml · iceberg.properties · scripts/ · 그림 · 문서

4-5 · 실습 1H 마무리

다음은 정리·회고 (0.5H)

4주차 나흘을 되짚고, 컨테이너를 정돈한 뒤 5주차 Spark 클러스터로 넘어갈 준비를 합니다

✓ 4-1~4-5 배운 것·결과물 한 표

✓ 체크리스트로 산출물 점검

✓ 자주 겪는 오류 네 가지

✓ 5-1 분산 처리와 Spark 예고

가져갈 것

제출 완료 · ~/lakehouse 그대로