4-5 · 카탈로그 연결 · 레이크하우스 통합 · 실습 1H

레이크하우스 통합 산출물

쿼리 파일 하나 · 그림 한 장 · 설명 문서

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1시간 뒤에는

① scripts/lakehouse_queries.sql 을 히어독으로 만들고 끝까지 돌린다

② 구성 요소 5개와 포트를 넣은 다이어그램을 그린다

③ lakehouse_architecture.md — 「없으면」 열을 채운다

④ down → up 뒤에도 count "7" 을 확인하고 제출한다

마감 10-23(금) 23:59 · 「산출물 제출」의 「파일/링크 URL」 칸에 GitHub 저장소 주소

실습 흐름

네 단계 — 스크립트 · 그림 · 문서 · 재현

산출물 두 가지: ① 다이어그램 1장 + lakehouse_architecture.md ② scripts/lakehouse_queries.sql

1. 쿼리 스크립트	2. 다이어그램	3. 설명 문서	4. 재현 확인
히어독으로 파일 만들기	구성 5개 포트 4개	구성·흐름 검증·한계	down → up count "7"

1단계

쿼리 파일 만들고 한 번에 돌리기

1 **cd ~/lakehouse && mkdir -p scripts**
쿼리 파일을 둘 scripts 폴더

2 **cat > scripts/lakehouse_queries.sql << 'EOF'**
히어독 — 쿼리 네 부분을 붙이고 마지막 줄에 EOF

3 **exec -T trino trino < 파일 | head -n 40**
파일을 넘기므로 -T — 결과는 따옴표 친 CSV 줄 40개

> **docker compose exec -T trino trino < scripts/lakehouse_queries.sql | head -n 40**

1단계

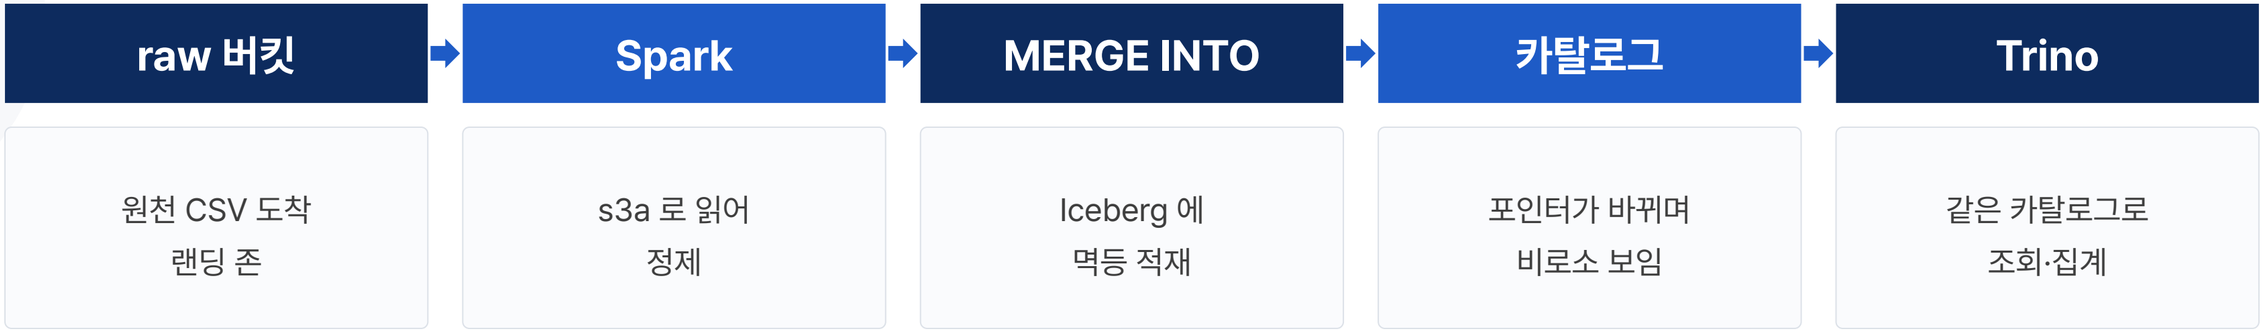
lakehouse_queries.sql — 네 부분과 결과

부분	쿼리	결과(따옴표 CSV)
1. 연결 확인	SHOW CATALOGS SCHEMAS · TABLES	카탈로그 둘 · 스키마 셋 표 둘
2. 데이터 조회	SELECT * ORDER BY order_id	orders 일곱 행
3. 집계	고객별 · 채널 비중 daily_sales	app 118000.0 61.5 web 74000.0 38.5
4. 이력	"orders$snapshots" "orders$files"	스냅샷 이력 파일 목록

중간에 멈추면 그 쿼리를 CLI 에서 따로 실행해 원인을 찾습니다

2단계

다이어그램 — 구성 5개 · 흐름에 번호



포트: 9000(S3 API) · 9001(콘솔) · 8181(카탈로그) · 8080(Trino) — 도구는 자유(손그림 촬영·draw.io·Mermaid)

연결선: Spark → raw 읽기 · Spark → warehouse 쓰기 · Trino → warehouse 읽기 · 두 엔진 → 카탈로그

3단계

lakehouse_architecture.md — 「없으면」 열

구성 요소	역할	포트	없으면
MinIO	파일을 담는 오브젝트 스토리지	9000·9001	저장할 곳이 없다
Iceberg	파일 묶음을 테이블처럼	—	무엇이 현재 상태인지 모른다
REST 카탈로그	테이블 → 최신 메타데이터 위치	8181	엔진끼리 같은 테이블을 못 본다
Spark	적재·변환 (MERGE)	—	대량 쓰기를 할 수 없다
Trino	대화형 조회·집계	8080	빠른 분석 질의가 어렵다

문서 네 절: 1. 구성 · 2. 데이터 흐름 · 3. 검증한 것 · 4. 한계와 다음 단계(본인이 느낀 것 한 줄)

4단계

제출 전 재현 확인 — 내렸다 올려도 같은가

1. **ls · ls catalog scripts**
   iceberg.properties / etl_bad.py · etl_orders.py · lakehouse_queries.sql

2. **docker compose down → up -d**
   -v 없이 down — 볼륨은 남는다

3. **until ... SELECT 1 → 「Trino 준비 완료」**
   다섯 컨테이너가 한꺼번에 떠서 실측 89초 — 기다린 뒤 조회

4. **exec -T ... count(*) → "7"**
   4-2 에서 붙인 카탈로그 볼륨 덕분에 그대로

down → up 뒤

"7"

실패에서 읽기 — 자주 겪는 오류

한쪽에서 넣은 데이터가 다른 쪽에 안 보인다

1. **증상**
   한쪽 엔진에서 넣은 데이터가 다른 쪽 조회에 안 보인다

2. **원인**
   쓰기 쿼리가 아직 실패·미완료 — 커밋 전 데이터는 어디서도 안 보인다

3. **해결**
   성공 메시지 확인 → "orders$snapshots" 에 새 스냅샷 → 다시 조회

문서 3절에

실패한 쓰기는 안 보임

확인 포인트

이 1시간이 끝날 때 확인할 것

1. lakehouse_queries.sql 이 위에서 아래로 전부 오류 없이 실행된다
2. 다이어그램에 MinIO·Iceberg·REST 카탈로그·Spark·Trino 와 포트 4개
3. 설명 문서 1번 표의 「없으면」 열을 스스로 채웠다
4. down 후 up 했는데도 count 가 "7" 그대로다
5. GitHub 저장소 주소를 「파일/링크 URL」 칸에 — 10-23 23:59
6. 패들릿에 이름_4주차.zip (.venv · data 제외)

4-5 · 실습 1H 마무리

다음은 주차 회고 · 산출물 점검 (0.5H)

4주차를 되짚고, 컨테이너를 정돈한 뒤 5주차 Spark 클러스터로 넘어갈 준비를 합니다

- ✓ **4-1~4-5 배운 것·결과물 한 표**
- ✓ **체크리스트 열두 개로 산출물 점검**
- ✓ **docker compose stop 으로 정돈**
- ✓ **5-1 분산 처리와 Spark 예고**

가져갈 것

쿼리 파일 · 그림 · 설명 문서