4-5 · 카탈로그 연결 및 레이크하우스 통합 · 정리·회고 0.5H

주차 회고 · 산출물 점검

데이터를 한 곳에 두고 도구를 갈아 끼운다 — 4주차

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

30분 뒤에는

① 4-1~4-5 에서 배운 것과 남은 결과물을 한 표로 본다

② 볼륨은 남기고 컨테이너를 정지해 5주차를 준비한다

③ 체크리스트 열두 개로 4주차 산출물을 스스로 점검한다

④ 자주 겪는 오류 네 가지의 원인과 해결을 안다

산출물 마감 — 10-23(금) 23:59, 수업이 끝나고 하루

4주차에 지나온 길

닷새 — 배운 것과 남은 결과물

차시	배운 것	남은 결과물
4-1	오브젝트 스토리지와 S3 API	MinIO · raw·warehouse 버킷
4-2	Iceberg 메타데이터 사슬과 타임 트래블	orders 테이블 · 스냅샷 이력
4-3	랜딩 존 → 정제 → MERGE 멱등 적재	etl_orders.py
4-4	Trino 로 같은 테이블 조회	iceberg.properties · daily_sales
4-5	카탈로그 중심 상호운용 검증	아키텍처 다이어그램 · 쿼리 스크립트

3주차에서 도구를 목적에 따라 골랐다면, 4주차는 그것을 저장소 수준에서 가능하게 만드는 구조

5주차로 이어지는 것

오늘 그린 그림의 왼쪽에 붙는다

1. **Spark**
   이번 주는 spark-sql 로 가볍게 — 5주차엔 클러스터를 띄우고 드라이버·익스큐터·셔플
2. **Iceberg**
   5주차는 별도 Spark 컨테이너 — ~/lakehouse 는 stop 해 두고 지우지 않는다
3. **파티셔닝**
   3-3 에서 맛보고 4주차에서 개념 — 5-5 에서 성능 문제로 다시 만난다
4. **아키텍처 그림**
   왼쪽에 6주차 Kafka, 8주차 Airflow 가 붙는다

컨테이너 정돈

볼륨은 남기고 정지만 — 5주차에도 쓴다

1. **cd ~/lakehouse · docker compose stop**
   다섯 컨테이너가 Exited(정지) — 지우지 않고 내려 둔다

2. **docker compose ps -a · docker volume ls**
   볼륨 lakehouse_minio-data · lakehouse_rest-catalog 는 그대로

3. **mkdir -p ~/data-eng/week5**
   5주차 실습 폴더를 미리 — 필요할 때 start 로 다시 켠다

4. **down 도 피한다**
   테이블은 남지만 4-3 hadoop-aws 부품을 지워 spark-submit 이 다시 받는다

쓰면 안 되는 것

down -v

테이블 소실

오늘의 체크리스트 1~6

열두 개를 스스로 확인해 보세요

1. 카탈로그가 단일 진실 원천인 이유를 설명할 수 있다
2. 카탈로그가 없으면 깨지는 것을 세 가지 이상 말할 수 있다
3. REST·Hive Metastore·Glue·Nessie 의 차이를 대략 말할 수 있다
4. 두 엔진의 count 가 같은 것을 확인하고 시작했다
5. Trino INSERT → Spark · Spark 스키마 변경 → Trino 를 검증했다
6. 두 엔진의 스냅샷 개수까지 일치하는 것을 확인했다

오늘의 체크리스트 7~12

열두 개를 스스로 확인해 보세요

7	카탈로그 이름은 별명 · uri·warehouse 가 실체임을 확인했다
8	실패한 쓰기는 커밋되지 않아 다른 엔진에도 안 보임을 확인했다
9	아키텍처 다이어그램에 구성 요소 5개와 포트를 표기했다
10	lakehouse_queries.sql 이 처음부터 끝까지 오류 없이 돈다
11	설명 문서의 「없으면」 열을 스스로 채웠다
12	down 후 up 해도 데이터가 남는 것을 확인하고 제출했다

제출 마감 10-23(금) 23:59 — 「파일/링크 URL」 칸에 GitHub 저장소 주소

자주 겪는 오류

증상으로 찾는 원인과 해결

증상	원인	해결
Spark 테이블이 Trino 에 안 보임	두 엔진이 다른 카탈로그 (uri 또는 warehouse)	rest:8181 · s3://warehouse/ 양쪽 값 대조
넣은 데이터가 다른 쪽에 안 보임	쓰기가 실패·미완료 커밋 전엔 어디서도 안 보임	성공 메시지 확인 → $snapshots 새 스냅샷 확인
FOR VERSION AS OF 스냅샷 못 찾음	다른 테이블의 id 또는 만료된 스냅샷	같은 테이블 $snapshots 결과에서 id 복사
catalog 파일 넣었는데 Trino 가 못 읽음	컨테이너는 기동 시점에 카탈로그를 읽는다	restart trino 뒤 SELECT 1 될 때까지(실측 48초)

「안 보인다」면 순서는 늘 같다 — 카탈로그 설정 대조 → 커밋 여부("orders$snapshots") 확인

다음 회차 예고

5-1 · 분산 처리와 Spark 아키텍처

01

이론 1H

분산 데이터 처리와

Spark 개요

02

실습 1.5H

단일 노드 Spark 기동

PySpark 첫 실행

03

실습 1H

Spark UI 로

잡 구조 읽기

04

정리 0.5H

정리·회고

이론·실습

준비: Docker Desktop 실행 · docker version 정상 출력 확인 · 4주차 MinIO·Iceberg 컨테이너는 내려 두어도 됨(지우지는 않음 — 4주차 결과물)

4-5 · 정리·회고 0.5H 마무리

다음 회차는 5-1 분산 처리와 Spark

Spark 의 드라이버·익스큐터 구조와 지연 평가를 컨테이너 실습으로 직접 확인합니다

- ✓ 스케일업과 스케일아웃의 차이
- ✓ 드라이버 · 익스큐터 · 클러스터 매니저
- ✓ transformation 과 action (지연 평가)
- ✓ Spark UI 의 Job → Stage → Task

준비할 것

docker version 확인 · week5 폴더