5-1 · 분산 처리와 Spark 아키텍처 · 수업 전 10분

실습점검 · 환경재설정

4주차 멈추기 · 4040 · Spark 이미지

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

왜 점검하나

수업 전에 걸러 둘 것

① 4주차 컨테이너 다섯 개가 떠 있어 메모리가 모자란다

② 4040 을 다른 프로그램이 쓰고 있다 — Spark UI 자리

③ Spark 이미지(1.56GB)를 실습 중에 처음 받는다

점검(1~4단계)은 멈추기 · 확인 · 미리 받기만 · 재설정(5단계)은 다시 할 때만

흐름

다섯 단계 — 위에서부터 한 번씩

4주차 테이블은 지우지 않는다 — 4주차 결과물

1 4주차 멈추기	2 4040 확인	3 이미지 받기	4 오늘 만들 것	5 환경 재설정
compose stop down 은 금지	docker ps + 운영체제별	spark:3.5.3 1.56GB	순서만 확인 아직 치지 않음	오늘 실습을 다시 할 때만

1단계

4주차 컨테이너를 멈춰 보세요

1. **cd ~/lakehouse**
   없으면(No such file or directory) cd · stop 은 건너뛴다
2. **docker compose stop**
   4-5 끝에 이미 멈췄다면 아무 일도 하지 않는다
3. **docker ps**
   제목 줄만 나오면 실행 중인 컨테이너가 없는 것
4. **down · down -v 는 쓰지 않는다**
   down -v 는 4주차 테이블을 지운다 — 4주차 결과물

다른 과정

docker stop

이름으로 멈춤

2단계 · 4040 포트

도커 밖에서 4040 을 쓰는 프로그램

01

Windows

netstat -ano | findstr

LISTENING 없으면 비어 있음

02

macOS

lsof -nP -iTCP:4040

아무것도 없으면 비어 있음

03

리눅스

sudo ss -ltnp | grep

docker-proxy 면 컨테이너

먼저 docker ps -a ... | grep -E 'NAMES|4040' — 제목 줄만이면 도커 안은 비어 있음

3단계

Spark 이미지를 미리 받아 두세요

1. **docker pull apache/spark:3.5.3**
   Status: Downloaded newer image … (있으면 Image is up to date)

2. **docker images apache/spark**
   apache/spark:3.5.3 · DISK USAGE 1.56GB 한 줄

3. **판에 따라 다른 모양**
   REPOSITORY · TAG 3.5.3 · SIZE 1.56GB 로도 나온다

4. **실측 32초**
   회선에 따라 몇 분 — 그래서 수업 전에 받는다

5-2 · 5-3

같은 이미지를 다시 쓴다

4단계 · 순서만

오늘 만드는 것 — 아직 치지 않는다

무엇	어디서 처음 만드나	남는가
~/data-eng/week5 폴더	단일 노드 실습 1단계 mkdir -p	예 — 5주차 작업 폴더
PySpark 셸 컨테이너	단일 노드 실습 1단계 docker run -it --rm	아니오 exit() 하면 지워짐
Spark UI localhost:4040	셸을 띄운 순간	아니오 셸이 살아 있는 동안

셸 안에서 DataFrame 을 만들고 Spark UI 로 본다 — exit() 하면 컨테이너째 사라진다(--rm)

5단계 · 환경 재설정

오늘 실습만 처음부터 다시 할 때

1. **>>> exit()**
   셸 안이면 먼저 나온다 — 컨테이너가 함께 지워진다

2. **docker ps -a --filter ancestor=apache/spark:3.5.3**
   남은 Spark 컨테이너가 있는지 본다

3. **docker rm -f $(docker ps -aq --filter ...)**
   셸을 창째로 닫아 남았을 때만 지운다

4. **다시 docker ps -a --filter ...**
   제목 줄만 나오면 끝 — 이미지는 지우지 않는다

다시 시작

실습 1단계

docker run 부터

확인 포인트

수업 준비가 끝났는지

1. docker ps 가 제목 줄만 낸다 — 4주차는 멈춤, 지우지 않음
2. 4040 을 잡은 컨테이너도, 밖의 프로그램도 없다
3. docker images 에 apache/spark:3.5.3 · 1.56GB 가 있다
4. PySpark 셸은 아직 띄우지 않았다 — 실습 시간에 띄운다

막히면 그 단계 아래 「막혔어요」 · 「질문」을 눌러 주세요

5-1 · 수업 전 10분 마무리

다음은 분산 데이터 처리와 Spark 개요 (1H)

점검을 마쳤으니 한 대로 안 될 때 여러 대에 나눠 맡기는 원리부터 봅니다

- ✓ 왜 분산 처리인가
- ✓ 드라이버와 익스큐터
- ✓ 지연 평가와 Job · Stage · Task

막혔다면

그 단계 아래 「막혔어요」 · 「질문」