

5-1 · 분산 처리와 Spark 아키텍처 · 실습 1.5H

단일 노드 Spark 기동과 PySpark 첫 실행

PySpark 를 띄우고 지연 평가를 눈으로 확인

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1.5시간 뒤에는

- ① `apache/spark:3.5.3` 컨테이너로 PySpark 셸을 띄운다
- ② transformation 만 걸었을 때 Jobs 탭이 비어 있는 것을 본다
- ③ `count()` · `show(5)` 로 action 하나가 Job 하나임을 확인한다
- ④ `explain()` 으로 실행 계획을 읽고 파티션 수를 확인한다

여기서 본 파티션 수가 다음 1H 실습에서 Task 수로 다시 나타납니다

일곱 단계 — 셀 하나에서 계획·실행·계획서까지

~/data-eng/week5 폴더를 만들고 시작합니다 — Spark UI 포트 4040 을 함께 엽니다

1. 셀 기동

```
docker run  
-p 4040:4040
```

2. 환경 확인

```
version  
master
```

3·4. 계획→실행

```
transformation  
action
```

5. 실행 계획

```
explain()
```

6·7. 파티션·과제

```
getNumPartitions  
미니 과제
```

기동과 환경 확인 — 명령 다섯 줄


기동	<code>docker run -it --rm -p 4040:4040 apache/spark:3.5.3</code>
셸	<code>/opt/spark/bin/pyspark</code> (run 명령 끝에 이어서)
버전	<code>spark.version</code>
병렬도	<code>spark.sparkContext.defaultParallelism</code>
마스터	<code>spark.sparkContext.master</code>

확인: 로고 아스키 아트 뒤 >>> 프롬프트 · 버전 3.5.x · master local[*] = 코어 수만큼 나눈다(5-2 에서 spark://... 로) · 이미지 약 1GB 라 첫 실행은 몇 분

transformation 은 즉시 반환, action 은 실행

3단계 — transformation 만

즉시 반환 · Jobs 탭에 Job 이 하나도 없다



VS

4단계 — action

count() 결과 500000 · Jobs 탭에 Job 이 나타난다



explain() 으로 계획서를 읽는다

명령	보이는 것	뜻
<code>filtered.explain()</code>	Range → Project → Filter	할 일 목록이 하나의 계획으로
<code>explain(True)</code>	논리 계획부터 물리 계획까지	전부 보기
<code>q.explain()</code>	안 쓰는 컬럼 계산이 빠짐	Catalyst 가 계획을 다시 짤
	Filter 가 앞으로 당겨짐	「쓴 대로 실행되지 않는다」

q = range → withColumn(x, 쓰지 않을 컬럼) → select("id") → filter("id > 999990") — 결국 id 만 쓰는 쿼리

action 없이 결과를 기다려 본다

「안 되는 것 같다」를 직접 겪어 봅니다 — 오류가 아니라 지연 평가입니다

transformation 5개	결과를 기다린다	UI 확인	action 을 붙인다	Job 이 생긴다
withColumn·filter 이어 붙이기	아무것도 안 나온다	Jobs 탭 여전히 0	show() 또는 count()	그제야 실행

파티션 수를 본다 — 이 수가 곧 Task 수

기본 파티션 수	df.rdd.getNumPartitions()
필터 뒤	filtered.rdd.getNumPartitions()
import	from pyspark.sql.functions import spark_partition_id
파티션별 행 수	df.groupBy(spark_partition_id()).count().show()

확인: 파티션 수 ≈ CPU 코어 수 · 각 파티션에 행이 고르게 분포 · 이 숫자가 곧 Task 수 — 다음 1H 에서 UI 로 확인

미니 과제 세 가지

1 1,000만 행에서 짝수 세기
spark.range(1, 10_000_001) 로 만들고 짝수만 count — 시간이 얼마나 걸리는지

2 filter 두 번 이어 걸기
explain() 으로 두 조건이 하나로 합쳐졌는지 본다

3 transformation 5개, action 없이
UI 의 Job 이 여전히 0 인지 — 앞 장에서 겪은 그것

count() 와 show(5) 가 각각 Job 을 만든다 = action 마다 처음부터 다시 계산 — 여러 번 쓸 결과는 cache() (심화 과제)

이 1.5시간이 끝날 때 확인할 것

- 1 >>> 프롬프트와 「SparkSession available as spark」가 떴다
- 2 spark.version 이 3.5.x · master 가 local[*]
- 3 transformation 뒤 Jobs 탭에 Job 이 0 이다
- 4 count() 가 500000 · Job 하나 · show(5) 로 하나 더
- 5 explain() 에 Range → Project → Filter 가 보인다
- 6 파티션 수 ≈ 코어 수 · 각 파티션의 행이 고르다

5-1 · 실습 1.5H 마무리

다음은 Spark UI 로 잡 구조 읽기 (1H)

지금 띄운 셀을 그대로 두고 localhost:4040 에서 Job → Stage → Task 와 DAG 를 읽습니다

✓ Jobs 탭 — count() 와 show(5) 두 줄

✓ groupBy 로 Stage 를 2개로 — 셔플

✓ Stages 탭의 Task 수 = 파티션 수

✓ cache 전후 시간 재기

가져갈 것

셀을 끄지 말 것 · 파티션 수 메모