

5-3 · Iceberg · MinIO 연결과 대용량 분석 준비 · 실습 1.5H

Spark ↔ MinIO(s3a) 연결

MinIO 를 클러스터에 붙이고, Parquet 왕복으로 확인

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1.5시간 뒤에는

- ① 5-2 compose 에 minio 서비스를 더해 세 컨테이너를 Up 으로 만든다
- ② warehouse 버킷을 만들고 콘솔(9001)에서 확인한다
- ③ --packages · --conf 로 PySpark 를 띄워 Parquet 을 s3a 로 왕복한다
- ④ 잘못된 버킷·자격증명·주소가 내는 오류 세 가지를 구분한다

여기서 막히면 Iceberg 문제가 아니라 연결 문제 — 다음 1H 전에 왕복까지 끝냅니다

다섯 단계 — ~/data-eng/week5 의 5-2 compose 위에서

4주차 MinIO 가 9000 을 쓰고 있으면 먼저 내리고 시작합니다

1. compose	2. 버킷	3. PySpark	4. 왕복	5. 일부러 틀리기
minio 서비스 volumes 추가	warehouse mc 또는 콘솔	--packages --conf 9줄	write → read count 100	오류 세 가지 구분

붙여넣을 조각 둘 — 들어갈 자리가 다르다

① minio: 덩이

services: 아래에 — 들여쓰기 2칸 그대로

- image: pgsty/minio:latest
- container_name: spark-minio
- admin / password123 · 9000 · 9001

VS

② volumes: 덩이

파일 맨 아래 최상위 — 들여쓰기 없음

- spark-minio-data: 한 줄
- services: 안에 넣으면 must be a mapping
- YAML 은 들여쓰기가 곧 구조

핵심 명령 — 기동 · 상태 · 버킷 · 콘솔

4주차 MinIO 내리기	cd ~/lakehouse && docker compose stop
기동	cd ~/data-eng/week5 && docker compose up -d
상태	docker compose ps — 세 서비스 Up
버킷(mc)	mc mb -p m/warehouse (--network week5_default)
콘솔	localhost:9001 · admin / password123

네트워크 이름은 docker network ls 로 확인 — 폴더 이름에 따라 week5_default 가 아닐 수 있다

3단계

라이브러리와 설정을 담아 PySpark 를 띄운다

1

--packages 둘

hadoop-aws:3.3.4 · iceberg-spark-runtime-3.5_2.12:1.5.2 — 첫 실행은 몇 분

2

--conf (1) 주소와 열쇠

endpoint=http://minio:9000 · admin / password123 · path.style.access=true

3

--conf (2)(3) 확장과 카탈로그

sql.extensions 한 줄 + spark.sql.catalog.lake 세 줄(hadoop · s3a://warehouse/)

endpoint 호스트

minio

서비스 이름

의존성 로그가 지나간 뒤 >>> 가 뜨면 성공 — 긴 명령은 셀 함수나 스크립트로 저장해 두세요

4단계

s3a 왕복 — count 가 100 이면 연결 완료

쓰기 → 읽기

Iceberg 전에 「그냥 파일 읽고 쓰기」부터

파일 수 = 파티션 수

콘솔에서 part 파일 개수를 비교

VS

spark.range(1, 101) → write.parquet → read → count

100행

smoke-test/

100

getNumPartitions → smoke-test/ → coalesce(1)

파티션 수

part 여러 개

smoke-one/ 하나

없는 버킷을 읽어 본다 — 오류 세 가지를 구분

틀린 것	나는 오류	좁히는 법
s3a://no-such-bucket/x/	버킷이 없다는 취지	버킷 이름 · mc ls
자격증명(키)	403	MinIO 계정과 키 값 대조
주소(endpoint)	UnknownHost	서비스 이름 minio 인지

try/except 로 type(e).__name__ 과 str(e)[:300] 을 찍어 두면 실무에서 원인을 바로 좁힌다

이 1.5시간이 끝날 때 확인할 것

- 1 docker compose ps 에 spark-master · spark-worker · minio 가 Up
- 2 localhost:9001 에 admin / password123 으로 로그인된다
- 3 PySpark 에 >>> 가 뜨고 endpoint 호스트명이 minio 다
- 4 count 100 · 콘솔의 warehouse 에 smoke-test/ 와 .parquet 파일
- 5 없는 버킷 · 403 · UnknownHost 를 구분해 말할 수 있다

5-3 · 실습 1.5H 마무리

다음은 Iceberg 카탈로그 구성과 테이블 생성 (1H)

띄워 둔 셀에서 SQL 로 Iceberg 테이블을 만들고, MinIO 에 어떤 파일이 생기는지 확인합니다

✓ SHOW CATALOGS 로 lake 확인

✓ CREATE TABLE ... USING iceberg · INSERT

✓ 콘솔에서 metadata/ · data/ 폴더 확인

✓ snapshots 메타테이블과 타임 트래블

가져갈 것

띄워 둔 PySpark 셀(>>>) 그대로