5-3 · Iceberg · MinIO 연결 · 실습 1H

Iceberg 카탈로그 구성과 테이블 생성

SQL 로 테이블을 만들고, 생긴 파일 확인

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

1시간 뒤에는

① CREATE NAMESPACE 뒤 SHOW CATALOGS 에 lake 가 생기는 것을 본다

② lake.db.orders 를 USING iceberg 로 만들고 3행을 넣는다

③ 콘솔에서 warehouse/lake/db/orders 의 metadata/ · data/ 확인

④ INSERT·UPDATE 로 스냅샷을 쌓고 첫 판으로 되돌려 본다

카탈로그 타입이 달라도 Iceberg 기능은 그대로 — 4주차와 같은 결과

실습 흐름

다섯 단계 — 앞 시간에 띄운 PySpark 셸에서

셸을 나갔다면 ~/data-eng/week5 에서 bash lake-pyspark.sh 로 다시 띄웁니다

1. 카탈로그	2. 테이블	3. 파일 구조	4. 스냅샷	5. 클러스터
SHOW CATALOGS CREATE NAMESPACE	CREATE · INSERT SELECT 3행	메타테이블 snapshots · files	INSERT · UPDATE VERSION AS OF	master 7077 UI 8080

1단계

카탈로그는 처음 쓸 때 등록된다

1. **SHOW CATALOGS**
   spark_catalog 한 줄뿐 — 아직 lake 가 없는 것이 정상
2. **일부러: SHOW NAMESPACES IN lake**
   NoSuchNamespaceException — 빈 warehouse 라 폴더가 없다
3. **CREATE NAMESPACE IF NOT EXISTS lake.db**
   warehouse/lake 아래에 db 가 생긴다
4. **SHOW CATALOGS · SHOW NAMESPACES IN lake**
   lake · spark_catalog 두 줄, 네임스페이스는 db 한 줄

모두

```
spark.sql("...")
.show()
```

2·3단계

만들고, 넣고, 뜯어본다

spark.sql("...")	결과(실측)
CREATE TABLE lake.db.orders	DataFrame[] 한 줄
INSERT 3행	DataFrame[] 한 줄
SELECT ... ORDER BY id	45000.0 · 23000.0 · 310000.0
SHOW TABLES IN lake.db	orders
DESCRIBE TABLE	id · item · price
orders.snapshots	append 하나
orders.files	3개 · record_count 1 씩

files 가 3개인 것은 세 행이 태스크 셋으로 나뉘어 각자 파일을 썼기 때문

3단계

테이블의 실체 — MinIO 의 폴더

lake.db.orders	warehouse/lake	db/orders/	metadata/ · data/
SQL 에서 부르는 이름	설정의 warehouse 값	db · orders 네임스페이스·테이블	JSON·avro Parquet

앞의 lake 폴더는 warehouse 값에서 온 것 — 카탈로그 이름이 자동으로 따라온 것이 아님

hadoop 타입은 폴더 구조가 곧 테이블 목록 — rest 와 달리 별도 서비스가 없다

4단계

스냅샷이 쌓인다 — 그리고 시간을 되돌린다

1. **INSERT (4, 'webcam', 89000) · UPDATE id 1 → 47000**
   둘 다 DataFrame[] 한 줄 — UPDATE 는 파일을 다시 써서 overwrite
2. **snapshots ORDER BY committed_at**
   append · append · overwrite 세 줄, keyboard 47000.0
3. **콘솔 metadata/**
   v1~v4.metadata.json · version-hint.text · snap-*.avro · *-m0.avro
4. **VERSION AS OF 첫 스냅샷**
   3행 · keyboard 45000.0 — 타임 트래블도 그대로

최신 판 번호

version-hint.text

클러스터에서 도는지 확인하고, 더 해 보기

01

5단계 클러스터

sparkContext.master

spark-master:7077

02

파티션 테이블

PARTITIONED BY

(item) 폴더 비교

03

events.parquet

콘솔 Upload 뒤

Iceberg 로 적재

04

CTAS 집계

lake.db.summary

AS SELECT …

마스터 UI(8080) Running Applications 에 PySparkShell · Cores 4 · RUNNING

일부러 실패시키기

메시지로 빠진 것을 찾는다

상황	나는 오류	뜻
빈 lake 에 SHOW NAMESPACES	NoSuchNamespaceException	아직 폴더가 없다
catalog.lake 세 줄 없음	REQUIRES_SINGLE_PART_NAMESPACE	lake 를 카탈로그로 모름
iceberg 패키지 없음	Cannot find catalog plugin class	--packages 확인

첫 줄은 1단계에서 쳐 본 것 — 아래 둘은 lake-pyspark.sh 에서 줄이 빠졌을 때(실측)

확인 포인트

이 1시간이 끝날 때 확인할 것

1. 처음엔 spark_catalog 하나, CREATE NAMESPACE 뒤 lake 가 보인다
2. SELECT 3행 · files 3개 · file_path 가 warehouse/lake/db/orders
3. 콘솔 metadata/ 에 v1~v4.metadata.json · version-hint.text
4. snapshots append·append·overwrite · keyboard 47000.0
5. 첫 스냅샷 VERSION AS OF 는 45000.0 · master 가 7077

5-3 · 실습 1H 마무리

다음은 정리·회고 (0.5H)

설정을 「없으면 무슨 오류」로 한 장에 정리하고, 5-4 를 위해 멈춰 둡니다

- ✓ **설정 요약 — 없으면 나는 오류**
- ✓ **오늘의 체크리스트**
- ✓ **자주 겪는 오류**
- ✓ **exit() 뒤 docker compose stop**

가져갈 것

셸(>>>)은 그대로 두기