

5-3 · Iceberg · MinIO 연결과 대용량 분석 준비 · 실습 1H

Iceberg 카탈로그 구성과 테이블 생성

SQL 로 테이블을 만들고, 저장소에 생긴 파일을 확인

수도권ICT 이노베이션스퀘어

데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① SHOW CATALOGS 로 lake 카탈로그가 등록됐는지 확인한다
- ② CREATE TABLE ... USING iceberg 로 lake.db.orders 를 만들고 3행을 넣는다
- ③ MinIO 콘솔에서 metadata/ 와 data/ 폴더를 눈으로 확인한다
- ④ INSERT·UPDATE 뒤 snapshots 가 쌓이고 타임 트래블이 되는 것을 본다

카탈로그 타입이 달라도 Iceberg 기능은 그대로 — 4주차와 같은 결과가 나와야 합니다

다섯 단계 — 앞 시간에 띄워 둔 PySpark 셀에서

셀을 나갔다면 3단계 명령(--packages · --conf)으로 다시 띄우고 시작합니다

1. 카탈로그	2. 테이블	3. 파일 구조	4. 스냅샷	5. 클러스터
SHOW CATALOGS lake 보이나	CREATE · INSERT SELECT 3행	콘솔 · 메타테이블 snapshots · files	INSERT · UPDATE VERSION AS OF	master 7077 UI 8080

핵심 명령 — spark.sql("...") 로 실행

카탈로그	SHOW CATALOGS
DB 목록	SHOW DATABASES IN lake — 아직 비어 있다
테이블	CREATE TABLE lake.db.orders (id, item, price) USING iceberg
넣기	INSERT INTO lake.db.orders VALUES (1, 'keyboard', 45000) ...
확인	SELECT * FROM lake.db.orders ORDER BY id — 3행

lake 가 안 보이면 --conf 의 spark.sql.catalog.lake 세 줄부터 다시 확인

2·3단계

테이블의 실체 — MinIO 의 두 폴더



콘솔(9001)에서 warehouse/db/orders/ 아래 두 폴더가 생겼는지 확인 — 이것이 Iceberg 테이블의 실체

hadoop 타입에서는 폴더 구조가 곧 테이블 목록 — rest 와 달리 별도 서비스가 없는 이유

카탈로그가 아는 것 · 메타테이블 — 4주차와 같다

질의	무엇이 나오나
SHOW TABLES IN lake.db	orders
DESCRIBE TABLE lake.db.orders	id · item · price
lake.db.orders.snapshots	append 한 건
lake.db.orders.files	parquet 한 개 · file_path

file_path 가 s3a://warehouse/db/orders/data/... 로 시작하면 데이터가 MinIO 에 있다는 뜻

스냅샷이 쌓인다 — 그리고 시간을 되돌린다

1 INSERT 한 건 더
(4, 'webcam', 89000) — snapshots 에 append 가 하나 더

2 UPDATE id 1 의 price → 47000
overwrite 로 기록 — 파일을 통째로 다시 쓰기 때문(4-2)

3 snapshots 3행
append · append · overwrite — committed_at 순으로 정렬

4 VERSION AS OF 첫 스냅샷
3행 · id 1 의 price 45000 — 타임 트래블도 그대로

operation 값

append

overwrite

카탈로그 세 줄을 빼고 띄우면 — 무엇이 깨지나

자주 겪는 오류를 미리 만나 둡니다 — 셀을 나가서 --conf 의 spark.sql.catalog.lake 세 줄을 뺀 채 다시 띄워 보세요

세 줄 빼고 재실행	SHOW CATALOGS	CREATE TABLE lake...	세 줄 복구
catalog.lake type · warehouse	lake 가 보이지 않는다	Cannot find catalog plugin	다시 띄워 lake 확인

클러스터에서 돌고 있는지 확인하고, 더 해 보기

01

5단계 클러스터

sparkContext.master
= spark-master:7077

02

파티션 테이블

PARTITIONED BY
(item) 폴더 비교

03

events.parquet

3주차 파일 올려
Iceberg 로 적재

04

CTAS 집계

lake.db.summary
AS SELECT ...

마스터 UI(8080) Running Applications 에 이 셀이 보인다 — 5-2 클러스터가 오늘 레이크하우스를 다루는 중

이 1시간이 끝날 때 확인할 것

- 1 SHOW CATALOGS 에 lake 가 보인다
- 2 SELECT 결과 3행 · 콘솔에 metadata/ 와 data/ 폴더
- 3 files 의 file_path 가 s3a://warehouse/db/orders/data/ 로 시작
- 4 snapshots 3행(append·append·overwrite) · id 1 의 price 47000
- 5 첫 스냅샷 VERSION AS OF 에서 price 45000 · master 가 7077

5-3 · 실습 1H 마무리

다음은 정리·회고 (0.5H)

설정 아홉 줄을 「없으면 무슨 오류」로 한 장에 정리하고, 5-4 데이터 가공을 위한 상태를 확인합니다

✓ 설정 요약 — 없으면 나는 오류

✓ 오늘의 체크리스트

✓ 자주 겪는 오류 네 가지

✓ 5-4 예고와 준비물

가져갈 것

셀은 나가지 말고 그대로 두기