5-3 · Iceberg · MinIO 연결 · 정리·회고 0.5H

정리·회고

설정을 한 장으로, 5-4 를 위한 상태 확인

이 시간의 목표

30분 뒤에는

① 설정 열 줄을 「없으면 무슨 오류」로 정리한다

② 오늘의 체크리스트 열두 개로 스스로 점검한다

③ 자주 겪는 오류 여섯 가지의 원인과 해결을 안다

④ exit() → ps 넷 Up · ls 세 파일 → stop 으로 마친다

지우지 않고 멈춥니다 — 5-4 는 start 뒤 bash lake-pyspark.sh 로 시작

설정 요약 ①

라이브러리와 스토리지 — 없으면 무슨 오류

설정	없으면 · 틀리면	값
spark.jars.ivy	FileNotFound .../.ivy2/...	/tmp/.ivy2
--packages hadoop-aws	S3AFileSystem 못 찾음	hadoop-aws:3.3.4
--packages iceberg-...	catalog plugin 못 찾음	runtime-3.5_2.12:1.5.2
fs.s3a.endpoint	HTTP request 실패 · 오래 멈춤	http://minio:9000
fs.s3a.access/secret.key	AccessDenied · 403	admin / password123
fs.s3a.path.style.access	HTTP 실패: warehouse.minio	true

ivy·fs.s3a.* 는 --conf, 패키지 둘은 --packages — 모두 lake-pyspark.sh 한 파일에

설정 요약 ②

SQL 확장과 카탈로그 — 없으면 무슨 오류

설정	없으면 · 틀리면	값
sql.extensions	MERGE·타임트래블 문법 오류	IcebergSparkSession Extensions
sql.catalog.lake	REQUIRES_SINGLE_PART _NAMESPACE	SparkCatalog
sql.catalog.lake.type	기본값으로 감	hadoop
sql.catalog.lake.warehouse	버킷 바로 아래면 SHOW TABLES 실패	s3a://warehouse/lake

lake 는 내가 정한 카탈로그 이름 — 경로의 warehouse/lake/ 는 warehouse 값에서 온 것

5-4 를 위한 상태 확인

수업 끝 — 지우지 않고 멈춥니다

1. **exit()**
   >>> 에서 PySpark 셸을 나옵니다

2. **docker compose ps**
   cd ~/data-eng/week5 — 컨테이너 4개가 Up

3. **ls**
   docker-compose.yml · first_job.py · lake-pyspark.sh

4. **docker compose stop**
   넷 Stopped — 데이터는 볼륨에, jar 는 컨테이너에 남음

> **down -v 를 하면 볼륨과 jar 가 둘 다 사라집니다 · 5-4 는 docker compose start → bash lake-pyspark.sh**

오늘의 체크리스트 ①

연결과 설정 — 스스로 확인해 보세요

1. s3a 커넥터가 무엇을 해 주는지 설명할 수 있다
2. hadoop-aws · iceberg-spark-runtime 의 쓰임을 구분한다
3. 라이브러리 버전이 Spark·Scala 와 맞아야 하는 이유를 안다
4. Spark · 워커 · MinIO 가 한 compose 네트워크에서 동작한다
5. s3a 경로로 Parquet 을 쓰고 읽는 왕복을 확인했다
6. 버킷·열쇠·주소·path style 오류가 각각 다르고 오래 멈출 수 있다

오늘의 체크리스트 ②

Iceberg 와 클러스터 — 스스로 확인해 보세요

7	Iceberg 설정 네 줄의 뜻과 warehouse 를 버킷 안 폴더로 주는 이유
8	spark.jars.ivy 를 빼면 왜 --packages 가 실패하는지 안다
9	hadoop 카탈로그에서 폴더 구조가 곧 테이블 목록임을 이해했다
10	MinIO 콘솔에서 metadata/ 와 data/ 폴더 구조를 확인했다
11	snapshots·files 메타테이블과 타임 트래블을 확인했다
12	이 작업이 5-2 클러스터에서 도는 것을 마스터 UI 로 확인했다

자주 겪는 오류

증상으로 찾는 원인과 해결

증상	원인	해결
ClassNotFound S3AFileSystem	hadoop-aws 미로드	--packages 확인 · 재실행
403 · Access Denied	키 불일치 · path.style 빠짐	키 대조 · path.style=true
오래 멈춘 뒤 HTTP 요청 실패	네트워크 · endpoint 철자	http://minio:9000 으로
catalog plugin · SINGLE_PART	런타임 · 카탈로그 3줄 빠짐	--packages · 3줄 확인
SHOW TABLES s3a://warehousedb	warehouse 가 버킷 바로 아래	s3a://warehouse/lake
FileNotFound /home/spark/.ivy2	spark.jars.ivy 줄 빠짐	--packages 앞에 넣기

셸이 몇 분 말없이 멈추면 S3A 재시도 의심 — Ctrl+C 로 멈추고 설정부터 대조

예상 질문

자주 나오는 질문 네 가지

1. **4주차 테이블에 붙을 수는 없나요?**
   type rest + uri 가 방법 — 네트워크·MinIO 계정·9000 포트를 맞춰야 하는 심화(실측 안 함)

2. **--packages 를 매번 받아야 하나요?**
   /tmp/.ivy2 에 남아 두 번째부터 안 받음 — down 하면 다시 받으니 운영은 이미지에 미리

3. **hadoop 카탈로그가 동시 쓰기에 약하다는 뜻은?**
   커밋이 파일 이름 바꾸기에 기대는데 S3 계열은 그것이 원자적이지 않음 — 여럿이면 rest·hive

4. **왜 4주차와 계정이 다른가요?**
   실습을 독립적으로 만들기 위해 — 실무에서는 하나로 통일하고 키를 시크릿으로 관리

다음 회차 예고 · 10-28(수)

5-4 · Spark DataFrame 과 SparkSQL 데이터 가공

01
이론 1H
DataFrame 과
SparkSQL 동작 원리

02
실습 1.5H
DataFrame API 로
데이터 가공

03
실습 1H
SparkSQL 로
집계와 뷰 만들기

04
정리 0.5H
정리·회고

사전 준비: 5-3 compose 기동 + lake.db.orders · cd ~/data-eng/week5 → docker compose start → bash lake-pyspark.sh

5-3 · 정리·회고 0.5H 마무리

다음 회차는 5-4 DataFrame 과 SparkSQL

select · filter · groupBy · join 으로 가공하고, 같은 일을 SparkSQL 로도 해 두 방식이 한 엔진에서 만나는 것을 확인합니다

- ✓ **DataFrame API — 선택 · 필터 · 파생 컬럼 · 집계 · 조인**
- ✓ **임시 뷰로 같은 가공을 SparkSQL 로**
- ✓ **explain() 으로 같은 실행 계획 확인**
- ✓ **가공 결과를 Iceberg 테이블로 저장**

준비할 것

start 뒤 bash lake-pyspark.sh