

5-3 · Iceberg · MinIO 연결 · 정리·회고 0.5H

정리·회고

설정을 한 장으로, 5-4 를 위한 상태 확인

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

30분 뒤에는

- ① 설정 아홉 줄을 「없으면 무슨 오류」로 정리한다
- ② 오늘의 체크리스트로 스스로 점검한다
- ③ 자주 겪는 오류 네 가지의 원인과 해결을 안다
- ④ 5-4 를 위해 컨테이너 3종 Up · warehouse/db/orders/ 를 확인한다

셀을 나가지 않았다면 그대로 — 5-4 는 이 연결 위에서 바로 시작합니다

라이브러리와 스토리지 — 없으면 무슨 오류

설정	없으면	값
--packages hadoop-aws	S3AFileSystem 못 찾음	hadoop-aws:3.3.4
--packages iceberg-...	USING iceberg 모름	runtime-3.5_2.12:1.5.2
fs.s3a.endpoint	어디로 붙을지 모름	http://minio:9000
fs.s3a.access/secret.key	403	admin / password123
fs.s3a.path.style.access	UnknownHost · 403	true

앞의 둘은 --packages, 나머지는 --conf spark.hadoop.fs.s3a.* — 4-3 에서 쓴 것과 같다

SQL 확장과 카탈로그 — 없으면 무슨 오류

설정	없으면	값
sql.extensions	MERGE·타임트래블 문법 오류	IcebergSparkSession Extensions
sql.catalog.lake	카탈로그 없음	SparkCatalog
sql.catalog.lake.type	기본값으로 감	hadoop
sql.catalog.lake.warehouse	어디에 쓸지 모름	s3a://warehouse/

--conf spark.sql.* 네 줄 — lake 라는 이름은 내가 정한 것, 이후 SQL 에서 lake.db.table

여덟 개를 스스로 확인해 보세요

- 1 s3a 커넥터가 무엇을 해 주는지 설명할 수 있다
- 2 hadoop-aws 와 iceberg-spark-runtime 이 각각 왜 필요한지 구분한다
- 3 Spark · 워커 · MinIO 가 한 compose 네트워크에서 동작한다
- 4 s3a 경로로 Parquet 을 쓰고 읽는 왕복을 확인했다
- 5 잘못된 버킷·자격증명·주소가 각각 다른 오류를 낸다는 것을 봤다
- 6 hadoop 타입 카탈로그에서 폴더 구조가 곧 테이블 목록임을 이해했다
- 7 MinIO 콘솔에서 metadata/ 와 data/ 폴더 구조를 눈으로 확인했다
- 8 snapshots·files 메타테이블과 타임 트래블이 그대로 되는 것을 확인했다

5-4 를 위한 상태 확인

다음 차시 준비 — 세 가지가 남아 있는가

1

docker compose ps

cd ~/data-eng/week5 — 컨테이너 3종이 Up

2

PySpark 셀

나가지 않았다면 그대로 · 나갔다면 3챕터 3단계 명령으로 다시

3

테이블

콘솔(9001)의 warehouse/db/orders/ 폴더가 남아 있는지

5-4 에서는

DataFrame

SparkSQL

5-4 는 이 연결 위에서 DataFrame API 와 SparkSQL 로 본격적인 가공을 한다

증상으로 찾는 원인과 해결

증상	원인	해결
ClassNotFoundException S3AFileSystem	hadoop-aws 미로드 (--packages 누락·실패)	--packages 확인 · 셸 종료 후 재실행
403 Forbidden Access Denied	키 값 불일치 또는 path.style 빠짐	ROOT_USER/PASSWORD 대조 path.style.access=true
UnknownHost minio Connection refused	다른 네트워크 또는 endpoint 가 localhost	compose 하나로 합치기 endpoint 는 서비스 이름
USING iceberg 오류 catalog plugin 못 찾음	런타임 없음 또는 카탈로그 세 줄 빠짐	--packages 와 catalog.lake 세 줄 확인

컨테이너 안에서 localhost 는 자기 자신 — endpoint 는 http://minio:9000 처럼 서비스 이름으로

자주 나오는 질문 네 가지

1 4주차 테이블에 붙을 수는 없나요?

됩니다 — type 을 rest 로, uri 를 4주차 카탈로그(rest:8181)로. 두 compose 가 같은 네트워크여야

2 --packages 를 매번 받아야 하나요?

첫 실행 후에는 캐시에 남는다 — 컨테이너를 지우면 다시 받으니 운영에서는 이미지에 미리 넣는다

3 hadoop 카탈로그가 동시 쓰기에 약하다는 뜻은?

커밋을 파일 이름으로 관리해 두 프로세스가 동시에 쓰면 한쪽이 덮어쓸 수 있다 — 여럿이면 rest·hive

4 왜 4주차와 계정이 다른가요?

실습을 독립적으로 만들기 위해 — 실무에서는 하나로 통일하고 키를 시크릿으로 관리

다음 회차 예고

5-4 · Spark DataFrame 과 SparkSQL 데이터 가공

01

이론 1H

DataFrame 과
SparkSQL 동작 원리

02

실습 1.5H

DataFrame API 로
데이터 가공

03

실습 1H

SparkSQL 로
집계와 뷰 만들기

04

정리 0.5H

정리·회고
Iceberg 저장 확인

준비: 5-3 compose 기동 + lake.db.orders · PySpark 는 같은 --packages · --conf 로(셀 스크립트로 저장해 두면 편하다)

5-3 · 정리·회고 0.5H 마무리

다음 회차는 5-4 DataFrame 과 SparkSQL

select · filter · groupBy · join 으로 가공하고, 같은 일을 SQL 로도 해 두 방식이 한 엔진에서 만나는 것을 explain() 으로 확인합니다

✓ DataFrame API — 선택 · 필터 · 파생 · 집계 · 조인

✓ 임시 뷰로 같은 가공을 SparkSQL 로

✓ explain() 으로 같은 실행 계획 확인

✓ 가공 결과를 Iceberg 테이블로 저장

준비할 것

compose 기동 · lake.db.orders · 옵션 스크립트