5-4 · DataFrame과 SparkSQL · 수업 전 10분

실습점검 · 환경재설정

5-3 끝 상태 · 4주차 멈춤 · 켜기

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

왜 점검하나

수업 전에 걸러 둘 것

① 5-3 파일 셋 · 컨테이너 넷이 그대로인지

② 4주차 MinIO 가 9000 · 9001 을 잡으면 오늘 MinIO 가 못 뜬다

③ 새 이미지도 jar 도 없다 — 5-3 jar 가 컨테이너 안에 남아 있다

점검(1~3단계)은 확인 · 멈추기 · 켜기만 · 재설정(5단계)은 처음부터 할 때만

흐름

다섯 단계 — 위에서부터 한 번씩

4주차 컨테이너는 멈추기만 — 지우지 않는다

1 5-3 확인	2 4주차 멈춤	3 켜기	4 오늘 만들 것	5 환경 재설정
ls 세 파일 ps -a 넷 Exited	stop 만 네 포트 비었나	start → 넷 Up mc ls 로 orders/	순서만 확인 아직 치지 않음	처음부터 다시 할 때만

1단계

5-3 끝 상태를 확인해 보세요

1 **cd ~/data-eng/week5 && ls**
docker-compose.yml · first_job.py · lake-pyspark.sh 세 파일

2 **docker compose ps -a**
spark-master · spark-minio · worker-1 · 2 넷이 Exited

3 **lake-pyspark.sh 가 없으면**
5-3 「MinIO 연결」 3단계 cat > lake-pyspark.sh 로 다시

4 **spark-minio 가 없으면**
5-3 을 1단계부터 한다

5-3 끝

stop 으로

멈춘 상태

2단계 · 도커 안

4주차 컨테이너를 멈춰 보세요

1. **cd ~/lakehouse 2>/dev/null && docker compose stop**
   다섯이 Stopped — 이미 멈춰 있어도 똑같이 찍힌다

2. **docker ps ... | grep -E 'NAMES|9000|9001|8080|7077'**
   제목 줄만 나오면 도커 쪽은 비어 있다

3. **~/lakehouse 가 없으면**
   첫 줄은 아무것도 하지 않고 넘어간다

4. **왜 멈추나**
   4주차 MinIO 와 오늘 MinIO 가 같은 9000 · 9001 을 쓴다

4주차

멈춤만

지우지 않음

2단계 · 도커 밖

네 포트를 쓰는 다른 프로그램

01

Windows (WSL2)

netstat -ano | findstr

LISTENING 없으면 비어 있음

02

macOS

lsof -nP -iTCP:9000 …

아무것도 없으면 비어 있음

03

리눅스

sudo ss -ltnp | grep

docker-proxy 면 컨테이너

Windows 는 이 한 줄만 PowerShell 에서 · PID 는 작업 관리자 → 세부 정보 · macOS 의 com.docker 는 컨테이너

3단계

클러스터를 켜고 orders 를 확인해 보세요

1. **docker compose start**
   Started 가 넷 — 실측 약 1.5초

2. **docker compose ps**
   spark-master · spark-minio · worker-1 · 2 넷이 Up

3. **docker run ... pgsty/mc ... mc ls m/warehouse/lake/db/**
   orders/ 한 줄 — 5-3 의 Iceberg 테이블이 남아 있다

4. **connection refused 가 나오면**
   MinIO 가 뜨는 몇 초 사이 — 잠시 뒤 다시 친다

더 보이면

product_sales

· 5단계로

4단계 · 순서만

오늘 만드는 것 — 아직 치지 않는다

무엇	어디서 처음 만드나	남는가
orders · products · sales **DataFrame 변수**	DataFrame 가공 1~6단계	아니요 — 셀을 나가면 사라짐
임시 뷰 **orders_v · products_v**	SparkSQL 1단계	아니요 — 셀을 나가면 사라짐
lake.db.product_sales	SparkSQL 5단계	예
lake.db.daily_revenue	SparkSQL 5단계	예

셀 안 orders(오늘 DataFrame 5행)와 lake.db.orders(Iceberg 4행)는 이름만 같은 다른 것

5단계 · 환경 재설정

오늘 실습만 처음부터 다시 할 때

1. **bash lake-pyspark.sh**
   셸(>>>)이 없으면 ~/data-eng/week5 에서 먼저 띄운다

2. **DROP TABLE IF EXISTS lake.db.product_sales PURGE**
   spark.sql(...) 로 — DataFrame[] 만 찍힌다

3. **DROP TABLE IF EXISTS lake.db.daily_revenue PURGE**
   PURGE 가 MinIO 의 파일까지 지운다

4. **spark.sql("SHOW TABLES IN lake.db").show()**
   orders 한 줄만 남으면 5-3 끝 상태

WARN

MetricsConfig

한 줄은 무시

확인 포인트

수업 준비가 끝났는지

1. ls 에 세 파일 — lake-pyspark.sh 까지 있다
2. 4주차 다섯은 Stopped, 네 포트는 도커 밖에서도 비어 있다
3. ps 에 넷 Up, mc ls 에 orders/ 한 줄
4. lake.db.orders 까지 없으면 5-3 「Iceberg 테이블」 1~2단계로

막히면 그 단계 아래 「막혔어요」 · 「질문」을 눌러 주세요

5-4 · 수업 전 10분 마무리

다음은 DataFrame과 SparkSQL 동작 원리 (1H)

클러스터를 켰으니 API와 SQL이 왜 같은 결과를 내는지부터 봅니다

- ✓ DataFrame은 분산된 표
- ✓ API와 SQL은 같은 곳으로 수렴
- ✓ Spark 조인의 두 가지 방식

막혔다면

그 단계 아래 「막혔어요」 · 「질문」