

5-4 · Spark DataFrame과 SparkSQL 데이터 가공 · 이론 1H

DataFrame과 SparkSQL 동작 원리

API 와 SQL 이 같은 곳으로 수렴하는 이유

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① PySpark DataFrame 문법을 Pandas 문법과 짝지어 말할 수 있다
- ② API 와 SQL 이 같은 실행 계획으로 번역되는 흐름을 설명한다
- ③ F.col 로 컬럼을 가리키고, 조인 키를 문자열로 주는 이유를 안다
- ④ 조인 how 다섯 가지와 Broadcast·Sort Merge 두 방식을 구별한다

다음 1.5H 실습에서 orders·products 두 표로 조인·집계까지 직접 해 봅니다

1. 분산된 표

Pandas 와 PySpark — 이름이 거의 그대로

하려는 일	Pandas (3주차)	PySpark
열 고르기	<code>df[['a','b']]</code>	<code>df.select("a", "b")</code>
조건 필터	<code>df[df.a > 10]</code>	<code>df.filter(F.col("a") > 10)</code>
파생 열	<code>df.assign(c=...)</code>	<code>df.withColumn("c", ...)</code>
그룹 집계	<code>df.groupby('g').agg(...)</code>	<code>df.groupBy("g").agg(...)</code>
조인	<code>a.merge(b, on='k')</code>	<code>a.join(b, on="k")</code>
정렬	<code>df.sort_values('a')</code>	<code>df.orderBy("a")</code>
보기	<code>df.head()</code>	<code>df.show()</code>

엑셀 시트가 여러 컴퓨터에 조각조각 나뉘어 있다 — 표 전체를 다루듯 쓰고, 조각 처리는 Spark 가 맡는다

다른 점은 지연 평가(action 을 불러야 실행)와 F.col(...) 로 컬럼을 가리킨다는 것 정도

2. 수렴

API 든 SQL 이든 — 같은 논리 계획으로 번역된다



그래서 성능 차이가 아니라 표현의 취향·상황 문제 — 오늘 explain() 출력을 직접 대조합니다

2. 수렴

API 와 SQL — 언제 무엇을 고를까

DataFrame API

여러 단계를 변수로 이어 붙이는 파이프라인

- 중간 결과에 이름을 붙여 재사용
- 함수로 쪼개기 쉬워 단위 테스트에 유리
- 3주차 Pandas 감각이 그대로

VS

SparkSQL

분석가와 공유하는 집계 · 한눈에 읽히는 쿼리

- 한 문장으로 읽히는 집계 로직
- 실무에서는 한 스크립트에 섞어 쓴다
- 3-4 의 DuckDB↔Pandas 왕복과 같은 발상

3. 컬럼 가리키기

컬럼을 가리키는 세 가지 방법 — F.col 이 기본

기본값

F.col(...)

1 (1) F.col("amount") > 100000
가장 안전 — 권장

2 (2) df["amount"] > 100000
그 DataFrame 소속임이 분명 — 조인 뒤 같은 이름이 양쪽에 있을 때

3 (3) "amount > 100000"
SQL 문자열 — 짧고 읽기 좋다

from pyspark.sql import functions as F — 파일 첫 줄에 한 번

4. 조인

조인 how 다섯 가지 — 무엇이 남는가

how	남는 것	주의
inner (기본)	양쪽 다 있는 키만	한쪽에 없으면 행이 사라진다
left	왼쪽 전부	파이프라인의 기본 선택
right / full	오른쪽 / 양쪽 전부	—
left_anti	오른쪽에 없는 왼쪽 행만	「매칭 안 된 것 찾기」에 유용
left_semi	오른쪽에 있는 왼쪽 행만	컬럼은 왼쪽 것만 남는다

오른쪽 키가 중복이면 행이 늘고 합계가 부풀려진다 — Spark 에는 validate 옵션이 없으니 조인 전후 count() 를 직접 비교

4. 조인

조인에서 컬럼이 충돌할 때 — 두 가지 처방

키를 문자열로

결과에 product_id 가 한 번만 남는다

- on="product_id" — 같은 이름일 때
- a["pid"] == b["product_id"] — 다른 이름
- 이름이 다르면 두 컬럼이 다 남는다

VS

별칭(alias)으로 출처를

같은 이름이 양쪽에 있을 때 o. · p. 로 구분


- ao, bo = a.alias("o"), b.alias("p")
- F.col("o.pid") == F.col("p.product_id")
- select("o.pid", "p.name") 로 출처 명시

5. 조인 방식

Spark 조인의 두 가지 방식 — explain() 에서 찾을 이름

Broadcast Hash Join

한쪽이 작을 때(기본 10MB 이하)



VS

Sort Merge Join

양쪽 다 클 때 — 성능 튜닝의 기본(5-5)



이 1시간에서 꼭 가져갈 것

- 1 PySpark 의 DataFrame 문법은 Pandas 와 거의 같은 이름이다
- 2 API 와 SQL 은 같은 논리 계획으로 번역된다 — 취향·상황으로 고른다
- 3 컬럼은 F.col 로 가리키는 것이 가장 안전하다
- 4 조인 키를 문자열로 주면 중복 컬럼이 안 생긴다
- 5 조인 후에는 행 수를 직접 확인한다 — Spark 에는 validate 가 없다

5-4 · 이론 1H 마무리

다음은 DataFrame API 실습 (1.5H)

orders·products 두 표를 만들어 타입 변환 → 조인 → 파생 → 필터 → 집계 → 윈도우까지 체인으로 잇고 explain() 을 봅니다

✓ createDataFrame 으로 orders 5행 · products 3행

✓ to_date 로 타입 바로잡기

✓ join → withColumn → filter → groupBy

✓ explain() 에서 BroadcastHashJoin 찾기

준비할 것

5-3 compose 기동 · PySpark 셀 옵션