5-5 · 파티셔닝과 셔플링 최적화 · 수업 전 10분

실습점검 · 환경재설정

5-4 끝 상태 · 4040 열기 · 켜기

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

왜 점검하나

수업 전에 걸러 둘 것

① 5-4 파일 셋 · 컨테이너 넷이 그대로인지

② 4주차 MinIO 가 9000 · 9001 을 잡으면 오늘 MinIO 가 못 뜬다

③ compose 는 8080 · 7077 만 연다 — 4040 은 아직 막혀 있다

점검(1~2단계)은 확인 · 멈추기만 · 3~4단계는 4040 열고 켜기 · 재설정(6단계)은 처음부터 할 때만

흐름

여섯 단계 — 위에서부터 한 번씩

4040 을 여는 덧붙임 파일은 오늘 한 번만 만든다

1 5-4 확인	2 4주차 멈춤	3 4040 열기	4 테이블 확인	5 오늘 만들 것	6 환경 재설정
ls 세 파일 ps -a 넷 Exited	stop 만 다섯 포트 비었나	override 파일 up -d 로 켜기	mc ls 로 세 줄	순서만 확인 아직 치지 않음	처음부터 다시 할 때만

1단계

5-4 끝 상태를 확인해 보세요

1 **cd ~/data-eng/week5 && ls**
docker-compose.yml · first_job.py · lake-pyspark.sh 세 파일

2 **docker compose ps -a**
spark-master · spark-minio · worker-1 · 2 넷이 Exited

3 **왜 Exited 인가**
5-4 끝에 docker compose stop 으로 멈춰 두었다

4 **다음 단계로**
넷이 Exited 로 남아 있으면 2단계로 넘어간다

5-4 끝

stop 으로
멈춘 상태

2단계 · 도커 안

4주차 컨테이너를 멈춰 보세요

1. **cd ~/lakehouse 2>/dev/null && docker compose stop**
   다섯이 Stopped — ~/lakehouse 가 없으면 그냥 넘어간다

2. **docker ps ... | grep -E 'NAMES|9000|...|4040'**
   제목 줄만 나오면 도커 쪽은 비어 있다

3. **오늘 쓰는 포트**
   9000 · 9001(MinIO) · 8080 · 7077(마스터) · 4040(앱 UI)

4. **왜 멈추나**
   4주차 MinIO 와 오늘 MinIO 가 같은 9000 · 9001 을 쓴다

4주차

멈춤만

지우지 않음

2단계 · 도커 밖

다섯 포트를 쓰는 다른 프로그램

01

Windows (WSL2)

netstat -ano | findstr

LISTENING 없으면 비어 있음

02

macOS

lsof -nP -iTCP:9000 …

아무것도 없으면 비어 있음

03

리눅스

sudo ss -ltnp | grep

docker-proxy 면 컨테이너

Windows 는 이 한 줄만 PowerShell 에서 · 4040 은 주피터 안 PySpark 등 다른 Spark 가 자주 쓴다

3단계 · 핵심

4040 을 여는 덧붙임 파일을 만들어 보세요

1. **cat > docker-compose.override.yml << 'EOF'**
   spark-master 의 ports 에 "4040:4040" 한 줄 — yml 은 그대로
2. **docker compose up -d**
   넷이 Started — compose 가 override 를 자동으로 함께 읽는다
3. **docker compose ps**
   spark-master 만 방금 새로 만들어짐 · PORTS 에 4040
4. **왜 필요한가**
   셸(드라이버)이 spark-master 안이라 4040 을 열어야 보인다

한 번만

다음부터는

start 만

3단계 · 대가

spark-master 를 새로 만들면

얻는 것

브라우저 localhost:4040 에서 Stage · Task

4040	애플리케이션 UI 가 열린다
워커 둘	새 마스터에 다시 붙는다
8080	Alive Workers: 2

VS

잃는 것

컨테이너 안 jar 캐시(/tmp/.ivy2)

jar	5-3 에 받은 것이 사라진다
첫 실행	lake-pyspark.sh 가 다시 받음
실측	jar 4개 316MB · 65초

4단계 · 6단계

테이블 확인과 환경 재설정

1. **docker run ... pgsty/mc ... mc ls m/warehouse/lake/db/**
   daily_revenue/ · orders/ · product_sales/ 세 줄

2. **connection refused 가 나오면**
   up -d 바로 뒤 MinIO 가 뜨는 몇 초 — 잠시 뒤 다시 친다

3. **6) rm -f mart.py mart.log**
   오늘 실습을 처음부터 다시 할 때만

4. **6) mc rm -r --force ... test-narrow test-one daily_sales_mart**
   없으면 아무 줄 없이 지나간다 — 5-4 테이블 · override 는 남음

5단계 · 순서만

오늘 만드는 것 — 아직 치지 않는다

무엇	어디서 처음 만드나	남는가
docker-compose.override.yml (4040)	실습점검 3단계	예 — 6주차 이후도
warehouse/test-narrow · test-one	셔플 관찰 3 · 6단계	예 (볼륨 안)
mart.py · mart.log	배치 스크립트 1 · 3단계	예 — mart.py 가 5주차 산출물
lake.db.daily_sales_mart	배치 스크립트 1단계	예

셸은 셔플 관찰 1단계에서, mart.py 는 배치 스크립트 1단계에서 처음 만든다

5-5 · 수업 전 10분 마무리

다음은 파티셔닝과 셔플링 원리 (1H)

4040 을 열었으니 왜 느린가 — 파티션과 셔플부터 봅니다

- ✓ **파티션 = 일감의 조각**
- ✓ **셔플 = 조별 재편성**
- ✓ **repartition과 coalesce**

막혔다면

그 단계 아래 「막혔어요」 · 「질문」