

5-5 · 파티셔닝과 셔플링 최적화 · 실습 1H

PySpark 배치 스크립트로 데이터 마트 산출

`mart.py` 한 파일 — 이것이 5주차 산출물

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

① 접속 설정을 코드에 담은 `mart.py` 를 `spark-submit` 으로 실행한다

② 두 번 돌려 결과가 같은 것(멥등)을 확인한다

③ 날짜 인자·로그·종료 코드를 넣어 실무형으로 다듬는다

④ 스크립트·마트 조회 결과·실측표를 제출 형태로 정리한다

결과물 = ① `mart.py` ② 마트 테이블 조회 캡처 — 제출은 사이트 「산출물 제출」 페이지에서

네 단계 — 셀의 `--conf` 를 코드 안으로

5-3 에서 셀에 길게 주던 접속 옵션을 스크립트 안에 담는 것부터 시작합니다

1. 작성·실행

`mart.py`
`spark-submit`

2. 먹등

한 번 더 실행
같은 3행

3. 실무형


인자·로그
종료 코드

4. 정리

실측표
제출

1단계

mart.py 의 처리 흐름 — 일별 매출 마트



원천은 5-4 의 주문·상품 데이터 — 실무라면 원천 테이블을 읽는다

`writeTo("lake.db.daily_sales_mart").createOrReplace()` — 테이블을 통째로 교체해 저장

핵심 명령 — 복사 · 제출 · 재실행

복사	<code>docker compose cp mart.py spark-master:/tmp/mart.py</code>
제출	<code>docker compose exec spark-master /opt/spark/bin/spark-submit</code>
마스터	<code>--master spark://spark-master:7077</code>
패키지	<code>--packages hadoop-aws:3.3.4, iceberg-spark-runtime-3.5_2.12:1.5.2</code>
재실행	<code>... /tmp/mart.py 2>&1 tail -n 12 # 같은 3행</code>

로그 끝에 날짜별 3행(08-24·25·26) — MinIO 의 `daily_sales_mart/data/` 에 Parquet 1개면 `coalesce(1)` 효과

먹등 — 전체 교체 vs 증분 병합

createOrReplace — 전체 교체

몇 번을 돌려도 같은 3행이 나온다

- 테이블을 통째로 바꿔 쓴다
- 매번 다시 계산해도 되는 작은 집계
- 마트에는 이쪽이 단순하다

VS

MERGE — 증분 병합 (4-3)

바뀐 행만 끼워 넣는다

- 원천이 크고 일부만 바뀔 때 유리
- 4-3 에서 배운 방식
- 같은 먹등, 다른 전략

실무형으로 — 인자 · 로그 · 종료 코드

1

날짜를 인자로 받는다

`sys.argv[1]` — 있으면 그 날짜만 filter

2

로그와 검증을 남긴다

`[mart]` 원천 N행 · 마트 N행 — 원천이 0행이면 중단

3

종료 코드로 알린다

`sys.exit(1)` — 8주차 Airflow 가 이 값을 보고 재시도 여부를 정한다

grep 으로 골라 볼 글자

[mart]

1-2 에서 배운 종료 코드가 여기서도 쓰인다 — 배치하는 사람이 아니라 스케줄러가 읽는다

있는 날짜와 없는 날짜 — 실패로 끝나야 한다

2026-08-25 — 있는 날짜

그 날짜만 처리 · 마트 1행 · 정상 종료



VS

2099-01-01 — 없는 날짜

「원천이 비어 있습니다 — 중단」 · 종료 코드 1



5주차 산출물 세 가지

① mart.py

01

배치 스크립트

인자·로그·종료 코드 포함

② 마트 조회 결과

02

spark-sql 또는

콘솔 캡처

③ 실측표

03

파티션 수 · 200→8 시간

파일 수 · 스큐 시간

README의 실측표를 본인 수치로 — 환경마다 달라도 정상, 중요한 것은 방향. 제출 후 산출물 갤러리에도 올려 동료와 비교

이 1시간이 끝날 때 확인할 것

- 1 로그 끝에 날짜별 3행의 `daily_amount` · `order_cnt` 표가 찍힌다
- 2 MinIO `warehouse/db/daily_sales_mart/data/` 에 Parquet 1개
- 3 두 번째 실행도 같은 3행 — `createOrReplace` 의 멍등
- 4 2026-08-25 를 주면 그 날짜만, 2099-01-01 은 실패로 끝난다
- 5 `mart.py` · 조회 캡처 · 실측표가 제출 형태로 모였다

5-5 · 실습 1H 마무리

다음은 정리·회고 및 산출물 점검 (0.5H)

5주차 닷새를 표 하나로 되짚고, 튜닝 체크리스트와 자주 겪는 오류를 정리한 뒤 6주차 Kafka 로 넘어갈 준비를 합니다

✓ 5주차에 지나온 길 · 튜닝 체크리스트

✓ 자주 겪는 오류 네 가지

✓ 컨테이너 정돈 — stop 만, down -v 금지

✓ 6-1 Kafka 예고

가져갈 것

mart.py 와 실측표 — 제출 전 마지막 점검