6-5 · Kafka Connect와 MinIO 적재 · 실습 2.5H

S3 Sink로 MinIO 적재와 엔드투엔드 검증

DB 변경이 파일로 떨어지는 전 과정을 눈으로

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

2.5시간 뒤에는

① S3 Sink 플러그인을 마운트해 connector-plugins 에서 확인한다

② minio 서비스를 띄우고 cdc-raw 버킷을 만든다

③ sink-minio.json 을 등록해 RUNNING 을 확인한다

④ INSERT 5건 → MinIO JSON 파일 생성을 엔드투엔드로 확인한다

⑤ 파일이 안 생길 때 짚는 다섯 단계와 주차 산출물을 정리한다

토픽 목록과 sink-minio.json 이 주차 산출물 — 마지막 단계에서 README 로 정리합니다

실습 흐름

여덟 단계 — 6-4 스택 위에 minio 를 얹는다

~/data-eng/week6 에서 6-4 스택과 mysql-cdc RUNNING, plugins/ 에 S3 Sink 를 풀어 둔 상태로 시작합니다

1. 플러그인	2·3. minio	4. Sink 등록	5·6. 검증	7·8. 정리
확인만 실습점검에서 받음	compose 통째로 cdc-raw 버킷	sink-minio.json RUNNING	INSERT 5건 파일 확인	안 생길 때 5곳 산출물

1~3단계

플러그인 확인 · compose 다시 쓰기 · 버킷

1

ls plugins/confluentinc-kafka-connect-s3/lib

jar 145개 — 판 번호(-12.1.15)가 붙어 있으면 실습점검 3단계의 mv 를 빠뜨린 것

2

cat > docker-compose.yml << 'EOF' ... EOF

조각을 덧붙이면 connect 키가 둘 — 파일 전체를 다시 쓴다

3

up -d --force-recreate connect → up -d minio

Container cdc-minio Started · 14초 뒤 connector-plugins 에 S3SinkConnector

4

mc mb -p m/cdc-raw

Bucket created successfully — 버킷은 커넥터가 만들어 주지 않는다

컨테이너 이름은 cdc-minio(4주차 minio 와 충돌), 부르는 이름은 서비스 이름 minio 그대로 — store.url 은 http://minio:9000

4단계

sink-minio.json 의 핵심 줄

설정	값	뜻
connector.class	…s3.S3SinkConnector	S3 Sink 커넥터
topics	shop.shop.orders	구독할 CDC 토픽
s3.bucket.name	cdc-raw	미리 만든 버킷
store.url	http://minio:9000	MinIO 로 가는 갈림길
aws.access.key.id 등	minioadmin	compose 의 ROOT 값
format.class	JsonFormat	raw 그대로 JSON
flush.size	5	5건 모이면 파일 하나
behavior.on.null.values	ignore	툼스톤만 건너뛴다

등록하자마자 6-4 이벤트(실측 12건)부터 읽어 5건씩 파일 둘 — status 의 connector · tasks[0] 가 RUNNING

5단계 — 엔드투엔드

INSERT 5건 뒤 파일 셋 — 마지막이 방금 넣은 것

1. **INSERT 5건 → sleep 10 → mc ls --recursive m/cdc-raw**
   …+0000000000 · …0006 · …0011.json — 앞 둘은 6-4 의 이벤트

2. **0 → 6 처럼 5씩이 아닌 곳**
   끝 숫자는 첫 메시지의 오프셋 — 툼스톤을 건너뛴 자리

3. **mc find … | tail -n 1 → python3**
   가장 최근 파일의 op 와 after — 방금 넣은 행이 c 로 나온다

4. **다섯 번째 INSERT 는 아직 없다**
   다음 다섯 건이 모일 때까지 Sink 가 들고 있다

mc 이미지

awk·grep 없음

tail 은 있음

6단계

세 터미널로 전체 흐름을 한 번 더

어디서 얼마나 걸리는지 감을 잡습니다 — Kafka 까지는 즉시, 파일까지는 flush.size 만큼 기다린다

터미널 1	터미널 2	터미널 3	보이는 것	5건 차면
console-consumer shop.shop.orders	for 1~5 INSERT · sleep 1	consumer-groups --list	그룹 connect-minio-sink	MinIO 에 파일 하나 더

일부러 실패시키기

behavior.on.null.values 를 빼고 등록하면

빼면 — 태스크 FAILED

커넥터는 RUNNING 인데 tasks[0] 가 FAILED

- trace 끝: Null valued records are not writeable
- 6-4 DELETE 뒤 툼스톤(값 없음)이 원인
- 파일에 쓸 수 없는 메시지라 멈춘다

VS

"ignore" 를 넣으면

그 메시지만 건너뛰고 RUNNING

- DELETE 이벤트(op=d)는 값이 있어 쌓인다
- 파일 이름 0 → 6 — 건너뛴 자리
- 고치려면 DELETE 로 지우고 다시 등록

7단계

파일이 안 생길 때 짚는 다섯 곳

순서	무엇을	어디서
(1)	커넥터가 살아 있는가	.../minio-sink/status
(2)	구독 토픽 이름이 맞는가	.../config | grep topics
(3)	토픽에 메시지가 있는가	kafka-get-offsets.sh
(4)	Sink 가 어디까지 읽었는가	consumer-groups --describe
(5)	Connect 로그에 오류가	compose logs connect

(4) LAG 1~4 는 정상(실측 1) — 아직 flush.size 를 못 채워 들고 있는 것 · 대부분 (2) 토픽 오타나 (1) 버킷·자격증명

확인 포인트

이 2.5시간이 끝날 때 확인할 것

1. plugins/.../lib 에 jar 가 있고 connector-plugins 에 S3SinkConnector 가 보인다
2. localhost:9001 콘솔이 열리고 cdc-raw 버킷이 있다
3. minio-sink status 의 connector·tasks[0] 가 RUNNING 이다
4. INSERT 5건 뒤 topics/shop.shop.orders/partition=0/ 에 JSON 이 있다
5. 가장 최근 파일의 c 줄이 방금 넣은 행과 같다
6. kafka-topics --list 의 토픽 아홉의 용도를 설명할 수 있다

8단계 — compose · register-mysql.json · sink-minio.json + 토픽 구성을 README 로 정리해 제출

6-5 · 실습 2.5H 마무리

다음은 주차 회고 · 산출물 점검 (0.5H)

6주차를 되짚고 컨테이너를 정돈한 뒤, 7주차 RAG 로 넘어가는 다리를 놓습니다

- ✓ 6주차 다섯 차시와 남은 결과물
- ✓ 자주 겪는 오류 다섯 가지
- ✓ docker compose stop (down 금지)
- ✓ 7-1 LangChain 챗봇 기초 예고

가져갈 것

토픽 목록 · 산출물 README