

7-1 · LangChain 챗봇 기초 · 정리·회고 0.5H

정리·회고

부품 일곱 개를 한 장으로, 7-2 문서 처리 준비

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

이 시간의 목표

30분 뒤에는

① LangChain 부품 일곱 개의 역할과 코드 모양을 한 장으로 정리한다

② 오늘의 체크리스트를 스스로 확인한다

③ 자주 겪는 오류 네 가지의 원인과 해결을 안다

④ 7-2 문서 분할에 쓸 패키지와 실습 문서를 준비한다

모델이 지어낸 답을 봤다면 오늘은 성공 — 그 문제를 고치는 것이 이번 주의 일입니다

부품 일곱 개 — 역할과 코드

부품	역할	코드
ChatModel	LLM 호출	ChatOpenAI(...).invoke(...)
PromptTemplate	메시지 틀	from_messages([...])
OutputParser	원하는 형태로 꺼내기	StrOutputParser()
체인	부품 잇기	prompt llm parser
SystemMessage	역할·규칙 지정	체인의 첫 메시지
이력	멀티턴 기억	메시지 목록을 매번 다시 보냄
temperature	답의 무작위성	사실 조회는 0 쪽

ChatOpenAI 를 ChatOllama 로 바꿔도 나머지는 그대로 돈다 — 심화 과제 ④에서 직접 확인

열두 개를 여덟 줄로 — 스스로 확인해 보세요

- 1 LLM 이 학습 시점까지만 알고 모르는 것을 지어낼 수 있다는 것을 확인했다
- 2 RAG 가 그 한계를 어떻게 푸는지 한 문장으로 말할 수 있다
- 3 API 키(또는 Ollama)로 `llm.invoke()` 첫 호출에 성공했다
- 4 응답 메타데이터에서 토큰 사용량을 봤다
- 5 `ChatPromptTemplate` 의 {빈칸}에 값을 채워 체인을 실행했다
- 6 파서 유무에 따라 결과 타입이 달라지는 것을 확인했다
- 7 시스템 메시지·`temperature` 를 바꿔 답이 달라지는 것을 봤다
- 8 이력을 안 보내면 잊고, 누적하면 기억하고, 턴이 늘면 토큰이 커진다

증상으로 찾는 원인과 해결

증상	원인	해결
401 / AuthenticationError	OPENAI_API_KEY 가 비었거나 오타	echo \$OPENAI_API_KEY 확인 새 터미널이면 export 다시
Connection refused (포트 11434)	Ollama 서버가 안 떠 있거나 모델을 안 받았다	ollama serve → ollama pull llama3.1
model not found 404	모델명 오타 · 그 키로 못 쓰는 모델	공식 문서 이름과 대조 Ollama 는 ollama list 이름
429 Rate limit 반복	짧은 시간 과다 호출 · 무료 한도 초과	호출 사이 간격 두기 반복 실험 횟수 줄이기

따옴표 포함 복사·앞뒤 공백도 401 의 흔한 원인 · 429 는 2-5 의 크롤링 예절과 같은 이야기

자주 나오는 질문 네 가지

1 파인튜닝과 RAG 중 뭘 써야 하나요?

문서가 자주 바뀌거나 출처를 밝혀야 하면 RAG — 말투·형식을 바꾸는 것이 목적이면 파인튜닝

2 로컬 모델로도 충분한가요?

구조를 배우는 데는 충분 — 답의 품질은 상용 모델이 낮지만 파이프라인은 완전히 같다

3 이력을 DB 에 저장하면 되나요?

된다 — 다만 저장한다고 토큰이 줄지는 않는다, 보낼 때는 여전히 전체가 간다

4 답이 매번 달라서 테스트가 어렵습니다

temperature 0 — 그래도 완전히 같진 않으니 「필요한 내용이 들어 있는가」로 테스트

다음 차시 준비

7-2 를 위한 준비 — 지금 세 줄만

1

가상환경 켜기

`cd ~/data-eng/week7 → source .venv/bin/activate`

2

`pip install langchain-text-splitters pypdf`

7-2 에서는 문서를 잘라 본다 — 개요의 langchain-community 까지 함께

3

실습용 문서 하나 — ls 로 확인

긴 텍스트나 PDF · 없으면 이 사이트 학습 노트를 복사해 텍스트로 저장

확인 포인트

패키지 설치됨
문서 파일 있음

다음 회차 예고

7-2 · 텍스트 데이터 Chunking

01

이론 1H

RAG 파이프라인과
Chunking 개념

02

실습 1.5H

Document Loader
와 텍스트 분할

03

실습 1H

Chunk 파라미터
튜닝·품질 비교

04

정리 0.5H

정리·회고

준비: 7-1 가상환경 그대로 · `pip install langchain-community langchain-text-splitters pypdf` · 한글 텍스트 1개 + PDF 1개

7-1 · 정리·회고 0.5H 마무리

다음 회차는 7-2 텍스트 데이터 Chunking

RAG 는 오픈북 시험 — 책을 「찾기 좋은 크기」로 미리 잘라 두는 Chunking 을 배웁니다

✓ RAG 파이프라인 전체에서 Chunking 의 위치

✓ TextLoader·PyPDFLoader 로 한글 문서 로드

✓ chunk_size·chunk_overlap 조절

✓ 조합별 분할 결과를 비교해 기준값 정하기

준비할 것

week7 가상환경 · 한글 텍스트와 PDF 각 1개