

7-2 · 텍스트 데이터 Chunking · 실습 1H

Chunk 파라미터 튜닝과 품질 비교

재 보고 정한다 — 우리 문서의 기준값

수도권ICT 이노베이션스퀘어
데이터 엔지니어링 & RAG 파이프라인 160H · 3기

1시간 뒤에는

- ① 수천 자 긴 문서로 **size·overlap** 다섯 조합을 비교한다
- ② 문장 중간에서 잘린 조각 수를 세어 **overlap** 효과를 본다
- ③ 같은 키워드가 조각 크기에 따라 어떻게 잡히는지 본다
- ④ 기준값 **chunk_size·overlap** 을 근거와 함께 표에 적는다

오늘 정한 값이 7-3 에서 임베딩할 때 그대로 쓰입니다

여섯 단계 — 짧은 문서로는 차이가 안 보인다

실제 강의 자료나 사내 문서가 있으면 그것으로 하는 편이 훨씬 유용합니다

1. 긴 문서

long_notes.txt
8장 × 3

2. 조합 비교

다섯 조합
조각 수·평균

3. 절단 검사

broken_endings
overlap 0 / 30

4·5. 검색·MD

키워드 포함
separators

6. 기록

기준값 표
선택·근거

다섯 조합을 한 반복문으로 — 조각 수 · 평균 · 최대

chunk_size	chunk_overlap	볼 것
200	0	조각 가장 많음 · 겹침 없음
200	30	같은 size 에 겹침만 추가
500	50	무난한 출발점
1000	100	문맥이 살아남
2000	200	조각 가장 적음

출력 한 줄: size=... overlap=... → 조각 N개, 평균 M자, 최대 K자

size 가 커질수록 조각 수가 줄고 평균 길이가 느는 단조 관계가 보여야 한다 — 이 표를 기록해 두세요(오늘 산출물의 근거)

문장 중간에서 잘린 조각 세기

1 broken_endings(chunks)
마침표·「다」·줄바꿈으로 끝나지 않는 조각을 센다

2 (200,0) · (200,30) · (500,50) 세 조합
「중간에서 끝난 조각 n/전체」와 샘플 끝 50자를 찍는다

3 overlap=0 이 더 많이 잘리는지
문서에 따라 차이가 작을 수도 — 중요한 건 재 보고 판단하는 태도

검사기의 한계

자동 검사 +
육안 확인

overlap $\geq$ size 로 넣으면 — ValueError

자주 겪는 오류를 미리 겪어 둡니다 — overlap 이 chunk_size 보다 크거나 같으면 조각이 앞으로 나아가지 못합니다

바꿔 넣기	보이는 것	원인	되돌리기
chunk_size=200 chunk_overlap=200	ValueError 또는 이상한 분할	겹침이 조각을 다 잡아먹는다	size 의 10~20% 예: 500 / 50

4단계 — 검색 대신 문자열 포함(in)으로

「스트리밍」이 어느 조각에 걸리나

chunk_size=200

딱 그 문장만 — 좁고 정확

- $\text{overlap} = \text{size} // 10 = 20$
- keyword in c.page_content 로 센다
- hits[0] 앞 300자 — 그 문장 위주

VS

chunk_size=1000

앞뒤 문맥까지 함께 — 넓고 풍부

- $\text{overlap} = \text{size} // 10 = 100$
- 같은 키워드, 같은 문서
- hits[0] 앞 300자 — 앞뒤 문장까지

Markdown 은 제목 경계를 우선

기본 분할기

chunk_size=100, overlap=10 — 기본 separators

- 문단 \n\n → 줄 → 공백 순으로
- doc.md 의 ## 절 세 개를 자른다
- 결과를 한 줄씩 60자로 찍어 비교

VS

제목 우선 분할기

separators 맨 앞에 "\n## " 를 둔다

- ["\n## ", "\n\n", "\n", " ", ""]
- 절(##) 단위로 더 깔끔하게 나뉜다
- 문서 형식에 맞춘 separators 가 품질을 올린다

기준값을 정해 기록한다 — 오늘의 산출물

size	overlap	조각 수	평균 길이	중간 절단
200	0			
200	30			
500	50			
1000	100			

선택: chunk_size = __ , chunk_overlap = __ · 근거 두 줄 · separators 를 조정했다면 함께

표를 채우고 선택과 근거를 적으면 오늘 몫이 끝 — 이 값이 7-3 에서 임베딩할 때 그대로 쓰인다

이 1시간이 끝날 때 확인할 것

- 1 long_notes.txt 가 수천 자 규모로 만들어졌다
- 2 size 가 커질수록 조각 수가 줄고 평균 길이가 늘었다
- 3 overlap=0 과 30 의 중간 절단 개수를 비교했다
- 4 200 과 1000 에서 「스트리밍」 조각의 앞뒤 문맥 차이를 봤다
- 5 기준값 표에 size·overlap 선택과 근거를 적었다

7-2 · 실습 1H 마무리

다음은 정리·회고 (0.5H)

분할 문법을 한 표로 정리하고, 7-3 임베딩·벡터DB 를 위한 패키지와 Qdrant 이미지를 미리 받아 둡니다

✓ 하려는 일 ↔ 코드 요약표

✓ 오늘의 체크리스트

✓ 자주 겪는 오류 네 가지

✓ 7-3 준비: qdrant-client · docker pull

가져갈 것

기준값 표(size·overlap·근거)